

Modelos Bayesianos de Población para América Latina y el Caribe

Implementación, Validación y Aplicación Subnacional

Andrés Gutiérrez¹ Stalyn Guerrero²

¹Experto Regional en Estadísticas Sociales, CEPAL. andres.gutierrez@cepal.org

²Consultor, CEPAL. guerrero stalyn@gmail.com

Índice general

Prefacio	5
Introducción	7
1 Enfoque General de los Modelos de Población	9
1.1 Producción de conteos censales	9
1.1.1 Producción subnacional	10
1.1.2 Desagregación por sexo y edad	11
1.1.3 Uso en marcos muestrales	12
1.1.4 Definición de dominios	12
1.2 Indicadores de interés	13
1.2.1 Conteos poblacionales	14
1.2.2 Tasas derivadas	15
1.2.3 Estructuras etarias	16
1.3 Formulación del problema de subcobertura, no respuesta y omisión censal	17
2 Integración de Fuentes de Información	19
2.1 Principios de modelamiento	19
2.1.1 Modelos de conteo	20
2.1.2 Requerimientos de estimación subnacional	21
2.1.3 Justificación del enfoque bayesiano	21
2.1.4 Integración de múltiples fuentes	22
2.1.5 Relación con <i>Small Area Estimation</i> (SAE)	23
2.2 Identificación de fuentes	23
2.2.1 Medición de cobertura a nivel de segmento	24
2.2.2 Preconteos y segmentación	25
2.2.3 Registros administrativos	25
2.2.4 Fuentes satelitales	26
2.3 Variables explicativas	27
2.3.1 Variables socioeconómicas	27
2.3.2 Variables espaciales	27
3 Preparación de Insumos para Modelamiento	29
3.1 Estandarización de fuentes	29
3.1.1 Homologación de variables	29
3.1.2 Normalización de variables	30
3.2 Evaluación de cobertura	31
3.2.1 Clasificación de segmentos	32
3.3 Construcción de la variable dependiente	32

3.3.1	Densidad poblacional	32
3.3.2	Número promedio de personas por hogar	33
3.3.3	Definición de población base	33
3.3.4	Variable de exposición	34
3.4	Diagnóstico exploratorio	34
3.4.1	Distribución de conteos	34
3.4.2	Outliers	37
3.4.3	Relación entre variables	39
4	Modelo para Conteos Poblacionales	43
4.1	Modelo Poisson-lognormal	43
4.1.1	Definición formal	44
4.1.2	Función de verosimilitud	44
4.1.3	Distribuciones previas	49
4.1.4	Distribución posterior	50
4.1.5	Interpretación de parámetros	53
4.2	Componentes del modelo	54
4.2.1	Efectos fijos	54
4.2.2	Efectos aleatorios	55
4.2.3	Interacciones	56
4.2.4	Sobredispersión y offset	57
5	Inferencia Bayesiana e Implementación Computacional	59
5.1	Métodos de simulación	59
5.1.1	Cadenas de Markov Monte Carlo	59
5.1.2	Monte Carlo Hamiltoniano y el algoritmo NUTS	60
5.1.3	Implementación en Stan	61
5.1.4	Configuración de cadenas, muestras e iteraciones	63
5.1.5	Paralelización y eficiencia computacional	64
5.2	Distribución posterior y estimaciones	65
5.2.1	Estimaciones puntuales y resumen posterior	65
5.2.2	Extracción de muestras e intervalos de credibilidad	66
5.2.3	Estimaciones a nivel de segmento censal	66
5.2.4	Agregación a niveles geográficos superiores	67
5.2.5	Verificación predictiva posterior	68
5.2.6	Criterios de información LOO y WAIC	69
5.3	Resumen	70

Índice de figuras

3.1	Distribución de $\log(Y + 1)$ por segmento	36
3.2	Segmentos atípicos según residuo de Pearson y distancia de Mahalanobis	38

3.3	Matriz de correlación entre el conteo poblacional (log) y las covariables auxiliares	40
-----	--	----

Índice de cuadros

3.1	Resumen descriptivo de los conteos observados por segmento	35
3.2	Factores de inflación de varianza (VIF) de las covariables auxiliares	40

Prefacio

La producción de estadísticas oficiales sobre población constituye uno de los pilares fundamentales para la formulación, implementación y evaluación de políticas públicas. En América Latina y el Caribe, los censos de población continúan siendo la principal fuente de información demográfica; sin embargo, la creciente complejidad de los operativos censales, las limitaciones presupuestarias y los problemas de cobertura observados en distintos países han puesto de manifiesto la necesidad de desarrollar metodologías que permitan mejorar la calidad de los conteos censales, particularmente en unidades geográficas pequeñas donde las omisiones y otros errores de cobertura pueden tener un impacto considerable.

Este libro surge de la experiencia acumulada durante diversos proyectos de asistencia técnica desarrollados con oficinas nacionales de estadística de América Latina y el Caribe, en el marco de las actividades de cooperación estadística de la Comisión Económica para América Latina y el Caribe (CEPAL). En estos proyectos fue evidente que la mejora de los conteos censales requiere integrar información proveniente de diferentes fuentes, como preconteos operativos, registros administrativos, imágenes satelitales y variables geoespaciales. Estas fuentes presentan distintos niveles de cobertura, calidad y resolución espacial, por lo que su utilización exige modelos estadísticos capaces de representar explícitamente la incertidumbre asociada a cada una de ellas y de producir estimaciones consistentes de la población.

El objetivo de este libro trasciende la presentación de modelos bayesianos para la estimación de población. Su propósito es desarrollar una metodología integral para la producción de estimaciones subnacionales que articule de manera coherente las diferentes etapas del proceso estadístico. El lector encontrará un recorrido completo que abarca la preparación y evaluación de las fuentes de información, la construcción de variables auxiliares derivadas de información geoespacial y registros administrativos, la formulación de modelos bayesianos jerárquicos, la estimación mediante técnicas modernas de inferencia y la evaluación de la calidad de las estimaciones obtenidas mediante procedimientos de validación y diagnóstico.

Un principio transversal de la obra es la reproducibilidad. Todos los métodos se implementan utilizando herramientas de código abierto, principalmente R y Stan, y cada capítulo incluye desarrollos computacionales que permiten reproducir íntegramente los análisis presentados. Más que ilustrar algoritmos aislados, el libro propone flujos de trabajo completos que pueden adaptarse a las necesidades de las oficinas nacionales de estadística y de otras instituciones responsables de la producción de información demográfica. Aunque los ejemplos se basan en aplicaciones inspiradas en experiencias de América Latina y el Caribe, las metodologías desarrolladas son de carácter general y pueden extenderse a otros contextos geográficos.

El libro está dirigido a estadísticos, demógrafos, científicos de datos e investigadores involucrados en la producción y análisis de estadísticas oficiales, así como a profesionales de organismos nacionales e internacionales interesados en métodos bayesianos aplicados a la estimación de población. Asimismo, puede servir como texto de referencia para estudiantes de posgrado en estadística, demografía o disciplinas afines que deseen profundizar en la construcción e implementación de modelos jerárquicos para datos de conteo. Se asume que el lector posee formación en probabilidad, inferencia estadística, modelos lineales y fundamentos de inferencia bayesiana.

Finalmente, este libro parte de una premisa fundamental: ningún modelo estadístico reemplaza el conocimiento sustantivo sobre los procesos demográficos ni la experiencia acumulada por los especialistas encargados de la producción estadística. Los modelos constituyen, más bien, un instrumento para integrar información pro-

veniente de múltiples fuentes, representar explícitamente las diferentes fuentes de incertidumbre y producir estimaciones consistentes bajo supuestos claramente establecidos. En este sentido, la inferencia bayesiana proporciona un marco flexible para combinar evidencia, incorporar conocimiento previo cuando resulte pertinente y cuantificar rigurosamente la incertidumbre asociada a las estimaciones. El objetivo último es contribuir al fortalecimiento de la producción de estadísticas oficiales mediante metodologías transparentes, reproducibles y científicamente fundamentadas.

Introducción

Los censos nacionales de población y vivienda constituyen la principal fuente de información para cuantificar la población de un país y describir su distribución espacial. Sus resultados sirven de base para la producción de estadísticas oficiales, el cálculo de indicadores demográficos y socioeconómicos, la asignación de recursos públicos y la elaboración de las estimaciones y proyecciones de población realizadas por las oficinas nacionales de estadística.

A pesar de su importancia, los conteos censales están sujetos a errores de cobertura, siendo la omisión censal la principal fuente de discrepancia entre la población observada y la población efectivamente residente. Este problema ha adquirido una relevancia particular durante la ronda censal de 2020 en América Latina y el Caribe, donde diversos países reportaron niveles de subcobertura superiores a los previstos (CEPAL, 2023). Dado que la omisión censal no se distribuye de manera uniforme sobre el territorio, sus efectos son especialmente significativos en unidades geográficas pequeñas, donde incluso un número reducido de personas no censadas puede generar sesgos importantes en los conteos observados y, en consecuencia, en las estadísticas e indicadores derivados de ellos.

La evaluación de la cobertura censal se ha apoyado tradicionalmente en estudios de cobertura, encuestas pos-censales y procedimientos de conciliación demográfica. Estas herramientas permiten cuantificar la magnitud de la omisión y evaluar la calidad global del operativo censal; sin embargo, sus resultados suelen obtenerse para dominios geográficos relativamente amplios y ofrecen información limitada sobre la variabilidad espacial de la cobertura. Como resultado, persiste la necesidad de desarrollar metodologías que permitan estimar la población residente en escalas geográficas más desagregadas, incorporando la información disponible durante y después del operativo censal.

En los últimos años, las oficinas nacionales de estadística han comenzado a disponer de un volumen creciente de información auxiliar generada antes, durante y después del censo. Los preconteos operativos, los registros administrativos, la cartografía digital, las imágenes satelitales, los modelos digitales de elevación, las bases de datos de infraestructura y otras variables geoespaciales contienen información relacionada tanto con la distribución espacial de la población como con los patrones de cobertura censal. La integración de estas fuentes representa una oportunidad para mejorar las estimaciones derivadas del censo, siempre que se disponga de modelos estadísticos capaces de incorporar información heterogénea y representar explícitamente la incertidumbre asociada a cada fuente.

En este contexto, los modelos bayesianos de población constituyen una herramienta particularmente adecuada para abordar este problema. Su formulación permite representar simultáneamente el proceso que genera la población de interés y el proceso mediante el cual esta es observada durante el censo, incorporando además información auxiliar, efectos espaciales y diferentes fuentes de incertidumbre. Bajo este enfoque, el interés no radica en reemplazar el conteo censal, sino en utilizar toda la evidencia disponible para obtener una estimación más consistente de la población residente compatible con la información observada.

Las estimaciones obtenidas mediante estos modelos no pretenden sustituir los métodos demográficos empleados para producir estimaciones y proyecciones de población. Por el contrario, constituyen un complemento estadístico a dichos procedimientos, al proporcionar estimaciones ajustadas de los conteos censales que pueden emplearse como insumo para la construcción de una población base de mayor calidad.

Este libro desarrolla un marco metodológico para la estimación de población a partir de conteos censales mediante modelos bayesianos de población. Se presentan los fundamentos probabilísticos de los modelos para datos de conteo, las estrategias para integrar información censal, administrativa y geoespacial, los métodos de inferencia implementados en Stan y los procedimientos necesarios para evaluar la calidad y consistencia de las estimaciones obtenidas. Cada uno de los desarrollos metodológicos se acompaña de implementaciones reproducibles en R, con énfasis en aplicaciones inspiradas en experiencias desarrolladas por oficinas nacionales de estadística de América Latina y el Caribe.

La propuesta presentada en esta obra no constituye un nuevo método demográfico de estimación o proyección de población. Se trata de una metodología estadística diseñada para abordar uno de los principales problemas que enfrentan los censos modernos: la estimación de la población residente en presencia de omisión censal y otras fuentes de error de cobertura. Mediante la integración de múltiples fuentes de información y el uso de modelos bayesianos de población, se busca obtener estimaciones espacialmente consistentes, acompañadas de una cuantificación explícita de la incertidumbre, que fortalezcan la producción de estadísticas oficiales y sirvan como insumo para los procesos demográficos desarrollados posteriormente.

Enfoque General de los Modelos de Población

1.1 Producción de conteos censales

La producción de conteos poblacionales constituye uno de los procesos más relevantes dentro de los sistemas estadísticos nacionales. A través de los censos de población y vivienda, los países construyen la base demográfica utilizada para la planificación pública, la elaboración de indicadores sociales, la construcción de marcos muestrales y la formulación de políticas territoriales. En términos operativos y metodológicos, el censo representa la única operación estadística diseñada para enumerar exhaustivamente la población residente dentro de un territorio nacional bajo un mismo marco conceptual, temporal y geográfico.

Los conteos censales no solo permiten conocer cuántas personas habitan un país, sino también cómo se distribuyen territorialmente y cómo se estructuran según características demográficas básicas como sexo y edad. Esta información es utilizada posteriormente en una gran variedad de procesos institucionales: proyecciones demográficas, encuestas de hogares, sistemas de focalización social, distribución presupuestaria, delimitación administrativa y producción de estadísticas subnacionales.

En la práctica, la producción censal implica mucho más que el levantamiento de información en campo. Detrás de los conteos publicados existe una estructura compleja de actualización cartográfica, segmentación territorial, logística operativa, capacitación, validación y conciliación estadística. Cada una de estas etapas introduce potenciales fuentes de error que afectan la calidad final de las estimaciones poblacionales.

Como se señaló en la introducción, uno de los principales desafíos de los censos modernos corresponde a los problemas de cobertura: la enumeración nunca es perfecta, y la omisión censal —así como la duplicación de registros o su asignación territorial incorrecta— tiende a concentrarse en determinados contextos territoriales y sociales, como áreas rurales dispersas, asentamientos informales, territorios indígenas, zonas fronterizas o áreas urbanas con alta movilidad poblacional. En América Latina y el Caribe, esta heterogeneidad territorial se combina con diferencias sustanciales en capacidad operativa, actualización cartográfica e infraestructura estadística entre países, dificultades que la ronda censal de 2020 volvió a evidenciar mediante retrasos operativos asociados a restricciones presupuestarias, conflictos sociales y efectos derivados de la pandemia de COVID-19 (CEPAL, 2023).

A medida que aumenta el nivel de desagregación geográfica, estos problemas se vuelven más visibles: mientras a nivel nacional algunos errores pueden compensarse entre regiones, en niveles territoriales pequeños las omisiones o duplicaciones generan distorsiones importantes sobre indicadores demográficos y sociales, afectando directamente la capacidad de los gobiernos para asignar recursos, diseñar programas y producir estadísticas territoriales consistentes.

En este contexto, la producción moderna de conteos poblacionales requiere complementar el operativo censal tradicional con mecanismos de validación, integración de fuentes auxiliares y modelamiento estadístico. Los modelos bayesianos de población surgen precisamente como una respuesta metodológica a este problema, permitiendo integrar información proveniente de distintas fuentes y representar explícitamente la incertidumbre asociada a los conteos observados.

1.1.1 Producción subnacional

Aunque los censos generan un conteo nacional de población, gran parte de su utilidad práctica se concentra en la producción de información subnacional. Los gobiernos requieren estadísticas desagregadas para departamentos, provincias, municipios, áreas urbanas y rurales, sectores censales y segmentos operativos. Es en estas escalas territoriales donde se ejecutan la mayoría de las políticas públicas, se distribuyen recursos y se planifican los servicios públicos.

La producción subnacional implica construir conteos consistentes entre distintos niveles geográficos. Los totales municipales deben coincidir con los agregados departamentales y estos, a su vez, con los conteos nacionales. Esta coherencia jerárquica constituye uno de los principios fundamentales de la estadística oficial y garantiza que las cifras publicadas sean comparables entre diferentes niveles administrativos.

Sin embargo, garantizar dicha consistencia no es un proceso trivial. A medida que disminuye el tamaño poblacional de las unidades geográficas, los efectos de los errores de cobertura adquieren una mayor magnitud relativa. En áreas pequeñas, la omisión de un reducido número de viviendas o personas puede modificar significativamente indicadores derivados como tasas de dependencia, razones de masculinidad, estructuras por edad o indicadores socioeconómicos.

La calidad de los conteos subnacionales depende críticamente de la cartografía censal y de los procesos de segmentación territorial. Antes del levantamiento censal, los institutos nacionales de estadística actualizan la cartografía, identifican las edificaciones y viviendas, delimitan áreas de enumeración y organizan el territorio en unidades operativas relativamente homogéneas. Estas unidades, denominadas generalmente segmentos censales o áreas de enumeración, constituyen la base para la asignación de cargas de trabajo, el control operativo y la supervisión del operativo de campo.

En América Latina y el Caribe, la definición de estas unidades presenta diferencias metodológicas importantes. Algunos países las delimitan buscando un número relativamente constante de viviendas por segmento, mientras que otros priorizan criterios de continuidad espacial, accesibilidad geográfica, densidad poblacional o tiempos estimados de recorrido del censista. Como consecuencia, las unidades básicas de enumeración no son completamente comparables entre países, aun cuando persigan objetivos operativos similares.

Otra diferencia metodológica relevante corresponde al criterio utilizado para asignar la población al territorio. Las recomendaciones internacionales distinguen dos modalidades principales: los censos de hecho (de facto) y los censos de derecho (de jure). En los censos de hecho, cada persona es contabilizada en el lugar donde se encuentra físicamente durante el momento de referencia del censo. En los censos de derecho, en cambio, cada persona se registra en su residencia habitual, independientemente de dónde se encuentre el día de la enumeración.

Ambos enfoques han sido utilizados históricamente en América Latina y el Caribe. Países como Bolivia, Guatemala, Paraguay y Perú han desarrollado sus censos recientes bajo un enfoque predominantemente de hecho, mientras que Argentina, Brasil, Chile, Colombia, Costa Rica, Cuba, Ecuador, El Salvador, Honduras, México, Nicaragua, Panamá, República Dominicana, Uruguay y Venezuela utilizan un enfoque de derecho, basado en la residencia habitual de la población. En algunos casos, además, los operativos incorporan procedimientos complementarios para registrar personas temporalmente ausentes o visitantes, dando lugar a esquemas operativos con características mixtas.

La elección entre uno u otro enfoque tiene implicaciones directas sobre la producción de estadísticas subnacionales. Los censos de hecho reflejan la distribución espacial de la población presente durante el momento censal, mientras que los censos de derecho buscan representar la distribución de la población residente, que constituye el marco de referencia para la planificación territorial, la asignación de recursos públicos y la elaboración de

estimaciones y proyecciones demográficas. En territorios con elevada movilidad diaria, migración temporal o actividades estacionales, ambos enfoques pueden producir diferencias apreciables en los conteos locales.

La producción subnacional también enfrenta desafíos asociados al crecimiento urbano acelerado y a la expansión de asentamientos informales. En muchas ciudades de la región, la urbanización ocurre con mayor rapidez que la actualización cartográfica, generando nuevas viviendas, barrios o asentamientos que pueden no estar plenamente incorporados en los marcos censales. Estas situaciones incrementan el riesgo de omisiones y afectan la calidad de los conteos obtenidos, especialmente en las áreas periféricas de las grandes ciudades.

Desde una perspectiva estadística, los conteos subnacionales deben entenderse como observaciones imperfectas de una población subyacente cuya magnitud real no es completamente observable. Las diferencias en los criterios de enumeración, los errores de cobertura, la movilidad poblacional y las limitaciones inherentes al operativo censal introducen incertidumbre que posteriormente debe ser considerada durante los procesos de conciliación demográfica y en los modelos de estimación de población. Esta necesidad constituye uno de los principales argumentos para el desarrollo de los modelos probabilísticos y bayesianos presentados en los capítulos siguientes.

1.1.2 Desagregación por sexo y edad

Uno de los principales aportes de los censos de población es la posibilidad de caracterizar la estructura demográfica de la población. Los conteos no se producen únicamente para áreas geográficas, sino también para grupos de edad y sexo, desagregación que constituye un insumo fundamental para el análisis demográfico, la formulación de políticas públicas y la elaboración de proyecciones poblacionales (Preston et al., 2001; Siegel and Swanson, 2004; Naciones Unidas, 2017).

La distribución por edad y sexo condiciona directamente múltiples dimensiones del desarrollo social y económico. La demanda de servicios educativos, sistemas de salud, programas de protección social y mercados laborales depende estrechamente de la estructura etaria, y numerosos indicadores —índice de envejecimiento, razón de dependencia, relación de masculinidad o niveles de fecundidad— requieren información detallada sobre la composición por edad y sexo (Preston et al., 2001; Siegel and Swanson, 2004).

Ahora bien, producir estimaciones de población por sexo y edad con niveles aceptables de sesgo incrementa la complejidad del proceso censal, porque exige corregir errores que no se distribuyen de manera uniforme en la población. La evidencia de las encuestas de posenumeración muestra que los errores de cobertura tienen un carácter marcadamente diferencial: su magnitud depende de las características demográficas, socioeconómicas y territoriales de las personas. La omisión tiende a concentrarse de forma sistemática en subgrupos específicos —hombres jóvenes, niñez de 0 a 4 años, población migrante y hogares en zonas de difícil acceso o asentamientos informales—, lo que introduce sesgos en la estructura observada por sexo y edad (Hogan, 1993; Naciones Unidas, 2017). A estos errores de cobertura se suman los errores de contenido, en particular la mala declaración de la edad y la atracción de dígitos (age heaping), que deforman el perfil por edad por una vía distinta y se evalúan con indicadores específicos como los índices de Whipple, Myers o el índice combinado de las Naciones Unidas (Siegel and Swanson, 2004).

Estas diferencias generan distorsiones importantes en la estructura observada de la población. En niveles territoriales pequeños, incluso omisiones de baja magnitud pueden alterar de manera apreciable los indicadores demográficos derivados, dado que operan sobre denominadores reducidos (Bryant and Graham, 2013). Por esta razón, los sistemas estadísticos implementan procedimientos de validación, conciliación y ajuste orientados a identificar y corregir inconsistencias en la distribución por sexo y edad (Naciones Unidas, 2017; Siegel and Swanson, 2004).

La desagregación etaria constituye, además, un componente central de los procesos de proyección demográfica. Los métodos de cohortes-componentes, utilizados por la mayoría de los países, requieren información detallada sobre la estructura poblacional para modelar nacimientos, defunciones y migración (Preston et al., 2001; Siegel and Swanson, 2004). En consecuencia, los errores en la distribución censal inicial pueden propagarse a lo largo de toda la serie de proyecciones; los enfoques probabilísticos permiten, al menos, cuantificar y comunicar la incertidumbre asociada a esa estructura de base (Raftery et al., 2012).

Finalmente, la desagregación simultánea por área geográfica, sexo y edad incrementa considerablemente la dimensionalidad del problema de estimación poblacional. En dominios con pocos habitantes, los conteos observados presentan una mayor variabilidad y los errores de cobertura adquieren una mayor relevancia relativa. Estas características motivan el desarrollo de métodos estadísticos capaces de representar explícitamente la incertidumbre y producir estimaciones consistentes entre grupos demográficos y niveles territoriales.

1.1.3 Uso en marcos muestrales

Los conteos censales constituyen la principal base para la construcción de marcos muestrales utilizados en encuestas de hogares y otras operaciones estadísticas. Los sectores y segmentos definidos durante el operativo censal son utilizados posteriormente como unidades primarias de muestreo en gran parte de las encuestas nacionales desarrolladas por los institutos de estadística.

La calidad de un marco muestral depende directamente de la calidad de los conteos censales y de la actualización cartográfica asociada. Cuando existen omisiones territoriales, viviendas no registradas o límites desactualizados, los diseños muestrales pueden introducir sesgos de cobertura y pérdida de eficiencia estadística.

En América Latina y el Caribe, muchos marcos muestrales permanecen vigentes durante periodos intercensales prolongados. Durante estos intervalos, los cambios demográficos y territoriales pueden modificar sustancialmente la distribución espacial de la población. La expansión urbana, la migración interna y la transformación de áreas rurales generan desactualizaciones progresivas en las unidades de muestreo originalmente construidas a partir del censo.

La segmentación censal también cumple un papel operativo fundamental en la implementación de encuestas probabilísticas. Las unidades territoriales utilizadas durante el censo suelen redefinirse y reorganizarse para optimizar costos operativos, carga de trabajo y precisión estadística. Como resultado, la calidad de la información censal afecta directamente el desempeño posterior de múltiples sistemas de encuestas.

En este contexto, mejorar la calidad de los conteos subnacionales no solo fortalece las estadísticas demográficas, sino también toda la infraestructura estadística utilizada posteriormente por los países para producir información social y económica.

1.1.4 Definición de dominios

La producción de estadísticas poblacionales requiere definir dominios geográficos y demográficos sobre los cuales se generan estimaciones e indicadores. Estos dominios corresponden a distintos niveles territoriales utilizados para organización administrativa, planificación pública y análisis estadístico.

El nivel nacional constituye el agregado principal del sistema estadístico y funciona como referencia para la producción de indicadores macrodemográficos y proyecciones oficiales. Sin embargo, gran parte de las decisiones operativas se realizan en escalas territoriales inferiores.

El nivel intermedio, conformado generalmente por departamentos, provincias o estados, representa uno de los principales niveles de descentralización administrativa en América Latina y el Caribe. En estos territorios se ejecutan programas regionales, se distribuyen recursos fiscales y se implementan estrategias sectoriales de salud, educación e infraestructura.

La diferenciación urbano-rural constituye además una dimensión central en la producción estadística regional. Las brechas territoriales entre áreas urbanas y rurales continúan siendo una de las principales características demográficas y socioeconómicas de la región. Como consecuencia, muchos indicadores poblacionales requieren desagregación específica según tipo de área.

A nivel local, los municipios representan una de las principales unidades de gestión territorial. En este nivel se concentran procesos de planeación urbana, focalización social, administración tributaria y provisión de servicios públicos. La precisión de los conteos municipales afecta directamente la asignación presupuestaria y la medición de múltiples indicadores sociales.

Finalmente, el segmento censal constituye la unidad operativa básica del levantamiento. Estas unidades poseen alta resolución espacial y permiten representar con mayor detalle la heterogeneidad territorial. Sin embargo, también presentan mayor sensibilidad a errores de cobertura y problemas de consistencia espacial.

En países como Bolivia, Paraguay y Colombia, los segmentos censales adquieren especial importancia debido a la implementación de censos de hecho y a la necesidad de coordinar operativos intensivos de corta duración. En este contexto, la calidad de la segmentación territorial condiciona directamente la cobertura del operativo y la precisión de los conteos finales.

Desde la perspectiva del modelamiento estadístico, los dominios territoriales conforman una estructura jerárquica que permite compartir información entre unidades relacionadas y estabilizar las estimaciones en segmentos con datos escasos o ausentes. Esta estructura, combinada con información auxiliar de fuentes externas—registros administrativos, censos previos o datos geoespaciales—, constituye la base de los modelos bayesianos de población a escala subnacional, orientados a la integración de fuentes y al ajuste de cobertura. La validez de estas predicciones depende de manera crítica de que la información auxiliar capture las diferencias sistemáticas entre las áreas cubiertas y no cubiertas, dado que la omisión no se distribuye de forma aleatoria; cuando se dispone de un total agregado confiable, la coherencia entre niveles geográficos (*benchmarking*) opera como una restricción adicional que refuerza la consistencia del sistema.

1.2 Indicadores de interés

La producción de estadísticas de población tiene como propósito cuantificar el número de habitantes y describir su distribución territorial y demográfica. A partir de los conteos obtenidos en los censos de población y vivienda se construye un amplio conjunto de indicadores utilizados para la elaboración de estadísticas oficiales, el diseño y evaluación de políticas públicas, la asignación de recursos, la planificación territorial y la formulación de estimaciones y proyecciones de población.

Desde una perspectiva estadística, estos indicadores pueden clasificarse en tres grandes categorías: conteos poblacionales, tasas derivadas y estructuras etarias. Aunque cada uno describe una dimensión distinta de la población, todos dependen de una misma cantidad fundamental: el número de personas residentes en un determinado dominio geográfico y demográfico. En consecuencia, la calidad de los indicadores derivados está condicionada por la precisión de los conteos poblacionales que les sirven de base.

En la práctica, los conteos observados durante un censo pueden verse afectados por errores de cobertura, omi-

siones, duplicaciones, problemas de acceso al territorio, rechazo de los informantes y otras dificultades operativas propias del proceso de enumeración. Estas limitaciones adquieren mayor relevancia a medida que aumenta el nivel de desagregación geográfica, donde incluso pequeñas diferencias en los conteos pueden producir variaciones importantes en los indicadores derivados y comprometer la comparabilidad entre territorios.

Por esta razón, el objetivo central de este libro no consiste en modelar cada indicador demográfico de manera independiente, sino en estimar de forma consistente los conteos poblacionales por área geográfica, sexo y grupo de edad. Una vez estimados estos conteos, es posible obtener de manera coherente la mayoría de los indicadores utilizados en el análisis demográfico y en la producción de estadísticas oficiales. Bajo este enfoque, los indicadores derivados se entienden como funciones de una población subyacente cuya estimación constituye el problema fundamental del modelamiento estadístico desarrollado en los capítulos siguientes.

En este contexto, la presente sección describe las principales cantidades de interés consideradas a lo largo del libro y su relación con los modelos de población. En particular, se distinguen tres componentes fundamentales:

- *Conteos poblacionales*, que constituyen la variable de interés principal del modelamiento.
- *Tasas derivadas*, obtenidas como funciones de los conteos y utilizadas para comparar territorios con diferentes tamaños poblacionales.
- *Estructuras etarias*, que describen la distribución de la población según características como la edad y el sexo y sirven de base para numerosos indicadores y proyecciones demográficas.

1.2.1 Conteos poblacionales

Los conteos poblacionales constituyen la unidad básica de información de los sistemas estadísticos de población y la principal variable de interés de este libro. Representan el número de personas residentes o presentes en un dominio geográfico determinado y sirven de base para la construcción de indicadores demográficos, sociales y económicos.

Sea $N_{i,s,e}$ el número de personas residentes en el dominio geográfico i , de sexo $s \in \{M, F\}$ y grupo de edad $e \in \{1, \dots, E\}$. Esta cantidad constituye la unidad fundamental de análisis, al representar simultáneamente la dimensión territorial y la estructura demográfica de la población.

El conteo total de población del dominio i se obtiene mediante

$$N_i = \sum_{s \in \{M, F\}} \sum_{e=1}^E N_{i,s,e},$$

mientras que la población total del país corresponde a

$$N = \sum_{i=1}^I N_i.$$

La organización jerárquica de los sistemas estadísticos requiere que los conteos de niveles geográficos inferiores sean consistentes con los totales de niveles superiores. Si $N_j^{(2)}$, $N_k^{(3)}$ y $N_\ell^{(4)}$ representan, respectivamente, los conteos de un departamento, municipio y segmento censal, entonces deben cumplirse las relaciones

$$N_j^{(2)} = \sum_{k:k \subset j} N_k^{(3)}, \quad N_k^{(3)} = \sum_{\ell:\ell \subset k} N_\ell^{(4)}.$$

En la práctica, los conteos observados pueden diferir de la población verdadera debido a errores de cobertura, omisiones, problemas de acceso al territorio o dificultades durante el operativo censal. Estas diferencias adquieren mayor importancia en dominios pequeños, donde incluso pequeñas omisiones pueden afectar significativamente los indicadores derivados.

Por esta razón, en este libro los conteos poblacionales se consideran variables observadas sujetas a incertidumbre. Los modelos bayesianos desarrollados en los capítulos siguientes tienen como objetivo estimar los conteos poblacionales en dominios con cobertura parcial o incompleta, preservando la coherencia entre los distintos niveles territoriales y las desagregaciones por sexo y edad.

1.2.2 Tasas derivadas

Los conteos poblacionales constituyen la base para la construcción de numerosos indicadores utilizados en el análisis demográfico y territorial. A diferencia de los conteos absolutos, las tasas e índices permiten comparar poblaciones de diferente tamaño y describir características relativas de su distribución y estructura. Sin embargo, todos estos indicadores dependen directamente de los conteos poblacionales y, por tanto, su calidad está condicionada por la precisión de las estimaciones que les sirven de base.

Uno de los indicadores más utilizados es la **densidad poblacional**, que expresa la relación entre el número de habitantes y la superficie del territorio. Para un dominio geográfico i , se define como

$$DP_i = \frac{N_i}{A_i},$$

donde N_i representa la población del territorio y A_i su superficie. Se usa la notación DP_i , y no D_i , para evitar toda confusión con la cardinalidad $D = |S|$ del conjunto de segmentos introducida en el Capítulo 4.

Otro indicador de uso frecuente es la **razón de masculinidad**, que mide la relación entre la población masculina y femenina,

$$RM_i = \frac{N_{i,M}}{N_{i,F}} \times 100,$$

donde $N_{i,M} = \sum_e N_{i,M,e}$ y $N_{i,F} = \sum_e N_{i,F,e}$ corresponden a la población masculina y femenina del territorio i , respectivamente.

La **tasa de dependencia demográfica** resume la relación entre la población potencialmente dependiente y la población en edades económicamente activas,

$$TD_i = \frac{N_{i,[0,14]} + N_{i,[65+]}}{N_{i,[15,64]}} \times 100,$$

donde

$$N_{i,[a,b]} = \sum_s \sum_{e:e \in [a,b]} N_{i,s,e}$$

denota la población del dominio i comprendida entre las edades a y b , agregada sobre ambos sexos. De manera complementaria, el **índice de envejecimiento** se expresa como

$$IE_i = \frac{N_{i,[65+]}}{N_{i,[0,14]}} \times 100.$$

Estos indicadores constituyen funciones de los conteos poblacionales y permiten caracterizar la distribución territorial y la estructura demográfica de la población. Debido a que se construyen a partir de los conteos observados, cualquier error de cobertura, omisión o subenumeración se transmite a las tasas derivadas. Este efecto es especialmente importante en dominios geográficos pequeños, donde diferencias reducidas en los conteos pueden producir variaciones relativamente grandes en los indicadores.

Por esta razón, el interés metodológico de este libro no se centra en modelar directamente las tasas derivadas, sino en estimar de manera consistente los conteos poblacionales que les sirven de base. Una vez obtenidos estos conteos, los indicadores derivados pueden calcularse preservando la coherencia entre áreas geográficas y grupos demográficos.

1.2.3 Estructuras etarias

La distribución de la población por sexo y edad constituye una de las principales dimensiones de análisis demográfico, ya que permite caracterizar la composición de la población y estudiar los cambios asociados a la fecundidad, la mortalidad y la migración. La mayoría de los indicadores demográficos y las proyecciones de población requieren información desagregada por estas características, razón por la cual los censos nacionales producen conteos para diferentes grupos de edad y sexo.

Retomando el conteo $N_{i,s,e}$ definido en la sección 1.2.1, la distribución por edad para cada sexo puede expresarse mediante la proporción

$$P_{i,s,e} = \frac{N_{i,s,e}}{N_i},$$

donde N_i representa la población total del dominio. Estas proporciones describen la estructura demográfica y permiten construir pirámides poblacionales, indicadores de dependencia y otros resúmenes de la composición por edad y sexo.

La desagregación demográfica también resulta fundamental para el análisis territorial. Las diferencias en la estructura por edad entre regiones reflejan procesos de urbanización, envejecimiento, migración y dinámica demográfica, proporcionando información esencial para la formulación de políticas públicas y la planificación de servicios dirigidos a grupos específicos de población.

Desde la perspectiva del modelamiento estadístico, la estimación simultánea de la población por área geográfica, sexo y grupo de edad representa un problema de alta dimensionalidad. En dominios con cobertura censal incompleta o con baja población, la información disponible puede ser insuficiente para estimar de manera precisa cada uno de estos subconjuntos de población. En estos casos, los modelos jerárquicos bayesianos permiten aprovechar la dependencia existente entre áreas geográficas y grupos demográficos para obtener estimaciones más estables y coherentes, preservando las relaciones de agregación entre los distintos niveles territoriales y las desagregaciones por sexo y edad.

1.3 Formulación del problema de subcobertura, no respuesta y omisión censal

Uno de los principales desafíos de los censos modernos corresponde a los problemas de cobertura asociados al operativo de enumeración. Aunque el objetivo conceptual del censo consiste en registrar exhaustivamente toda la población presente o residente dentro del territorio nacional, en la práctica siempre existen diferencias entre la población efectivamente observada y la población real presente en el territorio.

Estas diferencias surgen por múltiples razones. Algunas personas no son censadas, ciertas viviendas quedan fuera del operativo, algunos registros son duplicados y, en otros casos, existen errores en la asignación territorial de la información recolectada. Como resultado, los conteos censales deben entenderse como realizaciones observadas de un proceso de enumeración sujeto a limitaciones operativas, errores cartográficos y dificultades de cobertura.

Formalmente, sea $Y_{i,s,e}$ el conteo observado en el operativo censal para el territorio i , sexo s y grupo de edad e , y sea $N_{i,s,e}$ la población verdadera correspondiente, definida en la sección 1.2.1. La relación entre ambos puede representarse como:

$$Y_{i,s,e} = N_{i,s,e} - O_{i,s,e} + D_{i,s,e} + C_{i,s,e}$$

donde $O_{i,s,e}$ representa la omisión censal, $D_{i,s,e}$ la duplicación de personas y $C_{i,s,e}$ los errores asociados a clasificación o asignación territorial. Bajo esta formulación, los conteos observados no constituyen una medición exacta de la población, sino una aproximación afectada por distintos mecanismos de error.

En América Latina y el Caribe, la subcobertura censal presenta además una marcada heterogeneidad territorial. La omisión no ocurre aleatoriamente sobre la población ni sobre el territorio. Por el contrario, suele concentrarse en contextos específicos como asentamientos informales, zonas rurales dispersas, territorios indígenas, áreas de frontera o sectores urbanos con elevada movilidad residencial. Estas características generan patrones espaciales de cobertura diferencial que afectan directamente la calidad de los conteos subnacionales.

La no respuesta constituye un problema adicional dentro del proceso censal. Incluso cuando una vivienda logra ser efectivamente enumerada, algunas variables pueden quedar incompletas debido a ausencia de informantes, rechazo parcial, inconsistencias durante la entrevista o errores de captura. Este fenómeno afecta particularmente variables socioeconómicas y laborales, reduciendo la completitud analítica de la información censal.

La combinación entre subcobertura, omisión y no respuesta produce efectos acumulativos sobre múltiples procesos estadísticos posteriores. Las proyecciones demográficas, la construcción de marcos muestrales, la estimación de indicadores sociales y los procesos de focalización territorial dependen directamente de la calidad de los conteos base. En consecuencia, errores relativamente pequeños en la enumeración pueden propagarse posteriormente hacia distintas operaciones estadísticas oficiales.

Estos problemas adquieren una relevancia aún mayor en niveles geográficos pequeños. En municipios con baja población o segmentos censales reducidos, la omisión de un número limitado de viviendas puede alterar significativamente las estructuras poblacionales observadas. Este fenómeno se intensifica cuando los errores de cobertura afectan diferencialmente determinados grupos de edad, sexo o condiciones socioeconómicas.

Adicionalmente, la rápida transformación territorial observada en muchos países de la región ha incrementado la complejidad operativa de los censos. La expansión urbana acelerada, el crecimiento de asentamientos informales y los procesos migratorios dificultan la actualización cartográfica permanente y reducen la capacidad de cobertura completa del operativo censal.

Frente a este escenario, los sistemas estadísticos han comenzado a complementar los enfoques tradicionales de conciliación censal mediante estrategias de integración de múltiples fuentes de información. Los registros administrativos, las imágenes satelitales, los preconteos operativos y otras fuentes auxiliares permiten identificar inconsistencias territoriales y fortalecer la estimación de poblaciones subenumeradas.

En este libro, el interés principal no se centra en modelar directamente tasas de cobertura, sino en estimar conteos poblacionales en segmentos censales donde existen problemas de cobertura, omisión o inconsistencias territoriales. Bajo esta perspectiva, los conteos observados se interpretan como información parcial sobre una población subyacente cuya magnitud real debe inferirse utilizando información auxiliar y estructuras jerárquicas coherentes con la organización territorial del censo.

Desde esta perspectiva, los modelos bayesianos ofrecen un marco flexible para integrar múltiples fuentes de información, representar explícitamente la incertidumbre asociada a los conteos observados y estabilizar estimaciones en dominios geográficos pequeños. Los capítulos posteriores desarrollan estos elementos metodológicos y presentan estrategias orientadas específicamente a la estimación subnacional de conteos poblacionales en segmentos censales bajo esquemas probabilísticos modernos.

Integración de Fuentes de Información

La estimación de conteos poblacionales en unidades territoriales pequeñas requiere combinar información proveniente de diversas fuentes que describen, de manera complementaria, la distribución espacial de la población. Cuando el operativo censal presenta omisiones de cobertura, segmentos no observados o limitaciones para representar adecuadamente la heterogeneidad territorial, los datos censales por sí solos resultan insuficientes para reconstruir la distribución completa de la población.

Los avances recientes en disponibilidad de imágenes satelitales, productos derivados de sensores remotos, registros geoespaciales, modelos digitales del terreno, infraestructura, redes viales y otras fuentes de información auxiliar han ampliado significativamente la capacidad para caracterizar el territorio y explicar los patrones de asentamiento humano. Integrar estas fuentes dentro de un marco estadístico coherente permite aprovechar la información contenida en cada una de ellas para mejorar la predicción de los conteos poblacionales.

Este capítulo presenta los fundamentos conceptuales de la integración de fuentes de información en el contexto de los modelos bayesianos de población. Se describen las principales fuentes de información disponibles para América Latina y el Caribe, sus características, cobertura, resolución, calidad y principales limitaciones. Asimismo, se presentan los criterios para la construcción, transformación y selección de variables auxiliares derivadas de estas fuentes, así como los principios para su integración dentro de un marco estadístico coherente. Estas variables constituyen la base de los modelos utilizados para predecir los conteos poblacionales en unidades territoriales de interés y complementar la información proveniente de los censos de población.

2.1 Principios de modelamiento

Los modelos estadísticos empleados para la estimación de conteos poblacionales relacionan los conteos observados con un conjunto de covariables auxiliares, con el fin de explicar las diferencias en magnitud poblacional entre unidades de análisis y predecir los conteos en aquellas donde la información censal es incompleta o no está disponible.

El desarrollo de estos modelos debe satisfacer cuatro principios fundamentales: respetar la naturaleza discreta y no negativa de los conteos poblacionales mediante distribuciones de probabilidad apropiadas para este tipo de variable respuesta; incorporar de forma coherente información auxiliar proveniente de fuentes heterogéneas en resolución y calidad; producir estimaciones consistentes con los totales poblacionales disponibles y coherentes entre niveles de agregación territorial; y cuantificar la incertidumbre de las predicciones de forma que respalde su uso en procesos de toma de decisiones.

Estos principios constituyen la base para la selección de la familia distribucional, la especificación de la estructura del predictor y la adopción del marco inferencial bayesiano que se desarrolla en los capítulos siguientes.

2.1.1 Modelos de conteo

Los conteos poblacionales son variables aleatorias discretas no negativas. Esta naturaleza fundamental distingue el problema de estimación subnacional de los problemas de regresión con variables continuas y exige el uso de modelos de probabilidad apropiados para datos de conteo.

La distribución de Poisson constituye el punto de partida canónico para el modelamiento de conteos. Si Y_i denota el conteo observado en el segmento i , el modelo de Poisson establece:

$$Y_i | \lambda_i \sim \text{Poisson}(\lambda_i)$$

donde $\lambda_i > 0$ es el parámetro de intensidad, que representa simultáneamente la media y la varianza de la distribución. La función de probabilidad es:

$$P(Y_i = y | \lambda_i) = \frac{e^{-\lambda_i} \lambda_i^y}{y!}, \quad y = 0, 1, 2, \dots$$

La parametrización log-lineal del modelo relaciona el logaritmo de la intensidad con un predictor lineal de covariables:

$$\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta} + \mathbf{z}_i^\top \boldsymbol{\gamma}$$

donde $\mathbf{x}_i$ es el vector de covariables auxiliares del segmento i con coeficientes de efectos fijos $\boldsymbol{\beta}$, y $\mathbf{z}_i^\top \boldsymbol{\gamma}$ es el efecto aleatorio territorial que captura la variabilidad no explicada por las covariables, con $\gamma_j \sim \mathcal{N}(0, \sigma_\gamma^2)$ para cada unidad territorial j . Esta notación $-\boldsymbol{\beta}, \mathbf{z}_i^\top \boldsymbol{\gamma}, \sigma_\gamma$ es la que se emplea en la especificación completa del modelo de conteos poblacionales del Capítulo 4.

Un supuesto fundamental del modelo de Poisson es la equidispersión: $\mathbb{E}[Y_i | \lambda_i] = \text{Var}(Y_i | \lambda_i) = \lambda_i$. En la práctica, los conteos poblacionales suelen exhibir sobredispersión, es decir, una varianza observada mayor a la media. Este fenómeno puede originarse en heterogeneidad no observada entre segmentos, clustering espacial o errores de especificación del predictor.

Para tratar la sobredispersión sin abandonar la familia Poisson, se introduce un multiplicador aleatorio en la intensidad: $\lambda_i = \mu_i \cdot \exp(\varepsilon_i)$ con $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$. La distribución marginal de Y_i ya no tiene forma cerrada, pero $\exp(\varepsilon_i)$ conserva una interpretación directa como factor multiplicativo que amplifica o reduce la intensidad esperada en cada segmento, capturando la variabilidad extra-Poisson no explicada por las covariables ni por el efecto aleatorio territorial. Esta es la especificación —denominada Poisson-lognormal— adoptada en el modelo de conteos poblacionales, donde μ_i se especifica precisamente como $\mathbf{x}_i^\top \boldsymbol{\beta} + \mathbf{z}_i^\top \boldsymbol{\gamma}$ y ε_i se convierte en la densidad latente log-normal.

En contextos de modelamiento jerárquico, la necesidad de este componente adicional debe fundamentarse en el diagnóstico de sobredispersión: una especificación más rica de covariables puede reducir la sobredispersión aparente al explicar parte de la heterogeneidad entre segmentos, y solo el remanente no explicado justifica la inclusión del término log-normal.

2.1.2 Requerimientos de estimación subnacional

La estimación de conteos en niveles territoriales pequeños impone requerimientos adicionales que van más allá de la simple elección de una distribución de probabilidad. Estos requerimientos se derivan de la naturaleza jerárquica del problema y de las condiciones operativas en las que se producen los datos.

Coherencia jerárquica. Las estimaciones en niveles inferiores deben ser consistentes con los totales conocidos o estimados en niveles superiores. Si $\hat{N}_k^{(3)}$ denota la estimación del municipio k y $\hat{N}_j^{(2)}$ la del departamento j , la coherencia exige:

$$\hat{N}_j^{(2)} = \sum_{k: k \subset j} \hat{N}_k^{(3)}$$

Esta restricción de coherencia entre niveles es fundamental para garantizar la consistencia interna del sistema estadístico y constituye un criterio de validación esencial de cualquier modelo de estimación subnacional.

Estimación en unidades con cobertura incompleta. La estimación de conteos poblacionales solo es necesaria en aquellas unidades territoriales donde el operativo censal no logró observar la totalidad de la población o donde los conteos disponibles presentan deficiencias de cobertura o calidad. En estos casos, la información observada resulta insuficiente para determinar directamente el número de habitantes, por lo que es necesario complementar los datos censales mediante información auxiliar proveniente de múltiples fuentes. El modelo estadístico combina ambas fuentes de información para predecir los conteos poblacionales faltantes y reconstruir una distribución poblacional consistente con la información disponible.

Propagación de incertidumbre. Toda predicción de conteos poblacionales debe acompañarse de una medida de incertidumbre que refleje la información disponible y la variabilidad asociada al proceso de estimación. La incertidumbre depende, entre otros factores, de la cantidad y calidad de la información observada, de la capacidad explicativa de las covariables y de la incertidumbre inherente al modelo estadístico. Su cuantificación es indispensable para evaluar la confiabilidad de las predicciones y apoyar su utilización en la producción de estadísticas oficiales y en la toma de decisiones.

2.1.3 Justificación del enfoque bayesiano

La estimación de conteos poblacionales en unidades territoriales con cobertura censal incompleta requiere un marco inferencial capaz de integrar información proveniente de múltiples fuentes, representar explícitamente la incertidumbre asociada a las predicciones y modelar la heterogeneidad inherente a la distribución de la población. El enfoque bayesiano proporciona una formulación natural para abordar estos desafíos, al combinar la evidencia observada con información previa dentro de un modelo probabilístico coherente. Esta formulación permite incorporar estructuras jerárquicas, compartir información entre unidades territoriales relacionadas y obtener distribuciones posteriores para todos los parámetros y cantidades de interés, facilitando tanto la predicción de conteos poblacionales como la cuantificación de la incertidumbre asociada a dichas predicciones. Estas características convierten al enfoque bayesiano en un marco particularmente adecuado para el desarrollo de los modelos de población presentados en este libro.

Representación explícita de la incertidumbre. En el paradigma bayesiano, todos los parámetros desconocidos se tratan como variables aleatorias cuya incertidumbre se cuantifica mediante distribuciones de probabilidad. En el modelo de conteos poblacionales desarrollado en este libro, el vector de parámetros estructurales es $\theta = \{\beta, \gamma, \sigma, \sigma_U\}$: β son los coeficientes de efectos fijos asociados a las covariables auxiliares, γ son los efectos

aleatorios territoriales, σ es la escala de la densidad poblacional latente y σ_U es el hiperparámetro que controla la variabilidad de γ entre unidades territoriales. La distribución posterior $p(\theta \mid \mathbf{Y})$ encapsula el estado de conocimiento sobre estos parámetros —y, a través de ellos, sobre la población en cada segmento— dado el vector de conteos observados $\mathbf{Y}$:

$$p(\theta \mid \mathbf{Y}) \propto p(\mathbf{Y} \mid \theta) p(\theta)$$

Esta representación permite calcular intervalos de credibilidad, probabilidades de excedencia y cualquier otra cantidad de interés derivada de la distribución posterior.

Incorporación de información previa. El enfoque bayesiano permite incorporar conocimiento previo mediante distribuciones a priori asignadas a los parámetros del modelo. Estas distribuciones pueden representar restricciones derivadas del problema de estudio o reflejar información disponible antes de observar los datos. La combinación de esta información con la evidencia aportada por los datos da lugar a la distribución posterior, que constituye la base de la inferencia bayesiana.

Modelamiento jerárquico. Los modelos bayesianos permiten organizar los distintos componentes del problema mediante estructuras jerárquicas, facilitando la integración de información proveniente de múltiples fuentes y el intercambio de información entre unidades territoriales. Esta característica produce estimaciones más estables en aquellas unidades con información limitada, sin perder la capacidad de representar la heterogeneidad observada entre territorios.

En modelos jerárquicos de alta complejidad, la distribución posterior rara vez admite una expresión analítica, por lo que su aproximación requiere métodos numéricos de simulación. En este libro, la inferencia bayesiana se realiza mediante técnicas de Monte Carlo por cadenas de Markov (MCMC) ([Tierney, 1994](#)), utilizando el algoritmo Hamiltonian Monte Carlo (HMC) y el muestreador No-U-Turn (NUTS) implementados en Stan ([Duane et al., 1987](#); [Neal, 2011](#); [Betancourt, 2017](#); [Hoffman and Gelman, 2014](#); [Carpenter et al., 2017](#)). Los fundamentos de estos algoritmos y su aplicación al modelo propuesto se presentan en el Capítulo 4.

2.1.4 Integración de múltiples fuentes

Uno de los principales retos en la modelación de población consiste en aprovechar la información disponible en fuentes de naturaleza heterogénea. Además de los conteos provenientes del censo, actualmente existe una amplia variedad de fuentes auxiliares que describen características demográficas, ambientales, físicas y socio-económicas del territorio, como registros administrativos, imágenes satelitales, productos de observación de la Tierra, cartografía temática e infraestructura geoespacial ([CEPAL, 2023](#)). Aunque estas fuentes no constituyen mediciones directas de la población, contienen información que puede utilizarse para explicar su distribución y mejorar la capacidad predictiva de los modelos.

El enfoque bayesiano proporciona un marco probabilístico coherente para integrar esta información dentro de un único modelo ([Bryant and Zhang, 2018](#)). En la metodología desarrollada en este libro, la integración se realiza principalmente mediante la incorporación de variables auxiliares derivadas de las distintas fuentes en el vector de covariables $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip})^\top$ del predictor log-lineal $\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta} + \mathbf{z}_i^\top \boldsymbol{\gamma}$ presentado en la Sección 2.1.1. Cada componente de $\mathbf{x}_i$ puede provenir de una fuente distinta, y de esta forma la información contenida en múltiples fuentes contribuye conjuntamente a explicar la intensidad poblacional y a mejorar las predicciones en las unidades donde la cobertura censal es incompleta.

La integración de fuentes requiere un proceso previo de armonización para garantizar que las variables auxiliares sean comparables entre sí y consistentes con la unidad territorial de análisis. Este proceso comprende

la transformación de escalas espaciales, la agregación o desagregación de información, el tratamiento de valores faltantes, la estandarización de definiciones y la evaluación de la calidad de cada fuente. Estos aspectos se desarrollan en las secciones siguientes del capítulo.

En la literatura también existen modelos que integran múltiples mediciones directas de la población mediante funciones de verosimilitud específicas para cada fuente de información (Bryant and Graham, 2013; Wheldon et al., 2013). Aunque este enfoque resulta apropiado cuando se dispone de varias observaciones comparables del mismo fenómeno, en este libro se adopta una estrategia diferente: utilizar una única variable respuesta —el conteo poblacional observado— y complementar su información mediante covariables derivadas de múltiples fuentes auxiliares, en la línea de los modelos de área de la Estimación en Áreas Pequeñas (Rao and Molina, 2015; Mercer et al., 2015). Esta formulación permite aprovechar la riqueza de la información disponible sin requerir que todas las fuentes midan directamente la población bajo un mismo esquema de observación.

2.1.5 Relación con *Small Area Estimation* (SAE)

Los modelos presentados en este libro guardan una estrecha relación conceptual con la metodología de Estimación en Áreas Pequeñas (*Small Area Estimation*, SAE), en cuanto ambos buscan producir estimaciones confiables para unidades territoriales donde la información disponible es insuficiente para responder directamente al problema de interés (Rao and Molina, 2015). En ambos enfoques, las variables auxiliares desempeñan un papel fundamental al complementar la información observada mediante modelos estadísticos que permiten mejorar la precisión de las estimaciones.

No obstante, el problema abordado en este libro difiere del planteamiento clásico de SAE. En los modelos tradicionales, el objetivo consiste en estimar parámetros poblacionales —como medias, proporciones o totales— a partir de encuestas probabilísticas cuyos tamaños muestrales son insuficientes en determinados dominios de estudio. En consecuencia, el modelo se construye sobre estimadores directos o sobre observaciones individuales provenientes del diseño muestral, incorporando explícitamente el error de muestreo como parte de la especificación estadística.

En contraste, los modelos bayesianos de población desarrollados en este libro utilizan como variable respuesta el conteo poblacional observado durante el operativo censal y recurren a fuentes auxiliares para predecir la población únicamente en aquellas unidades territoriales donde la cobertura censal es incompleta o la información disponible resulta insuficiente. En este contexto, la incertidumbre proviene principalmente del modelo de predicción y de la calidad de las fuentes de información utilizadas, más que del error de muestreo asociado a un diseño probabilístico.

Desde el punto de vista metodológico, ambos enfoques comparten el uso de modelos jerárquicos, efectos aleatorios y variables auxiliares para combinar información de diferentes orígenes. Sin embargo, difieren en la naturaleza de la variable de interés, en el mecanismo que genera la incertidumbre y en la formulación del modelo estadístico. Mientras que la metodología SAE clásica se desarrolla principalmente para parámetros derivados de encuestas, el enfoque presentado en este libro se orienta a la reconstrucción y predicción de conteos poblacionales mediante modelos bayesianos de conteo que integran información proveniente de múltiples fuentes.

2.2 Identificación de fuentes

La calidad de los modelos bayesianos de estimación subnacional depende críticamente de la disponibilidad y pertinencia de las fuentes de información auxiliar incorporadas. En América Latina y el Caribe, el conjunto de

fuentes disponibles varía considerablemente entre países, pero puede organizarse en cuatro categorías principales: medición de cobertura censal, preconteos operativos, registros administrativos y fuentes satelitales.

2.2.1 Medición de cobertura a nivel de segmento

La cobertura censal constituye el primer aspecto que debe evaluarse antes de emprender cualquier proceso de estimación poblacional subnacional. La cobertura representa la proporción de la población real que fue efectivamente enumerada durante el operativo censal, mientras que su complemento, la tasa de omisión censal, cuantifica la fracción de la población que no fue observada.

Sea N_i la población verdadera del segmento i y $Y_i^{(C)}$ el conteo registrado durante el censo. La tasa de cobertura del segmento se define como

$$c_i = \frac{Y_i^{(C)}}{N_i},$$

mientras que la tasa de omisión correspondiente es

$$\omega_i = 1 - c_i.$$

Dado que la población verdadera N_i no es directamente observable, la cobertura no puede calcularse de manera exacta y debe estimarse a partir de información independiente del operativo censal.

En la práctica, la evaluación de la cobertura se basa principalmente en tres tipos de fuentes. La primera corresponde a las encuestas postcensales de cobertura, diseñadas específicamente para medir la omisión mediante un operativo de campo independiente. La segunda comprende los métodos de conciliación demográfica, que contrastan los resultados censales con estimaciones derivadas de estadísticas vitales y proyecciones de población. La tercera utiliza técnicas de captura-recaptura que combinan la información del censo con registros administrativos para estimar la población no observada.

La cobertura censal presenta una marcada heterogeneidad territorial. En general, los menores niveles de cobertura se concentran en áreas rurales dispersas, asentamientos informales, territorios indígenas, zonas de difícil acceso y sectores urbanos con elevada movilidad residencial. Estas diferencias reflejan las condiciones operativas del levantamiento censal y constituyen uno de los principales factores que justifican la incorporación de información auxiliar en los modelos de estimación poblacional.

En la metodología propuesta, la cobertura de cada segmento se aproxima mediante un estimador

$$\hat{c}_i = \frac{Y_i^{(C)}}{\hat{N}_i},$$

donde $\hat{N}_i$ representa una referencia externa obtenida a partir de una encuesta postcensal, una conciliación demográfica, un procedimiento de captura-recaptura o un preconteo operativo ajustado —este último se retoma en la Sección 2.2.2—. **Nota de notación.** A partir de aquí, el acento ancho $\hat{N}_i$ (comando LaTeX `\widehat`) se reserva exclusivamente para referencias poblacionales externas al modelo, como la empleada en este estimador de cobertura. El acento angosto $\hat{N}$ (`\hat`), utilizado más arriba en esta misma sección para la coherencia jerárquica y retomado en los Capítulos 4, ?? y ??, denota en cambio la propia estimación agregada del modelo bayesiano —la cantidad que en el Capítulo ?? se calibra frente a un total de control externo—. Ambas cantidades son

conceptualmente distintas —una es insumo para evaluar cobertura, la otra es un resultado del modelo— y no deben confundirse pese a la similitud visual del símbolo. Este estimador se utiliza para clasificar los segmentos según su nivel de cobertura y definir el tratamiento que recibirán en las etapas posteriores del modelamiento: los segmentos con cobertura completa ($\hat{c}_i = 1$) utilizan directamente el conteo censal; los segmentos con cobertura parcial ($0 < \hat{c}_i < 1$) combinan el conteo observado con la predicción del modelo para la población omitida; y los segmentos con cobertura nula ($\hat{c}_i = 0$) se estiman íntegramente mediante las covariables auxiliares y la estructura jerárquica del modelo. Esta clasificación se formaliza en la Sección 3.2 del Capítulo 3.

Es importante señalar que la metodología no busca estimar ni corregir explícitamente la omisión censal dentro del modelo bayesiano. La evaluación de la cobertura constituye una etapa previa cuyo propósito es determinar la calidad de la información disponible y establecer cómo participa cada segmento en el proceso de estimación.

2.2.2 Preconteos y segmentación

Los preconteos operativos constituyen una de las fuentes auxiliares más directamente vinculadas a la estimación de la población en segmentos censales. Estas operaciones, realizadas durante la fase de actualización cartográfica previa al levantamiento censal, producen información sobre el número aproximado de viviendas o estructuras habitacionales presentes en cada unidad operativa.

La segmentación censal es el proceso mediante el cual el territorio nacional se divide en unidades operativas de trabajo, denominadas segmentos o áreas de enumeración. Cada segmento es asignado a un censista y está diseñado para ser enumerable en el tiempo operativo disponible. Los criterios de segmentación varían entre países: algunos utilizan como criterio el número esperado de viviendas, otros priorizan continuidad espacial o accesibilidad geográfica.

Sea V_i el preconteo de viviendas o estructuras habitacionales registrado en el segmento i durante la actualización cartográfica. El preconteo cumple un papel operativo central en la planeación del propio operativo censal: permite dimensionar la carga de trabajo de cada censista, estimar el número de enumeradores y el tiempo requerido para cubrir el territorio, anticipar necesidades presupuestarias y logísticas, y detectar segmentos cuyo crecimiento habitacional exige una resegmentación antes del levantamiento. La segmentación, a su vez, garantiza que esta planeación cubra la totalidad del territorio nacional sin traslapes ni vacíos entre unidades operativas.

El preconteo es especialmente valioso en contextos donde el operativo censal no logró cobertura completa, dado que provee una señal anticipada sobre la magnitud poblacional esperada que es independiente del proceso de enumeración —la misma propiedad que permite emplearlo como referencia externa en el estimador de cobertura de la Sección 2.2.1—. Su principal limitación es la distancia temporal entre la actualización cartográfica y el momento censal: en contextos con crecimiento urbano acelerado, los preconteos pueden quedar desactualizados rápidamente.

2.2.3 Registros administrativos

Los registros administrativos son bases de datos generadas por entidades gubernamentales como resultado de sus funciones institucionales. A diferencia de los censos, no tienen por objetivo la medición estadística de la población, sino la gestión de servicios, beneficios o trámites administrativos. Sin embargo, en la medida en que su cobertura es razonablemente alta y su definición territorial compatible con los segmentos censales, pueden utilizarse como variables proxy de la magnitud poblacional (Rao and Molina, 2015).

Entre los registros administrativos más utilizados en modelos de estimación subnacional en América Latina y el Caribe se encuentran:

Registros de afiliación a sistemas de salud y seguridad social. Los sistemas de salud pública o los registros de afiliación a la seguridad social contienen información sobre personas que acceden regularmente a servicios institucionales. Su cobertura depende del grado de formalidad laboral y del acceso efectivo a los servicios en cada territorio.

Registros o consumo de servicios públicos. Los registros de conexiones o consumo de electricidad, agua potable o gas domiciliario, administrados por las empresas prestadoras de servicios, proporcionan un conteo de usuarios activos o viviendas conectadas por unidad territorial. Su cobertura está condicionada por el grado de formalización de la vivienda y por la extensión de las redes de distribución, por lo que puede subestimar la población en asentamientos informales o en zonas rurales dispersas sin conexión a la red.

Registros de beneficiarios de programas sociales. Los padrones de beneficiarios de programas de transferencias condicionadas u otros programas sociales focalizados proporcionan información sobre hogares en situación de vulnerabilidad. Aunque su cobertura no es universal, pueden ser especialmente informativos en áreas con alta concentración de población en condición de pobreza.

2.2.4 Fuentes satelitales

Las imágenes satelitales y los productos de percepción remota han ampliado considerablemente el conjunto de covariables disponibles para la estimación poblacional subnacional. Su principal ventaja es la cobertura territorial universal, la continuidad temporal y la independencia respecto a los sistemas estadísticos institucionales.

Las fuentes satelitales más utilizadas en estimación poblacional pueden agruparse en las siguientes categorías:

Luminosidad nocturna. Los datos de radiancia nocturna capturados por sensores satelitales, como el producto VIIRS-DNB de la NOAA, permiten identificar áreas con presencia de iluminación artificial. La intensidad lumínica nocturna está correlacionada con la actividad económica y la densidad de asentamientos humanos permanentes.

Área construida y cobertura urbana. Los productos de clasificación de uso del suelo derivados de imágenes ópticas como Sentinel-2 o Landsat permiten estimar la proporción de área construida dentro de cada segmento. El producto Global Human Settlement Layer (GHSL) de la Comisión Europea ofrece estimaciones de área construida a resolución de 100 metros con cobertura global.

Índice de vegetación de diferencia normalizada (NDVI). El NDVI mide la densidad y vitalidad de la vegetación a partir de la reflectancia en bandas del infrarrojo cercano y el rojo visible. Valores bajos de NDVI en áreas no áridas generalmente indican presencia de infraestructura construida y asentamientos urbanos, mientras que valores altos corresponden a áreas con cobertura vegetal densa.

Temperatura superficial terrestre (LST). Las islas de calor urbano, reflejadas en valores elevados de temperatura superficial, constituyen un indicador indirecto de densidad de infraestructura y actividad humana.

Modelos digitales de elevación. La topografía del terreno condiciona la distribución espacial de la población. Los modelos de elevación digital como SRTM o ALOS permiten derivar variables como altitud media, pendiente y orientación del terreno, que están correlacionadas con la densidad y distribución de los asentamientos humanos.

La integración de covariables satelitales en el modelo requiere procesar las imágenes hasta el nivel del segmento censal, lo que implica operaciones de reproyección, remuestreo y estadísticas zonales. La resolución espacial de

las imágenes debe ser compatible con el tamaño de los segmentos: resoluciones muy gruesas pueden introducir errores de asignación en segmentos pequeños, mientras que resoluciones muy finas pueden aumentar el costo computacional sin beneficio estadístico apreciable.

En la práctica, esta información satelital se extrae y se procesa a través de plataformas de computación geoespacial en la nube, como Google Earth Engine ([Gorelick et al., 2017](#)), que alojan los catálogos de VIIRS-DNB, Sentinel-2, Landsat, GHSL y los modelos digitales de elevación descritos arriba, y permiten calcular directamente las estadísticas zonales por segmento sin necesidad de descargar las imágenes completas.

2.3 Variables explicativas

Mientras la Sección 2.2 identificó el origen institucional u operativo de cada fuente auxiliar, esta sección describe el paso siguiente del proceso: cómo esas fuentes se transforman en las covariables efectivamente incorporadas al predictor x_i del modelo. La calidad predictiva del modelo de estimación subnacional depende directamente de esta selección y construcción. Las covariables resultantes pueden organizarse en dos grandes grupos según su naturaleza conceptual: variables socioeconómicas y variables espaciales. Indicadores demográficos como la estructura por sexo y edad, la razón de masculinidad o el tamaño medio del hogar quedan excluidos de este conjunto: al derivarse de la propia tabulación censal por sexo y edad, no están disponibles de forma independiente en los segmentos con cobertura incompleta —que son precisamente aquellos donde se necesita una variable explicativa— y por tanto no cumplen el requisito de disponibilidad territorial exigido a toda covariable auxiliar.

2.3.1 Variables socioeconómicas

Las condiciones socioeconómicas del territorio están correlacionadas con la densidad de población, la calidad de la enumeración censal y la cobertura de los registros administrativos. Su incorporación como covariables permite al modelo capturar parte de la heterogeneidad no observada entre segmentos.

Indicadores de acceso a servicios. A partir de los registros de conexión y consumo de servicios públicos descritos en la Sección 2.2.3, se construye la proporción de viviendas del segmento conectadas a la red de electricidad, agua potable, alcantarillado o internet. Esta proporción está correlacionada tanto con la densidad poblacional como con la cobertura censal, y refleja el nivel de integración del territorio a la infraestructura formal del Estado.

Nivel educativo de la población. El nivel de instrucción promedio de la población adulta del segmento, derivado de censos anteriores o de registros de matrícula escolar, puede utilizarse como indicador proxy de características socioeconómicas del territorio.

Actividad económica predominante. La clasificación del segmento según la actividad económica predominante —agropecuaria, industrial, comercial, servicios— condiciona la estructura demográfica esperada y los patrones de movilidad residencial. Esta clasificación puede derivarse de cartografía censal o de imágenes satelitales.

2.3.2 Variables espaciales

Las variables espaciales capturan la posición geográfica del segmento y sus relaciones de vecindad con el entorno territorial. Su incorporación permite al modelo aprovechar, a través de covariables observadas, la conti-

nidad espacial de la distribución poblacional —sin que ello implique una estructura de dependencia espacial modelada explícitamente entre segmentos vecinos.

Distancia a centros urbanos. La distancia euclidiana o por red vial desde el centroide del segmento hasta el centro urbano más cercano es un predictor relevante de la densidad y tipo de asentamiento. Segmentos más próximos a centros urbanos tienden a presentar mayor densidad poblacional, mayor acceso a servicios y mayor cobertura de registros administrativos.

Accesibilidad y tiempos de desplazamiento. El tiempo de desplazamiento por carretera hasta el centro urbano o el hospital más cercano, derivado de modelos de redes viales, es un indicador de accesibilidad territorial con mayor valor predictivo que la distancia euclidiana en contextos con topografía compleja o infraestructura vial deficiente.

Altitud y topografía. A partir de los modelos digitales de elevación descritos en la Sección 2.2.4, se calculan a nivel de segmento la altitud media, la pendiente del terreno y la variabilidad topográfica interna, que condicionan la viabilidad de asentamientos humanos y la densidad de población esperable. Estas variables son especialmente relevantes en países con territorios montañosos.

El efecto aleatorio territorial y del Capítulo 4 —de especificación intercambiable (jerárquica) a nivel de unidad territorial superior, sin estructura de adyacencia entre segmentos vecinos— no debe interpretarse como un mecanismo de modelamiento de la omisión censal: su función es capturar heterogeneidad residual en la densidad poblacional una vez incluidas las covariables observadas, no compensar la subenumeración diferencial descrita en la Sección 2.2.1, que no se modela ni se corrige, sino que únicamente se utiliza para clasificar los segmentos según su nivel de cobertura.

La selección final del conjunto de variables explicativas debe fundamentarse en criterios de disponibilidad territorial —las variables deben estar disponibles para todos los segmentos—, pertinencia conceptual, capacidad predictiva demostrada y ausencia de multicolinealidad severa entre predictores. Los capítulos siguientes presentan la especificación formal de los modelos que integran estas variables en un esquema bayesiano jerárquico orientado a la estimación de conteos poblacionales subnacionales.

Preparación de Insumos para Modelamiento

La construcción de un modelo bayesiano de estimación subnacional requiere, como condición previa, disponer de un conjunto de insumos analíticos preparados con criterios estadísticos explícitos y documentados. La calidad de las estimaciones finales depende no solo de la sofisticación del modelo, sino fundamentalmente de la coherencia, completitud y representatividad de los datos que lo alimentan.

Este capítulo describe el proceso de preparación de insumos en cuatro etapas secuenciales: la estandarización de las fuentes de información, la evaluación de cobertura por segmento, la construcción de la variable dependiente y el diagnóstico exploratorio de los datos. Cada etapa introduce operaciones estadísticas específicas cuya omisión puede comprometer la validez de las inferencias posteriores.

3.1 Estandarización de fuentes

Las fuentes de información descritas en el capítulo anterior provienen de sistemas institucionales con distintas definiciones operativas, unidades de medida, fechas de referencia y marcos territoriales. Su incorporación conjunta en un modelo estadístico exige un proceso previo de estandarización que garantice la comparabilidad entre fuentes y la compatibilidad con los dominios de estimación definidos.

3.1.1 Homologación de variables

La homologación consiste en establecer correspondencias semánticas y operativas entre variables provenientes de distintas fuentes que miden conceptos equivalentes o relacionados bajo definiciones diferentes. Este proceso es necesario porque los sistemas administrativos, los registros satelitales y los datos censales utilizan nomenclaturas, clasificaciones y criterios de asignación territorial que no siempre son directamente comparables.

Compatibilización de marcos territoriales. El primer paso en la homologación es garantizar que todas las fuentes estén referenciadas al mismo marco geográfico. En América Latina y el Caribe, los distintos registros administrativos suelen estar organizados por municipios, provincias o departamentos que no coinciden directamente con los segmentos censales. Sea $\mathcal{S} = \{1, 2, \dots, I\}$ el conjunto de segmentos del operativo censal y $\mathcal{U} = \{1, 2, \dots, J\}$ las unidades geográficas del registro administrativo —un marco de referencia distinto del nivel territorial superior indexado también por j en los efectos aleatorios del Capítulo 4, con el que puede o no coincidir—. La asignación de cada registro al segmento correspondiente requiere construir una función de mapeo $\phi : \mathcal{S} \rightarrow \mathcal{U}$ que identifica, para cada segmento i , la unidad administrativa $j(i)$ que lo contiene, basada en la intersección espacial entre las geometrías de ambos marcos.

Cuando las unidades del registro son más grandes que los segmentos censales —el caso habitual en la región, donde un municipio, provincia o departamento agrupa numerosos segmentos—, la compatibilización no des- agrega el conteo administrativo entre esos segmentos: todos los segmentos pertenecientes a una misma unidad territorial reciben el mismo valor, el de la unidad que los contiene. Formalmente:

$$\hat{Y}_i^{(A)} = Y_{j(i)}^{(A)}$$

donde $Y_{j(i)}^{(A)}$ es el conteo total del registro administrativo (Sección 2.2.3 del Capítulo 2) en la unidad territorial $j(i)$ a la que pertenece el segmento i . Bajo este esquema, la covariable resultante es constante entre los segmentos de una misma unidad administrativa y solo varía de una unidad a otra, por lo que su capacidad para explicar diferencias de población entre segmentos vecinos de la misma unidad es limitada; esta limitación debe documentarse al evaluar la pertinencia de la covariable en el diagnóstico exploratorio (Sección 3.4.3 más adelante en este capítulo). La notación $Y^{(A)}$ sigue el mismo convenio de superíndices por fuente empleado más adelante para el conteo censal $Y_i^{(C)}$.

Validación de la completitud y pertinencia del registro administrativo. Las distintas fuentes administrativas pueden diferir de los censos en la definición de su unidad de observación. Mientras que los censos contabilizan personas según su residencia habitual o su presencia durante el operativo censal, los padrones electorales registran ciudadanos habilitados para votar, los sistemas de salud registran afiliados activos y los registros civiles documentan hechos vitales. Estas diferencias responden a los objetivos específicos de cada sistema de información y no impiden su utilización como fuentes auxiliares para el modelamiento de la población.

Dado que los registros administrativos se incorporan como covariables explicativas y no como una medición alternativa de la población, su evaluación se centra en dos aspectos fundamentales: la completitud y la pertinencia. La completitud hace referencia a la cobertura territorial del registro, verificando que no existan segmentos sistemáticamente ausentes o con información insuficiente. La pertinencia evalúa si la unidad de observación y las variables disponibles mantienen una relación conceptual con la población que se desea modelar. En consecuencia, las diferencias conceptuales entre las fuentes deben documentarse como parte de la caracterización de las covariables, ya que constituyen un elemento clave para interpretar adecuadamente su contribución al modelo.

Desfase temporal entre fuentes. Las fuentes de información suelen corresponder a diferentes fechas de referencia. Los preconteos pueden realizarse meses antes del censo, los registros administrativos responden a fechas de corte específicas y las imágenes satelitales capturan el territorio en distintos momentos del año. Dado que estas fuentes se utilizan como covariables auxiliares y no como mediciones directas de la población, el desfase temporal se documenta como una fuente adicional de incertidumbre y las variables se incorporan en la fecha en que se encuentran disponibles. Cuando una misma fuente dispone de información para varios periodos, se evalúa la redundancia entre las distintas versiones mediante análisis de correlación y del factor de inflación de la varianza (VIF) (Sección 3.4.3), conservando únicamente aquellas que aportan información adicional al modelo.

3.1.2 Normalización de variables

Una vez homologadas, las variables auxiliares presentan distribuciones con escalas y dispersiones heterogéneas que dificultan la estimación numérica de los coeficientes y la interpretación comparada de los efectos. La normalización transforma las variables a una escala común que facilita la estimación y mejora el comportamiento computacional de los algoritmos de inferencia.

Estandarización por media y desviación estándar. Para una variable continua $x_{i,k}$ medida en el segmento i , la estandarización produce:

$$\tilde{x}_{i,k} = \frac{x_{i,k} - \bar{x}_k}{s_k}$$

donde $\bar{x}_k = \frac{1}{I} \sum_{i=1}^I x_{i,k}$ es la media y $s_k = \sqrt{\frac{1}{I-1} \sum_{i=1}^I (x_{i,k} - \bar{x}_k)^2}$ es la desviación estándar de la variable calculadas sobre todos los segmentos. Bajo esta transformación, $\tilde{x}_{i,k}$ tiene media cero y desviación estándar uno, y el coeficiente β_k se interpreta como el cambio esperado en el logaritmo de la población por unidad de desviación estándar en la covariable k .

Normalización al intervalo unitario. Para variables que representan proporciones o índices con interpretación intrínseca en el rango $[0, 1]$, como tasas de cobertura o índices de vegetación, puede ser preferible la normalización min-max:

$$\tilde{x}_{i,k} = \frac{x_{i,k} - \min_i(x_{i,k})}{\max_i(x_{i,k}) - \min_i(x_{i,k})}$$

Esta transformación preserva la interpretación original de la variable y facilita la especificación de distribuciones a priori informativas sobre los coeficientes.

Tratamiento de valores faltantes. La presencia de valores faltantes en las covariables auxiliares debe ser resuelta antes de la estimación. Las estrategias más comunes incluyen la imputación por la mediana o la media del grupo territorial al que pertenece el segmento, la imputación mediante modelos de regresión utilizando covariables con cobertura completa, y la imputación múltiple para propagar la incertidumbre asociada a los valores faltantes hacia las estimaciones finales.

3.2 Evaluación de cobertura

La evaluación de cobertura censal por segmento es un paso crítico previo a la estimación. Permite identificar los dominios con información deficiente, cuantificar el grado de omisión territorial y establecer una clasificación de los segmentos que oriente las decisiones de modelamiento.

La tasa de cobertura de un segmento censal expresa la proporción de la población del segmento que fue efectivamente enumerada durante el operativo censal. Como la población verdadera no es observable, la cobertura debe estimarse utilizando una referencia externa, como un preconteo operativo ajustado o una estimación demográfica independiente.

Si $\hat{N}_i$ representa la población de referencia del segmento i y $Y_i^{(C)}$ el conteo obtenido por el censo, la tasa de cobertura se calcula como

$$\hat{c}_i = \frac{Y_i^{(C)}}{\hat{N}_i}.$$

Un valor cercano a uno indica que el conteo censal es consistente con la población de referencia. Valores inferiores a uno sugieren subcobertura, mientras que valores superiores a uno pueden reflejar sobrecobertura o diferencias entre el conteo censal y la fuente utilizada como referencia.

La comparación de las tasas de cobertura entre segmentos permite identificar áreas donde el operativo censal presentó mayores dificultades de enumeración. Cuando la cobertura varía significativamente entre segmentos, la omisión deja de ser un fenómeno aleatorio y pasa a depender de características territoriales u operativas. En estos casos, la información sobre cobertura constituye un insumo importante para interpretar la calidad de los datos y para definir la estrategia de modelamiento de la población en los segmentos afectados.

3.2.1 Clasificación de segmentos

La estrategia de estimación depende del nivel de cobertura observado en cada segmento censal. Con base en la tasa de cobertura estimada, los segmentos se clasifican en tres grupos:

- **Cobertura completa** ($\hat{c}_i = 1$). El operativo censal logró enumerar la totalidad de la población del segmento. En este caso, el conteo observado se considera completo y se utiliza para ajustar el modelo de población.
- **Cobertura nula** ($\hat{c}_i = 0$). El segmento no fue enumerado durante el operativo censal. La población se estima íntegramente mediante el modelo, utilizando la información auxiliar disponible.
- **Cobertura parcial** ($0 < \hat{c}_i < 1$). El operativo censal logró enumerar únicamente una fracción de la población del segmento. En este caso, el modelo estima la población no observada y la estimación final se obtiene combinando el conteo censal observado con la predicción correspondiente a la población omitida.

Esta clasificación determina el papel que desempeña el modelo en cada segmento: reproducir el conteo observado cuando la cobertura es completa, predecir la población cuando la cobertura es nula y complementar el conteo censal cuando la cobertura es parcial. La expresión formal de la variable dependiente bajo estos tres casos se presenta en la sección siguiente.

3.3 Construcción de la variable dependiente

La variable dependiente corresponde al número de personas que residen en cada segmento censal. Su construcción combina el conteo censal observado con la predicción del modelo según el nivel de cobertura del segmento, siguiendo la clasificación de la Sección 3.2.1.

Sea $Y_i^{(C)}$ el conteo censal observado en el segmento i y $\hat{Y}_i^{(M)}$ la población omitida estimada por el modelo cuando la cobertura no es completa. La variable dependiente se define como:

$$Y_i = \begin{cases} Y_i^{(C)}, & \hat{c}_i = 1 \\ \hat{Y}_i^{(M)}, & \hat{c}_i = 0 \\ Y_i^{(C)} + \hat{Y}_i^{(M)}, & 0 < \hat{c}_i < 1, \end{cases} \quad i = 1, \dots, I.$$

Esta definición asigna a cada segmento el conteo observado cuando la enumeración fue completa, la predicción íntegra del modelo cuando no hubo enumeración, y la suma de ambas fuentes cuando la cobertura fue parcial.

En los capítulos siguientes, una vez desarrollado el modelo para el conteo total de personas, se extenderá la metodología para estimar la población desagregada por sexo y grupos de edad, preservando la coherencia entre las estimaciones agregadas y sus componentes.

3.3.1 Densidad poblacional

Aunque la variable dependiente del modelo es el número de personas por segmento, en el análisis exploratorio resulta útil considerar la densidad poblacional como una medida complementaria de la distribución espacial de la población. La densidad permite comparar segmentos con áreas muy diferentes y facilita la identificación de patrones de concentración o dispersión que pueden ser explicados por las covariables auxiliares.

Si Y_i representa el número de personas del segmento i y A_i su superficie, la densidad poblacional se define como

$$DP_i = \frac{Y_i}{A_i},$$

donde A_i se expresa en kilómetros cuadrados u otra unidad de superficie consistente. Se usa DP_i , y no D_i , por la misma razón señalada en el Capítulo 1: evitar confusión con la cardinalidad $D = |\mathcal{S}|$ introducida en el Capítulo 4. La densidad no constituye la variable de respuesta del modelo, sino una variable derivada utilizada para el análisis exploratorio, la evaluación de valores atípicos y la interpretación de la variabilidad espacial de la población.

3.3.2 Número promedio de personas por hogar

El número promedio de personas por hogar constituye un indicador descriptivo que relaciona la población observada con el número de hogares del segmento censal. Este indicador resume la intensidad de ocupación residencial y permite identificar segmentos con valores inusualmente bajos o altos que pueden reflejar problemas de cobertura, errores de enumeración o características particulares del territorio.

Sea Y_i el número de personas del segmento i y H_i el número de hogares registrados en el mismo segmento. El promedio de personas por hogar se calcula como

$$\bar{P}_i = \frac{Y_i}{H_i},$$

donde $H_i > 0$. Este indicador se utiliza principalmente durante el análisis exploratorio para evaluar la consistencia de la información censal y comparar segmentos con características similares. Valores extremos pueden señalar la necesidad de revisar la calidad de los datos o la existencia de condiciones demográficas particulares que deban considerarse durante la especificación del modelo.

3.3.3 Definición de población base

La población base define el universo de referencia sobre el cual se construye el conteo de interés. Su especificación correcta es fundamental para garantizar la comparabilidad entre segmentos y la coherencia con los totales de niveles superiores.

La definición de población base más común en censos de población es la población residente habitual: el conjunto de personas cuya residencia principal está localizada en el segmento en el momento del censo. Sin embargo, algunos censos implementan el criterio de población de hecho, que contabiliza a las personas presentes en el segmento durante el momento censal, independientemente de su residencia habitual.

Formalmente, la población base $\mathcal{P}_i$ del segmento i puede definirse bajo distintos criterios:

- **Población residente:** $\mathcal{P}_i = \{j : \text{residencia habitual de } j \text{ está en } i\}$
- **Población de hecho:** $\mathcal{P}_i = \{j : j \text{ está físicamente presente en } i \text{ en el momento censal}\}$
- **Población en hogares particulares:** excluye a las personas en colectividades institucionales (hospitales, cárceles, cuarteles).
- **Población civil:** excluye adicionalmente al personal militar.

La elección de la población base afecta la coherencia de los conteos en territorios con alta movilidad diurna, presencia de instituciones totales o frontera entre áreas urbanas y rurales. El modelo de estimación debe adaptarse

a la misma definición de población base utilizada en el operativo censal.

3.3.4 Variable de exposición

En los modelos de conteo es frecuente incorporar una variable de exposición que represente el tamaño potencial del segmento. En este libro, la exposición corresponde al número de estructuras habitacionales o viviendas identificadas durante el preconteo, denotado por V_i . Esta variable constituye una aproximación al tamaño físico del segmento y está disponible incluso en aquellos casos donde el operativo censal presenta cobertura parcial o nula.

La utilización de V_i permite comparar segmentos con diferentes tamaños y modelar el número esperado de personas en función de la cantidad de estructuras existentes. En los modelos de conteo desarrollados en el Capítulo 4, esta variable se incorpora mediante un término de *offset*, de forma que las covariables expliquen la intensidad poblacional por estructura habitacional y no únicamente el conteo absoluto de personas.

3.4 Diagnóstico exploratorio

Antes de ajustar el modelo bayesiano, es indispensable realizar un análisis exploratorio sistemático de los datos preparados. Este diagnóstico permite verificar la coherencia interna de los insumos, identificar observaciones atípicas, evaluar la capacidad predictiva de las covariables y detectar posibles violaciones de los supuestos del modelo.

A continuación se ilustran los diagnósticos descritos sobre el conjunto de segmentos preparado según los criterios de las secciones anteriores, con la densidad latente δ_i , el offset de estructuras habitacionales V_i y el conteo poblacional Y_i ya construidos:

3.4.1 Distribución de conteos

El análisis de la distribución de los conteos observados Y_i permite caracterizar la variabilidad entre segmentos y evaluar la adecuación de las familias distribucionales consideradas para el modelamiento.

Los estadísticos descriptivos básicos —media, mediana, desviación estándar, coeficientes de asimetría y curtosis— proveen una caracterización inicial de la distribución. La comparación entre la media y la varianza muestral:

$$\bar{Y} = \frac{1}{I} \sum_{i=1}^I Y_i, \quad S_Y^2 = \frac{1}{I-1} \sum_{i=1}^I (Y_i - \bar{Y})^2$$

ofrece un diagnóstico informal de sobredispersión: si $S_Y^2 \gg \bar{Y}$, el modelo de Poisson simple resulta insuficiente. En ese caso, el diagnóstico respalda la especificación jerárquica con densidad latente log-normal (Poisson-lognormal) desarrollada en el Capítulo 4, dado que es precisamente el parámetro σ de la densidad latente δ_i quien absorbe la sobredispersión detectada aquí. El índice de dispersión $ID = S_Y^2 / \bar{Y}$ cuantifica el grado de sobredispersión; valores superiores a 1.5 o 2 suelen justificar esa especificación más flexible. Se usa ID, y no D , para no confundir este índice con la cardinalidad $D = |\mathcal{S}|$ del Capítulo 4.

El Código 3.1 calcula estos estadísticos sobre los conteos observados.

Código 3.1 (Cálculo de estadísticos descriptivos).

```
library(tidyverse)

# Asimetría y curtosis muestrales (evita la dependencia del paquete moments)
skewness <- function(x) mean((x - mean(x))^3) / sd(x)^3
kurtosis <- function(x) mean((x - mean(x))^4) / sd(x)^4

resumen_conteos <- tibble(
  n_segmentos = length(Y),
  media       = mean(Y),
  mediana     = median(Y),
  desv_est    = sd(Y),
  asimetria   = skewness(Y),
  curtosis    = kurtosis(Y),
  indice_disp = var(Y) / mean(Y)
)
```

Cuadro 3.1. Resumen descriptivo de los conteos observados por segmento

N.º segmentos	Media	Mediana	Desv. estándar	Asimetría	Curtosis	Índice
500	54.29	51	28.9	6.92	65.11	

La Tabla 3.1 resume los estadísticos descriptivos calculados sobre los 500 segmentos. El índice de dispersión es 15.38, muy por encima de 1, lo que confirma la sobredispersión de los conteos y respalda la especificación jerárquica con densidad latente log-normal desarrollada en el Capítulo 4. El coeficiente de asimetría (6.92) señala una distribución con cola derecha pesada, mientras que la curtosis (65.11) evidencia un comportamiento leptocúrtico respecto a la distribución normal (curtosis = 3). Este patrón es característico de los conteos poblacionales por segmento, donde la mayoría de las unidades presenta valores moderados y un número reducido de segmentos concentra valores extremos.

```
tibble(log_Y = log(Y + 1)) %>%
  ggplot(aes(x = log_Y)) +
  geom_histogram(bins = 40, fill = "#CBD5E1", color = "white") +
  labs(x = "log(conteo + 1)", y = "Frecuencia") +
  theme_minimal()
```

La visualización de la distribución debe realizarse tanto en escala original como en escala logarítmica. En la escala original, la distribución suele ser fuertemente asimétrica con cola derecha pesada; en la escala logarítmica, la distribución es más simétrica y permite evaluar si la especificación log-lineal es adecuada.

La proporción de ceros en los conteos es otro indicador relevante. Un exceso de ceros respecto a lo esperado bajo el modelo de Poisson puede indicar la presencia de segmentos genuinamente deshabitados, problemas de cobertura en áreas con baja densidad, o la necesidad de incorporar un componente de inflación de ceros en el modelo.




Figura 3.1. Distribución de $\log(Y + 1)$ por segmento

3.4.2 Outliers

La identificación de observaciones atípicas en los conteos y en las covariables auxiliares es fundamental para evitar que estas observaciones dominen la estimación de los parámetros del modelo. En el contexto de datos de conteo, los outliers pueden manifestarse como valores excepcionalmente altos o bajos en relación con la tendencia general de los datos, o como combinaciones inusuales de conteo y covariables.

Detección basada en residuos del modelo nulo. Un modelo de regresión de Poisson sin covariables permite obtener residuos de Pearson para cada segmento:

$$r_i^P = \frac{Y_i - \hat{\lambda}_i}{\sqrt{\hat{\lambda}_i}}$$

donde $\hat{\lambda}_i = \exp(\hat{\alpha})$ con $\hat{\alpha} = \log(\bar{Y})$. Segmentos con $|r_i^P| > 3$ son candidatos a revisión como observaciones atípicas.

Detección multivariada. Las observaciones atípicas en el espacio de covariables pueden identificarse mediante la distancia de Mahalanobis:

$$d_i^2 = (\mathbf{x}_i - \bar{\mathbf{x}})^\top \hat{\Sigma}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}})$$

donde $\bar{\mathbf{x}}$ es el vector de medias y $\hat{\Sigma}$ es la matriz de covarianza muestral de las covariables. Bajo normalidad multivariada, $d_i^2 \sim \chi_p^2$, y valores superiores al percentil 97.5 de esta distribución son indicativos de observaciones atípicas en el espacio de covariables.

El Código 3.2 implementa ambos criterios de detección.

Código 3.2 (Detección de observaciones atípicas).

```
lambda_nulo      <- mean(Y)
residuos_p       <- (Y - lambda_nulo) / sqrt(lambda_nulo)
segmentos_outlier <- which(abs(residuos_p) > 3)

X_mat  <- as.matrix(covariables_std)
d2_mah <- mahalanobis(X_mat, colMeans(X_mat), cov(X_mat))
p_valor <- pchisq(d2_mah, df = ncol(X_mat), lower.tail = FALSE)
outliers_multivariados <- which(p_valor < 0.025)
```

La Figura 3.2 ubica a cada uno de los 500 segmentos en el plano definido por el residuo de Pearson del modelo nulo y la distancia de Mahalanobis sobre las covariables auxiliares, con líneas punteadas que marcan los respectivos umbrales de decisión ($|r_i^P| = 3$ y el percentil 97.5 de χ_p^2). De ellos, 48 segmentos superan el umbral del residuo de Pearson (categoría “Residuo de Pearson”, en azul), 16 superan el umbral de la distancia de Mahalanobis (categoría “Mahalanobis”, en naranja), y 3 son señalados simultáneamente por los dos criterios (categoría “Ambos criterios”, en rojo).

Los segmentos marcados en rojo constituyen los candidatos prioritarios de revisión, ya que combinan un conteo discordante con el nivel general de la muestra y una combinación inusual de covariables auxiliares. Los




Figura 3.2. Segmentos atípicos según residuo de Pearson y distancia de Mahalanobis

segmentos señalados por un solo criterio —ya sea un conteo extremo sin covariables atípicas, o covariables atípicas con un conteo dentro del rango esperado— requieren un análisis más detallado antes de decidir su tratamiento, pues cada criterio captura una forma distinta de atipicidad: el residuo de Pearson detecta conteos discordantes con el nivel medio de la muestra, mientras que la distancia de Mahalanobis detecta combinaciones inusuales en el espacio de las covariables, independientemente del valor del conteo. Una vez identificadas, las observaciones atípicas deben revisarse para determinar si corresponden a errores de procesamiento, a características genuinas del territorio o a problemas de cobertura del operativo. La decisión sobre su tratamiento —corrección, exclusión o inclusión con peso reducido— debe documentarse explícitamente.

3.4.3 Relación entre variables

El análisis de la relación entre la variable dependiente y las covariables auxiliares permite evaluar la pertinencia predictiva de cada fuente de información y orientar las decisiones de especificación del modelo. Dado que el modelo desarrollado en este libro tiene un propósito predictivo y no explicativo, este análisis no busca establecer relaciones causales ni interpretar el efecto individual de cada covariable sobre la población, sino identificar patrones que puedan mejorar la capacidad de predicción del modelo en los segmentos con información censal incompleta.

Correlación con los conteos. La correlación de Pearson entre $\log(Y_i + 1)$ y cada covariable estandarizada $\tilde{x}_{i,k}$ proporciona una medida lineal de la asociación bivariada. Covariables con correlación superior a 0.5 en valor absoluto suelen tener valor predictivo relevante; covariables con correlación inferior a 0.1 pueden ser candidatas a exclusión del modelo.

Diagramas de dispersión. La representación gráfica de $\log(Y_i + 1)$ contra cada covariable permite detectar relaciones no lineales, patrones de heteroscedasticidad y grupos de segmentos con comportamiento diferenciado. La adición de una curva de suavizado no paramétrico (LOESS) facilita la identificación de estructuras no lineales que podrían requerir transformaciones adicionales de las covariables.

Correlación entre covariables. La matriz de correlación entre las covariables auxiliares permite identificar pares con alta colinealidad. Correlaciones superiores a 0.85 en valor absoluto indican que dos covariables aportan información casi redundante. Los factores de inflación de varianza (VIF) son una herramienta complementaria para el diagnóstico de multicolinealidad:

$$\text{VIF}_k = \frac{1}{1 - R_k^2}$$

donde R_k^2 es el coeficiente de determinación obtenido al regresar la covariable k sobre el resto de covariables. Valores de $\text{VIF}_k > 10$ son indicativos de multicolinealidad problemática.

El Código 3.3 calcula la matriz de correlación y los factores de inflación de varianza.

Código 3.3 (Correlación y factores de inflación de varianza).

```

cor_mat <- cor(cbind(log_Y = log(Y + 1), covariables_std),
               method = "pearson")


modelo_ols <- lm(log(Y + 1) ~ ., data = as.data.frame(covariables_std))
tabla_vif <- tibble(
  covariable = names(car::vif(modelo_ols)),
  VIF        = car::vif(modelo_ols)
)

```

Cuadro 3.2. Factores de inflación de varianza (VIF) de las covariables auxiliares

Covariable	VIF
luminosidad	1.01
area_construida	1.01
dist_urbano	1.00

La Tabla 3.2 reporta el VIF de cada covariable. El valor máximo observado es 1.01, muy por debajo del umbral de 10, por lo que no se evidencia multicolinealidad problemática entre las covariables auxiliares.

**Figura 3.3.** Matriz de correlación entre el conteo poblacional (log) y las covariables auxiliares

La Figura 3.3 muestra la matriz de correlación entre $\log(Y_i + 1)$ y las covariables estandarizadas, en una escala divergente (rojo = correlación negativa, azul = correlación positiva) que facilita distinguir la dirección y magnitud de cada asociación de un vistazo.

En un modelo de propósito predictivo, la presencia de correlaciones elevadas entre la variable dependiente y las covariables no constituye por sí sola un criterio suficiente para seleccionar o descartar predictores, ni una correlación baja implica necesariamente ausencia de valor predictivo una vez consideradas las demás covariables. De igual forma, la multicolinealidad detectada mediante el VIF no necesariamente deteriora la capacidad predictiva del modelo, especialmente en el enfoque bayesiano adoptado en este libro, donde la regularización inducida por las distribuciones a priori contribuye a estabilizar las estimaciones ante covariables correlacionadas. Por esta razón, los diagnósticos de esta sección deben interpretarse como herramientas para comprender la estructura de los datos y detectar redundancias, y no como reglas automáticas de inclusión o exclusión de covariables.

La documentación sistemática de los resultados del diagnóstico exploratorio es un insumo esencial para la especificación del modelo. Las decisiones sobre transformaciones, exclusión de covariables, tratamiento de outliers y estratificación del análisis deben fundamentarse en este diagnóstico y quedar registradas para garantizar la reproducibilidad de las estimaciones finales.

Modelo para Conteos Poblacionales

Los capítulos precedentes han establecido el marco conceptual de la estimación subnacional, identificado las fuentes de información disponibles y detallado el proceso de construcción de los insumos analíticos. Sobre esta base, el presente capítulo introduce la especificación formal del modelo estadístico que integra dichos elementos bajo un esquema probabilístico coherente, orientado a estimar los conteos de población en segmentos censales con cobertura parcial o incompleta.

La formulación adoptada debe satisfacer los requerimientos establecidos en capítulos anteriores: representar adecuadamente la naturaleza discreta y no negativa de los conteos, incorporar información auxiliar de fuentes heterogéneas, producir estimaciones en dominios sin cobertura directa y cuantificar explícitamente la incertidumbre de los resultados. Frente a estos requerimientos, un modelo de Poisson simple resulta insuficiente cuando los datos exhiben sobredispersión o cuando se dispone de información de referencia sobre el número de estructuras habitacionales en cada segmento. La extensión log-normal del modelo de Poisson, articulada con una estructura jerárquica de efectos aleatorios, responde a estas limitaciones de manera estadísticamente coherente.

El modelo propuesto opera en dos niveles. En el primer nivel, la densidad poblacional —definida como el número de personas por estructura habitacional— se representa mediante una distribución log-normal cuyo parámetro de localización es función lineal de covariables auxiliares y efectos aleatorios territoriales. En el segundo nivel, los conteos de población observados se modelan como realizaciones de una distribución de Poisson cuyo parámetro de intensidad resulta del producto entre la densidad estimada y el número de estructuras en cada segmento. Esta arquitectura de dos etapas constituye el modelo Poisson-lognormal y provee un mecanismo natural de control de la sobredispersión mientras mantiene la interpretabilidad de los parámetros (Bryant and Graham, 2013; Mercer et al., 2015).

La estructura del capítulo se organiza en dos secciones principales. La primera presenta la especificación probabilística completa del modelo: definición formal, función de verosimilitud, distribuciones previas, distribución posterior e interpretación de parámetros. La segunda describe en detalle los componentes del modelo: efectos fijos, efectos aleatorios, mecanismos de interacción y elementos adicionales como el offset y la sobredispersión.

4.1 Modelo Poisson-lognormal

Esta sección desarrolla la especificación probabilística completa del modelo Poisson-lognormal introducido anteriormente. Se parte de la definición formal de sus componentes observados y latentes, se deriva la función de verosimilitud conjunta que los articula, se establecen las distribuciones previas de cada parámetro estructural y se caracteriza la distribución posterior resultante. El recorrido cierra con la interpretación sustantiva de los parámetros estimados, de modo que la formulación matemática quede conectada con su lectura demográfica.

4.1.1 Definición formal

Sea $\mathcal{S} = \{1, \dots, D\}$ el conjunto de todos los segmentos censales del país, donde $D = |\mathcal{S}|$ representa el número total de segmentos. En este capítulo se utiliza la notación D para el número de segmentos, en reemplazo de la notación I empleada en los Capítulos 1 y 3, con el propósito de mantener consistencia con la implementación computacional presentada en el Capítulo 5.1.3. En consecuencia, se utilizarán las cantidades D_{obs} y D_{tot} para denotar, respectivamente, el número de segmentos observados y el número total de segmentos considerados en el análisis.

Para cada segmento censal $i \in \mathcal{S}$ se consideran dos cantidades fundamentales. La primera corresponde al conteo de población observado, denotado por Y_i , el cual únicamente está disponible para los segmentos que alcanzaron cobertura efectiva durante el operativo censal. La segunda corresponde al número de estructuras habitacionales, denotado por V_i , disponible para todos los segmentos del país. Esta variable proviene del pre-conteo operativo descrito en el Capítulo 2 o, cuando este no se encuentra disponible, puede derivarse de fuentes auxiliares basadas en imágenes satelitales y estimaciones de área construida.

El objetivo del modelo consiste en describir la relación entre ambas cantidades mediante una tasa promedio de ocupación poblacional por estructura habitacional. Esta razón se denota por

$$\delta_i = \frac{N_i}{V_i},$$

donde N_i representa la población verdadera del segmento i . La notación δ_i se adopta para evitar confusión con la densidad poblacional por unidad de área,

$$DP_i = \frac{N_i}{A_i},$$

introducida en el Capítulo 1, la cual responde a un concepto diferente. Mientras DP_i mide el número de personas por unidad de superficie, δ_i representa el número esperado de personas por estructura habitacional y constituye el parámetro central de los modelos desarrollados en este capítulo. Nótese además que DP_i no guarda relación alguna con la cardinalidad $D = |\mathcal{S}|$ definida al inicio de esta sección: una es una medida de densidad por segmento, la otra es el número total de segmentos del país.

4.1.2 Función de verosimilitud

La inferencia del modelo se basa exclusivamente en la información disponible para los segmentos censales observados durante el operativo de campo. Sea

$$\mathcal{S}_{obs} \subseteq \mathcal{S}$$

el conjunto de segmentos con cobertura efectiva, para los cuales se dispone simultáneamente del conteo de población observado Y_i y del número de estructuras habitacionales V_i . Los segmentos no observados no aportan información directa a la verosimilitud, puesto que el conteo poblacional es desconocido. Su estimación se realiza posteriormente mediante la distribución predictiva posterior.

En cada segmento observado, el modelo supone que el conteo poblacional se genera mediante un proceso de Poisson cuya intensidad depende de una densidad poblacional latente por estructura habitacional,

$$Y_i \mid \delta_i, V_i \sim \text{Poisson}(\delta_i V_i),$$

donde δ_i representa el número esperado de personas por estructura habitacional. Esta cantidad no es observable y constituye el parámetro fundamental del modelo, ya que captura la heterogeneidad existente entre segmentos censales con características similares.

A diferencia del modelo Poisson clásico, donde la intensidad es un parámetro fijo, el modelo Poisson-lognormal considera que cada δ_i es una realización de una distribución log-normal,

$$\delta_i \mid \mu_i, \sigma \sim \text{LogNormal}(\mu_i, \sigma),$$

de manera que la variabilidad entre segmentos queda incorporada explícitamente en la estructura probabilística del modelo. El parámetro de localización

$$\mu_i = \mathbf{x}_i^\top \beta + \mathbf{z}_i^\top \gamma$$

resume la contribución de las variables auxiliares disponibles a través de los efectos fijos β y el ajuste territorial no explicado por dichas covariables a través de los efectos aleatorios γ , mientras que σ cuantifica la variabilidad residual entre segmentos una vez explicados ambos efectos.

Bajo esta formulación jerárquica, la información observada se encuentra completamente determinada por dos componentes probabilísticos: el modelo de generación de los conteos y el modelo de variación de las densidades latentes. Asumiendo independencia condicional entre segmentos dado el conjunto de parámetros estructurales

$$\theta = (\beta, \gamma, \sigma, \sigma_U),$$

la distribución conjunta factoriza como

$$p(\mathbf{Y}_{obs}, \delta \mid \theta) = \prod_{i \in \mathcal{S}_{obs}} p(Y_i \mid \delta_i, V_i) \cdot p(\delta_i \mid \mu_i, \sigma),$$

donde $\mathbf{Y}_{obs} = \{Y_i : i \in \mathcal{S}_{obs}\}$ denota el vector de conteos observados y $\delta = \{\delta_i : i \in \mathcal{S}_{obs}\}$ el conjunto de densidades latentes asociadas a dichos segmentos.

Sustituyendo las expresiones funcionales de las distribuciones Poisson y log-normal se obtiene

$$p(\mathbf{Y}_{obs}, \delta \mid \theta) = \prod_{i \in \mathcal{S}_{obs}} \frac{e^{-\delta_i V_i} (\delta_i V_i)^{Y_i}}{Y_i!} \cdot \frac{1}{\delta_i \sigma \sqrt{2\pi}} \exp\left(-\frac{(\log \delta_i - \mu_i)^2}{2\sigma^2}\right).$$

La primera contribución corresponde al mecanismo de generación de los conteos observados, mientras que la segunda describe la distribución de las densidades poblacionales entre segmentos. La función de verosimilitud refleja, por tanto, el compromiso entre reproducir los conteos efectivamente observados y mantener valores plausibles para las densidades de acuerdo con el modelo estructural.

Trabajar sobre la escala logarítmica simplifica considerablemente la inferencia, ya que transforma el producto de densidades en una suma de contribuciones individuales. Partiendo de la verosimilitud conjunta de la Ecuación (4.1.2), se aplica el logaritmo natural a ambos lados,

$$\log p(\mathbf{Y}_{obs}, \delta \mid \theta) = \log \left[\prod_{i \in \mathcal{S}_{obs}} \frac{e^{-\delta_i V_i} (\delta_i V_i)^{Y_i}}{Y_i!} \cdot \frac{1}{\delta_i \sigma \sqrt{2\pi}} \exp\left(-\frac{(\log \delta_i - \mu_i)^2}{2\sigma^2}\right) \right].$$

Utilizando la propiedad

$$\log \left(\prod_i a_i \right) = \sum_i \log(a_i),$$

la expresión anterior puede escribirse como

$$\log p(\mathbf{Y}_{obs}, \delta \mid \theta) = \sum_{i \in \mathcal{S}_{obs}} \log \left[\frac{e^{-\delta_i V_i} (\delta_i V_i)^{Y_i}}{Y_i!} \cdot \frac{1}{\delta_i \sigma \sqrt{2\pi}} \exp\left(-\frac{(\log \delta_i - \mu_i)^2}{2\sigma^2}\right) \right].$$

Posteriormente, el logaritmo de un producto se separa en la suma de los logaritmos,

$$\log p(\mathbf{Y}_{obs}, \delta \mid \theta) = \sum_{i \in \mathcal{S}_{obs}} \left[\log \left(\frac{e^{-\delta_i V_i} (\delta_i V_i)^{Y_i}}{Y_i!} \right) + \log \left(\frac{1}{\delta_i \sigma \sqrt{2\pi}} \exp\left(-\frac{(\log \delta_i - \mu_i)^2}{2\sigma^2}\right) \right) \right].$$

Ahora se desarrolla cada uno de estos términos por separado.

Para la componente Poisson,

$$\begin{aligned} \log \left(\frac{e^{-\delta_i V_i} (\delta_i V_i)^{Y_i}}{Y_i!} \right) &= \log(e^{-\delta_i V_i}) + \log((\delta_i V_i)^{Y_i}) - \log(Y_i!) \\ &= -\delta_i V_i + Y_i \log(\delta_i V_i) - \log(Y_i!). \end{aligned}$$

Para la componente log-normal,

$$\begin{aligned} \log \left(\frac{1}{\delta_i \sigma \sqrt{2\pi}} \exp\left(-\frac{(\log \delta_i - \mu_i)^2}{2\sigma^2}\right) \right) &= -\log(\delta_i) - \log(\sigma) - \frac{1}{2} \log(2\pi) \\ &\quad - \frac{(\log \delta_i - \mu_i)^2}{2\sigma^2}. \end{aligned}$$

Sustituyendo ambos desarrollos en la expresión anterior se obtiene

$$\begin{aligned} \log p(\mathbf{Y}_{obs}, \delta \mid \theta) &= \sum_{i \in \mathcal{S}_{obs}} \left[Y_i \log(\delta_i V_i) - \delta_i V_i - \log(Y_i!) \right. \\ &\quad \left. - \log(\delta_i) - \log(\sigma) - \frac{1}{2} \log(2\pi) \right. \\ &\quad \left. - \frac{(\log \delta_i - \mu_i)^2}{2\sigma^2} \right]. \end{aligned}$$

Finalmente, dado que los términos

$$\log(Y_i!) \quad \text{y} \quad \frac{1}{2} \log(2\pi)$$

no dependen de ninguno de los parámetros del modelo, pueden agruparse dentro de una constante aditiva. Como la inferencia bayesiana y la optimización dependen únicamente de cantidades proporcionales a la verosimilitud, estas constantes pueden omitirse, obteniéndose la log-verosimilitud

$$\log p(\mathbf{Y}_{obs}, \delta \mid \theta) = \sum_{i \in \mathcal{S}_{obs}} \left[Y_i \log(\delta_i V_i) - \delta_i V_i - \log(\delta_i) - \frac{(\log \delta_i - \mu_i)^2}{2\sigma^2} - \log(\sigma) \right].$$

Cada uno de estos términos posee una interpretación estadística directa. El componente

$$Y_i \log(\delta_i V_i) - \delta_i V_i$$

proviene de la distribución de Poisson y mide el grado de concordancia entre la intensidad propuesta por el modelo y el conteo efectivamente observado. El término cuadrático

$$-\frac{(\log \delta_i - \mu_i)^2}{2\sigma^2}$$

corresponde a la penalización inducida por la distribución log-normal y favorece densidades compatibles con la información auxiliar incorporada mediante el predictor lineal. Finalmente, el término

$$-\log \delta_i$$

es consecuencia del jacobiano asociado al cambio de variable entre la escala logarítmica y la escala original de las densidades, garantizando que la distribución log-normal quede correctamente normalizada.

Desde una perspectiva bayesiana, esta función constituye el mecanismo mediante el cual la información observada actualiza el conocimiento previo sobre las densidades poblacionales. Los valores de δ_i que maximizan la contribución Poisson pueden diferir de aquellos sugeridos por la estructura log-normal; la estimación posterior resulta precisamente del equilibrio entre ambas fuentes de información.

Una característica fundamental del modelo Poisson-lognormal es que la distribución marginal de los conteos ya no pertenece a la familia Poisson. Dado que la intensidad δ_i es una variable aleatoria, la distribución marginal de Y_i se obtiene integrando respecto a la distribución de las densidades latentes,

$$p(Y_i \mid \theta) = \int_0^\infty p(Y_i \mid \delta_i, V_i) \cdot p(\delta_i \mid \mu_i, \sigma) d\delta_i.$$

Sustituyendo las distribuciones del modelo,

$$Y_i \mid \delta_i \sim \text{Poisson}(\delta_i V_i),$$

y

$$\delta_i \sim \text{LogNormal}(\mu_i, \sigma),$$

se obtiene

$$p(Y_i | \theta) = \int_0^\infty \frac{e^{-\delta_i V_i} (\delta_i V_i)^{Y_i}}{Y_i!} \cdot \frac{1}{\delta_i \sigma \sqrt{2\pi}} \exp\left(-\frac{(\log \delta_i - \mu_i)^2}{2\sigma^2}\right) d\delta_i.$$

Esta integral no posee una solución analítica cerrada, por lo que la distribución marginal no pertenece a una familia paramétrica simple. Sin embargo, sus primeros momentos —consistentes con los reportados para la mezcla Poisson-lognormal en modelos bayesianos de estimación subnacional (Bryant and Graham, 2013; Mercer et al., 2015)— pueden obtenerse utilizando las propiedades de la esperanza y la varianza condicionales, sin necesidad de resolver la integral directamente.

La media marginal se obtiene aplicando la ley de la esperanza total,

$$\mathbb{E}[Y_i] = \mathbb{E}[\mathbb{E}(Y_i | \delta_i)].$$

Como $Y_i | \delta_i \sim \text{Poisson}(\delta_i V_i)$, se tiene $\mathbb{E}(Y_i | \delta_i) = \delta_i V_i$, de modo que

$$\mathbb{E}[Y_i] = \mathbb{E}[\delta_i V_i] = V_i \mathbb{E}[\delta_i],$$

dado que V_i es conocido. Y puesto que $\delta_i \sim \text{LogNormal}(\mu_i, \sigma)$, su primer momento es $\mathbb{E}[\delta_i] = \exp\left(\mu_i + \frac{\sigma^2}{2}\right)$, con lo que la media marginal del conteo queda determinada por

$$\mathbb{E}[Y_i] = V_i \exp\left(\mu_i + \frac{\sigma^2}{2}\right).$$

La varianza marginal se deriva de manera análoga, apoyándose esta vez en la ley de la varianza total,

$$\text{Var}(Y_i) = \mathbb{E}[\text{Var}(Y_i | \delta_i)] + \text{Var}[\mathbb{E}(Y_i | \delta_i)],$$

cuyos dos términos conviene desarrollar por separado. El primero recoge la variabilidad propia del proceso Poisson: dado que su varianza condicional coincide con su media, $\text{Var}(Y_i | \delta_i) = \delta_i V_i$, y reutilizando el primer momento de la log-normal calculado arriba,

$$\mathbb{E}[\text{Var}(Y_i | \delta_i)] = V_i \mathbb{E}[\delta_i] = V_i \exp\left(\mu_i + \frac{\sigma^2}{2}\right),$$

expresión que coincide exactamente con $\mathbb{E}[Y_i]$. El segundo término recoge, en cambio, la variabilidad que aporta la propia densidad latente: como $\mathbb{E}(Y_i | \delta_i) = \delta_i V_i$ y V_i es constante,

$$\text{Var}[\mathbb{E}(Y_i | \delta_i)] = \text{Var}(\delta_i V_i) = V_i^2 \text{Var}(\delta_i),$$

y dado que la varianza de una log-normal es $\text{Var}(\delta_i) = e^{2\mu_i + \sigma^2} (e^{\sigma^2} - 1)$, se sigue que

$$\text{Var}[\mathbb{E}(Y_i | \delta_i)] = V_i^2 e^{2\mu_i + \sigma^2} (e^{\sigma^2} - 1).$$

Sustituyendo ambos términos en la ley de la varianza total,

$$\text{Var}(Y_i) = \mathbb{E}[Y_i] + V_i^2 e^{2\mu_i + \sigma^2} (e^{\sigma^2} - 1).$$

La expresión anterior muestra que la varianza marginal está compuesta por dos fuentes de variabilidad. El primer término, $\mathbb{E}[Y_i]$, corresponde a la variabilidad inherente del proceso Poisson. El segundo, $V_i^2 e^{2\mu_i + \sigma^2} (e^{\sigma^2} - 1)$, representa la variabilidad adicional introducida por la heterogeneidad de las densidades poblacionales entre segmentos. Este componente desaparece únicamente cuando $\sigma = 0$, caso en el cual la distribución log-normal degenera en una constante y el modelo se reduce exactamente a un modelo Poisson clásico.

Dado que $\text{Var}(Y_i) > \mathbb{E}[Y_i]$ siempre que $\sigma > 0$, el modelo incorpora de manera natural sobredispersión respecto a la distribución Poisson clásica, con el grado de sobredispersión controlado directamente por σ : cuando $\sigma \rightarrow 0$, la distribución log-normal degenera en un punto y el modelo converge al modelo Poisson estándar; a medida que σ aumenta, la heterogeneidad entre segmentos se incrementa y la distribución marginal de los conteos presenta colas más pesadas y una varianza considerablemente mayor que la media. Esta propiedad resulta especialmente adecuada para datos censales, donde las diferencias locales en composición demográfica, ocupación de viviendas y patrones de asentamiento producen variabilidad que difícilmente puede ser explicada bajo el supuesto de equidispersión propio del modelo Poisson clásico (Gelman et al., 2013).

4.1.3 Distribuciones previas

La especificación bayesiana del modelo requiere asignar distribuciones previas a todos los parámetros desconocidos. En el contexto del modelo Poisson-lognormal, el conjunto de parámetros a los que se asignan distribuciones previas incluye los coeficientes de efectos fijos β , los coeficientes de efectos aleatorios γ , el parámetro de escala de la densidad σ y el hiperparámetro de variabilidad de los efectos aleatorios σ_U .

El enfoque adoptado en este libro utiliza distribuciones previas no informativas: normales centradas en cero con varianza grande —normales planas— para los parámetros definidos sobre toda la recta real (β , σ_U), de modo que sea la información contenida en los datos, y no la previa, la que domine la distribución posterior. Bajo este enfoque, las distribuciones previas no imponen restricciones de signo ni concentran probabilidad sobre valores específicos, evitando introducir información sustantiva ajena a los datos.

Para los coeficientes de efectos fijos se adopta una distribución normal centrada en cero:

$$\beta_k \sim \mathcal{N}(0, \tau_\beta^2), \quad k = 1, \dots, P$$

donde τ_β^2 es un hiperparámetro de escala fijado en un valor grande, de modo que la distribución resulte esencialmente plana en el rango plausible de las covariables —previamente estandarizadas—, sin dejar de ser una distribución propia. La centrada en cero refleja la ausencia de conocimiento previo sobre la dirección del efecto de cada covariable, mientras que τ_β^2 grande garantiza que dicha información sea mínima.

Para los coeficientes de efectos aleatorios se adopta una distribución normal jerárquica con varianza controlada por el hiperparámetro σ_U :

$$\gamma_j \sim \mathcal{N}(0, \sigma_U^2), \quad j = 1, \dots, Q$$

Esta especificación introduce una estructura de encogimiento sobre los efectos aleatorios: territorios con información escasa son atraídos hacia el promedio global capturado por los efectos fijos, mientras que territorios con información abundante y patrón sistemáticamente distinto pueden mantener efectos locales de mayor magnitud. El grado de encogimiento está regulado por σ_U , que a su vez es un parámetro desconocido al que se asigna una distribución previa.

Para el hiperparámetro de variabilidad de los efectos aleatorios se adopta, igualmente, una normal plana truncada a valores positivos:

$$\sigma_U \sim \mathcal{N}^+(0, \tau_U^2)$$

con τ_U^2 grande. Esta elección permite que el modelo aprenda la magnitud de la variabilidad territorial a partir de los datos, sin imponer un valor fijo ni una restricción informativa sobre su escala.

Para el parámetro de escala de la densidad σ se mantiene, en cambio, una distribución de Cauchy positiva:

$$\sigma \sim \text{Cauchy}^+(0, \tau_\sigma)$$

con τ_σ grande. A diferencia de β y σ_U , para σ se prefiere la Cauchy positiva sobre la normal plana truncada: sus colas más pesadas evitan concentrar probabilidad en valores pequeños de la escala, lo que la vuelve más robusta como previa no informativa para un parámetro de dispersión, especialmente en contextos con marcada heterogeneidad territorial y cobertura censal diferencial.

4.1.4 Distribución posterior

La inferencia bayesiana combina la información aportada por los datos observados con el conocimiento previo especificado para los parámetros del modelo. Formalmente, el teorema de Bayes establece que la distribución posterior conjunta sobre los parámetros estructurales θ y las densidades latentes δ es

$$p(\theta, \delta \mid \mathbf{Y}_{obs}) = \frac{p(\mathbf{Y}_{obs}, \delta \mid \theta) \cdot p(\theta)}{p(\mathbf{Y}_{obs})},$$

donde $p(\mathbf{Y}_{obs}, \delta \mid \theta)$ corresponde a la verosimilitud conjunta desarrollada en la sección anterior, $p(\theta)$ representa la distribución previa conjunta de todos los parámetros estructurales, y $p(\mathbf{Y}_{obs})$ es la distribución marginal de los datos, conocida como constante de normalización o evidencia bayesiana. La evidencia se obtiene integrando la distribución conjunta sobre la totalidad del espacio de parámetros y densidades latentes,

$$p(\mathbf{Y}_{obs}) = \iint p(\mathbf{Y}_{obs}, \delta \mid \theta) \cdot p(\theta) d\delta d\theta,$$

donde la integración comprende simultáneamente los coeficientes de regresión, los efectos aleatorios, las desviaciones estándar y las densidades latentes. En modelos jerárquicos como el Poisson-lognormal esta integral no posee solución analítica cerrada. Sin embargo, dado que la evidencia no depende de θ ni de δ , puede tratarse como una constante de proporcionalidad durante la inferencia, de modo que

$$p(\theta, \delta \mid \mathbf{Y}_{obs}) \propto p(\mathbf{Y}_{obs}, \delta \mid \theta) \cdot p(\theta).$$

Resta expandir la distribución previa conjunta $p(\theta)$. Bajo el supuesto de independencia entre los distintos bloques de parámetros en su distribución previa,

$$p(\theta) = p(\beta) \cdot p(\gamma \mid \sigma_U) \cdot p(\sigma) \cdot p(\sigma_U),$$

donde la dependencia de γ respecto a σ_U refleja precisamente la estructura jerárquica introducida en la sección de distribuciones previas: los efectos aleatorios no son previamente independientes de su propio hiperparámetro de variabilidad. Sustituyendo esta descomposición en la expresión de proporcionalidad se obtiene

$$p(\theta, \delta \mid \mathbf{Y}_{obs}) \propto p(\mathbf{Y}_{obs}, \delta \mid \beta, \gamma, \sigma) \cdot p(\gamma \mid \sigma_U) \cdot p(\beta) \cdot p(\sigma) \cdot p(\sigma_U).$$

Finalmente, reemplazando la verosimilitud y las distribuciones previas por sus formas funcionales específicas, la distribución posterior puede escribirse como

$$\begin{aligned} p(\theta, \delta \mid \mathbf{Y}_{obs}) \propto & \prod_{i \in \mathcal{S}_{obs}} \left[\frac{e^{-\delta_i V_i} (\delta_i V_i)^{Y_i}}{Y_i!} \times \frac{1}{\delta_i \sigma \sqrt{2\pi}} \exp\left(-\frac{(\log \delta_i - \mu_i)^2}{2\sigma^2}\right) \right] \times \\ & \prod_{j=1}^Q \frac{1}{\sigma_U \sqrt{2\pi}} \exp\left(-\frac{\gamma_j^2}{2\sigma_U^2}\right) \times \\ & \prod_{k=1}^P \frac{1}{\tau_\beta \sqrt{2\pi}} \exp\left(-\frac{\beta_k^2}{2\tau_\beta^2}\right) \times \\ & p(\sigma) \times p(\sigma_U) \end{aligned}$$

donde el predictor lineal está dado por

$$\mu_i = \mathbf{x}_i^\top \beta + \mathbf{z}_i^\top \gamma.$$

Sustituyendo esta expresión en la densidad log-normal, la distribución posterior puede escribirse completamente en función de los parámetros del modelo como

$$\begin{aligned} p(\theta, \delta \mid \mathbf{Y}_{obs}) \propto & \prod_{i \in \mathcal{S}_{obs}} \left[\frac{e^{-\delta_i V_i} (\delta_i V_i)^{Y_i}}{Y_i!} \times \frac{1}{\delta_i \sigma \sqrt{2\pi}} \exp\left(-\frac{(\log \delta_i - (\mathbf{x}_i^\top \beta + \mathbf{z}_i^\top \gamma))^2}{2\sigma^2}\right) \right] \times \\ & \prod_{j=1}^Q \frac{1}{\sigma_U \sqrt{2\pi}} \exp\left(-\frac{\gamma_j^2}{2\sigma_U^2}\right) \times \\ & \prod_{k=1}^P \frac{1}{\tau_\beta \sqrt{2\pi}} \exp\left(-\frac{\beta_k^2}{2\tau_\beta^2}\right) \times \\ & p(\sigma) \times p(\sigma_U). \end{aligned}$$

La expresión anterior constituye la distribución posterior conjunta del modelo, y en ella aparecen simultáneamente: la información aportada por los conteos observados a través de la distribución Poisson; la estructura

jerárquica de las densidades latentes a través de la distribución log-normal; y las restricciones introducidas por las distribuciones previas sobre los coeficientes de regresión, los efectos aleatorios y los parámetros de variabilidad.

A diferencia de los modelos conjugados, esta distribución posterior no pertenece a una familia paramétrica conocida: la combinación entre la verosimilitud Poisson y la estructura log-normal rompe la conjugación y hace imposible obtener expresiones analíticas cerradas para las distribuciones marginales de los parámetros. Por esta razón, la inferencia debe realizarse mediante métodos numéricos de simulación.

Una vez obtenida la distribución posterior, el objetivo de la inferencia consiste en generar realizaciones de dicha distribución para aproximar las cantidades de interés. Dado que la distribución posterior del modelo Poisson-lognormal no posee una forma analítica cerrada, este proceso debe realizarse mediante algoritmos de simulación Monte Carlo, cuyo esquema conceptual puede resumirse en los siguientes pasos:

1. Definir las distribuciones previas para β , γ , σ y σ_U .
2. Construir la verosimilitud conjunta $p(\mathbf{Y}_{obs}, \delta \mid \theta)$.
3. Aplicar el teorema de Bayes para obtener la distribución posterior no normalizada, $p(\theta, \delta \mid \mathbf{Y}_{obs}) \propto p(\mathbf{Y}_{obs}, \delta \mid \theta) p(\theta)$.
4. Inicializar los parámetros del modelo y, para cada iteración $t = 1, \dots, T$, generar una muestra conjunta $(\theta^{(t)}, \delta^{(t)}) \sim p(\theta, \delta \mid \mathbf{Y}_{obs})$, almacenando las realizaciones obtenidas.
5. Aproximar las cantidades de interés mediante promedios Monte Carlo.
6. Generar la distribución predictiva posterior para los segmentos sin observación.
7. Agregar las predicciones por segmento para obtener estimaciones de niveles geográficos superiores.

La implementación computacional de este procedimiento, mediante el algoritmo de Monte Carlo Hamiltoniano en Stan, se desarrolla en el capítulo siguiente. A continuación se detallan las expresiones correspondientes a los pasos 4 a 7.

Las muestras generadas en la iteración t ,

$$(\theta^{(t)}, \delta^{(t)}), \quad t = 1, \dots, T,$$

permiten aproximar cualquier funcional de la distribución posterior mediante integración Monte Carlo. En particular, la esperanza posterior de la densidad poblacional para el segmento i se estima como

$$\hat{\delta}_i = \mathbb{E}[\delta_i \mid \mathbf{Y}_{obs}] \approx \frac{1}{T} \sum_{t=1}^T \delta_i^{(t)}.$$

Una vez obtenidas las muestras posteriores, para cada segmento no observado $i \in \mathcal{S} \setminus \mathcal{S}_{obs}$ se generan realizaciones de la distribución predictiva posterior,

$$\tilde{\delta}_i^{(t)} \sim \text{LogNormal}(\mu_i^{(t)}, \sigma^{(t)}), \quad \tilde{Y}_i^{(t)} \sim \text{Poisson}(\tilde{\delta}_i^{(t)} \cdot V_i),$$

donde

$$\mu_i^{(t)} = \mathbf{x}_i^\top \beta^{(t)} + \mathbf{z}_i^\top \gamma^{(t)}.$$

En la práctica, la densidad simulada $\hat{\delta}_i^{(t)}$ se trunca superiormente antes de generar el conteo predicho, según la restricción descrita en la Sección 4.2.4. Finalmente, las predicciones de los segmentos se agregan para estimar la población de municipios, departamentos o del total nacional, propagando automáticamente la incertidumbre posterior del modelo.

4.1.5 Interpretación de parámetros

Cada parámetro del modelo describe un aspecto diferente de la distribución de la población entre los segmentos censales. En conjunto, permiten explicar cómo varía el número esperado de personas por estructura habitacional y cuantificar la incertidumbre asociada a esa variación.

El predictor lineal, introducido en la Sección 4.1.2,

$$\mu_i = \mathbf{x}_i^\top \beta + \mathbf{z}_i^\top \gamma,$$

representa el nivel esperado de ocupación del segmento i antes de incorporar la variabilidad propia del modelo. Este predictor resume toda la información auxiliar disponible y constituye el punto de partida para estimar la densidad poblacional del segmento.

Los coeficientes de efectos fijos, β —descritos con mayor detalle en la Sección 4.2.1—, cuantifican la contribución de cada variable auxiliar a la densidad poblacional. En particular, el coeficiente β_k mide cómo cambia la ocupación esperada de un segmento cuando la covariable correspondiente aumenta una desviación estándar, manteniendo constantes las demás variables del modelo. Debido a que la relación se establece sobre una escala logarítmica, el efecto suele interpretarse mediante su exponencial,

$$\exp(\beta_k),$$

que corresponde al factor por el cual cambia la densidad mediana de personas por estructura habitacional. Por ejemplo, un valor de $\exp(\beta_k) = 1.10$ indica que, al aumentar una desviación estándar la covariable k , la densidad esperada aumenta aproximadamente un 10 %; por el contrario, un valor de 0.90 indica una reducción cercana al 10 %.

Los efectos aleatorios, representados por γ —tratados con mayor detalle en la Sección 4.2.2—, capturan diferencias sistemáticas entre unidades territoriales que no pueden ser explicadas por las variables auxiliares. En otras palabras, permiten que territorios con características similares presenten densidades poblacionales distintas debido a factores no observados, como patrones de urbanización, condiciones geográficas o dinámicas demográficas locales. Cada efecto aleatorio actúa como un ajuste específico para la unidad territorial correspondiente y desplaza hacia arriba o hacia abajo la densidad estimada de todos los segmentos pertenecientes a esa unidad.

El parámetro σ mide la variabilidad de las densidades poblacionales entre segmentos después de considerar tanto las covariables como los efectos aleatorios. Valores pequeños de σ indican que segmentos con características similares presentan densidades relativamente homogéneas, mientras que valores grandes reflejan una mayor heterogeneidad residual y, por tanto, una mayor incertidumbre en las predicciones individuales.

Por su parte, el hiperparámetro σ_U describe el grado de variabilidad existente entre las unidades territoriales consideradas en el modelo. Si σ_U es cercano a cero, los territorios presentan comportamientos muy similares una vez controladas las covariables. En cambio, valores elevados indican que existen diferencias importantes

entre territorios que no son explicadas únicamente por la información auxiliar disponible. Las distribuciones previas de σ y σ_U se describen en la Sección 4.1.3.

Finalmente, el parámetro de mayor interés es la densidad poblacional latente, δ_i —definida en la Sección 4.1.1—, la cual representa el número esperado de personas por estructura habitacional en el segmento censal i . Esta cantidad resume la intensidad de ocupación del segmento y constituye la base para predecir la población cuando únicamente se conoce el número de estructuras habitacionales. Su distribución posterior, caracterizada en la Sección 4.1.4, no solo proporciona una estimación puntual, sino también un intervalo de valores plausibles que refleja la incertidumbre inherente al proceso de estimación.

En conjunto, los parámetros del modelo cumplen funciones complementarias: los efectos fijos explican cómo las características observables influyen sobre la ocupación de los segmentos; los efectos aleatorios representan diferencias territoriales no observadas; los parámetros de dispersión cuantifican la variabilidad residual entre segmentos y territorios; y la densidad latente δ_i integra toda esta información para producir las estimaciones finales de población.

4.2 Componentes del modelo

La especificación completa del modelo Poisson-lognormal requiere detallar la construcción de cada uno de sus componentes estructurales. El predictor lineal dado en la Sección 4.1.2 integra dos tipos de información: efectos sistemáticos capturados por las covariables auxiliares a través de los efectos fijos, y ajustes territoriales no explicados por dichas covariables a través de los efectos aleatorios. Estos componentes interactúan con el offset de estructuras V_i y con el mecanismo de sobredispersión log-normal para producir estimaciones coherentes en el conjunto completo de segmentos.

4.2.1 Efectos fijos

Los efectos fijos del modelo capturan la relación sistemática entre las covariables auxiliares y la densidad poblacional. Sea $\mathbf{X}_{obs}$ la matriz de covariables de dimensión $D_{obs} \times P$, donde la fila i corresponde al vector $\mathbf{x}_i^T$ del segmento observado i y las columnas corresponden a las P covariables seleccionadas tras el proceso de preparación de insumos descrito en el capítulo anterior. Análogamente, $\mathbf{X}_{tot}$ es la matriz de covariables de dimensión $D \times P$ que contiene los vectores de covariables para la totalidad de los segmentos del país, incluyendo aquellos no observados en el operativo censal.

El predictor lineal de efectos fijos para el segmento i es:

$$(\mathbf{X}_{obs}\boldsymbol{\beta})_i = \sum_{k=1}^P \beta_k \tilde{x}_{i,k}$$

donde $\tilde{x}_{i,k}$ denota la versión estandarizada de la covariable k en el segmento i , construida mediante las transformaciones descritas en el capítulo anterior: estandarización por media y desviación estándar para variables continuas, o normalización al intervalo unitario para proporciones e índices con interpretación intrínseca en $[0, 1]$.

Las covariables incorporadas en $\mathbf{X}_{obs}$ se organizan en las dos categorías descritas en el capítulo de integración de fuentes. Las variables socioeconómicas incluyen tasas de acceso a servicios públicos —electricidad, agua

potable, internet— y conteos provenientes de registros administrativos como padrones electorales o afiliados a sistemas de salud. Las variables espaciales de origen satelital incluyen la luminosidad nocturna media del segmento L_i , el área construida derivada del producto Global Human Settlement Layer, la proporción de distintas categorías de cobertura de suelo, la pendiente media del terreno y la altitud media sobre el nivel del mar.

Un aspecto crítico en la especificación de los efectos fijos es el tratamiento de la multicolinealidad entre covariables. Dado que muchas de las fuentes auxiliares descritas están correlacionadas entre sí —la luminosidad nocturna y el área construida tienden a ser altas en las mismas zonas urbanas, y el número de registros administrativos crece con la población—, la inclusión simultánea de variables altamente correlacionadas puede dificultar la estimación individual de los coeficientes. En la práctica, esto se aborda principalmente mediante el análisis de correlación y la selección de variables descritos en el Capítulo 3, realizados antes de la estimación. Cabe señalar que las distribuciones previas $\beta_k \sim \mathcal{N}(0, \tau_\beta^2)$ no cumplen aquí un papel regularizador relevante: al fijarse τ_β^2 en un valor grande —precisamente para que la previa sea no informativa—, la estabilización frente a predictores correlacionados debe resolverse mediante el tratamiento de las covariables previo al modelamiento, y no delegarse en la previa.

La estimación del vector β a partir de los datos proporciona información sobre cuáles características del segmento están más fuertemente asociadas con la densidad poblacional. Esta información puede utilizarse para orientar la actualización cartográfica, priorizar la recolección de covariables en futuros operativos censales y validar la consistencia de las fuentes utilizadas con los patrones demográficos observados en el territorio.

4.2.2 Efectos aleatorios

Los efectos aleatorios capturan la variabilidad sistemática entre unidades territoriales de nivel superior que no es explicada por las covariables auxiliares incluidas en los efectos fijos. Esta variabilidad puede deberse a factores institucionales no medidos —diferencias en la capacidad operativa de los equipos censales entre provincias, por ejemplo—, a condiciones locales no capturadas por las fuentes disponibles, o a características territoriales latentes que afectan simultáneamente a múltiples segmentos de una misma unidad.

Sea $\mathbf{Z}_{obs}$ la matriz de indicadores de dimensión $D_{obs} \times Q$, donde Q es el número de unidades territoriales de nivel superior consideradas. El elemento $z_{i,j}$ vale uno si el segmento i pertenece a la unidad territorial j y cero en caso contrario. Análogamente, $\mathbf{Z}_{tot}$ es la matriz de indicadores de dimensión $D \times Q$ para el conjunto completo de segmentos. La contribución de los efectos aleatorios al predictor lineal del segmento i es:

$$(\mathbf{Z}_{obs}\gamma)_i = \sum_{j=1}^Q z_{i,j} \gamma_j = \gamma_{j(i)}$$

donde $j(i)$ denota la unidad territorial a la que pertenece el segmento i . Dado que cada segmento pertenece a exactamente una unidad territorial, la contribución de los efectos aleatorios es simplemente el coeficiente $\gamma_{j(i)}$ correspondiente a su territorio.

La distribución previa jerárquica $\gamma_j \sim \mathcal{N}(0, \sigma_U^2)$ regula el comportamiento de los efectos aleatorios a través del hiperparámetro σ_U . Cuando σ_U es pequeño, el modelo impone que los efectos aleatorios sean cercanos a cero, lo que es equivalente a una especificación sin ajustes territoriales específicos. Cuando σ_U es grande, los efectos aleatorios pueden tomar valores sustanciales, capturando diferencias importantes entre territorios no explicadas por las covariables. La estimación conjunta de σ_U y γ permite que el modelo aprenda automáticamente el grado de heterogeneidad territorial presente en los datos.

Una propiedad fundamental de la estructura jerárquica es el préstamo de fortaleza entre segmentos de un mismo territorio. Los segmentos con escasa información —conteos muy bajos, alta variabilidad en el conteo observado o baja cobertura censal— son estabilizados por la información de los demás segmentos de la misma unidad territorial, a través del efecto aleatorio compartido $\gamma_{j(i)}$. Simultáneamente, los efectos fijos proveen información de todos los segmentos del país para estimar el vector β , que contribuye a la predicción en segmentos con poca o ninguna cobertura censal. Este mecanismo de préstamo de información entre dominios constituye una de las principales ventajas del enfoque jerárquico bayesiano sobre los métodos de estimación directa (Rao and Molina, 2015; Banerjee et al., 2015).

La estructura de efectos aleatorios puede extenderse a múltiples niveles territoriales. En las aplicaciones sobre censos de América Latina y el Caribe desarrolladas en el marco de este libro, los efectos aleatorios se han especificado sobre provincias, departamentos o regiones, que constituyen la unidad administrativa intermedia más relevante para la gestión censal. En países con censos de alta resolución cartográfica y disponibilidad de datos administrativos a nivel de municipio, es posible incorporar efectos aleatorios anidados que capturen simultáneamente variabilidad regional y municipal, a costa de mayor complejidad computacional y mayor exigencia de información.

4.2.3 Interacciones

El predictor lineal en su forma básica representa efectos aditivos y lineales de las covariables sobre el logaritmo de la densidad poblacional. En determinados contextos, la relación entre las covariables y la densidad puede presentar patrones no lineales o interacciones que requieren representación explícita en el modelo.

Las interacciones entre covariables se incorporan mediante la inclusión de productos entre variables estandarizadas en la matriz $\mathbf{X}_{obs}$. Si $\tilde{x}_{i,k}$ y $\tilde{x}_{i,l}$ son dos covariables estandarizadas, su término de interacción se define como:

$$\tilde{x}_{i,kl} = \tilde{x}_{i,k} \cdot \tilde{x}_{i,l}$$

El predictor lineal extendido con interacciones incluye un coeficiente adicional β_{kl} con distribución previa $\beta_{kl} \sim \mathcal{N}(0, \tau_{\beta}^2)$, tratando el término de interacción de manera simétrica a los efectos principales. Esta formulación es apropiada cuando las covariables están estandarizadas, ya que garantiza que los términos de interacción operen en una escala comparable a los efectos principales.

En el contexto de la estimación de conteos censales, las interacciones de mayor relevancia sustantiva suelen involucrar combinaciones entre variables de uso del suelo y clasificaciones territoriales —la interacción entre luminosidad nocturna y la condición urbano-rural puede capturar diferencias en el patrón de ocupación habitacional según el tipo de asentamiento— o entre variables socioeconómicas y espaciales, como la relación entre el acceso a servicios públicos y la distancia a centros urbanos, cuya dirección puede variar sistemáticamente entre contextos urbanos y rurales.

Las interacciones entre efectos fijos y efectos aleatorios, conocidas como efectos de pendiente aleatoria, permiten que la relación de una covariable con la densidad varíe entre territorios. En esta especificación extendida, el coeficiente de la covariable k en el territorio j es $\beta_k + v_{j,k}$, donde $v_{j,k}$ representa la desviación específica del territorio respecto al efecto promedio nacional. Esta extensión aumenta la flexibilidad del modelo a costa de mayor dimensionalidad y puede resultar útil cuando se sospecha que el efecto de un predictor varía sistemáticamente entre regiones del país.

La inclusión de términos de interacción debe equilibrar la mejora en el ajuste del modelo con el riesgo de sobreajuste en datos de alta dimensión. En la práctica, la selección de interacciones relevantes se evalúa mediante criterios de comparación de modelos como el criterio LOO-CV o el WAIC (Vehtari et al., 2017; Watanabe, 2010), cuyas bases se desarrollan en el capítulo dedicado al diagnóstico y validación.

4.2.4 Sobredispersión y offset

El diseño del modelo Poisson-lognormal incorpora dos elementos adicionales que merecen consideración específica: el uso del número de estructuras como offset del proceso de conteo, y el mecanismo de control de sobredispersión a través de la distribución log-normal.

El offset de estructuras habitacionales. El número de estructuras habitacionales V_i desempeña el papel de offset en el modelo: escala la intensidad del proceso de Poisson de manera proporcional al tamaño del segmento en términos de unidades habitacionales. A partir de la definición $\lambda_i = \delta_i V_i$, la intensidad puede escribirse en escala logarítmica como

$$\log(\lambda_i) = \log(\delta_i) + \log(V_i).$$

Dado que $\log(\delta_i) = \mu_i + \varepsilon_i$, con $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ (Sección 4.1.2), se obtiene

$$\log(\lambda_i) = \mu_i + \varepsilon_i + \log(V_i).$$

El término $\log(V_i)$ actúa como offset con coeficiente fijado en uno, lo que equivale a modelar la densidad —y no el conteo total— como función de las covariables. Esta parametrización es estadísticamente más apropiada que incluir $\log(V_i)$ como covariable con coeficiente libre, ya que el número de estructuras debe considerarse una referencia de escala del proceso y no un predictor ordinario del logaritmo de la densidad.

Esta parametrización posee además una interpretación demográfica directa: dos segmentos con igual densidad poblacional pero distinto número de estructuras tendrán conteos esperados diferentes únicamente por esa diferencia en el número de estructuras. El modelo explica, en consecuencia, la ocupación promedio por estructura habitacional, y utiliza V_i para escalar dicha ocupación hasta el nivel del conteo total del segmento.

La fuente del offset puede variar según la disponibilidad de información. En segmentos con preconteo operativo, V_i corresponde directamente al número de viviendas registradas durante la actualización cartográfica previa al censo. En segmentos sin preconteo o con preconteo desactualizado por cambios demográficos recientes, V_i puede aproximarse mediante el número de estructuras identificadas en imágenes satelitales. La calidad de la estimación final depende directamente de la precisión de V_i , dado que errores en el offset se propagan directamente hacia las predicciones de conteo en todo el conjunto de segmentos.

El mecanismo de sobredispersión log-normal. La inclusión de la densidad latente δ_i con distribución log-normal constituye el principal mecanismo de control de sobredispersión del modelo. Bajo un modelo de Poisson puro, sin densidad latente y con predictor lineal fijo, la media y la varianza del conteo coinciden, $\text{Var}(Y_i) = \mathbb{E}(Y_i)$ —un supuesto que los conteos poblacionales observados en segmentos censales suelen incumplir, dada la variabilidad adicional que introducen las diferencias locales en ocupación de viviendas, procesos de urbanización y composición demográfica—.

La introducción de δ_i log-normal rompe esta restricción de equidispersión: como se mostró en la Sección 4.1.2, la varianza marginal del conteo es

$$\text{Var}(Y_i) = \mathbb{E}(Y_i) + V_i^2 e^{2\mu_i + \sigma^2} (e^{\sigma^2} - 1),$$

donde el segundo término representa la variabilidad adicional inducida por la mezcla Poisson-lognormal, estrictamente positiva para $\sigma > 0$. El parámetro σ controla directamente esta sobredispersión: cuando $\sigma \rightarrow 0$, la distribución log-normal degenera en un valor fijo y el modelo se reduce al Poisson clásico; a medida que σ aumenta, también aumenta la heterogeneidad entre segmentos y, con ella, la varianza marginal de los conteos. Esta propiedad permite que el modelo se adapte automáticamente al nivel de variabilidad presente en los datos, sin requerir la especificación previa del grado de sobredispersión.

Restricción de la densidad en predicción. En la implementación práctica del modelo, la densidad predicha para segmentos no observados —generada según el procedimiento descrito en la Sección 4.1.4— se trunca superiormente con el objetivo de evitar predicciones demográficamente implausibles en segmentos con alto valor del predictor lineal. Concretamente, se aplica la restricción:

$$\tilde{\delta}_i = \min(\delta_i^*, \delta_{\max})$$

donde δ_i^* es la densidad generada por la distribución log-normal predictiva y $\delta_{\max}$ es un valor máximo admisible definido a partir del conocimiento experto sobre los rangos plausibles de ocupación habitacional en el contexto regional. En la práctica, $\delta_{\max}$ se determina a partir de la distribución empírica de las densidades observadas en $\mathcal{S}_{obs}$: un valor habitual es el percentil 99 de $\{\delta_i : i \in \mathcal{S}_{obs}\}$ o un umbral redondo —por ejemplo, 20 personas por estructura— que refleje el máximo demográficamente plausible para el país en cuestión. Esta restricción previene que la combinación de un predictor lineal alto y variabilidad log-normal genere densidades que, multiplicadas por el número de estructuras, produzcan conteos individuales que superen toda referencia demográfica razonable.

La pertinencia de este mecanismo de sobredispersión debe fundamentarse en el diagnóstico exploratorio de los datos —en particular, en la relación empírica entre la media y la varianza de los conteos por segmento, descrita en el Capítulo 3— y confirmarse posteriormente mediante criterios de comparación de modelos. En contextos con elevada variabilidad territorial, alta proporción de segmentos con baja cobertura y disponibilidad de información sobre el número de estructuras, el modelo Poisson-lognormal con offset representa la especificación estadísticamente más apropiada para la estimación subnacional de conteos poblacionales en segmentos censales (Bryant and Zhang, 2018), y ha mostrado buen desempeño en las aplicaciones desarrolladas sobre censos de América Latina y el Caribe que sirven de referencia para este libro.

Inferencia Bayesiana e Implementación Computacional

El capítulo anterior estableció la especificación probabilística completa del modelo Poisson-lognormal: la distribución log-normal para la densidad latente de personas por estructura, la distribución de Poisson para los conteos observados, el predictor lineal con efectos fijos y aleatorios, y las distribuciones previas no informativas para todos los parámetros (Gelman et al., 2013). Esa especificación, derivada a partir del teorema de Bayes en la Sección 4.1.4, define la distribución posterior

$$p(\theta, \delta \mid \mathbf{Y}_{obs}) \propto p(\mathbf{Y}_{obs}, \delta \mid \beta, \gamma, \sigma) \cdot p(\gamma \mid \sigma_U) \cdot p(\beta) \cdot p(\sigma) \cdot p(\sigma_U)$$

pero no la hace analíticamente tratable: la combinación entre Poisson y log-normal no tiene forma cerrada en ninguno de los parámetros, y la dimensión del espacio parametral —que incluye D_{obs} densidades latentes más los $P + Q + 2$ parámetros estructurales— puede superar varios miles de dimensiones en aplicaciones censales reales.

El presente capítulo cierra esa brecha entre la especificación y la inferencia. La herramienta central es la simulación Monte Carlo por cadenas de Markov (MCMC), y dentro de ella el algoritmo de Monte Carlo Hamiltoniano (HMC) con el muestreador adaptativo NUTS (Hoffman and Gelman, 2014), cuya implementación en Stan (Carpenter et al., 2017) permite obtener muestras de alta calidad de distribuciones posteriores complejas de manera eficiente. El capítulo se organiza en dos secciones: la primera describe los fundamentos del método de simulación y su implementación en Stan, ilustrada con las aplicaciones desarrolladas en cinco países del Caribe y América Latina en el marco de proyectos de asistencia técnica de CEPAL; la segunda describe el procedimiento para derivar estimaciones, intervalos de credibilidad y agregaciones territoriales.

5.1 Métodos de simulación

5.1.1 Cadenas de Markov Monte Carlo

El principio fundamental de la inferencia MCMC es aproximar la distribución posterior $p(\theta \mid \mathbf{Y})$ mediante una colección de muestras $\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(T)}$ generadas por una cadena de Markov ergódica cuya distribución estacionaria es precisamente la distribución posterior (Tierney, 1994). Una vez que la cadena ha convergido a su distribución estacionaria, las muestras pueden tratarse como realizaciones aproximadas de la distribución posterior y utilizarse para calcular cualquier cantidad de interés mediante promedios de Monte Carlo.

Formalmente, para cualquier función $g(\theta)$ cuadrado-integrable respecto a la distribución posterior, el estimador de Monte Carlo

$$\hat{g}_T = \frac{1}{T} \sum_{t=1}^T g(\theta^{(t)})$$

converge casi seguramente a $\mathbb{E}[g(\theta) \mid \mathbf{Y}]$ cuando $T \rightarrow \infty$, por la ley fuerte de los grandes números para cadenas de Markov ergódicas. La tasa de convergencia depende de la correlación entre muestras consecutivas: cadenas con alta autocorrelación requieren mayor número de iteraciones para alcanzar la misma precisión que cadenas con baja autocorrelación.

Los métodos de Metropolis-Hastings y sus variantes, que dominaron la práctica bayesiana computacional desde la década de 1990, generan cadenas cuya eficiencia decrece rápidamente con la dimensión del espacio paramétrico. En modelos de alta dimensión como el Poisson-lognormal aplicado a miles de segmentos censales, la exploración aleatoria del espacio parametral produce cadenas altamente correlacionadas que requieren un número prohibitivo de iteraciones para converger. El algoritmo HMC resuelve este problema de manera fundamental al incorporar información de gradiente para guiar la exploración del espacio paramétrico (Neal, 2011).

5.1.2 Monte Carlo Hamiltoniano y el algoritmo NUTS

El Monte Carlo Hamiltoniano fue introducido originalmente en el contexto de la física de partículas bajo el nombre de *Hybrid Monte Carlo* (Duane et al., 1987) y adaptado a la estadística bayesiana por Neal (2011). La idea central es transformar el problema de muestreo de la distribución posterior en un problema de simulación de dinámica hamiltoniana. El espacio parametral se interpreta como un espacio de posición, y se introduce un vector de momento p del mismo tamaño que θ . La energía del sistema se define como la función hamiltoniana:

$$H(\theta, p) = -\log p(\theta \mid \mathbf{Y}) + \frac{1}{2} p^\top M^{-1} p$$

donde M es una matriz de masa que actúa como preconditionador. La dinámica hamiltoniana conserva H y genera trayectorias que exploran regiones de alta densidad posterior de manera mucho más eficiente que los saltos aleatorios, ya que el gradiente de $\log p(\theta \mid \mathbf{Y})$ guía al sistema hacia regiones de mayor probabilidad.

En la práctica, la dinámica hamiltoniana se simula discretizando el tiempo con el integrador leapfrog, que alterna actualizaciones de la posición y el momento mediante pasos de tamaño ε :

$$p^{(t+\varepsilon/2)} = p^{(t)} + \frac{\varepsilon}{2} \nabla_{\theta} \log p(\theta^{(t)} \mid \mathbf{Y})$$

$$\theta^{(t+\varepsilon)} = \theta^{(t)} + \varepsilon M^{-1} p^{(t+\varepsilon/2)}$$

$$p^{(t+\varepsilon)} = p^{(t+\varepsilon/2)} + \frac{\varepsilon}{2} \nabla_{\theta} \log p(\theta^{(t+\varepsilon)} \mid \mathbf{Y})$$

Una introducción conceptual accesible a la mecánica de HMC, orientada a la práctica estadística bayesiana, puede encontrarse en Betancourt (2017). El análisis más detallado de las propiedades teóricas del método y su implementación en el contexto de modelos jerárquicos se encuentra en Neal (2011) y en el capítulo 12 de Gelman et al. (2013).

El algoritmo NUTS (Hoffman and Gelman, 2014) resuelve el problema de elegir automáticamente el número de pasos leapfrog en cada iteración. La selección manual de este hiperparámetro en HMC estándar requiere ajuste fino; NUTS elimina esta necesidad mediante un criterio de parada automático que detiene la simulación cuando la trayectoria empieza a retroceder —a hacer un *U-turn* en el espacio parametral—, indicando que continuar la trayectoria no aportaría información adicional sobre la distribución posterior. El tamaño de paso ε se ajusta

automáticamente durante la fase de calentamiento mediante un algoritmo de tipo dual-averaging para alcanzar una tasa de aceptación objetivo en torno al 65–80 %.

Las ventajas de HMC-NUTS sobre los métodos clásicos son decisivas para modelos de alta dimensión. En tanto que los métodos tipo Gibbs o Metropolis-Hastings presentan un tamaño efectivo de muestra que crece aproximadamente como $T/\sqrt{d}$ con d dimensiones, HMC-NUTS escala mucho más favorablemente —en ciertos regímenes aproximadamente como $T/d^{1/4}$ — lo que hace factible la inferencia en modelos con miles de parámetros latentes como los que surgen en el contexto de la estimación subnacional de población (Betancourt, 2017). Esta propiedad ha sido un factor determinante en la adopción de Stan como plataforma de estimación en los proyectos de estimación censal de CEPAL descritos en la sección 5.1.3.

5.1.3 Implementación en Stan

Stan es un lenguaje de programación probabilística que compila modelos en código C++ optimizado e implementa HMC-NUTS con calibración automática de hiperparámetros (Carpenter et al., 2017). La interfaz con R se realiza a través del paquete rstan (Stan Development Team, 2023), que permite especificar el modelo en el lenguaje propio de Stan y gestionar la compilación, ejecución y extracción de resultados desde R.

Un programa Stan se organiza en bloques con funciones específicas. El bloque `data` declara las cantidades conocidas que se pasan desde R al modelo. El bloque `parameters` declara los parámetros desconocidos sobre los que se realiza la inferencia. El bloque `transformed parameters` define cantidades deterministas calculadas a partir de los parámetros. El bloque `model` define la distribución posterior a través de sus componentes log-verosimilitud y log-prior. El bloque `generated quantities` define cantidades que se calculan a partir de las muestras posteriores una vez completado el muestreo, incluyendo predicciones para nuevas observaciones.

El código Stan del modelo Poisson-lognormal, desarrollado en el marco de los proyectos de asistencia técnica de CEPAL y aplicado en Costa Rica, Barbados, Jamaica, Dominica y República Dominicana, tiene la siguiente estructura:

```
data {
  int<lower=1> D_obs;           // Segmentos observados en el censo
  int<lower=1> D_tot;          // Total de segmentos en el país
  int<lower=1> P;              // Número de covariables
  int<lower=1> Q;              // Número de efectos aleatorios
  array[D_obs] int<lower=0> Y_obs; // Conteos poblacionales observados
  array[D_obs] int<lower=0> V_obs; // Estructuras en segmentos observados
  array[D_tot] int<lower=0> V_tot; // Estructuras en todos los segmentos
  matrix[D_obs, P] X_obs;      // Covariables en segmentos observados
  matrix[D_tot, P] X_tot;      // Covariables en todos los segmentos
  matrix[D_obs, Q] Z_obs;      // Indicadores de efectos aleatorios (observadas)
  matrix[D_tot, Q] Z_tot;      // Indicadores de efectos aleatorios (todas)
}

parameters {
  vector[P]      beta;         // Coeficientes de efectos fijos
  vector[Q]      gamma;        // Coeficientes de efectos aleatorios
  real<lower=0>   sigma;        // Escala de la distribución log-normal
  real<lower=0>   sigmaU;       // Escala de los efectos aleatorios
```

```

    vector<lower=0>[D_obs] densidad; // Densidades latentes en segmentos observados
}

transformed parameters {
    vector[D_obs] lp; // Predictor Lineal
    vector<lower=0>[D_obs] lambda; // Parámetro Poisson

    lp = X_obs * beta + Z_obs * gamma;

    for (d in 1:D_obs)
        lambda[d] = fmin(fmax(1, densidad[d] * V_obs[d]), 10000000);
}

model {
    // Distribuciones previas
    beta ~ normal(0, 1);
    gamma ~ normal(0, sigmaU);
    sigma ~ cauchy(0, 2.5);
    sigmaU ~ normal(0, 1);

    // Verosimilitud
    Y_obs ~ poisson(lambda);
    densidad ~ lognormal(lp, sigma);
}

generated quantities {
    vector[D_tot] lp_tot;
    array[D_tot] real<lower=0> densidad_hat;
    vector<lower=0>[D_tot] lambda2;
    array[D_tot] int<lower=0> Y_tot;
    vector[D_obs] log_lik; // Log-verosimilitud puntual (LOO/WAIC)

    lp_tot = X_tot * beta + Z_tot * gamma;

    for (d in 1:D_tot) {
        densidad_hat[d] = lognormal_rng(lp_tot[d], sigma);
        lambda2[d] = fmin(fmax(1, densidad_hat[d] * V_tot[d]), 10000000);
        Y_tot[d] = poisson_rng(lambda2[d]);
    }

    for (d in 1:D_obs)
        log_lik[d] = poisson_lpmf(Y_obs[d] | lambda[d]);
}

```

Cada bloque cumple una función precisa en relación con la especificación matemática del capítulo anterior. El bloque data recibe las ocho matrices y vectores que constituyen los insumos del modelo: dimensiones del

problema (D_{obs}, D_{tot}, P, Q) , conteos y estructuras observados, y las matrices de diseño para efectos fijos y aleatorios. El bloque `parameters` declara los cinco grupos de parámetros desconocidos $\{\beta, \gamma, \sigma, \sigma_U, \delta\}$; la restricción `lower=0` en `sigma`, `sigmaU` y densidad garantiza que Stan opere en el espacio transformado correspondiente, con la transformación logarítmica aplicada automáticamente durante el muestreo.

En el bloque `transformed parameters` se calcula el predictor lineal $\mathbf{lp} = \mathbf{X}_{obs}\beta + \mathbf{Z}_{obs}\gamma$ y se construye el parámetro de intensidad Poisson $\lambda_d = \delta_d \cdot V_d$. La función `fmin(fmax(1, ...), 10000000)` implementa la restricción de la intensidad a un rango numéricamente estable: impide intensidades menores que uno y previene desbordamientos aritméticos en segmentos con predictor lineal muy alto.

El bloque `model` transcribe directamente las especificaciones probabilísticas del capítulo anterior. La línea `Y_obs ~ poisson(lambda)` acumula la log-verosimilitud de Poisson; `densidad ~ lognormal(lp, sigma)` acumula la contribución log-normal de las densidades latentes incluyendo el jacobiano correspondiente; y las distribuciones previas reflejan las elecciones no informativas discutidas en la Sección 4.1.3 del capítulo anterior, siguiendo las recomendaciones de Gelman et al. (2013) y McElreath (2020) para modelos jerárquicos.

El bloque `generated quantities` implementa la predicción fuera de muestra. Para cada segmento del conjunto completo $\mathcal{S}$ se calcula el predictor lineal con las covariables de todos los segmentos, se genera una muestra de la densidad predictiva $\tilde{\delta}_d \sim \text{LogNormal}(\text{lp}_{tot_d}, \sigma)$ y se genera un conteo predictivo $\tilde{Y}_d \sim \text{Poisson}(\tilde{\delta}_d \cdot V_d)$. Este bloque se ejecuta una vez por muestra de la distribución posterior, de modo que la colección de matrices `Y_tot` y `densidad_hat` a lo largo de las T iteraciones constituye directamente la distribución predictiva posterior. Adicionalmente, el bloque calcula el vector `log_lik` con la log-verosimilitud puntual de Poisson evaluada en cada segmento observado $-\log p(Y_i | \delta_i, V_i)$ para $i \in \mathcal{S}_{obs}$, requerido posteriormente para el cálculo de los criterios LOO y WAIC.

5.1.4 Configuración de cadenas, muestras e iteraciones

La ejecución del modelo Stan desde R requiere configurar cuatro parámetros principales: el número de cadenas, el número de iteraciones totales, el número de iteraciones de calentamiento y los parámetros de control del algoritmo (Gelman et al., 2013, cap. 11):

```
library(rstan)
library(bayesplot)
library(loo)

# Habilitar paralelización y caché de modelos compilados
options(mc.cores = parallel::detectCores())
rstan::rstan_options(auto_write = TRUE)

# Ajustar el modelo
stan_model <- rstan::stan(
  file = "00_function/Modelo_ECLAC_V02_fin.stan",
  data = list_par,
  iter = 2000,
  warmup = 1500,
  chains = 4,
  control = list(max_treedepth = 15)
)
```

El parámetro `iter` fija el número total de iteraciones por cadena, incluyendo el calentamiento. De las 2 000 iteraciones totales por cadena, 1 500 corresponden a la fase de calentamiento y 500 a la fase de inferencia. Con 4 cadenas en paralelo, el conjunto de muestras útiles comprende $4 \times 500 = 2\,000$ muestras de la distribución posterior. En aplicaciones censales con alta dimensión latente — D_{obs} del orden de miles de segmentos— esta configuración es un punto de partida razonable que puede refinarse en función de los diagnósticos de convergencia descritos en el capítulo siguiente.

El uso de múltiples cadenas independientes, iniciadas desde puntos dispersos del espacio paramétrico, es una práctica estándar en inferencia MCMC (Gelman and Rubin, 1992). La comparación entre cadenas permite detectar problemas de convergencia que una cadena única no puede revelar: si todas las cadenas convergen a la misma región de alta densidad posterior, existe mayor confianza en que están explorando adecuadamente la distribución objetivo. El diagnóstico formal basado en la comparación de varianza entre cadenas e intra-cadena, el estadístico $\hat{R}$ (Gelman and Rubin, 1992; Vehtari et al., 2021), cuyo fundamento matemático se documenta en dichas referencias, se reporta de forma sistemática junto con el tamaño efectivo de muestra en el resumen posterior presentado en la sección siguiente.

La fase de calentamiento cumple tres funciones en Stan. Primera: el algoritmo NUTS ajusta adaptativamente el tamaño de paso ϵ para alcanzar la tasa de aceptación objetivo. Segunda: se estima la matriz de masa M que actúa como métrica del espacio parametral; Stan utiliza por defecto una métrica euclidiana diagonal cuyos elementos se estiman a partir de la varianza empírica de las muestras de calentamiento. Tercera: la cadena se aproxima a la región de alta densidad posterior, descartando las muestras iniciales que pueden estar lejos del modo. Las muestras de la fase de calentamiento no son utilizables para inferencia porque los hiperparámetros del algoritmo aún están siendo ajustados.

El parámetro `max_treedepth = 15` controla la profundidad máxima del árbol binomial que construye NUTS en cada iteración. Un árbol de profundidad L equivale a 2^L evaluaciones del leapfrog, lo que permite trayectorias de gran alcance en distribuciones posteriores con geometría compleja. El valor por defecto en Stan es 10; aumentarlo a 15 es recomendable en modelos con alta dimensionalidad latente o correlaciones posteriores fuertes, al costo de mayor tiempo de cómputo por iteración. Si durante la ejecución Stan registra advertencias de tipo `maximum treedepth exceeded`, se debe aumentar este parámetro o revisar la parametrización del modelo.

5.1.5 Paralelización y eficiencia computacional

La línea `options(mc.cores = parallel::detectCores())` configura la ejecución de las cuatro cadenas en paralelo, utilizando tantos núcleos del procesador como estén disponibles. La opción `rs-tan_options(auto_write = TRUE)` permite que Stan almacene en disco el modelo compilado en C++, de modo que sucesivas ejecuciones del mismo modelo reutilizan el código compilado y evitan el tiempo de compilación —que puede ser de 30 a 90 segundos según la complejidad del modelo— en cada llamada a `stan()`.

En aplicaciones con D_{obs} del orden de varios miles de segmentos, el costo computacional dominante por iteración proviene de la evaluación del gradiente del logaritmo de la distribución conjunta respecto a los parámetros latentes δ . Stan calcula estos gradientes mediante diferenciación automática sobre el grafo computacional del modelo (Carpenter et al., 2017), lo que garantiza gradientes exactos al costo de un factor constante —típicamente entre 2 y 5— sobre el tiempo de evaluación de la log-densidad.

El manejo de memoria es relevante cuando el bloque `generated quantities` genera matrices de predicción de dimensión $D_{tot} \times T$. Es recomendable guardar el objeto Stan en disco inmediatamente tras la ejecución para evitar recomputaciones:

```
# Guardar el objeto ajustado
saveRDS(stan_model,
        file = "Data/modelo/fit_pob_bayes_lognormal.rds")

# Cargar para análisis posteriores sin reejecutar el modelo
stan_model <- readRDS("Data/modelo/fit_pob_bayes_lognormal.rds")
```

5.2 Distribución posterior y estimaciones

5.2.1 Estimaciones puntuales y resumen posterior

Una vez obtenidas las muestras de la distribución posterior, el objeto `stan_model` generado por `rstan::stan()` concentra toda la información inferencial del modelo. La función `summary()` extrae para cada parámetro las estadísticas de resumen posterior más relevantes: media, error estándar de Monte Carlo, desviación estándar, percentiles y los diagnósticos de convergencia $\hat{R}$ (Vehtari et al., 2021) y tamaño efectivo de muestra (Gelman and Rubin, 1992):

```
# Resumen de todos los parámetros
params <- summary(stan_model)$summary

# Resumen específico de parámetros de interés
densidad_obs <- summary(stan_model, pars = "densidad")$summary
densidad_pred <- summary(stan_model, pars = "densidad_hat")$summary
Y_tot_pred <- summary(stan_model, pars = "Y_tot")$summary
```

Cada fila de estas matrices de resumen corresponde a un parámetro o cantidad generada, y las columnas reportan las siguientes estadísticas:

Columna	Descripción
mean	Media posterior $\hat{\theta} = \mathbb{E}[\theta \mathbf{Y}]$
se_mean	Error estándar de Monte Carlo $\hat{\sigma}_{\theta} / \sqrt{n_{eff}}$
sd	Desviación estándar posterior
2.5 %, 97.5 %	Intervalo de credibilidad al 95 %
50 %	Mediana posterior
n_eff	Tamaño efectivo de muestra
Rhat	Estadístico de convergencia $\hat{R}$

Para los conteos predichos `Y_tot`, la media posterior y la mediana posterior constituyen las dos estimaciones puntuales naturales. La media es el estimador de Bayes bajo pérdida cuadrática y suele preferirse para agregaciones. La mediana es el estimador de Bayes bajo pérdida absoluta y es más robusta a colas pesadas de la distribución predictiva (Gelman et al., 2013). La diferencia entre ambas estimaciones a nivel nacional —obtenida con `sum(Y_tot_pred[, "mean"])` y `sum(Y_tot_pred[, "50%"])` respectivamente— cuantifica la asimetría agregada de la distribución predictiva y debe documentarse en los reportes técnicos.

5.2.2 Extracción de muestras e intervalos de credibilidad

La función `rstan::extract()` extrae las muestras brutas de la distribución posterior en forma de arreglos, lo que permite calcular cualquier funcional que no esté incluido en el resumen estándar:

```
# Extraer muestras posteriores de los parámetros de interés
posterior_samples <- rstan::extract(
  stan_model,
  pars = c("densidad", "Y_tot", "densidad_hat")
)

# densidad_post: matriz de dimensión T x D_obs
densidad_post <- posterior_samples$densidad

# Y_tot_samp: matriz de dimensión T x D_tot
Y_tot_samp <- posterior_samples$Y_tot
```

El intervalo de credibilidad al 95 % para el conteo del segmento d se calcula como:

$$IC_{95\%}(Y_d) = [F_{Y_d}^{-1}(0,025), F_{Y_d}^{-1}(0,975)]$$

donde $F_{Y_d}^{-1}$ denota el cuantil empírico de las T muestras de $Y_tot_samp[, d]$. A diferencia de los intervalos de confianza frecuentistas, el intervalo de credibilidad tiene una interpretación probabilística directa: dada la información observada y el modelo, la probabilidad posterior de que Y_d caiga en ese intervalo es 0.95 (Gelman et al., 2013). Esta propiedad facilita la comunicación de la incertidumbre a usuarios institucionales no especializados en estadística.

5.2.3 Estimaciones a nivel de segmento censal

La predicción del conteo poblacional para cada segmento del país combina la información directa del censo con las predicciones del modelo según el estado de cobertura del operativo censal:

```
library(tidyverse)

# Extraer predicciones como data frame
df_y_pred <- data.frame(t(Y_tot_samp))
colnames(df_y_pred) <- paste0("pred_cont_", seq_len(ncol(df_y_pred)))

# Unir con metadatos del segmento
df_y_pred <- data_model %>%
  select(ED:Status) %>%
  bind_cols(df_y_pred)

pred_cols <- grep("^pred_cont_", names(df_y_pred), value = TRUE)
```

```
# Calcular estimación puntual y medidas de incertidumbre por segmento
estimaciones_segmento <- df_y_pred %>%
  rowwise() %>%
  mutate(
    pob_media = mean(c_across(all_of(pred_cols))),
    pob_mediana = median(c_across(all_of(pred_cols))),
    pob_sd = sd(c_across(all_of(pred_cols))),
    pob_li_95 = quantile(c_across(all_of(pred_cols)), 0.025),
    pob_ls_95 = quantile(c_across(all_of(pred_cols)), 0.975)
  ) %>%
  ungroup()
```

La estimación definitiva del conteo de cada segmento aplica la siguiente regla según el estado de cobertura:

```
estimaciones_segmento <- estimaciones_segmento %>%
  mutate(
    pob_final = case_when(
      # Cobertura completa: se usa directamente el conteo censal
      Status == "Completed-full" ~ T_pers,
      # Sin cobertura: se usa la predicción del modelo
      Status == "Not Attempted" ~ pob_media,
      # Cobertura parcial con subenumeración: se usa la predicción
      Status %in% c("Completed-with refusals", "Completed-partial") &
        T_pers < pob_media ~ pob_media,
      # Cobertura parcial sin subenumeración evidente: se mantiene el observado
      Status %in% c("Completed-with refusals", "Completed-partial") &
        T_pers >= pob_media ~ T_pers,
      TRUE ~ NA_real_
    )
  )
```

Esta regla garantiza coherencia operativa y refleja la naturaleza unidireccional del error de cobertura: la omisión genera subenumeración, no sobreconteo. Los segmentos con cobertura completa no son modificados por el modelo; los no abordados reciben íntegramente la predicción bayesiana; los parcialmente cubiertos son tratados según el principio de dominancia descrito en [Mercer et al. \(2015\)](#) para contextos similares de integración de múltiples fuentes.

5.2.4 Agregación a niveles geográficos superiores

La distribución posterior del total de población en cualquier unidad geográfica de nivel superior se obtiene sumando los conteos de los segmentos que la componen a través de cada muestra de la distribución predictiva. Esta propiedad de coherencia por agregación es una de las ventajas del enfoque probabilístico respecto a los métodos de estimación directa ([Rao and Molina, 2015](#)):

```

# Agregación a nivel parroquial con intervalo de credibilidad
estimaciones_parroquia <- df_y_pred %>%
  group_by(parish) %>%
  summarise(
    across(all_of(pred_cols), sum, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  rowwise() %>%
  mutate(
    tot_pob_media = mean(c_across(all_of(pred_cols))),
    tot_pob_sd    = sd(c_across(all_of(pred_cols))),
    tot_pob_li_95 = quantile(c_across(all_of(pred_cols)), 0.025),
    tot_pob_ls_95 = quantile(c_across(all_of(pred_cols)), 0.975),
    len_ic       = tot_pob_ls_95 - tot_pob_li_95
  ) %>%
  ungroup()

# Total nacional con intervalo de credibilidad
estimacion_nacional <- df_y_pred %>%
  summarise(across(all_of(pred_cols), sum, na.rm = TRUE)) %>%
  pivot_longer(everything(), names_to = "iteracion", values_to = "total_pob") %>%
  summarise(
    media    = mean(total_pob),
    sd       = sd(total_pob),
    li_95    = quantile(total_pob, 0.025),
    ls_95    = quantile(total_pob, 0.975),
    mediana  = median(total_pob)
  )

```

La amplitud del intervalo de credibilidad del total nacional refleja simultáneamente la incertidumbre sobre los parámetros del modelo y la variabilidad estocástica del proceso de Poisson en cada segmento. En aplicaciones prácticas, este intervalo es usualmente estrecho en comparación con el total estimado porque la mayor parte de la variabilidad individual se cancela en la suma; pero puede ser sustancialmente amplio para unidades geográficas con pocos segmentos y baja cobertura censal.

5.2.5 Verificación predictiva posterior

La verificación de la capacidad del modelo para reproducir los patrones observados en los datos se realiza mediante la comparación de la distribución predictiva posterior con los datos observados (Gabry et al., 2019). En el contexto del modelo Poisson-lognormal, es más informativo verificar la capacidad predictiva sobre la densidad $\delta_i = Y_i/V_i$ que directamente sobre los conteos, ya que la densidad es la cantidad central del modelo y su distribución no depende del número de estructuras:

```

# Subconjunto aleatorio de muestras de densidad
densidad_post <- posterior_samples$densidad

```

```

idx_muestra <- sample(nrow(densidad_post), 500)
densidad_rep <- densidad_post[idx_muestra, ]

# Gráfico de verificación predictiva posterior
ppc_dens <- bayesplot::ppc_dens_overlay(
  y = as.numeric(Y_obs / V_obs),
  yrep = densidad_rep
)

# Verificación sobre los conteos brutos
ppc_pers <- bayesplot::ppc_dens_overlay(
  y = as.numeric(Y_obs),
  yrep = t(t(densidad_rep) * V_obs)
)

ppc_dens | ppc_pers

```

En este gráfico (Gabry and Mahr, 2022), la línea sólida corresponde a la distribución empírica de los datos observados y las líneas semitransparentes representan las distribuciones predictivas generadas por las muestras posteriores. Un modelo bien especificado produce líneas predictivas que envuelven razonablemente bien la distribución observada sin exceso ni defecto sistemático. Desviaciones importantes señalan limitaciones del modelo que pueden orientar la reformulación del predictor lineal o el cambio de la distribución de la densidad latente (Gabry et al., 2019).

5.2.6 Criterios de información LOO y WAIC

Los criterios de comparación de modelos permiten seleccionar entre especificaciones alternativas sin recurrir a validación cruzada explícita (Vehtari et al., 2017). El criterio LOO-CV y el WAIC (Watanabe, 2010) se calculan a partir de la log-verosimilitud evaluada en cada muestra posterior:

```

# Extraer log-verosimilitud puntual (una columna por segmento observado)
log_lik_mat <- loo::extract_log_lik(stan_model,
                                   parameter_name = "log_lik")

# WAIC y LOO-CV
waic_result <- loo::waic(log_lik_mat)
loo_result <- loo::loo(log_lik_mat)

print(waic_result)
print(loo_result)

# Comparar dos especificaciones alternativas
loo::loo_compare(loo_modelo_1, loo_modelo_2)

```

Valores más altos de elpd-LOO (*expected log predictive density*) indican mejor capacidad predictiva fuera de muestra (Vehtari et al., 2017). En la comparación entre modelos, una diferencia en elpd superior al doble de su

error estándar se interpreta como evidencia de diferencia predictiva sustancial. La comparación entre LOO y WAIC en presencia de observaciones influyentes —frecuentes en segmentos con conteos extremos— se discute en [Piironen and Vehtari \(2017\)](#), que concluye que LOO es más robusto en esos contextos y debe ser el criterio principal para selección del modelo final.

5.3 Resumen

Este capítulo describió el ciclo completo de inferencia computacional para el modelo Poisson-lognormal: desde los fundamentos del algoritmo HMC-NUTS ([Hoffman and Gelman, 2014](#); [Betancourt, 2017](#)), pasando por la implementación en Stan ([Carpenter et al., 2017](#)) con los cinco bloques del programa, hasta el procedimiento de extracción de estimaciones puntuales, intervalos de credibilidad y agregaciones territoriales en R mediante `rstan` ([Stan Development Team, 2023](#)), `bayesplot` ([Gabry and Mahr, 2022](#)) y `loo` ([Vehtari et al., 2022, 2017](#)). Las aplicaciones en Costa Rica, Barbados, Jamaica, Dominica y República Dominicana ilustraron cómo los parámetros de implementación —selección de covariables, fuente del offset, umbral de densidad y configuración MCMC— se adaptan al contexto de cada operativo censal sin alterar la especificación estadística del modelo. El capítulo incluyó además el diagnóstico de convergencia mediante los estadísticos $\hat{R}$ y ESS ([Vehtari et al., 2021](#); [Gelman and Rubin, 1992](#)), la validación predictiva posterior ([Gabry et al., 2019](#)) y la selección entre modelos alternativos mediante los criterios LOO y WAIC ([Vehtari et al., 2017](#); [Watanabe, 2010](#)). El capítulo siguiente profundiza en estos diagnósticos —trazas, autocorrelación y diagnósticos específicos de HMC, residuos bayesianos y calibración, criterios formales de aceptación de modelos— y añade la validación externa frente a proyecciones demográficas, registros administrativos independientes y coherencia geoespacial, como verificación final antes de la publicación de estimaciones oficiales.

Bibliografía

- Banerjee, S., Carlin, B. P., and Gelfand, A. E. (2015). *Hierarchical Modeling and Analysis for Spatial Data*. Chapman and Hall/CRC, Boca Raton, Florida, 2nd edition.
- Betancourt, M. (2017). A conceptual introduction to Hamiltonian Monte Carlo. *arXiv preprint*. arXiv:1701.02434.
- Bryant, J. and Zhang, J. L. (2018). *Bayesian Demographic Estimation and Forecasting*. Chapman and Hall/CRC, Boca Raton, FL.
- Bryant, J. R. and Graham, P. J. (2013). Bayesian demographic accounts: Subnational population estimation using multiple data sources. *Bayesian Analysis*, 8(3):591–622.
- Carpenter, B., Gelman, A., Hoffman, M. D., Lee, D., Goodrich, B., Betancourt, M., Brubaker, M., Guo, J., Li, P., and Riddell, A. (2017). Stan: A probabilistic programming language. *Journal of Statistical Software*, 76(1):1–32.
- CEPAL (2023). Recomendaciones para los censos de población y vivienda en América Latina: revisión 2020. Technical Report LC/CEA.10/3, Comisión Económica para América Latina y el Caribe, Santiago.
- Duane, S., Kennedy, A. D., Pendleton, B. J., and Roweth, D. (1987). Hybrid Monte Carlo. *Physics Letters B*, 195(2):216–222.
- Gabry, J. and Mahr, T. (2022). *bayesplot: Plotting for Bayesian Models*. R package version 1.10.0.
- Gabry, J., Simpson, D., Vehtari, A., Betancourt, M., and Gelman, A. (2019). Visualization in Bayesian workflow. *Journal of the Royal Statistical Society: Series A*, 182(2):389–402.
- Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., and Rubin, D. B. (2013). *Bayesian Data Analysis*. Chapman and Hall/CRC, Boca Raton, Florida, 3rd edition.
- Gelman, A. and Rubin, D. B. (1992). Inference from iterative simulation using multiple sequences. *Statistical Science*, 7(4):457–472.
- Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., and Moore, R. (2017). Google earth engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202:18–27.
- Hoffman, M. D. and Gelman, A. (2014). The No-U-Turn sampler: Adaptively setting path lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research*, 15:1593–1623.
- Hogan, H. (1993). The 1990 post-enumeration survey: Operations and results. *Journal of the American Statistical Association*, 88(423):1047–1060.
- McElreath, R. (2020). *Statistical Rethinking: A Bayesian Course with Examples in R and Stan*. Chapman and Hall/CRC, Boca Raton, Florida, 2nd edition.
- Mercer, L., Wakefield, J., Chen, C., and Lumley, T. (2015). Space-time smoothing of complex survey data: Small area inclusion probabilities and total population counts. *The Annals of Applied Statistics*, 9(4):1889–1917.

- Naciones Unidas (2017). *Principios y recomendaciones para los censos de población y habitación, Revisión 3*. Departamento de Asuntos Económicos y Sociales, División de Estadística, Nueva York. ST/ESA/STAT/SER.M/67/Rev.3.
- Neal, R. M. (2011). *MCMC Using Hamiltonian Dynamics*. Chapman and Hall/CRC, Boca Raton, Florida.
- Piironen, J. and Vehtari, A. (2017). Comparison of Bayesian predictive methods for model selection. *Statistics and Computing*, 27(3):711–735.
- Preston, S. H., Heuveline, P., and Guillot, M. (2001). *Demography: Measuring and Modeling Population Processes*. Blackwell Publishing, Malden, MA.
- Raftery, A. E., Li, N., Ševčíková, H., Gerland, P., and Heilig, G. K. (2012). Bayesian probabilistic population projections for all countries. *Proceedings of the National Academy of Sciences*, 109(35):13915–13921.
- Rao, J. N. K. and Molina, I. (2015). *Small Area Estimation*. John Wiley & Sons, Hoboken, New Jersey, 2nd edition.
- Siegel, J. S. and Swanson, D. A., editors (2004). *The Methods and Materials of Demography*. Elsevier Academic Press, San Diego, CA, 2 edition.
- Stan Development Team (2023). *RStan: the R interface to Stan*. R package version 2.21.8.
- Tierney, L. (1994). Markov chains for exploring posterior distributions. *The Annals of Statistics*, 22(4):1701–1728.
- Vehtari, A., Gabry, J., Magnusson, M., Yao, Y., Bürkner, P.-C., Paananen, T., and Gelman, A. (2022). *loo: Efficient Leave-One-Out Cross-Validation and WAIC for Bayesian Models*. R package version 2.5.1.
- Vehtari, A., Gelman, A., and Gabry, J. (2017). Practical Bayesian model evaluation using leave-one-out cross-validation and WAIC. *Statistics and Computing*, 27(5):1413–1432.
- Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., and Bürkner, P.-C. (2021). Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC. *Bayesian Analysis*, 16(2):667–718.
- Watanabe, S. (2010). Asymptotic equivalence of Bayes cross validation and widely applicable information criterion in singular learning theory. *Journal of Machine Learning Research*, 11:3571–3594.
- Wheldon, M. C., Raftery, A. E., Clark, S. J., and Gerland, P. (2013). Reconstructing past populations with uncertainty from fragmentary data. *Journal of the American Statistical Association*, 108(501):96–110.