

Modelos Bayesianos de Población para América Latina y el Caribe

Implementación, Validación y Aplicación Subnacional

Andrés Gutiérrez¹ Stalyn Guerrero²

julio de 2026

¹Experto Regional en Estadísticas Sociales, CEPAL. andres.gutierrez@cepal.org

²Consultor, CEPAL. guerrerostalyn@gmail.com

Índice general

Prefacio	7
Introducción	9
1 Enfoque General de los Modelos de Población	11
1.1 Producción de conteos censales	11
1.1.1 Producción subnacional	12
1.1.2 Desagregación por sexo y edad	13
1.1.3 Uso en marcos muestrales	13
1.1.4 Definición de dominios	14
1.2 Indicadores de interés	15
1.2.1 Conteos poblacionales	15
1.2.2 Tasas derivadas	17
1.2.3 Estructuras etarias	18
1.3 Formulación del problema de subcobertura, no respuesta y omisión censal	20
2 Integración de Fuentes de Información	23
2.1 Principios de modelamiento	23
2.1.1 Modelos de conteo	23
2.1.2 Requerimientos de estimación subnacional	24
2.1.3 Justificación del enfoque bayesiano	25
2.1.4 Integración de múltiples fuentes	26
2.1.5 Relación con Small Area Estimation	26
2.2 Identificación de fuentes	27
2.2.1 Medición de cobertura a nivel de segmento	27
2.2.2 Preconteos y segmentación	28
2.2.3 Registros administrativos (variables proxy)	28
2.2.4 Fuentes satelitales	29
2.3 Variables explicativas	30
2.3.1 Variables demográficas	30
2.3.2 Variables socioeconómicas	31
2.3.3 Variables espaciales	31
3 Preparación de Imágenes Satelitales	33
3.1 Fuentes de datos satelitales (Landsat, Sentinel, MODIS)	33
3.2 Preprocesamiento y correcciones atmosféricas	33
3.3 Extracción de características (NDVI, índices espectrales)	33
3.4 Validación con datos de campo	33
3.5 Generación de capas para el modelo	33

4	Preparación de Insumos para Modelamiento	35
4.1	Estandarización de fuentes	35
4.1.1	Homologación de variables	35
4.1.2	Normalización de variables	36
4.2	Evaluación de cobertura	37
4.2.1	Tasa de cobertura por segmento	37
4.2.2	Clasificación de segmentos	38
4.3	Construcción de la variable dependiente	38
4.3.1	Conteos agregados	39
4.3.2	Tasas poblacionales	39
4.3.3	Transformaciones	39
4.3.4	Definición de población base	40
4.3.5	Escalamiento	40
4.4	Diagnóstico exploratorio	41
4.4.1	Distribución de conteos	41
4.4.2	Outliers	42
4.4.3	Relación entre variables	43
5	Modelo para Conteos Poblacionales	45
5.1	Modelo Poisson-lognormal	45
5.1.1	Definición formal	45
5.1.2	Función de verosimilitud	47
5.1.3	Distribuciones a priori	48
5.1.4	Distribución posterior	49
5.1.5	Interpretación de parámetros	50
5.2	Componentes del modelo	51
5.2.1	Efectos fijos	51
5.2.2	Efectos aleatorios	52
5.2.3	Interacciones	53
5.2.4	Sobredispersión, offset y alternativas distribucionales	54
6	Inferencia Bayesiana e Implementación Computacional	57
6.1	Métodos de simulación	57
6.1.1	Cadenas de Markov Monte Carlo	57
6.1.2	Monte Carlo Hamiltoniano y el algoritmo NUTS	58
6.1.3	Implementación en Stan	59
6.1.4	Configuración de cadenas, muestras e iteraciones	61
6.1.5	Paralelización y eficiencia computacional	62
6.2	Distribución posterior y estimaciones	63
6.2.1	Estimaciones puntuales y resumen posterior	63
6.2.2	Extracción de muestras e intervalos de credibilidad	64
6.2.3	Estimaciones a nivel de segmento censal	64
6.2.4	Agregación a niveles geográficos superiores	65
6.2.5	Verificación predictiva posterior	66
6.2.6	Criterios de información LOO y WAIC	67
6.3	Resumen	68
7	Diagnóstico y Validación del Modelo	69

7.1	Diagnóstico de convergencia MCMC	69
7.1.1	Estadístico R-hat	69
7.1.2	Tamaño efectivo de muestra (ESS)	70
7.1.3	Trace plots, autocorrelación y diagnósticos específicos de HMC	71
7.2	Validación predictiva posterior	73
7.2.1	Posterior predictive checks (PPC)	73
7.2.2	Residuos bayesianos	74
7.2.3	Comparación con conteos observados y calibración	75
7.3	Selección y comparación de modelos	75
7.3.1	Criterio Leave-One-Out (LOO-CV) y diagnóstico de Pareto k	76
7.3.2	Widely Applicable Information Criterion (WAIC)	76
7.3.3	Criterio de elección del modelo final	77
7.4	Validación externa	78
7.4.1	Consistencia con proyecciones demográficas	78
7.4.2	Comparación con registros administrativos independientes	79
7.4.3	Evaluación de coherencia geoespacial	79
8	Calibración y Benchmarking Subnacional	81
8.1	Benchmarking con proyecciones poblacionales	81
8.1.1	Necesidad de coherencia entre niveles geográficos	81
8.1.2	Restricciones de consistencia jerárquica	82
8.1.3	Relación entre estimaciones locales y totales conocidos	82
8.2	Métodos de benchmarking	83
8.2.1	Benchmarking proporcional	83
8.2.2	Benchmarking por razones de ajuste	83
8.2.3	Benchmarking aditivo con restricciones de suma	84
8.2.4	Aplicación práctica a distintos niveles geográficos	85
8.3	Evaluación del impacto del benchmarking	86
8.3.1	Cambio en estimaciones puntuales	86
8.3.2	Intervalos de credibilidad post-calibración	87
9	Conclusiones y Recomendaciones Institucionales	89
9.1	Principales hallazgos metodológicos	89
9.2	Recomendaciones para organismos nacionales de estadística	90
9.3	Rol de organismos internacionales en la transferencia metodológica	91
9.4	Limitaciones del enfoque y condiciones para su aplicación	92

Índice de figuras

Índice de cuadros

Prefacio

Este libro expone el marco metodológico y computacional para la producción de estimaciones de población subnacional mediante modelos bayesianos jerárquicos. Surge de la experiencia acumulada en proyectos de asistencia técnica a institutos nacionales de estadística de América Latina y el Caribe, en el marco de las actividades de cooperación estadística de la Comisión Económica para América Latina y el Caribe (CEPAL).

La motivación central es práctica: los censos de población proporcionan conteos que, en unidades geográficas pequeñas, presentan errores de cobertura sistemáticos y difíciles de cuantificar con los métodos de conciliación demográfica tradicionales. La integración de fuentes modernas de información —preconteos operativos, registros administrativos e imágenes satelitales— en un marco probabilístico coherente ofrece una respuesta metodológica rigurosa a este problema.

El libro combina fundamentos estadísticos formales con implementación computacional reproducible en R y Stan, y está dirigido a estadísticos y demógrafos de organismos nacionales e internacionales con formación cuantitativa de nivel avanzado.

Cómo compilar este libro

```
# HTML interactivo
bookdown::render_book("index.Rmd", "bookdown::gitbook")

# PDF
bookdown::render_book("index.Rmd", "bookdown::pdf_book")

# Word (.docx)
bookdown::render_book("index.Rmd", "bookdown::word_document2")
```

Introducción

La producción de conteos poblacionales constituye uno de los procesos estadísticos más complejos y estratégicos desarrollados por los institutos nacionales de estadística. Los censos de población y vivienda no solo permiten cuantificar el tamaño de la población, sino también establecer la estructura demográfica, definir marcos de referencia territoriales y generar la base operativa para una gran parte de las estadísticas oficiales producidas posteriormente por los países.

A nivel subnacional, los conteos censales son utilizados en procesos de planificación territorial, asignación presupuestal, focalización de programas sociales, construcción de marcos muestrales, producción de indicadores sociales y elaboración de proyecciones demográficas. La calidad de estas aplicaciones depende directamente de la precisión y coherencia de los conteos poblacionales observados en cada unidad geográfica.

Sin embargo, la producción censal enfrenta limitaciones estructurales asociadas a errores de cobertura, omisión, duplicación y clasificación territorial. Estos problemas no se distribuyen homogéneamente en el territorio. Por el contrario, suelen concentrarse en áreas con alta dispersión poblacional, asentamientos informales, zonas rurales de difícil acceso, territorios indígenas y contextos urbanos con elevada movilidad poblacional.

Como consecuencia, los conteos observados durante el operativo censal no necesariamente representan la población verdadera presente en cada unidad geográfica. Esta situación se vuelve particularmente crítica en niveles territoriales pequeños, donde errores relativamente reducidos en términos absolutos pueden generar distorsiones importantes en tasas, indicadores derivados y procesos de asignación institucional.

Frente a este problema, los sistemas estadísticos modernos han comenzado a incorporar metodologías de integración de múltiples fuentes de información orientadas a fortalecer, ajustar y validar los conteos censales. Entre estas fuentes se incluyen preconteos operativos, registros administrativos, cartografía censal, imágenes satelitales y modelos espaciales derivados de información georreferenciada.

En este contexto, los modelos bayesianos jerárquicos ofrecen un marco probabilístico flexible para representar explícitamente la incertidumbre asociada al proceso de enumeración poblacional y combinar información procedente de distintas fuentes bajo un esquema coherente de inferencia estadística.

Enfoque General de los Modelos de Población

1.1 Producción de conteos censales

La producción de conteos poblacionales constituye uno de los procesos más relevantes dentro de los sistemas estadísticos nacionales. A través de los censos de población y vivienda, los países construyen la base demográfica utilizada para la planificación pública, la elaboración de indicadores sociales, la construcción de marcos muestrales y la formulación de políticas territoriales. En términos operativos y metodológicos, el censo representa la única operación estadística diseñada para enumerar exhaustivamente la población residente dentro de un territorio nacional bajo un mismo marco conceptual, temporal y geográfico.

Los conteos censales no solo permiten conocer cuántas personas habitan un país, sino también cómo se distribuyen territorialmente y cómo se estructuran según características demográficas básicas como sexo y edad. Esta información es utilizada posteriormente en una gran variedad de procesos institucionales: proyecciones demográficas, encuestas de hogares, sistemas de focalización social, distribución presupuestaria, delimitación administrativa y producción de estadísticas subnacionales.

En la práctica, la producción censal implica mucho más que el levantamiento de información en campo. Detrás de los conteos publicados existe una estructura compleja de actualización cartográfica, segmentación territorial, logística operativa, capacitación, validación y conciliación estadística. Cada una de estas etapas introduce potenciales fuentes de error que afectan la calidad final de las estimaciones poblacionales.

Uno de los principales desafíos de los censos modernos corresponde a los problemas de cobertura. La enumeración de la población nunca es perfecta. Existen personas que no son censadas, viviendas que no son visitadas, individuos registrados más de una vez o registros asignados incorrectamente a un territorio distinto. Estos problemas tienden a concentrarse en determinados contextos territoriales y sociales: áreas rurales dispersas, asentamientos informales, territorios indígenas, zonas fronterizas o áreas urbanas con alta movilidad poblacional.

En América Latina y el Caribe, estas dificultades adquieren una dimensión particularmente importante debido a la elevada heterogeneidad territorial de la región. Los países presentan diferencias sustanciales en capacidad operativa, actualización cartográfica, infraestructura estadística y disponibilidad de registros administrativos. Adicionalmente, muchos territorios enfrentan condiciones geográficas complejas que dificultan las labores de enumeración y supervisión censal.

La ronda censal de 2020 evidenció nuevamente estas limitaciones. Diversos países experimentaron retrasos operativos asociados a restricciones presupuestarias, conflictos sociales y efectos derivados de la pandemia de COVID-19. Como resultado, varios sistemas estadísticos enfrentaron dificultades para mantener continuidad temporal y coherencia territorial en sus conteos poblacionales.

A medida que aumenta el nivel de desagregación geográfica, los problemas de cobertura se vuelven más visibles. Mientras que a nivel nacional algunos errores pueden compensarse parcialmente entre regiones, en niveles territoriales pequeños las omisiones o duplicaciones generan distorsiones importantes sobre indicadores

demográficos y sociales. Esto afecta directamente la capacidad de los gobiernos para asignar recursos, diseñar programas y producir estadísticas territoriales consistentes.

En este contexto, la producción moderna de conteos poblacionales requiere complementar el operativo censal tradicional con mecanismos de validación, integración de fuentes auxiliares y modelamiento estadístico. Los modelos bayesianos de población surgen precisamente como una respuesta metodológica a este problema, permitiendo integrar información proveniente de distintas fuentes y representar explícitamente la incertidumbre asociada a los conteos observados.

1.1.1 Producción subnacional

Aunque los censos generan un conteo nacional de población, gran parte de su utilidad práctica se concentra en la producción de información subnacional. Los gobiernos requieren estadísticas desagregadas para departamentos, provincias, municipios, áreas urbanas y rurales, sectores censales y segmentos operativos. Es en estas escalas territoriales donde se ejecutan la mayoría de políticas públicas y procesos administrativos.

La producción subnacional implica construir conteos consistentes entre distintos niveles geográficos. Los totales municipales deben coincidir con los agregados departamentales, y estos, a su vez, con los conteos nacionales. Esta coherencia territorial constituye uno de los principios fundamentales de la estadística oficial.

Sin embargo, garantizar dicha consistencia no es un proceso trivial. A medida que disminuye el tamaño poblacional de las unidades geográficas, aumentan proporcionalmente los efectos de los errores de cobertura. En áreas pequeñas, la omisión de algunos hogares o viviendas puede alterar significativamente indicadores derivados como tasas de dependencia, razones de masculinidad o estructuras etarias.

La calidad de los conteos subnacionales depende críticamente de la cartografía censal y de los procesos de segmentación territorial. Antes del levantamiento censal, los países deben actualizar mapas, identificar viviendas, definir rutas operativas y dividir el territorio en unidades de trabajo relativamente homogéneas. Estas unidades, conocidas generalmente como segmentos censales, constituyen la base operativa del operativo de campo.

En América Latina y el Caribe, la definición de segmentos presenta importantes diferencias metodológicas entre países. Algunos sistemas censales utilizan criterios asociados al número esperado de viviendas, mientras que otros priorizan continuidad espacial, accesibilidad geográfica o carga operativa del censista. Como resultado, las unidades territoriales utilizadas en los censos no siempre son comparables entre países.

Otro aspecto relevante corresponde a la diferencia entre censos de hecho y censos de derecho. En países como Bolivia, Paraguay y Colombia, los operativos censales han sido implementados bajo esquemas de censo de hecho, donde las personas son contabilizadas en el lugar donde se encuentran durante el momento censal. En contraste, los censos de derecho buscan registrar a las personas según su residencia habitual.

Esta diferencia conceptual tiene implicaciones importantes sobre movilidad territorial, cobertura diferencial y consistencia espacial. En contextos con alta movilidad poblacional, los censos de hecho pueden generar concentraciones temporales de población en determinadas áreas, mientras que los censos de derecho requieren procedimientos más complejos para validar residencia habitual y evitar duplicaciones.

La producción subnacional también enfrenta desafíos asociados al crecimiento urbano acelerado y a la expansión de asentamientos informales. En muchas ciudades de la región, los procesos de urbanización ocurren más rápidamente que la actualización cartográfica oficial, generando sectores con viviendas no registradas o límites territoriales desactualizados. Esto afecta directamente la cobertura del operativo y la calidad de los conteos resultantes.

Desde la perspectiva estadística, los conteos subnacionales deben entenderse como observaciones imperfectas de una población subyacente cuya magnitud real no es completamente observable. Esta situación motiva el uso de modelos probabilísticos capaces de integrar múltiples fuentes de información, representar explícitamente la incertidumbre y garantizar coherencia entre niveles territoriales.

1.1.2 Desagregación por sexo y edad

Uno de los principales aportes de los censos de población consiste en la posibilidad de caracterizar la estructura demográfica de la población. Los conteos no solo se producen para áreas geográficas, sino también para distintos grupos de edad y sexo. Esta desagregación constituye un insumo fundamental para el análisis demográfico, la formulación de políticas públicas y la elaboración de proyecciones poblacionales.

La distribución por edad y sexo condiciona directamente múltiples dimensiones del desarrollo social y económico. La demanda de servicios educativos, sistemas de salud, programas de protección social y mercados laborales depende estrechamente de la estructura etaria de la población. Del mismo modo, indicadores como envejecimiento, dependencia demográfica o fecundidad requieren información detallada sobre composición poblacional.

En términos operativos, la producción de conteos por sexo y edad incrementa considerablemente la complejidad del proceso censal. Los errores de cobertura no afectan de manera homogénea a todos los grupos poblacionales. En América Latina y el Caribe, las tasas de omisión suelen ser más elevadas en niños pequeños, hombres jóvenes, población indígena, migrantes y habitantes de zonas rurales dispersas.

Estas diferencias generan distorsiones importantes en la estructura observada de la población. En niveles territoriales pequeños, incluso pequeñas omisiones pueden alterar significativamente indicadores demográficos derivados. Por esta razón, los sistemas estadísticos implementan procedimientos de validación y ajuste orientados a identificar inconsistencias en la distribución por sexo y edad.

La desagregación etaria también constituye un componente central de los procesos de proyección demográfica. Los métodos cohortes-componentes utilizados por la mayoría de países requieren información detallada sobre estructura poblacional para modelar nacimientos, defunciones y migración. Como consecuencia, errores en la distribución censal inicial pueden propagarse a lo largo de toda la serie de proyecciones futuras.

En el contexto del modelamiento bayesiano, la estructura por sexo y edad puede incorporarse mediante modelos jerárquicos que permiten compartir información entre grupos relacionados y estabilizar estimaciones en dominios con baja densidad poblacional. Esto resulta especialmente útil en áreas pequeñas donde la variabilidad observada puede ser considerablemente alta.

1.1.3 Uso en marcos muestrales

Los conteos censales constituyen la principal base para la construcción de marcos muestrales utilizados en encuestas de hogares y otras operaciones estadísticas. Los sectores y segmentos definidos durante el operativo censal son utilizados posteriormente como unidades primarias de muestreo en gran parte de las encuestas nacionales desarrolladas por los institutos de estadística.

La calidad de un marco muestral depende directamente de la calidad de los conteos censales y de la actualización cartográfica asociada. Cuando existen omisiones territoriales, viviendas no registradas o límites desactualizados, los diseños muestrales pueden introducir sesgos de cobertura y pérdida de eficiencia estadística.

En América Latina y el Caribe, muchos marcos muestrales permanecen vigentes durante periodos intercensales prolongados. Durante estos intervalos, los cambios demográficos y territoriales pueden modificar sustancialmente la distribución espacial de la población. La expansión urbana, la migración interna y la transformación de áreas rurales generan desactualizaciones progresivas en las unidades de muestreo originalmente construidas a partir del censo.

La segmentación censal también cumple un papel operativo fundamental en la implementación de encuestas probabilísticas. Las unidades territoriales utilizadas durante el censo suelen redefinirse y reorganizarse para optimizar costos operativos, carga de trabajo y precisión estadística. Como resultado, la calidad de la información censal afecta directamente el desempeño posterior de múltiples sistemas de encuestas.

En este contexto, mejorar la calidad de los conteos subnacionales no solo fortalece las estadísticas demográficas, sino también toda la infraestructura estadística utilizada posteriormente por los países para producir información social y económica.

1.1.4 Definición de dominios

La producción de estadísticas poblacionales requiere definir dominios geográficos y demográficos sobre los cuales se generan estimaciones e indicadores. Estos dominios corresponden a distintos niveles territoriales utilizados para organización administrativa, planificación pública y análisis estadístico.

El nivel nacional constituye el agregado principal del sistema estadístico y funciona como referencia para la producción de indicadores macrodemográficos y proyecciones oficiales. Sin embargo, gran parte de las decisiones operativas se realizan en escalas territoriales inferiores.

El nivel intermedio, conformado generalmente por departamentos, provincias o estados, representa uno de los principales niveles de descentralización administrativa en América Latina y el Caribe. En estos territorios se ejecutan programas regionales, se distribuyen recursos fiscales y se implementan estrategias sectoriales de salud, educación e infraestructura.

La diferenciación urbano-rural constituye además una dimensión central en la producción estadística regional. Las brechas territoriales entre áreas urbanas y rurales continúan siendo una de las principales características demográficas y socioeconómicas de la región. Como consecuencia, muchos indicadores poblacionales requieren desagregación específica según tipo de área.

A nivel local, los municipios representan una de las principales unidades de gestión territorial. En este nivel se concentran procesos de planeación urbana, focalización social, administración tributaria y provisión de servicios públicos. La precisión de los conteos municipales afecta directamente la asignación presupuestaria y la medición de múltiples indicadores sociales.

Finalmente, el segmento censal constituye la unidad operativa básica del levantamiento. Estas unidades poseen alta resolución espacial y permiten representar con mayor detalle la heterogeneidad territorial. Sin embargo, también presentan mayor sensibilidad a errores de cobertura y problemas de consistencia espacial.

En países como Bolivia, Paraguay y Colombia, los segmentos censales adquieren especial importancia debido a la implementación de censos de hecho y a la necesidad de coordinar operativos intensivos de corta duración. En este contexto, la calidad de la segmentación territorial condiciona directamente la cobertura del operativo y la precisión de los conteos finales.

Desde la perspectiva del modelamiento estadístico, los distintos dominios territoriales conforman una estructura jerárquica de información donde las estimaciones deben mantener coherencia entre niveles geográficos.

Esta jerarquía constituye uno de los elementos centrales en el desarrollo posterior de modelos bayesianos subnacionales orientados a integración de fuentes y ajuste de cobertura.

1.2 Indicadores de interés

La producción de conteos censales tiene como propósito central generar información estadística que permita caracterizar la dinámica demográfica y territorial de la población. A partir de los datos censales es posible construir un amplio conjunto de indicadores utilizados en procesos de planificación, evaluación de políticas públicas, asignación presupuestaria y análisis socioeconómico.

Los indicadores derivados de los censos no solo describen el tamaño de la población, sino también su distribución espacial, estructura etaria, composición por sexo y condiciones territoriales. Estos indicadores constituyen además el punto de partida para procesos posteriores de estimación, proyección demográfica y construcción de estadísticas oficiales.

En América Latina y el Caribe, la creciente demanda de información subnacional ha incrementado la necesidad de producir indicadores con alta desagregación territorial. Los gobiernos requieren estadísticas consistentes para departamentos, municipios, áreas urbanas y rurales, e incluso niveles operativos más pequeños como sectores y segmentos censales.

Sin embargo, la producción de indicadores en dominios pequeños enfrenta limitaciones importantes asociadas a errores de cobertura, omisión censal y variabilidad espacial de los conteos. En consecuencia, muchos indicadores derivados presentan altos niveles de inestabilidad cuando se calculan directamente a partir de los conteos observados.

En este contexto, resulta fundamental distinguir entre:

- conteos poblacionales básicos;
- tasas derivadas;
- y estructuras demográficas.

Cada uno de estos componentes presenta características particulares en términos de interpretación, sensibilidad a errores de cobertura y comportamiento territorial.

1.2.1 Conteos poblacionales

Los conteos poblacionales constituyen el núcleo de la producción estadística demográfica. A través de ellos, los países cuantifican la población presente o residente dentro de un territorio y construyen la base sobre la cual se desarrollan posteriormente las proyecciones demográficas, los marcos muestrales, los indicadores sociales y gran parte de las estadísticas oficiales utilizadas en procesos de planificación pública.

Estos conteos son producidos para múltiples niveles de desagregación territorial y demográfica. En términos generales, la información censal se organiza para el nivel nacional, departamentos o provincias, municipios, áreas urbanas y rurales, así como para distintos grupos de edad y sexo. Esta estructura jerárquica permite caracterizar la distribución espacial de la población y construir estadísticas coherentes entre distintos niveles administrativos.

Sea $N_{i,s,e}$ el número de personas en el dominio geográfico i , sexo $s \in \{M, F\}$ (masculino, femenino) y grupo de edad $e \in \{1, \dots, E\}$. El conteo total de población para una unidad geográfica se obtiene por agregación sobre sexo y edad:

$$N_i = \sum_{s \in \{M, F\}} \sum_{e=1}^E N_{i,s,e}$$

mientras que la población nacional corresponde a la suma sobre todos los dominios territoriales:

$$N = \sum_{i=1}^I N_i$$

La coherencia jerárquica exige que los conteos en niveles inferiores sean consistentes con los totales de los niveles superiores. Denotando con superíndice el nivel jerárquico — $N_j^{(2)}$ para un departamento j , $N_k^{(3)}$ para un municipio k y $N_\ell^{(4)}$ para un segmento ℓ — las restricciones de consistencia son:

$$N_j^{(2)} = \sum_{k: k \subset j} N_k^{(3)}, \quad N_k^{(3)} = \sum_{\ell: \ell \subset k} N_\ell^{(4)}$$

donde la notación $k \subset j$ indica que el municipio k pertenece al departamento j .

Esta coherencia jerárquica es esencial para garantizar la comparabilidad y consistencia de las estadísticas oficiales.

En la práctica, los conteos poblacionales pueden entenderse en distintos niveles. Los conteos observados corresponden directamente a la enumeración realizada durante el operativo censal. Posteriormente, algunos países incorporan procesos de conciliación y ajuste orientados a corregir problemas de cobertura o inconsistencias demográficas. Finalmente, en contextos donde existen limitaciones operativas o necesidad de actualización intercensal, los conteos pueden complementarse mediante procedimientos de estimación estadística e integración de múltiples fuentes de información.

Uno de los principales desafíos asociados a los conteos poblacionales corresponde a su sensibilidad frente a errores de cobertura territorial. A medida que aumenta el nivel de desagregación geográfica, incluso pequeñas omisiones pueden generar distorsiones importantes sobre indicadores derivados. Este problema es particularmente visible en municipios pequeños, áreas rurales dispersas o segmentos censales con baja densidad poblacional, donde la omisión de algunos hogares puede modificar significativamente estructuras etarias, tasas de dependencia o indicadores sociales.

En América Latina y el Caribe, estas dificultades adquieren una relevancia especial debido a la heterogeneidad territorial de la región. La expansión urbana acelerada, el crecimiento de asentamientos informales, la movilidad poblacional y las diferencias en capacidad operativa entre países generan importantes desafíos para la actualización cartográfica y la cobertura completa del operativo censal. Como consecuencia, la precisión espacial de los conteos puede variar considerablemente entre territorios.

Desde una perspectiva estadística, los conteos poblacionales no deben interpretarse como valores exactos libres de error, sino como observaciones sujetas a incertidumbre y condicionadas por las limitaciones propias del operativo censal. Esta interpretación resulta fundamental para el desarrollo posterior de modelos proba-

bilísticos de población, donde los conteos observados se entienden como aproximaciones de una población subyacente no completamente observable.

1.2.2 Tasas derivadas

A partir de los conteos poblacionales es posible construir un amplio conjunto de tasas e indicadores utilizados para describir dinámicas demográficas, caracterizar condiciones territoriales y apoyar procesos de planificación pública. Mientras los conteos absolutos permiten cuantificar el tamaño de la población, las tasas derivadas facilitan la comparación entre territorios con estructuras y magnitudes poblacionales diferentes.

Este tipo de indicadores resulta fundamental para el análisis territorial, ya que permite transformar los conteos censales en medidas comparables entre regiones, municipios o áreas urbanas y rurales. De esta manera, es posible evaluar fenómenos asociados a concentración poblacional, envejecimiento, dependencia demográfica o composición por sexo bajo una escala relativa más adecuada para el análisis estadístico.

Entre los indicadores más utilizados se encuentran la densidad poblacional, las tasas de dependencia, las razones de masculinidad y los índices de envejecimiento. Cada uno de ellos resume distintas dimensiones de la estructura demográfica y constituye un insumo importante para la toma de decisiones institucionales.

La densidad poblacional permite medir la relación entre población y superficie territorial. Para un territorio (i), esta puede expresarse como:

$$D_i = \frac{N_i}{A_i}$$

donde N_i representa la población observada y A_i el área geográfica correspondiente. Este indicador es ampliamente utilizado en procesos de planificación urbana, expansión de infraestructura, análisis ambiental y organización de servicios públicos.

Por su parte, la razón de masculinidad describe la relación entre población masculina y femenina dentro de un territorio determinado:

$$RM_i = \frac{N_{i,M}}{N_{i,F}} \times 100$$

donde $N_{i,M} = \sum_e N_{i,M,e}$ es la población masculina y $N_{i,F} = \sum_e N_{i,F,e}$ la femenina del territorio i . Este indicador permite identificar desequilibrios demográficos asociados a migración, envejecimiento o cambios en la estructura poblacional.

Otro indicador ampliamente utilizado corresponde a la tasa de dependencia demográfica, la cual relaciona la población potencialmente dependiente con la población en edades productivas:

$$TD_i = \frac{N_{i,[0,14]} + N_{i,[65+]}}{N_{i,[15,64]}} \times 100$$

donde $N_{i,[a,b]} = \sum_s \sum_{e: e \in [a,b]} N_{i,s,e}$ denota la población del territorio i en el intervalo de edad $[a, b]$. De manera complementaria, el índice de envejecimiento evalúa el peso relativo de la población adulta mayor frente a la población joven:

$$IE_i = \frac{N_{i,[65+]}}{N_{i,[0,14]}} \times 100$$

Estos indicadores desempeñan un papel central en la planificación territorial y sectorial. Su utilización es frecuente en procesos de asignación presupuestaria, focalización de programas sociales, evaluación de necesidades de infraestructura y análisis de demanda potencial de servicios públicos.

Sin embargo, las tasas derivadas presentan una sensibilidad considerable frente a errores de cobertura censal. Debido a que muchas de ellas se construyen como razones entre subgrupos poblacionales específicos, pequeñas omisiones o inconsistencias pueden generar fluctuaciones importantes en los resultados observados. Este fenómeno se vuelve particularmente evidente en dominios geográficos pequeños, donde diferencias reducidas en los conteos absolutos producen variaciones relativamente grandes en los indicadores derivados.

En municipios con baja población o segmentos censales reducidos, las tasas pueden presentar comportamientos altamente inestables, especialmente cuando existen problemas de omisión diferencial por edad, sexo o localización territorial. En América Latina y el Caribe, estas dificultades suelen amplificarse debido a la heterogeneidad territorial, la expansión metropolitana acelerada, los procesos migratorios y las diferencias operativas observadas entre países y regiones.

Como consecuencia, la producción de indicadores subnacionales requiere mecanismos de validación y ajuste orientados a mejorar estabilidad estadística y coherencia territorial. Desde esta perspectiva, los enfoques de modelamiento permiten complementar los métodos tradicionales mediante estrategias que incorporan integración de información auxiliar y representación explícita de la incertidumbre asociada a los conteos base.

1.2.3 Estructuras etarias

La estructura por edad de la población constituye uno de los componentes centrales del análisis demográfico. Su estudio permite comprender los cambios asociados a fecundidad, mortalidad, migración, envejecimiento y transición demográfica, así como las diferencias territoriales en la dinámica poblacional de los países.

Los censos de población representan la principal fuente de información para caracterizar estas estructuras con altos niveles de desagregación geográfica. A partir de los conteos por edad y sexo es posible construir pirámides poblacionales, relaciones de dependencia, índices de envejecimiento y proyecciones demográficas, elementos fundamentales para la planificación social y económica.

Sea $N_{i,e} = \sum_{s \in \{M,F\}} N_{i,s,e}$ la población del área i en el grupo de edad e , obtenida por suma sobre ambos sexos. La participación relativa de cada grupo etario dentro de la población total del territorio puede expresarse como:

$$p_{i,e} = \frac{N_{i,e}}{N_i}$$

donde $N_i = \sum_{e=1}^E N_{i,e}$ es la población total del territorio. Por construcción, $\sum_{e=1}^E p_{i,e} = 1$.

En la práctica, la estructura etaria suele organizarse utilizando grupos quinquenales de edad:

$$0 - 4, 5 - 9, 10 - 14, \dots, 80+$$

debido a que esta agrupación proporciona mayor estabilidad demográfica y facilita la comparabilidad entre países y periodos censales. Adicionalmente, los grupos quinquenales constituyen la base utilizada en la mayoría

de modelos de proyección poblacional y análisis demográficos oficiales.

Los indicadores de cambio demográfico más utilizados se expresan directamente en términos de $N_{i,[a,b]}$. El índice de envejecimiento relaciona la población adulta mayor con la población joven:

$$IE_i = \frac{N_{i,[65+]}}{N_{i,[0,14]}} \times 100$$

La tasa de dependencia demográfica total evalúa la presión potencial sobre la población en edades productivas y coincide con TD_i definida en la sección anterior:

$$TD_i = \frac{N_{i,[0,14]} + N_{i,[65+]}}{N_{i,[15,64]}} \times 100$$

Estos indicadores son ampliamente utilizados en procesos de planificación pública debido a que permiten anticipar necesidades asociadas a educación, salud, protección social, empleo e infraestructura. Territorios con estructuras jóvenes suelen demandar mayores inversiones en sistemas educativos y servicios materno-infantiles, mientras que áreas con envejecimiento avanzado requieren una mayor capacidad de atención en salud y sistemas de cuidado.

En América Latina y el Caribe, la estructura etaria presenta fuertes contrastes territoriales. Mientras algunas áreas metropolitanas muestran procesos avanzados de envejecimiento poblacional y reducción de fecundidad, otras regiones mantienen estructuras considerablemente más jóvenes asociadas a mayores niveles de natalidad y menor transición demográfica. Estas diferencias reflejan la elevada heterogeneidad demográfica de la región y generan importantes desafíos para la producción de estadísticas subnacionales comparables.

La construcción de estructuras etarias confiables enfrenta además importantes limitaciones operativas. Los errores de cobertura censal no afectan homogéneamente a todos los grupos de edad. En muchos países de la región, la omisión censal tiende a concentrarse en niños pequeños, hombres jóvenes, migrantes, población indígena y habitantes de zonas rurales dispersas. Como consecuencia, la distribución observada por edad puede diferir significativamente de la estructura poblacional verdadera.

Este problema se intensifica en dominios geográficos pequeños. En municipios con baja población o segmentos censales reducidos, pequeñas diferencias en los conteos observados pueden modificar considerablemente la forma de la estructura etaria y generar indicadores altamente inestables. La variabilidad observada suele aumentar aún más cuando los grupos poblacionales son desagregados simultáneamente por edad, sexo y localización territorial.

Adicionalmente, las estructuras etarias cumplen un papel central en los procesos de proyección demográfica y estimación intercensal. Los modelos cohortes-componentes utilizados por la mayoría de oficinas nacionales de estadística dependen directamente de la calidad de la distribución inicial por edad y sexo. En consecuencia, errores presentes en los conteos censales pueden propagarse hacia estimaciones futuras y afectar la consistencia temporal de las proyecciones oficiales.

Desde la perspectiva del modelamiento estadístico, las estructuras etarias pueden entenderse como realizaciones sujetas a incertidumbre y error de cobertura. Bajo este enfoque, los modelos bayesianos jerárquicos permiten incorporar dependencia entre grupos de edad relacionados, estabilizar estimaciones en áreas con información limitada e integrar múltiples fuentes auxiliares para mejorar la coherencia territorial y demográfica de las estimaciones poblacionales.

1.3 Formulación del problema de subcobertura, no respuesta y omisión censal

Uno de los principales desafíos de los censos modernos corresponde a los problemas de cobertura asociados al operativo de enumeración. Aunque el objetivo conceptual del censo consiste en registrar exhaustivamente toda la población presente o residente dentro del territorio nacional, en la práctica siempre existen diferencias entre la población efectivamente observada y la población real presente en el territorio.

Estas diferencias surgen por múltiples razones. Algunas personas no son censadas, ciertas viviendas quedan fuera del operativo, algunos registros son duplicados y, en otros casos, existen errores en la asignación territorial de la información recolectada. Como resultado, los conteos censales deben entenderse como realizaciones observadas de un proceso de enumeración sujeto a limitaciones operativas, errores cartográficos y dificultades de cobertura.

Formalmente, sea $Y_{i,s,e}$ el conteo observado en el operativo censal para el territorio i , sexo s y grupo de edad e , y sea $N_{i,s,e}$ la población verdadera correspondiente. La relación entre ambos puede representarse como:

$$Y_{i,s,e} = N_{i,s,e} - O_{i,s,e} + D_{i,s,e} + C_{i,s,e}$$

donde $O_{i,s,e}$ representa la omisión censal, $D_{i,s,e}$ la duplicación de personas y $C_{i,s,e}$ los errores asociados a clasificación o asignación territorial. Bajo esta formulación, los conteos observados no constituyen una medición exacta de la población, sino una aproximación afectada por distintos mecanismos de error.

En América Latina y el Caribe, la subcobertura censal presenta además una marcada heterogeneidad territorial. La omisión no ocurre aleatoriamente sobre la población ni sobre el territorio. Por el contrario, suele concentrarse en contextos específicos como asentamientos informales, zonas rurales dispersas, territorios indígenas, áreas de frontera o sectores urbanos con elevada movilidad residencial. Estas características generan patrones espaciales de cobertura diferencial que afectan directamente la calidad de los conteos subnacionales.

La no respuesta constituye un problema adicional dentro del proceso censal. Incluso cuando una vivienda logra ser efectivamente enumerada, algunas variables pueden quedar incompletas debido a ausencia de informantes, rechazo parcial, inconsistencias durante la entrevista o errores de captura. Este fenómeno afecta particularmente variables socioeconómicas y laborales, reduciendo la completitud analítica de la información censal.

La combinación entre subcobertura, omisión y no respuesta produce efectos acumulativos sobre múltiples procesos estadísticos posteriores. Las proyecciones demográficas, la construcción de marcos muestrales, la estimación de indicadores sociales y los procesos de focalización territorial dependen directamente de la calidad de los conteos base. En consecuencia, errores relativamente pequeños en la enumeración pueden propagarse posteriormente hacia distintas operaciones estadísticas oficiales.

Estos problemas adquieren una relevancia aún mayor en niveles geográficos pequeños. En municipios con baja población o segmentos censales reducidos, la omisión de un número limitado de viviendas puede alterar significativamente las estructuras poblacionales observadas. Este fenómeno se intensifica cuando los errores de cobertura afectan diferencialmente determinados grupos de edad, sexo o condiciones socioeconómicas.

Adicionalmente, la rápida transformación territorial observada en muchos países de la región ha incrementado la complejidad operativa de los censos. La expansión urbana acelerada, el crecimiento de asentamientos informales y los procesos migratorios dificultan la actualización cartográfica permanente y reducen la capacidad de cobertura completa del operativo censal.

Frente a este escenario, los sistemas estadísticos han comenzado a complementar los enfoques tradicionales de conciliación censal mediante estrategias de integración de múltiples fuentes de información. Los registros ad-

ministrativos, las imágenes satelitales, los preconteos operativos y otras fuentes auxiliares permiten identificar inconsistencias territoriales y fortalecer la estimación de poblaciones subenumeradas.

En este libro, el interés principal no se centra en modelar directamente tasas de cobertura, sino en estimar conteos poblacionales en segmentos censales donde existen problemas de cobertura, omisión o inconsistencias territoriales. Bajo esta perspectiva, los conteos observados se interpretan como información parcial sobre una población subyacente cuya magnitud real debe inferirse utilizando información auxiliar y estructuras jerárquicas coherentes con la organización territorial del censo.

Desde esta perspectiva, los modelos bayesianos ofrecen un marco flexible para integrar múltiples fuentes de información, representar explícitamente la incertidumbre asociada a los conteos observados y estabilizar estimaciones en dominios geográficos pequeños. Los capítulos posteriores desarrollan estos elementos metodológicos y presentan estrategias orientadas específicamente a la estimación subnacional de conteos poblacionales en segmentos censales bajo esquemas probabilísticos modernos.

Integración de Fuentes de Información

La estimación de conteos poblacionales en unidades territoriales pequeñas no puede resolverse adecuadamente mediante el análisis directo de los datos censales. Las limitaciones de cobertura, la variabilidad asociada a dominios con baja densidad poblacional y la disponibilidad creciente de información auxiliar de distinta naturaleza hacen necesario un marco metodológico que integre múltiples fuentes bajo un esquema estadístico coherente.

Este capítulo presenta los principios de modelamiento que fundamentan los modelos bayesianos de estimación subnacional, describe las principales fuentes de información disponibles en América Latina y el Caribe y caracteriza las variables explicativas utilizadas para predecir la distribución espacial de la población.

2.1 Principios de modelamiento

Los modelos estadísticos utilizados para la estimación subnacional de conteos poblacionales deben ser capaces de representar adecuadamente la naturaleza discreta y no negativa de los datos, de incorporar información auxiliar proveniente de fuentes heterogéneas, de producir estimaciones coherentes entre niveles territoriales y de cuantificar explícitamente la incertidumbre de las estimaciones resultantes. El cumplimiento de estos requisitos condiciona tanto la elección de la familia distribucional del modelo como el marco inferencial adoptado.

2.1.1 Modelos de conteo

Los conteos poblacionales son variables aleatorias discretas no negativas. Esta naturaleza fundamental distingue el problema de estimación subnacional de los problemas de regresión con variables continuas y exige el uso de modelos de probabilidad apropiados para datos de conteo.

La distribución de Poisson constituye el punto de partida canónico para el modelamiento de conteos. Si Y_i denota el conteo observado en el segmento i , el modelo de Poisson establece:

$$Y_i \mid \lambda_i \sim \text{Poisson}(\lambda_i)$$

donde $\lambda_i > 0$ es el parámetro de intensidad, que representa simultáneamente la media y la varianza de la distribución. La función de masa de probabilidad es:

$$P(Y_i = y \mid \lambda_i) = \frac{e^{-\lambda_i} \lambda_i^y}{y!}, \quad y = 0, 1, 2, \dots$$

La parametrización log-lineal del modelo relaciona el logaritmo de la intensidad con un predictor lineal de covariables:

$$\log(\lambda_i) = \mathbf{x}_i^\top \beta + u_i$$

donde $\mathbf{x}_i$ es el vector de covariables auxiliares del segmento i , β es el vector de coeficientes y u_i es un efecto aleatorio que captura la variabilidad no explicada por las covariables.

Un supuesto fundamental del modelo de Poisson es la equidispersión: $\mathbb{E}[Y_i | \lambda_i] = \text{Var}(Y_i | \lambda_i) = \lambda_i$. En la práctica, los conteos poblacionales suelen exhibir sobredispersión, es decir, una varianza observada mayor a la media. Este fenómeno puede originarse en heterogeneidad no observada entre segmentos, clustering espacial o errores de especificación del predictor.

Para tratar la sobredispersión, el modelo binomial negativo introduce un parámetro adicional $\phi > 0$ que controla la varianza:

$$Y_i | \mu_i, \phi \sim \text{NegBin}(\mu_i, \phi)$$

con función de masa de probabilidad:

$$P(Y_i = y | \mu_i, \phi) = \binom{y + \phi - 1}{y} \left(\frac{\phi}{\phi + \mu_i} \right)^\phi \left(\frac{\mu_i}{\phi + \mu_i} \right)^y$$

En este caso, $\mathbb{E}[Y_i] = \mu_i$ y $\text{Var}(Y_i) = \mu_i + \mu_i^2 / \phi$. A medida que $\phi \rightarrow \infty$, la distribución binomial negativa converge hacia la Poisson.

Alternativamente, la sobredispersión puede modelarse mediante la inclusión de efectos aleatorios con distribución gamma en el predictor de Poisson. Si $\lambda_i = \mu_i \cdot \gamma_i$ con $\gamma_i \sim \text{Gamma}(\phi, \phi)$, la distribución marginal de Y_i resulta binomial negativa con parámetros (μ_i, ϕ) . Esta representación facilita la interpretación de los efectos aleatorios como multiplicadores de la intensidad esperada en cada segmento.

En contextos de modelamiento jerárquico, la elección entre Poisson y binomial negativa debe fundamentarse tanto en consideraciones estadísticas —diagnóstico de sobredispersión— como en la disponibilidad de información auxiliar: una especificación más rica de covariables puede reducir la sobredispersión aparente al explicar parte de la heterogeneidad entre segmentos.

2.1.2 Requerimientos de estimación subnacional

La estimación de conteos en niveles territoriales pequeños impone requerimientos adicionales que van más allá de la simple elección de una distribución de probabilidad. Estos requerimientos se derivan de la naturaleza jerárquica del problema y de las condiciones operativas en las que se producen los datos.

Coherencia jerárquica. Las estimaciones en niveles inferiores deben ser consistentes con los totales conocidos o estimados en niveles superiores. Si $\hat{N}_k^{(3)}$ denota la estimación del municipio k y $\hat{N}_j^{(2)}$ la del departamento j , la coherencia exige:

$$\hat{N}_j^{(2)} = \sum_{k: k \subset j} \hat{N}_k^{(3)}$$

Esta restricción de coherencia entre niveles es fundamental para garantizar la consistencia interna del sistema estadístico y constituye un criterio de validación esencial de cualquier modelo de estimación subnacional.

Estimación en dominios pequeños. En segmentos censales con baja densidad poblacional, los conteos observados son altamente variables y presentan elevada incertidumbre. En estos dominios, los estimadores directos basados únicamente en la información del segmento son insuficientes y deben complementarse con información auxiliar proveniente de otras fuentes o de dominios relacionados.

Propagación de incertidumbre. Las estimaciones subnacionales deben acompañarse de medidas de incertidumbre que reflejen adecuadamente la variabilidad del proceso. En contextos donde los conteos observados son escasos o de baja calidad, la incertidumbre puede ser considerable, y su cuantificación explícita es esencial para el uso responsable de las estimaciones en procesos de planificación y asignación de recursos.

Estabilidad temporal. Cuando se dispone de información de periodos censales anteriores, el modelo debe ser capaz de incorporar dicha información de forma coherente, reconociendo que la población cambia en el tiempo y que la relevancia de la información histórica decrece a medida que aumenta el intervalo temporal.

2.1.3 Justificación del enfoque bayesiano

El enfoque bayesiano ofrece un marco de inferencia particularmente apropiado para la estimación subnacional de conteos poblacionales. Sus ventajas frente a los métodos frecuentistas se derivan directamente de las características del problema.

Representación explícita de la incertidumbre. En el paradigma bayesiano, todos los parámetros desconocidos se tratan como variables aleatorias cuya incertidumbre se cuantifica mediante distribuciones de probabilidad. La distribución posterior $p(\theta \mid \mathbf{Y})$ encapsula el estado de conocimiento sobre la población en cada segmento dado el conjunto de datos observados:

$$p(\theta \mid \mathbf{Y}) \propto p(\mathbf{Y} \mid \theta) p(\theta)$$

Esta representación permite calcular intervalos de credibilidad, probabilidades de excedencia y cualquier otra cantidad de interés derivada de la distribución posterior.

Incorporación de información previa. Las distribuciones a priori permiten incorporar conocimiento demográfico sustantivo sobre la estructura de la población, restricciones de positividad, información de censos anteriores o expertos en el área. A diferencia de los métodos frecuentistas, el marco bayesiano provee un mecanismo formal para integrar esta información de manera coherente con los datos observados.

Estimación simultánea de múltiples dominios. Los modelos jerárquicos bayesianos permiten estimar simultáneamente la población en todos los segmentos, compartiendo información entre dominios relacionados. Los parámetros del nivel superior —como los coeficientes de las covariables— se estiman a partir de la información conjunta de todos los segmentos, lo que permite que los dominios con mejor cobertura contribuyan a estabilizar las estimaciones en dominios con datos limitados.

Coherencia probabilística. Las estimaciones bayesianas son coherentes por construcción: cualquier función de los parámetros puede estimarse a partir de la distribución posterior, y los intervalos de credibilidad tienen interpretación probabilística directa. Esta propiedad es especialmente valiosa cuando se requiere reportar incertidumbre a distintos niveles de desagregación territorial.

La estimación de la distribución posterior en modelos complejos se realiza mediante métodos de Monte Carlo por cadenas de Markov (MCMC). Entre los algoritmos más utilizados en la práctica se encuentran el muestreo de Gibbs, el algoritmo de Metropolis-Hastings y, más recientemente, el método de Monte Carlo Hamiltoniano

(HMC) implementado en Stan. Estos algoritmos permiten obtener muestras de la distribución posterior en modelos con alta dimensionalidad y estructuras jerárquicas complejas.

2.1.4 Integración de múltiples fuentes

El marco bayesiano provee un mecanismo natural para integrar información proveniente de múltiples fuentes bajo un esquema probabilístico coherente. La integración se realiza a través de la función de verosimilitud, que puede descomponerse en contribuciones de distintas fuentes de información, y a través de las distribuciones a priori, que capturan conocimiento previo sobre los parámetros.

Supóngase que se dispone de tres fuentes de información para el segmento i : el conteo censal observado $Y_i^{(C)}$, el preconteo operativo $Y_i^{(P)}$ y un conteo derivado de registros administrativos $Y_i^{(A)}$. Bajo el supuesto de independencia condicional entre fuentes dado el parámetro de población N_i , la verosimilitud conjunta puede escribirse como:

$$p(Y_i^{(C)}, Y_i^{(P)}, Y_i^{(A)} | N_i, \theta) = p(Y_i^{(C)} | N_i, \theta^{(C)}) \cdot p(Y_i^{(P)} | N_i, \theta^{(P)}) \cdot p(Y_i^{(A)} | N_i, \theta^{(A)})$$

donde $\theta^{(C)}$, $\theta^{(P)}$ y $\theta^{(A)}$ son los parámetros específicos de cada modelo de medición. Esta factorización permite modelar de forma separada las características de cada fuente —su cobertura, sus sesgos y su variabilidad— sin imponer restricciones artificiosas de equivalencia entre ellas.

El supuesto de independencia condicional entre fuentes es una simplificación que puede no ser siempre válida. En la práctica, distintas fuentes pueden compartir errores comunes asociados a factores territoriales no observados. Este problema puede mitigarse parcialmente mediante la inclusión de efectos aleatorios compartidos entre fuentes en el modelo jerárquico.

2.1.5 Relación con Small Area Estimation

Los modelos bayesianos de estimación poblacional subnacional se inscriben dentro del campo más amplio de la Estimación en Áreas Pequeñas (*Small Area Estimation*, SAE). Este campo metodológico desarrolla métodos estadísticos orientados a producir estimaciones confiables en dominios con tamaño muestral insuficiente para la estimación directa.

Los modelos SAE se clasifican generalmente en dos grandes categorías según el nivel en el que se especifica la estructura del modelo:

Modelos a nivel de área. Estos modelos operan sobre estadísticos agregados calculados para cada dominio. El modelo de Fay-Herriot es el referente clásico: se postula que la estimación directa $\hat{\theta}_i$ del parámetro de interés θ_i en el área i satisface:

$$\hat{\theta}_i = \theta_i + e_i, \quad e_i | \sigma_i^2 \sim \mathcal{N}(0, \sigma_i^2)$$

donde σ_i^2 se supone conocido, y el modelo de enlace conecta θ_i con las covariables auxiliares:

$$\theta_i = \mathbf{x}_i^\top \beta + u_i, \quad u_i \sim \mathcal{N}(0, \sigma_u^2)$$

Modelos a nivel de unidad. Estos modelos incorporan información a nivel de observación individual. El modelo de Battese-Harter-Fuller es el referente en este caso, y permite explotar la variabilidad dentro de los dominios para mejorar la estimación.

En el contexto de la estimación de conteos poblacionales censales, los modelos más apropiados son generalmente de nivel de área, dado que la información disponible suele estar agregada a nivel de segmento. La extensión bayesiana del modelo de Fay-Herriot para conteos —utilizando distribuciones de Poisson o binomial negativa en lugar de la distribución normal— constituye la base de los modelos desarrollados en los capítulos siguientes.

Una diferencia importante entre el enfoque SAE clásico y el bayesiano reside en el tratamiento de los hiperparámetros del modelo, como la varianza de los efectos aleatorios σ_u^2 . En el enfoque frecuentista, estos se estiman mediante máxima verosimilitud restringida (REML). En el enfoque bayesiano, se les asigna una distribución a priori y se estiman conjuntamente con los demás parámetros, lo que permite propagar su incertidumbre hacia las estimaciones finales.

2.2 Identificación de fuentes

La calidad de los modelos bayesianos de estimación subnacional depende críticamente de la disponibilidad y pertinencia de las fuentes de información auxiliar incorporadas. En América Latina y el Caribe, el conjunto de fuentes disponibles varía considerablemente entre países, pero puede organizarse en cuatro categorías principales: medición de cobertura censal, preconteos operativos, registros administrativos y fuentes satelitales.

2.2.1 Medición de cobertura a nivel de segmento

La cobertura censal es el primer elemento que debe caracterizarse antes de iniciar cualquier proceso de estimación subnacional. La cobertura hace referencia a la proporción de la población real que fue efectivamente enumerada durante el operativo censal. Su complemento —la tasa de omisión censal— cuantifica la fracción de la población no observada.

Formalmente, sea N_i la población verdadera del segmento i y $Y_i^{(C)}$ el conteo observado durante el censo. La tasa de cobertura del segmento se define como:

$$c_i = \frac{Y_i^{(C)}}{N_i}$$

y la tasa de omisión correspondiente como $\omega_i = 1 - c_i$. Dado que N_i no es directamente observable, la estimación de c_i requiere el uso de métodos indirectos o información auxiliar.

En la práctica, la medición de cobertura a nivel de segmento se realiza a través de tres mecanismos principales. El primero consiste en encuestas postcensales de cobertura, diseñadas específicamente para estimar la tasa de omisión mediante una operación de campo independiente al censo. El segundo utiliza métodos de conciliación demográfica que comparan los conteos censales con proyecciones independientes basadas en estadísticas vitales. El tercero emplea técnicas de captura-recaptura que cruzan el padrón censal con registros administrativos para estimar la población no observada.

La heterogeneidad espacial de la cobertura censal es una característica sistemática en todos los países de la región. La cobertura tiende a ser menor en áreas rurales dispersas, asentamientos informales, zonas de difícil acceso, territorios indígenas y contextos urbanos con alta movilidad residencial. Esta heterogeneidad espacial

motiva la necesidad de modelar la tasa de cobertura como una función de características territoriales observables.

Bajo el marco bayesiano, la cobertura del segmento puede modelarse como un parámetro latente con distribución a priori que refleje el conocimiento previo sobre su variabilidad entre segmentos. La incorporación de covariables territoriales como predictores de la cobertura permite que el modelo utilice la información disponible para estimar la omisión diferencial entre dominios.

2.2.2 Preconteos y segmentación

Los preconteos operativos constituyen una de las fuentes auxiliares más directamente vinculadas a la estimación de la población en segmentos censales. Estas operaciones, realizadas durante la fase de actualización cartográfica previa al levantamiento censal, producen información sobre el número aproximado de viviendas o estructuras habitacionales presentes en cada unidad operativa.

La segmentación censal es el proceso mediante el cual el territorio nacional se divide en unidades operativas de trabajo, denominadas segmentos o áreas de enumeración. Cada segmento es asignado a un censista y está diseñado para ser enumerable en el tiempo operativo disponible. Los criterios de segmentación varían entre países: algunos utilizan como criterio el número esperado de viviendas, otros priorizan continuidad espacial o accesibilidad geográfica.

Sea P_i el preconteo de viviendas registrado en el segmento i durante la actualización cartográfica. La relación entre el preconteo y la población esperada puede expresarse mediante un modelo de regresión log-lineal:

$$\log(N_i) = \alpha_0 + \alpha_1 \log(P_i) + \eta_i$$

donde α_0 y α_1 son parámetros a estimar y η_i es un error residual que captura la variabilidad no explicada por el preconteo. El parámetro α_1 puede interpretarse como la elasticidad de la población respecto al preconteo: si $\alpha_1 = 1$, la relación entre viviendas y personas es proporcional; si $\alpha_1 > 1$, segmentos con más viviendas tienen mayor tamaño medio de hogar.

En los capítulos siguientes, esta misma cantidad —el número de viviendas o estructuras habitacionales del segmento— se denota V_i y desempeña el papel de offset en el modelo de conteos poblacionales (Capítulo 5). P_i y V_i deben entenderse, por tanto, como notaciones equivalentes del preconteo de estructuras; se conserva P_i en este capítulo por continuidad con la formulación de regresión log-lineal aquí presentada.

El preconteo es especialmente valioso en contextos donde el operativo censal no logró cobertura completa, dado que provee una señal anticipada sobre la magnitud poblacional esperada que es independiente del proceso de enumeración. Su principal limitación es la distancia temporal entre la actualización cartográfica y el momento censal: en contextos con crecimiento urbano acelerado, los preconteos pueden quedar desactualizados rápidamente.

2.2.3 Registros administrativos (variables proxy)

Los registros administrativos son bases de datos generadas por entidades gubernamentales como resultado de sus funciones institucionales. A diferencia de los censos, no tienen por objetivo la medición estadística de la población, sino la gestión de servicios, beneficios o trámites administrativos. Sin embargo, en la medida en que

su cobertura es razonablemente alta y su definición territorial compatible con los segmentos censales, pueden utilizarse como variables proxy de la magnitud poblacional.

Entre los registros administrativos más utilizados en modelos de estimación subnacional en América Latina y el Caribe se encuentran:

Registros civiles. Los sistemas de registro de nacimientos, defunciones y matrimonios proporcionan información sobre eventos demográficos ocurridos en el territorio. La densidad de nacimientos o defunciones por unidad territorial es un indicador parcial de la magnitud y composición de la población subyacente.

Padrones electorales. Los padrones de electores habilitados para votar proporcionan un conteo de personas adultas registradas con dirección conocida en cada territorio. Su cobertura está condicionada por la participación en el sistema electoral y puede ser incompleta en poblaciones jóvenes, migrantes o con baja interacción institucional.

Registros de afiliación a sistemas de salud y seguridad social. Los sistemas de salud pública o los registros de afiliación a la seguridad social contienen información sobre personas que acceden regularmente a servicios institucionales. Su cobertura depende del grado de formalidad laboral y del acceso efectivo a los servicios en cada territorio.

Registros de beneficiarios de programas sociales. Los padrones de beneficiarios de programas de transferencias condicionadas u otros programas sociales focalizados proporcionan información sobre hogares en situación de vulnerabilidad. Aunque su cobertura no es universal, pueden ser especialmente informativos en áreas con alta concentración de población en condición de pobreza.

Sea $A_{i,r}$ el conteo proveniente del registro r para el segmento i . Su uso como variable explicativa en el modelo de estimación se justifica por la correlación esperada con la población subyacente N_i :

$$A_{i,r} \approx c_{i,r} \cdot N_i$$

donde $c_{i,r} \in (0, 1]$ es la tasa de cobertura del registro r en el segmento i . La transformación logarítmica $\log(A_{i,r} + 1)$ estabiliza la varianza y facilita la incorporación de estos conteos como predictores en el modelo log-lineal.

2.2.4 Fuentes satelitales

Las imágenes satelitales y los productos de percepción remota han ampliado considerablemente el conjunto de covariables disponibles para la estimación poblacional subnacional. Su principal ventaja es la cobertura territorial universal, la continuidad temporal y la independencia respecto a los sistemas estadísticos institucionales.

Las fuentes satelitales más utilizadas en estimación poblacional pueden agruparse en las siguientes categorías:

Luminosidad nocturna. Los datos de radiancia nocturna capturados por sensores satelitales, como el producto VIIRS-DNB de la NOAA, permiten identificar áreas con presencia de iluminación artificial. La intensidad lumínica nocturna está correlacionada con la actividad económica y la densidad de asentamientos humanos permanentes. Sea L_i el valor medio de luminosidad nocturna en el segmento i ; su transformación logarítmica $\log(L_i + 1)$ es utilizada frecuentemente como predictor de la población.

Área construida y cobertura urbana. Los productos de clasificación de uso del suelo derivados de imágenes ópticas como Sentinel-2 o Landsat permiten estimar la proporción de área construida dentro de cada segmen-

to. El producto Global Human Settlement Layer (GHSL) de la Comisión Europea ofrece estimaciones de área construida a resolución de 100 metros con cobertura global.

Índice de vegetación de diferencia normalizada (NDVI). El NDVI mide la densidad y vitalidad de la vegetación a partir de la reflectancia en bandas del infrarrojo cercano y el rojo visible. Valores bajos de NDVI en áreas no áridas generalmente indican presencia de infraestructura construida y asentamientos urbanos, mientras que valores altos corresponden a áreas con cobertura vegetal densa.

Temperatura superficial terrestre (LST). Las islas de calor urbano, reflejadas en valores elevados de temperatura superficial, constituyen un indicador indirecto de densidad de infraestructura y actividad humana.

Modelos digitales de elevación. La topografía del terreno condiciona la distribución espacial de la población. Los modelos de elevación digital como SRTM o ALOS permiten derivar variables como altitud media, pendiente y orientación del terreno, que están correlacionadas con la densidad y distribución de los asentamientos humanos.

La integración de covariables satelitales en el modelo requiere procesar las imágenes hasta el nivel del segmento censal, lo que implica operaciones de reproyección, remuestreo y estadísticas zonales. La resolución espacial de las imágenes debe ser compatible con el tamaño de los segmentos: resoluciones muy gruesas pueden introducir errores de asignación en segmentos pequeños, mientras que resoluciones muy finas pueden aumentar el costo computacional sin beneficio estadístico apreciable.

2.3 Variables explicativas

La calidad predictiva del modelo de estimación subnacional depende directamente de la selección y construcción de las variables explicativas incorporadas como covariables. Estas variables pueden organizarse en tres grandes grupos según su naturaleza conceptual: variables demográficas, variables socioeconómicas y variables espaciales.

2.3.1 Variables demográficas

Las variables demográficas capturan características de la estructura y dinámica de la población que están directamente relacionadas con la magnitud y distribución de los conteos en cada segmento.

Estructura por sexo y edad. La composición demográfica de la población condiciona la demanda de servicios y la organización territorial de los asentamientos. La proporción de población en edades productivas (15–64 años), la proporción de adultos mayores (65 años y más) y la proporción de niños menores de 15 años son indicadores relevantes de la estructura etaria del segmento. Formalmente:

$$p_{i,[a,b]} = \frac{N_{i,[a,b]}}{N_i}, \quad \sum_e p_{i,e} = 1$$

Razón de masculinidad. La distribución por sexo puede ser informativa en contextos con migración diferencial o actividades económicas con sesgo de género. La razón de masculinidad $RM_i = N_{i,M}/N_{i,F} \times 100$ puede utilizarse como predictor complementario.

Tasa de fecundidad implícita. En territorios con registros de nacimientos disponibles, la relación entre nacimientos registrados y población femenina en edad reproductiva proporciona una estimación indirecta de la

dinámica de crecimiento natural del segmento.

Tamaño medio del hogar. El número promedio de personas por vivienda constituye un multiplicador fundamental en la relación entre el preconteo de viviendas y la estimación de personas. En América Latina y el Caribe, el tamaño medio del hogar presenta heterogeneidad territorial significativa, con valores más altos en áreas rurales y en hogares con mayor número de hijos.

2.3.2 Variables socioeconómicas

Las condiciones socioeconómicas del territorio están correlacionadas con la densidad de población, la calidad de la enumeración censal y la cobertura de los registros administrativos. Su incorporación como covariables permite al modelo capturar parte de la heterogeneidad no observada entre segmentos.

Índice de necesidades básicas insatisfechas (NBI). El NBI resume un conjunto de carencias básicas del hogar —acceso a agua potable, saneamiento, educación, hacinamiento, calidad de la vivienda— en un indicador sintético de pobreza estructural. Territorios con altos niveles de NBI suelen presentar mayor omisión censal y menor cobertura de registros administrativos.

Indicadores de acceso a servicios. La proporción de hogares con acceso a servicios públicos como electricidad, agua potable, alcantarillado o internet está correlacionada tanto con la densidad poblacional como con la cobertura censal. El acceso a servicios refleja el nivel de integración del territorio a la infraestructura formal del Estado.

Nivel educativo de la población. El nivel de instrucción promedio de la población adulta del segmento, derivado de censos anteriores o de registros de matrícula escolar, puede utilizarse como indicador proxy de características socioeconómicas del territorio.

Actividad económica predominante. La clasificación del segmento según la actividad económica predominante —agropecuaria, industrial, comercial, servicios— condiciona la estructura demográfica esperada y los patrones de movilidad residencial. Esta clasificación puede derivarse de cartografía censal o de imágenes satelitales.

2.3.3 Variables espaciales

Las variables espaciales capturan la posición geográfica del segmento y sus relaciones de vecindad con el entorno territorial. Su incorporación permite al modelo explotar la continuidad espacial de la distribución poblacional y modelar explícitamente la dependencia entre segmentos geográficamente cercanos.

Distancia a centros urbanos. La distancia euclidiana o por red vial desde el centroide del segmento hasta el centro urbano más cercano es un predictor relevante de la densidad y tipo de asentamiento. Segmentos más próximos a centros urbanos tienden a presentar mayor densidad poblacional, mayor acceso a servicios y mayor cobertura de registros administrativos.

Accesibilidad y tiempos de desplazamiento. El tiempo de desplazamiento por carretera hasta el centro urbano o el hospital más cercano, derivado de modelos de redes viales, es un indicador de accesibilidad territorial con mayor valor predictivo que la distancia euclidiana en contextos con topografía compleja o infraestructura vial deficiente.

Altitud y topografía. La altitud media del segmento, la pendiente del terreno y la variabilidad topográfica interna condicionan la viabilidad de asentamientos humanos y la densidad de población esperable. Las variables

topográficas derivadas de modelos digitales de elevación son especialmente relevantes en países con territorios montañosos.

Efectos espaciales aleatorios. Más allá de las covariables observadas, la distribución espacial de la población presenta autocorrelación espacial que puede ser capturada mediante efectos aleatorios estructurados. Los modelos de efectos espaciales, como el modelo condicional autorregresivo (CAR), permiten modelar explícitamente la dependencia entre segmentos vecinos:

$$u_i \mid \mathbf{u}_{-i} \sim \mathcal{N}\left(\frac{\sum_{j \sim i} u_j}{n_i}, \frac{\sigma_u^2}{n_i}\right)$$

donde la notación $j \sim i$ indica que el segmento j es vecino del segmento i y n_i es el número de vecinos. Este modelo impone que el efecto aleatorio de cada segmento sea similar al promedio de sus vecinos, reflejando la continuidad espacial de las características no observadas que determinan la densidad poblacional.

La selección final del conjunto de variables explicativas debe fundamentarse en criterios de disponibilidad territorial —las variables deben estar disponibles para todos los segmentos—, pertinencia conceptual, capacidad predictiva demostrada y ausencia de multicolinealidad severa entre predictores. Los capítulos siguientes presentan la especificación formal de los modelos que integran estas variables en un esquema bayesiano jerárquico orientado a la estimación de conteos poblacionales subnacionales.

Preparación de Imágenes Satelitales

- 3.1 Fuentes de datos satelitales (Landsat, Sentinel, MODIS)**
- 3.2 Preprocesamiento y correcciones atmosféricas**
- 3.3 Extracción de características (NDVI, índices espectrales)**
- 3.4 Validación con datos de campo**
- 3.5 Generación de capas para el modelo**

Preparación de Insumos para Modelamiento

La construcción de un modelo bayesiano de estimación subnacional requiere, como condición previa, disponer de un conjunto de insumos analíticos preparados con criterios estadísticos explícitos y documentados. La calidad de las estimaciones finales depende no solo de la sofisticación del modelo, sino fundamentalmente de la coherencia, completitud y representatividad de los datos que lo alimentan.

Este capítulo describe el proceso de preparación de insumos en cuatro etapas secuenciales: la estandarización de las fuentes de información, la evaluación de cobertura por segmento, la construcción de la variable dependiente y el diagnóstico exploratorio de los datos. Cada etapa introduce operaciones estadísticas específicas cuya omisión puede comprometer la validez de las inferencias posteriores.

4.1 Estandarización de fuentes

Las fuentes de información descritas en el capítulo anterior provienen de sistemas institucionales con distintas definiciones operativas, unidades de medida, fechas de referencia y marcos territoriales. Su incorporación conjunta en un modelo estadístico exige un proceso previo de estandarización que garantice la comparabilidad entre fuentes y la compatibilidad con los dominios de estimación definidos.

4.1.1 Homologación de variables

La homologación consiste en establecer correspondencias semánticas y operativas entre variables provenientes de distintas fuentes que miden conceptos equivalentes o relacionados bajo definiciones diferentes. Este proceso es necesario porque los sistemas administrativos, los registros satelitales y los datos censales utilizan nomenclaturas, clasificaciones y criterios de asignación territorial que no siempre son directamente comparables.

Compatibilización de marcos territoriales. El primer paso en la homologación es garantizar que todas las fuentes estén referenciadas al mismo marco geográfico. En América Latina y el Caribe, los distintos registros administrativos suelen estar organizados por municipios, provincias o códigos postales que no coinciden directamente con los segmentos censales. Sea $\mathcal{S} = \{1, 2, \dots, I\}$ el conjunto de segmentos del operativo censal y $\mathcal{U} = \{1, 2, \dots, J\}$ las unidades geográficas del registro administrativo. La asignación de cada registro al segmento correspondiente requiere construir una función de mapeo $\phi : \mathcal{U} \rightarrow \mathcal{S}$ basada en la intersección espacial entre las geometrías de ambos marcos.

Cuando las unidades del registro son más grandes que los segmentos censales, la desagregación territorial se realiza mediante ponderación por área o por densidad de viviendas. Si la unidad administrativa j contiene m_{ij} segmentos, la estimación del conteo administrativo para el segmento i se obtiene como:

$$\hat{A}_i = A_j \cdot \frac{w_{ij}}{\sum_{k: k \subset j} w_{kj}}$$

donde A_j es el conteo total del registro en la unidad j y w_{ij} es el peso asignado al segmento i dentro de la unidad j , que puede ser proporcional al área, al número de viviendas del preconteo o a la población proyectada.

Homologación de definiciones de población. Las distintas fuentes pueden diferir en la definición de la unidad de observación. Los censos cuentan personas según residencia habitual o presencia en el momento censal, los padrones electorales registran ciudadanos habilitados para votar, los sistemas de salud registran afiliados activos y los registros civiles registran eventos vitales. La homologación requiere documentar explícitamente estas diferencias y construir factores de ajuste que permitan aproximar cada fuente a la definición censal de referencia.

Compatibilización temporal. Las fuentes de información tienen distintas fechas de referencia. El preconteo puede haberse realizado entre seis y dieciocho meses antes del momento censal. Los registros administrativos corresponden al cierre de un ejercicio fiscal o al corte de un padrón en una fecha específica. Las imágenes satelitales capturan el territorio en distintos momentos a lo largo del año. La compatibilización temporal consiste en seleccionar o construir versiones de cada fuente que sean lo más próximas posible al momento censal de referencia, documentando el desfase temporal residual como fuente de incertidumbre adicional.

4.1.2 Normalización de variables

Una vez homologadas, las variables auxiliares presentan distribuciones con escalas y dispersiones heterogéneas que dificultan la estimación numérica de los coeficientes y la interpretación comparada de los efectos. La normalización transforma las variables a una escala común que facilita la estimación y mejora el comportamiento computacional de los algoritmos de inferencia.

Estandarización por media y desviación estándar. Para una variable continua $x_{i,k}$ medida en el segmento i , la estandarización produce:

$$\tilde{x}_{i,k} = \frac{x_{i,k} - \bar{x}_k}{s_k}$$

donde $\bar{x}_k = \frac{1}{I} \sum_{i=1}^I x_{i,k}$ es la media y $s_k = \sqrt{\frac{1}{I-1} \sum_{i=1}^I (x_{i,k} - \bar{x}_k)^2}$ es la desviación estándar de la variable calculadas sobre todos los segmentos. Bajo esta transformación, $\tilde{x}_{i,k}$ tiene media cero y desviación estándar uno, y el coeficiente β_k se interpreta como el cambio esperado en el logaritmo de la población por unidad de desviación estándar en la covariable k .

Transformación logarítmica. Las variables de conteo y magnitud —número de viviendas, conteos de registros administrativos, áreas construidas— presentan distribuciones fuertemente asimétricas con cola derecha pesada. La transformación logarítmica reduce la asimetría y aproxima la distribución a la normalidad:

$$\tilde{x}_{i,k} = \log(x_{i,k} + 1)$$

La constante +1 garantiza que la transformación esté definida para valores cero, lo cual es frecuente en covariables de conteo en segmentos con baja densidad poblacional.

Normalización al intervalo unitario. Para variables que representan proporciones o índices con interpretación intrínseca en el rango $[0, 1]$, como tasas de cobertura o índices de vegetación, puede ser preferible la normalización min-max:

$$\tilde{x}_{i,k} = \frac{x_{i,k} - \min_i(x_{i,k})}{\max_i(x_{i,k}) - \min_i(x_{i,k})}$$

Esta transformación preserva la interpretación original de la variable y facilita la especificación de distribuciones a priori informativas sobre los coeficientes.

Tratamiento de valores faltantes. La presencia de valores faltantes en las covariables auxiliares debe ser resuelta antes de la estimación. Las estrategias más comunes incluyen la imputación por la mediana o la media del grupo territorial al que pertenece el segmento, la imputación mediante modelos de regresión utilizando covariables con cobertura completa, y la imputación múltiple para propagar la incertidumbre asociada a los valores faltantes hacia las estimaciones finales.

4.2 Evaluación de cobertura

La evaluación de cobertura censal por segmento es un paso crítico previo a la estimación. Permite identificar los dominios con información deficiente, cuantificar el grado de omisión territorial y establecer una clasificación de los segmentos que oriente las decisiones de modelamiento.

4.2.1 Tasa de cobertura por segmento

La tasa de cobertura de un segmento censal mide la proporción de la población verdadera que fue efectivamente enumerada durante el operativo. Dado que la población verdadera N_i no es directamente observable, la estimación de la tasa de cobertura requiere una referencia externa independiente del conteo censal.

Sea R_i una estimación de referencia de la población del segmento i obtenida a partir de una fuente auxiliar confiable, como un preconteo operativo ajustado o una proyección demográfica intercensal. La tasa de cobertura estimada para el segmento i se define como:

$$\hat{c}_i = \frac{Y_i^{(C)}}{R_i}$$

donde $Y_i^{(C)}$ es el conteo censal observado en el segmento. Un valor $\hat{c}_i < 1$ indica subcobertura —el operativo no logró enumerar toda la población de referencia— mientras que $\hat{c}_i > 1$ puede indicar sobrecobertura, duplicación de registros o inconsistencias en la referencia utilizada.

En la práctica, la tasa de cobertura puede estimarse también mediante métodos de captura-recaptura cuando se dispone de dos fuentes de información independientes para el mismo segmento. Si $Y_i^{(C)}$ es el conteo censal y A_i es el conteo de un registro administrativo, y si M_i es el número de personas identificadas en ambas fuentes, la estimación de Chapman para la población total es:

$$\hat{N}_i^{CR} = \frac{(Y_i^{(C)} + 1)(A_i + 1)}{M_i + 1} - 1$$

y la tasa de cobertura del censo respecto a esta estimación:

$$\hat{c}_i^{CR} = \frac{Y_i^{(C)}}{\hat{N}_i^{CR}}$$

Este estimador requiere el supuesto de independencia entre ambas fuentes, condición que puede ser violada cuando la propensión a ser registrado en el censo y en el registro administrativo están correlacionadas con características del individuo o del territorio.

La distribución de las tasas de cobertura entre segmentos permite identificar patrones espaciales de omisión diferencial. El coeficiente de variación de $\hat{c}_i$ entre segmentos es un indicador de la heterogeneidad territorial de la cobertura. Valores elevados de este coeficiente indican que la omisión censal no es aleatoria y que un modelo que ignore esta heterogeneidad producirá estimaciones sesgadas.

4.2.2 Clasificación de segmentos

La clasificación de los segmentos según su nivel de cobertura permite diseñar estrategias diferenciadas de estimación y validación. Una tipología operativa agrupa los segmentos en tres categorías:

Segmentos con cobertura aceptable ($\hat{c}_i \geq c^*$): el conteo censal observado es suficientemente representativo de la población subyacente y puede utilizarse como variable dependiente del modelo sin ajuste previo. El umbral c^* se fija típicamente entre 0.85 y 0.95, dependiendo de los estándares de calidad del sistema estadístico.

Segmentos con cobertura parcial ($c_{**} \leq \hat{c}_i < c^*$): el conteo censal presenta omisión detectable pero el segmento fue efectivamente enumerado. Estos segmentos ingresan al modelo con un peso reducido o con un indicador de calidad que refleja la mayor incertidumbre de su conteo. El umbral inferior c_{**} se sitúa típicamente entre 0.60 y 0.75.

Segmentos con cobertura insuficiente ($\hat{c}_i < c_{**}$): el operativo censal no alcanzó una enumeración mínimamente representativa. Estos segmentos son tratados como dominios sin información propia y su estimación depende enteramente de las covariables auxiliares y de la estructura jerárquica del modelo.

Formalmente, la clasificación puede expresarse mediante la variable indicadora:

$$\kappa_i = \begin{cases} 2 & \text{si } \hat{c}_i \geq c^* \\ 1 & \text{si } c_{**} \leq \hat{c}_i < c^* \\ 0 & \text{si } \hat{c}_i < c_{**} \end{cases}$$

Esta clasificación se incorpora al modelo mediante pesos de verosimilitud o mediante la especificación diferenciada de la varianza del error de medición según la categoría del segmento.

4.3 Construcción de la variable dependiente

La variable dependiente del modelo de estimación subnacional es el conteo poblacional que se desea estimar en cada segmento. Su construcción no es un proceso trivial: requiere decisiones explícitas sobre la agregación de categorías, las transformaciones aplicadas y la definición de la población de referencia.

4.3.1 Conteos agregados

El conteo agregado para el segmento i se construye sumando los conteos censales observados sobre los grupos de sexo y edad de interés. Sea $Y_{i,s,e}^{(C)}$ el conteo censal del segmento i , sexo s y grupo de edad e . El conteo total del segmento es:

$$Y_i = \sum_{s \in \{M,F\}} \sum_{e=1}^E Y_{i,s,e}^{(C)}$$

Cuando el objetivo es estimar conteos desagregados por sexo o grupo etario, la variable dependiente se construye para cada celda demográfica de interés:

$$Y_{i,s,e} = Y_{i,s,e}^{(C)}, \quad s \in \{M,F\}, \quad e = 1, \dots, E$$

y el modelo se estima de forma separada para cada celda o mediante un modelo conjunto que impone coherencia entre celdas a través de una estructura jerárquica compartida.

La decisión sobre el nivel de desagregación de la variable dependiente tiene implicaciones directas sobre el tamaño del problema de estimación y la disponibilidad de información. A mayor desagregación, mayor es el número de celdas con conteos pequeños o nulos, lo que incrementa la dependencia del modelo respecto a las covariables auxiliares y a la estructura jerárquica.

4.3.2 Tasas poblacionales

En algunos contextos, la variable de interés no es el conteo absoluto sino una tasa relativa que expresa la magnitud de un subgrupo poblacional como proporción del total. Sea $Y_i^{(g)}$ el conteo del grupo de interés g en el segmento i y Y_i el total del segmento. La tasa poblacional se define como:

$$\pi_i^{(g)} = \frac{Y_i^{(g)}}{Y_i}$$

Las tasas poblacionales son especialmente relevantes cuando el objetivo es comparar la composición demográfica entre segmentos con magnitudes poblacionales muy distintas. Sin embargo, en dominios con conteos pequeños, las tasas presentan elevada variabilidad aleatoria que puede distorsionar la comparación territorial.

El modelamiento de tasas en el contexto bayesiano utiliza frecuentemente la distribución beta como modelo para la variable dependiente cuando $\pi_i^{(g)} \in (0, 1)$, o modelos binomiales cuando se dispone del denominador exacto:

$$Y_i^{(g)} \mid \pi_i^{(g)}, Y_i \sim \text{Binomial}(Y_i, \pi_i^{(g)})$$

4.3.3 Transformaciones

Las transformaciones de la variable dependiente buscan estabilizar la varianza, aproximar la distribución a la normalidad o linealizar la relación entre la variable de respuesta y los predictores. En el contexto de conteos poblacionales, las transformaciones más utilizadas son las siguientes.

Transformación logarítmica. La transformación $\log(Y_i + 1)$ es la más frecuentemente utilizada en modelos log-lineales de conteo. Estabiliza la varianza en distribuciones de Poisson y permite interpretar los efectos de las covariables en términos de cambios porcentuales en la población esperada.

Transformación raíz cuadrada. La transformación $\sqrt{Y_i}$ tiene la propiedad de estabilizar la varianza en distribuciones de Poisson, dado que $\text{Var}(\sqrt{Y_i}) \approx 1/4$ cuando λ_i es grande. Es menos utilizada que la logarítmica pero puede ser apropiada cuando los conteos son muy pequeños y la transformación logarítmica introduce distorsiones.

Transformación de potencia de Box-Cox. Para una búsqueda más sistemática de la transformación estabilizadora de varianza, la familia de transformaciones de Box-Cox parametriza el tipo de transformación mediante un parámetro λ_{BC} :

$$Y_i^{(\lambda_{BC})} = \begin{cases} \frac{Y_i^{\lambda_{BC}} - 1}{\lambda_{BC}} & \text{si } \lambda_{BC} \neq 0 \\ \log(Y_i) & \text{si } \lambda_{BC} = 0 \end{cases}$$

El parámetro λ_{BC} puede estimarse por máxima verosimilitud como parte del proceso de especificación del modelo. Los valores $\lambda_{BC} = 0$ (logarítmica) y $\lambda_{BC} = 0.5$ (raíz cuadrada) son los más frecuentes en la práctica.

4.3.4 Definición de población base

La población base define el universo de referencia sobre el cual se construye el conteo de interés. Su especificación correcta es fundamental para garantizar la comparabilidad entre segmentos y la coherencia con los totales de niveles superiores.

La definición de población base más común en censos de población es la población residente habitual: el conjunto de personas cuya residencia principal está localizada en el segmento en el momento del censo. Sin embargo, algunos censos implementan el criterio de población de hecho, que contabiliza a las personas presentes en el segmento durante el momento censal, independientemente de su residencia habitual.

Formalmente, la población base $\mathcal{P}_i$ del segmento i puede definirse bajo distintos criterios:

- **Población residente:** $\mathcal{P}_i = \{j : \text{residencia habitual de } j \text{ está en } i\}$
- **Población de hecho:** $\mathcal{P}_i = \{j : j \text{ está físicamente presente en } i \text{ en el momento censal}\}$
- **Población en hogares particulares:** excluye a las personas en colectividades institucionales (hospitales, cárceles, cuarteles).
- **Población civil:** excluye adicionalmente al personal militar.

La elección de la población base afecta la coherencia de los conteos en territorios con alta movilidad diurna, presencia de instituciones totales o frontera entre áreas urbanas y rurales. El modelo de estimación debe adaptarse a la misma definición de población base utilizada en el operativo censal.

4.3.5 Escalamiento

El escalamiento de los conteos es necesario cuando se trabaja simultáneamente con segmentos de tamaño muy heterogéneo o cuando se requiere comparar estimaciones entre países o periodos censales con distintas magnitudes poblacionales.

El escalamiento por tamaño esperado utiliza una referencia R_i para expresar el conteo observado como una proporción de la población esperada:

$$z_i = \frac{Y_i}{R_i}$$

donde R_i puede ser el preconteo ajustado, la proyección demográfica intercensal u otro estimador de referencia. La variable escalada z_i puede interpretarse como un factor de cobertura relativa y tiene la ventaja de reducir la dependencia del modelo respecto al tamaño absoluto de cada segmento.

El escalamiento por exposición es especialmente útil cuando la variable dependiente representa un conteo sobre un denominador que varía entre segmentos. En el modelo de Poisson, esta escala se incorpora mediante el término de offset:

$$\log(\lambda_i) = \log(R_i) + \mathbf{x}_i^\top \beta + u_i$$

donde $\log(R_i)$ es el offset —una constante conocida que ajusta la intensidad esperada por el tamaño de la exposición del segmento— y los coeficientes β se interpretan como efectos sobre la tasa por unidad de exposición.

4.4 Diagnóstico exploratorio

Antes de ajustar el modelo bayesiano, es indispensable realizar un análisis exploratorio sistemático de los datos preparados. Este diagnóstico permite verificar la coherencia interna de los insumos, identificar observaciones atípicas, evaluar la capacidad predictiva de las covariables y detectar posibles violaciones de los supuestos del modelo.

4.4.1 Distribución de conteos

El análisis de la distribución de los conteos observados Y_i permite caracterizar la variabilidad entre segmentos y evaluar la adecuación de las familias distribucionales consideradas para el modelamiento.

Los estadísticos descriptivos básicos —media, mediana, desviación estándar, coeficientes de asimetría y curtosis— proveen una caracterización inicial de la distribución. La comparación entre la media y la varianza muestral:

$$\bar{Y} = \frac{1}{I} \sum_{i=1}^I Y_i, \quad S_Y^2 = \frac{1}{I-1} \sum_{i=1}^I (Y_i - \bar{Y})^2$$

ofrece un diagnóstico informal de sobredispersión: si $S_Y^2 \gg \bar{Y}$, la distribución de Poisson puede ser insuficiente y el modelo binomial negativo resulta más apropiado. El índice de dispersión $D = S_Y^2 / \bar{Y}$ cuantifica el grado de sobredispersión; valores superiores a 1.5 o 2 suelen justificar el uso de modelos más flexibles.

```
resumen_conteos <- data.frame(
  n_segmentos = length(Y),
  media       = mean(Y),
```

```

    mediana      = median(Y),
    desv_est     = sd(Y),
    asimetria    = moments::skewness(Y),
    curtosis     = moments::kurtosis(Y),
    indice_disp  = var(Y) / mean(Y)
  )

  hist(log(Y + 1),
       breaks = 40,
       main   = "Distribución de log(Y + 1) por segmento",
       xlab   = "log(conteo + 1)",
       col    = "#CBD5E1",
       border = "white")

```

La visualización de la distribución debe realizarse tanto en escala original como en escala logarítmica. En la escala original, la distribución suele ser fuertemente asimétrica con cola derecha pesada; en la escala logarítmica, la distribución es más simétrica y permite evaluar si la especificación log-lineal es adecuada.

La proporción de ceros en los conteos es otro indicador relevante. Un exceso de ceros respecto a lo esperado bajo el modelo de Poisson puede indicar la presencia de segmentos genuinamente deshabitados, problemas de cobertura en áreas con baja densidad, o la necesidad de incorporar un componente de inflación de ceros en el modelo.

4.4.2 Outliers

La identificación de observaciones atípicas en los conteos y en las covariables auxiliares es fundamental para evitar que estas observaciones dominen la estimación de los parámetros del modelo. En el contexto de datos de conteo, los outliers pueden manifestarse como valores excepcionalmente altos o bajos en relación con la tendencia general de los datos, o como combinaciones inusuales de conteo y covariables.

Detección basada en residuos del modelo nulo. Un modelo de regresión de Poisson sin covariables permite obtener residuos de Pearson para cada segmento:

$$r_i^P = \frac{Y_i - \hat{\lambda}_i}{\sqrt{\hat{\lambda}_i}}$$

donde $\hat{\lambda}_i = \exp(\hat{\alpha})$ con $\hat{\alpha} = \log(\bar{Y})$. Segmentos con $|r_i^P| > 3$ son candidatos a revisión como observaciones atípicas.

Detección basada en la distancia de Cook. En el modelo log-lineal con covariables, la distancia de Cook D_i cuantifica la influencia del segmento i sobre el vector de coeficientes estimados. Valores elevados de D_i indican que la exclusión del segmento i modificaría sustancialmente los coeficientes del modelo.

Detección multivariada. Las observaciones atípicas en el espacio de covariables pueden identificarse mediante la distancia de Mahalanobis:

$$d_i^2 = (\mathbf{x}_i - \bar{\mathbf{x}})^\top \hat{\Sigma}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}})$$

donde $\bar{\mathbf{x}}$ es el vector de medias y $\hat{\Sigma}$ es la matriz de covarianza muestral de las covariables. Bajo normalidad multivariada, $d_i^2 \sim \chi_p^2$, y valores superiores al percentil 97.5 de esta distribución son indicativos de observaciones atípicas en el espacio de covariables.

```
lambda_nulo      <- mean(Y)
residuos_p       <- (Y - lambda_nulo) / sqrt(lambda_nulo)
segmentos_outlier <- which(abs(residuos_p) > 3)

X_mat  <- as.matrix(covariables_std)
d2_mah <- mahalanobis(X_mat, colMeans(X_mat), cov(X_mat))
p_valor <- pchisq(d2_mah, df = ncol(X_mat), lower.tail = FALSE)
outliers_multivariados <- which(p_valor < 0.025)
```

Una vez identificadas, las observaciones atípicas deben revisarse para determinar si corresponden a errores de procesamiento, a características genuinas del territorio o a problemas de cobertura del operativo. La decisión sobre su tratamiento —corrección, exclusión o inclusión con peso reducido— debe documentarse explícitamente.

4.4.3 Relación entre variables

El análisis de la relación entre la variable dependiente y las covariables auxiliares permite evaluar la pertinencia predictiva de cada fuente de información y orientar las decisiones de especificación del modelo.

Correlación con los conteos. La correlación de Pearson entre $\log(Y_i + 1)$ y cada covariable estandarizada $\tilde{x}_{i,k}$ proporciona una medida lineal de la asociación bivariada. Covariables con correlación superior a 0.5 en valor absoluto suelen tener valor predictivo relevante; covariables con correlación inferior a 0.1 pueden ser candidatas a exclusión del modelo.

Diagramas de dispersión. La representación gráfica de $\log(Y_i + 1)$ contra cada covariable permite detectar relaciones no lineales, patrones de heteroscedasticidad y grupos de segmentos con comportamiento diferenciado. La adición de una curva de suavizado no paramétrico (LOESS) facilita la identificación de estructuras no lineales que podrían requerir transformaciones adicionales de las covariables.

Correlación entre covariables. La matriz de correlación entre las covariables auxiliares permite identificar pares con alta colinealidad. Correlaciones superiores a 0.85 en valor absoluto indican que dos covariables aportan información casi redundante. Los factores de inflación de varianza (VIF) son una herramienta complementaria para el diagnóstico de multicolinealidad:

$$\text{VIF}_k = \frac{1}{1 - R_k^2}$$

donde R_k^2 es el coeficiente de determinación obtenido al regresar la covariable k sobre el resto de covariables. Valores de $\text{VIF}_k > 10$ son indicativos de multicolinealidad problemática.

```
library(corrplot)
cor_mat <- cor(cbind(log_Y = log(Y + 1), covariables_std),
               method = "pearson")
```

```
corrplot(cor_mat,
         method      = "color",
         type        = "upper",
         addCoef.col  = "black",
         number.cex  = 0.7,
         tl.cex      = 0.8)

modelo_ols <- lm(log(Y + 1) ~ ., data = as.data.frame(covariables_std))
car::vif(modelo_ols)
```

Análisis por estrato territorial. La relación entre la variable dependiente y las covariables puede variar entre distintos estratos territoriales —urbano/rural, región geográfica, nivel de cobertura—. La exploración estratificada permite detectar interacciones relevantes que podrían justificar la inclusión de términos de interacción o la estimación diferenciada de coeficientes por grupo.

La documentación sistemática de los resultados del diagnóstico exploratorio es un insumo esencial para la especificación del modelo. Las decisiones sobre transformaciones, exclusión de covariables, tratamiento de outliers y estratificación del análisis deben fundamentarse en este diagnóstico y quedar registradas para garantizar la reproducibilidad y auditabilidad de las estimaciones finales.

Modelo para Conteos Poblacionales

Los capítulos precedentes han establecido el marco conceptual de la estimación subnacional, identificado las fuentes de información disponibles, descrito los procedimientos de preparación de imágenes satelitales y detallado el proceso de construcción de los insumos analíticos. Sobre esta base, el presente capítulo introduce la especificación formal del modelo estadístico que integra dichos elementos bajo un esquema probabilístico coherente, orientado a estimar los conteos de población en segmentos censales con cobertura parcial o incompleta.

La formulación adoptada debe satisfacer los requerimientos establecidos en capítulos anteriores: representar adecuadamente la naturaleza discreta y no negativa de los conteos, incorporar información auxiliar de fuentes heterogéneas, producir estimaciones en dominios sin cobertura directa y cuantificar explícitamente la incertidumbre de los resultados. Frente a estos requerimientos, un modelo de Poisson simple resulta insuficiente cuando los datos exhiben sobredispersión o cuando se dispone de información de referencia sobre el número de estructuras habitacionales en cada segmento. La extensión log-normal del modelo de Poisson, articulada con una estructura jerárquica de efectos aleatorios, responde a estas limitaciones de manera estadísticamente coherente.

El modelo propuesto opera en dos niveles. En el primer nivel, la densidad poblacional —definida como el número de personas por estructura habitacional— se representa mediante una distribución log-normal cuyo parámetro de localización es función lineal de covariables auxiliares y efectos aleatorios territoriales. En el segundo nivel, los conteos de población observados se modelan como realizaciones de una distribución de Poisson cuyo parámetro de intensidad resulta del producto entre la densidad estimada y el número de estructuras en cada segmento. Esta arquitectura de dos etapas constituye el modelo Poisson-lognormal y provee un mecanismo natural de control de la sobredispersión mientras mantiene la interpretabilidad de los parámetros.

La estructura del capítulo se organiza en dos secciones principales. La primera presenta la especificación probabilística completa del modelo: definición formal, función de verosimilitud, distribuciones a priori, distribución posterior e interpretación de parámetros. La segunda describe en detalle los componentes del modelo: efectos fijos, efectos aleatorios, mecanismos de interacción y elementos adicionales como el offset, la sobredispersión y las alternativas distribucionales consideradas en el diseño.

5.1 Modelo Poisson-lognormal

5.1.1 Definición formal

La especificación del modelo parte de dos cantidades fundamentales definidas para cada segmento censal i perteneciente al conjunto $\mathcal{S} = \{1, 2, \dots, D\}$ de todos los segmentos del país. La primera es el conteo de población observado Y_i , disponible únicamente para los segmentos que alcanzaron cobertura efectiva durante el operativo censal. La segunda es el número de estructuras habitacionales V_i , derivado del preconteo operativo o de fuentes satelitales de área construida, y disponible para todos los segmentos del país.

Nota de notación. La cardinalidad $D = |\mathcal{S}|$ corresponde al mismo conjunto de segmentos denotado $\{1, \dots, I\}$ en los Capítulos 2 y 4; se adopta aquí la notación D (D_{obs} , D_{tot}) por su correspondencia directa con la implementación computacional en Stan (Sección 6.1.3 del capítulo siguiente). El número de estructuras habitacionales V_i es la misma cantidad denotada P_i (preconteo de viviendas) en el Capítulo 2. Finalmente, ni D ni sus variantes indexadas deben confundirse con la densidad poblacional por área $D_i = N_i/A_i$ definida en el Capítulo 1: la densidad de personas por estructura habitacional propia de este capítulo se denota δ_i .

Sea $\mathcal{S}_{obs} \subset \mathcal{S}$ el subconjunto de segmentos con información censal observada, de cardinalidad $D_{obs} = |\mathcal{S}_{obs}|$. El modelo distingue explícitamente entre estos dos conjuntos: los parámetros se estiman a partir de $\mathcal{S}_{obs}$ y se utilizan posteriormente para generar predicciones sobre la totalidad de $\mathcal{S}$, incluyendo los segmentos no observados en el operativo censal.

El elemento central del modelo es la densidad poblacional δ_i , definida como el número esperado de personas por estructura habitacional en el segmento i :

$$\delta_i = \frac{N_i}{V_i}$$

donde N_i denota la población verdadera del segmento, tal como se definió en el capítulo de conceptos generales. Esta cantidad no es directamente observable sino que debe inferirse a partir de la información disponible. La densidad δ_i representa una medida de intensidad específica de ocupación habitacional que permite comparar segmentos con distinto número de estructuras bajo una escala común y facilita la incorporación del número de viviendas como referencia natural del proceso de conteo.

El modelo Poisson-lognormal se formula mediante dos componentes probabilísticos anidados. En el primer nivel, la densidad latente δ_i sigue una distribución log-normal con parámetro de localización μ_i y parámetro de escala σ :

$$\delta_i \mid \mu_i, \sigma \sim \text{LogNormal}(\mu_i, \sigma), \quad i \in \mathcal{S}_{obs}$$

La distribución log-normal garantiza que $\delta_i > 0$ por construcción, lo cual es consistente con la interpretación de δ_i como densidad de personas por estructura. El parámetro μ_i captura la localización de la distribución en escala logarítmica y es modelado como función lineal de las covariables disponibles para el segmento. El parámetro $\sigma > 0$ controla la dispersión de las densidades alrededor de dicha localización.

En el segundo nivel, los conteos de población se modelan como realizaciones de una distribución de Poisson cuyo parámetro de intensidad es el producto entre la densidad estimada y el número de estructuras del segmento:

$$Y_i \mid \delta_i, V_i \sim \text{Poisson}(\lambda_i), \quad \lambda_i = \delta_i \cdot V_i, \quad i \in \mathcal{S}_{obs}$$

Esta parametrización incorpora el número de estructuras V_i como referencia natural de escala. Segmentos con mayor número de estructuras tienen, en igualdad de condiciones, una intensidad esperada proporcionalmente mayor. El parámetro de localización de la densidad sigue un predictor lineal de la forma:

$$\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \mathbf{z}_i^\top \boldsymbol{\gamma}$$

donde $\mathbf{x}_i \in \mathbb{R}^P$ es el vector de covariables auxiliares estandarizadas del segmento i , $\boldsymbol{\beta} \in \mathbb{R}^P$ es el vector de

coeficientes de efectos fijos, $\mathbf{z}_i \in \{0, 1\}^Q$ es el vector de indicadores para los efectos aleatorios territoriales y $\gamma \in \mathbb{R}^Q$ es el vector de coeficientes de efectos aleatorios. La dimensión P corresponde al número de covariables auxiliares seleccionadas y Q al número de unidades territoriales de nivel superior —provincias, departamentos o regiones— en las que se anidan los segmentos.

El conjunto de parámetros estructurales del modelo es $\theta = \{\beta, \gamma, \sigma, \sigma_U\}$, donde $\sigma_U > 0$ es el hiperparámetro que controla la variabilidad de los efectos aleatorios, cuya especificación se detalla en la sección de distribuciones a priori. Adicionalmente, $\delta = \{\delta_i : i \in \mathcal{S}_{obs}\}$ es el vector de densidades latentes para los segmentos observados, que se trata como conjunto de parámetros latentes en la inferencia bayesiana de manera conjunta con θ .

5.1.2 Función de verosimilitud

La función de verosimilitud del modelo Poisson-lognormal se construye sobre la información disponible en los segmentos observados $\mathcal{S}_{obs}$. Dado que las densidades δ_i son tratadas como parámetros latentes, la verosimilitud conjunta factoriza sobre segmentos bajo el supuesto de independencia condicional entre observaciones dado el vector de parámetros θ :

$$p(\mathbf{Y}_{obs}, \delta \mid \theta) = \prod_{i \in \mathcal{S}_{obs}} p(Y_i \mid \delta_i, V_i) \cdot p(\delta_i \mid \mu_i, \sigma)$$

donde $\mathbf{Y}_{obs} = \{Y_i : i \in \mathcal{S}_{obs}\}$ es el vector de conteos observados. Expandiendo cada factor con sus formas funcionales explícitas:

$$p(\mathbf{Y}_{obs}, \delta \mid \theta) = \prod_{i \in \mathcal{S}_{obs}} \frac{e^{-\delta_i V_i} (\delta_i V_i)^{Y_i}}{Y_i!} \cdot \frac{1}{\delta_i \sigma \sqrt{2\pi}} \exp\left(-\frac{(\log \delta_i - \mu_i)^2}{2\sigma^2}\right)$$

La verosimilitud log-conjunta, omitiendo constantes respecto a los parámetros, adopta la forma:

$$\log p(\mathbf{Y}_{obs}, \delta \mid \theta) = \sum_{i \in \mathcal{S}_{obs}} \left[Y_i \log(\delta_i V_i) - \delta_i V_i - \log \delta_i - \frac{(\log \delta_i - \mu_i)^2}{2\sigma^2} - \log \sigma \right]$$

Esta expresión pone de manifiesto la naturaleza jerárquica del modelo: el primer par de términos corresponde a la contribución de la distribución de Poisson para los conteos observados, mientras que los términos restantes corresponden a la contribución de la distribución log-normal para las densidades latentes. El término $-\log \delta_i$ proviene del jacobiano de la densidad log-normal —resultado de la transformación entre la escala multiplicativa de δ_i y la escala logarítmica— y garantiza la corrección del volumen en el cambio de variables. Ambas contribuciones están conectadas a través del parámetro δ_i , cuya estimación equilibra simultáneamente el ajuste a los conteos observados y la regularización impuesta por el modelo de densidad.

Una propiedad relevante de esta formulación es que la distribución marginal de Y_i , obtenida al integrar δ_i de la expresión conjunta, resulta en una mezcla de Poisson con distribución de mezcla log-normal. Esta mezcla genera mayor dispersión que la Poisson pura. Formalmente, si $\delta_i \sim \text{LogNormal}(\mu_i, \sigma)$ y $Y_i \mid \delta_i \sim \text{Poisson}(\delta_i V_i)$, entonces la media y la varianza marginales del conteo son:

$$\mathbb{E}[Y_i] = V_i \exp\left(\mu_i + \frac{\sigma^2}{2}\right)$$

$$\text{Var}(Y_i) = \mathbb{E}[Y_i] + V_i^2 e^{2\mu_i + \sigma^2} (e^{\sigma^2} - 1)$$

Dado que $\text{Var}(Y_i) > \mathbb{E}[Y_i]$ siempre que $\sigma > 0$, el modelo Poisson-lognormal es inherentemente sobredisperso respecto a la distribución de Poisson pura, con el grado de sobredispersión controlado por el parámetro σ . Esta propiedad lo hace apropiado para datos censales donde la varianza observada supera sistemáticamente la esperada bajo el supuesto de equidispersión.

5.1.3 Distribuciones a priori

La especificación bayesiana del modelo requiere asignar distribuciones a priori a todos los parámetros desconocidos. En el contexto del modelo Poisson-lognormal, el conjunto de parámetros a los que se asignan distribuciones a priori incluye los coeficientes de efectos fijos β , los coeficientes de efectos aleatorios γ , el parámetro de escala de la densidad σ y el hiperparámetro de variabilidad de los efectos aleatorios σ_U .

La elección de distribuciones a priori débilmente informativas ofrece un equilibrio entre la ausencia de información fuerte sobre los parámetros y la estabilización del proceso de estimación. Bajo este enfoque, las distribuciones a priori incorporan restricciones de signo y magnitud consistentes con el conocimiento sustantivo del problema sin imponer concentración excesiva sobre valores específicos. Esta estrategia resulta especialmente adecuada en modelos con alta dimensionalidad paramétrica, donde las distribuciones no informativas pueden generar problemas de identificación o inestabilidad en la inferencia.

Para los coeficientes de efectos fijos se adopta una distribución normal centrada en cero con varianza unitaria:

$$\beta_k \sim \mathcal{N}(0, 1), \quad k = 1, \dots, P$$

Esta distribución a priori es apropiada cuando las covariables han sido previamente estandarizadas, de modo que un coeficiente con valor absoluto superior a dos corresponde a un efecto sustancialmente grande en términos de la escala de las covariables. La centrada en cero refleja la ausencia de conocimiento previo sobre la dirección del efecto de cada covariable, mientras que la varianza unitaria actúa como regularización suave que favorece efectos de magnitud moderada.

Para los coeficientes de efectos aleatorios se adopta una distribución normal jerárquica con varianza controlada por el hiperparámetro σ_U :

$$\gamma_j \sim \mathcal{N}(0, \sigma_U^2), \quad j = 1, \dots, Q$$

Esta especificación introduce una estructura de encogimiento sobre los efectos aleatorios: territorios con información escasa son atraídos hacia el promedio global capturado por los efectos fijos, mientras que territorios con información abundante y patrón sistemáticamente distinto pueden mantener efectos locales de mayor magnitud. El grado de encogimiento está regulado por σ_U , que a su vez es un parámetro desconocido al que se asigna una distribución a priori.

Para el hiperparámetro de variabilidad de los efectos aleatorios se adopta una distribución normal positiva:

$$\sigma_U \sim \mathcal{N}^+(0, 1)$$

Esta elección permite que el modelo aprenda la magnitud de la variabilidad territorial a partir de los datos, sin imponer un valor fijo. La distribución normal positiva asigna probabilidad significativa a valores cercanos a cero —compatibles con un modelo sin efectos aleatorios relevantes— mientras permite valores mayores si los datos los respaldan.

Para el parámetro de escala de la densidad se adopta una distribución de Cauchy positiva:

$$\sigma \sim \text{Cauchy}^+(0, 2,5)$$

La distribución de Cauchy positiva presenta colas más pesadas que la distribución exponencial o que la gamma inversa, lo que permite una amplia dispersión a priori sin concentrar excesiva probabilidad en valores pequeños. Esta propiedad es útil cuando la variabilidad real de las densidades entre segmentos es sustancialmente alta, como suele ocurrir en contextos con marcada heterogeneidad territorial y cobertura censal diferencial.

5.1.4 Distribución posterior

La distribución posterior del modelo Poisson-lognormal combina la verosimilitud conjunta con las distribuciones a priori de todos los parámetros. Aplicando el teorema de Bayes, la distribución posterior conjunta sobre los parámetros estructurales θ y las densidades latentes δ es proporcional al producto de la verosimilitud y las previas:

$$p(\theta, \delta \mid \mathbf{Y}_{obs}) \propto p(\mathbf{Y}_{obs}, \delta \mid \beta, \gamma, \sigma) \cdot p(\gamma \mid \sigma_U) \cdot p(\beta) \cdot p(\sigma) \cdot p(\sigma_U)$$

Expandiendo cada componente con sus formas funcionales específicas:

$$p(\theta, \delta \mid \mathbf{Y}_{obs}) \propto \left[\prod_{i \in \mathcal{S}_{obs}} \text{Poisson}(Y_i \mid \delta_i V_i) \cdot \text{LogNormal}(\delta_i \mid \mu_i, \sigma) \right] \cdot \prod_{j=1}^Q \mathcal{N}(\gamma_j \mid 0, \sigma_U^2) \cdot \prod_{k=1}^P \mathcal{N}(\beta_k \mid 0, 1) \cdot p(\sigma) \cdot p(\sigma_U)$$

La distribución posterior no tiene forma analítica cerrada debido a la combinación de la distribución de Poisson para los conteos y la distribución log-normal para las densidades latentes. En consecuencia, la inferencia se realiza mediante métodos de Monte Carlo por cadenas de Markov (MCMC), específicamente mediante el algoritmo de Monte Carlo Hamiltoniano implementado en Stan, cuya descripción se desarrolla en el capítulo siguiente.

Las cantidades de interés inferencial se derivan directamente de la distribución posterior conjunta $p(\theta, \delta \mid \mathbf{Y}_{obs})$. Para cada segmento $i \in \mathcal{S}_{obs}$, la estimación puntual de la densidad poblacional se obtiene como la media posterior:

$$\hat{\delta}_i = \mathbb{E}[\delta_i \mid \mathbf{Y}_{obs}] \approx \frac{1}{T} \sum_{t=1}^T \delta_i^{(t)}$$

donde $\delta_i^{(1)}, \dots, \delta_i^{(T)}$ son las muestras de la distribución posterior generadas mediante MCMC. Para los segmentos no observados $i \in \mathcal{S} \setminus \mathcal{S}_{obs}$, la predicción se obtiene generando muestras de la distribución predictiva posterior en el bloque de cantidades generadas del modelo:

$$\tilde{\delta}_i^{(t)} \sim \text{LogNormal}(\mu_i^{(t)}, \sigma^{(t)}), \quad \tilde{Y}_i^{(t)} \sim \text{Poisson}(\tilde{\delta}_i^{(t)} \cdot V_i)$$

donde $\mu_i^{(t)} = \mathbf{x}_i^\top \boldsymbol{\beta}^{(t)} + \mathbf{z}_i^\top \boldsymbol{\gamma}^{(t)}$ se evalúa utilizando los parámetros de la muestra t . Esta predicción se realiza sobre la totalidad de $\mathcal{S}$, lo que permite obtener estimaciones de población para todos los segmentos del país, incluidos aquellos sin cobertura censal directa.

La estimación del total de población de un nivel geográfico superior —municipio, departamento o país— se obtiene agregando las distribuciones predictivas posteriores de los segmentos que lo componen. Si $\mathcal{S}_k \subset \mathcal{S}$ denota el conjunto de segmentos del municipio k , el conteo total estimado para ese municipio —nivel (3) en la jerarquía geográfica utilizada en el Capítulo 1, donde el departamento corresponde al nivel (2) y el segmento censal al nivel (4)— es:

$$\hat{N}_k^{(3)} = \sum_{i \in \mathcal{S}_k} \hat{N}_i, \quad \hat{N}_i = \begin{cases} Y_i + \hat{Y}_i^{(aus)} & \text{si } i \in \mathcal{S}_{obs} \\ \tilde{Y}_i & \text{si } i \notin \mathcal{S}_{obs} \end{cases}$$

donde $\hat{Y}_i^{(aus)}$ representa la predicción para las personas no observadas dentro de un segmento con cobertura parcial y $\tilde{Y}_i$ la predicción completa para segmentos sin cobertura. La incertidumbre de esta agregación se cuantifica mediante la distribución posterior del total, cuya varianza refleja simultáneamente la incertidumbre sobre los parámetros del modelo y la variabilidad del proceso de Poisson.

5.1.5 Interpretación de parámetros

La interpretación de los parámetros del modelo Poisson-lognormal requiere considerar la escala en la que opera cada componente. Dado que la densidad poblacional δ_i sigue una distribución log-normal, el predictor lineal μ_i actúa sobre el logaritmo de la densidad, lo que implica que los coeficientes $\boldsymbol{\beta}$ y $\boldsymbol{\gamma}$ se interpretan en escala logarítmica.

Para los coeficientes de efectos fijos, el coeficiente β_k representa el cambio esperado en el logaritmo de la densidad poblacional asociado a un incremento de una desviación estándar en la covariable estandarizada $\tilde{x}_{i,k}$, manteniendo constantes las demás covariables y los efectos aleatorios. Dado que $\mathbb{E}[\log \delta_i \mid \mu_i, \sigma] = \mu_i$ para la distribución log-normal, la derivada parcial del predictor lineal respecto a la covariable k es directamente:

$$\beta_k = \frac{\partial \mu_i}{\partial \tilde{x}_{i,k}}$$

En escala multiplicativa, $\exp(\beta_k)$ representa el factor por el cual se multiplica la densidad mediana cuando la covariable k aumenta en una desviación estándar. Valores de $\beta_k > 0$ indican que el segmento tiende a tener mayor densidad poblacional a medida que crece la covariable correspondiente; valores negativos indican la relación contraria.

Para los efectos aleatorios, el coeficiente γ_j representa el ajuste territorial específico de la unidad geográfica superior j una vez que el efecto de las covariables ha sido controlado. En escala multiplicativa, $\exp(\gamma_j)$ es el factor por el cual se ajusta la densidad de todos los segmentos pertenecientes al territorio j respecto al nivel implícito en los efectos fijos. La distribución a priori $\gamma_j \sim \mathcal{N}(0, \sigma_U^2)$ impone que estos ajustes se concentren alrededor de cero con una variabilidad determinada por σ_U , lo que produce el efecto de encogimiento sobre territorios con escasa información.

El parámetro σ controla la dispersión de las densidades δ_i alrededor de su media condicional $\exp(\mu_i + \sigma^2/2)$. En escala logarítmica, σ corresponde a la desviación estándar de $\log \delta_i$; valores grandes de σ indican alta heterogeneidad residual en las densidades no explicada por las covariables ni por los efectos aleatorios. El hiperparámetro σ_U cuantifica, por su parte, la dispersión de los efectos aleatorios entre unidades territoriales: valores grandes de σ_U indican que los territorios presentan densidades sistemáticamente distintas incluso después de controlar por las covariables auxiliares.

Finalmente, la densidad latente δ_i tiene una interpretación demográfica directa: representa el número estimado de personas por estructura habitacional en el segmento i . Este parámetro puede utilizarse para comparar la intensidad de ocupación habitacional entre segmentos, identificar áreas de alta concentración y construir predicciones de población condicionadas al número de estructuras disponibles. Su distribución posterior provee una medida de incertidumbre que refleja tanto la variabilidad del conteo observado como la posición del segmento en la distribución log-normal especificada por el modelo.

5.2 Componentes del modelo

La especificación completa del modelo Poisson-lognormal requiere detallar la construcción de cada uno de sus componentes estructurales. El predictor lineal $\mu_i = \mathbf{x}_i^T \boldsymbol{\beta} + \mathbf{z}_i^T \boldsymbol{\gamma}$ integra dos tipos de información: efectos sistemáticos capturados por las covariables auxiliares a través de los efectos fijos, y ajustes territoriales no explicados por dichas covariables a través de los efectos aleatorios. Estos componentes interactúan con el offset de estructuras V_i y con el mecanismo de sobredispersión log-normal para producir estimaciones coherentes en el conjunto completo de segmentos.

5.2.1 Efectos fijos

Los efectos fijos del modelo capturan la relación sistemática entre las covariables auxiliares y la densidad poblacional. Sea $\mathbf{X}_{obs}$ la matriz de covariables de dimensión $D_{obs} \times P$, donde la fila i corresponde al vector $\mathbf{x}_i^T$ del segmento observado i y las columnas corresponden a las P covariables seleccionadas tras el proceso de preparación de insumos descrito en el capítulo anterior. Análogamente, $\mathbf{X}_{tot}$ es la matriz de covariables de dimensión $D \times P$ que contiene los vectores de covariables para la totalidad de los segmentos del país, incluyendo aquellos no observados en el operativo censal.

El predictor lineal de efectos fijos para el segmento i es:

$$(\mathbf{X}_{obs}\boldsymbol{\beta})_i = \sum_{k=1}^P \beta_k \tilde{x}_{i,k}$$

donde $\tilde{x}_{i,k}$ denota la versión estandarizada de la covariable k en el segmento i , construida mediante las transformaciones descritas en el capítulo anterior: estandarización por media y desviación estándar para variables continuas simétricas, transformación logarítmica para variables de conteo con cola derecha, o normalización al intervalo unitario para índices y proporciones.

Las covariables incorporadas en $\mathbf{X}_{obs}$ se organizan en las tres categorías descritas en el capítulo de integración de fuentes. Las variables demográficas incluyen el tamaño medio del hogar, la razón de masculinidad y las proporciones de grupos etarios específicos. Las variables socioeconómicas incluyen índices de necesidades básicas insatisfechas, tasas de acceso a servicios públicos —electricidad, agua potable, internet— y conteos

provenientes de registros administrativos como padrones electorales o afiliados a sistemas de salud. Las variables espaciales de origen satelital incluyen la luminosidad nocturna media del segmento L_i , el área construida derivada del producto Global Human Settlement Layer, la proporción de distintas categorías de cobertura de suelo, la pendiente media del terreno y la altitud media sobre el nivel del mar.

Un aspecto crítico en la especificación de los efectos fijos es el tratamiento de la multicolinealidad entre covariables. Dado que muchas de las fuentes auxiliares descritas están correlacionadas entre sí —la luminosidad nocturna y el área construida tienden a ser altas en las mismas zonas urbanas, y el número de registros administrativos crece con la población—, la inclusión simultánea de variables altamente correlacionadas puede dificultar la estimación individual de los coeficientes. En la práctica, esto se aborda mediante análisis de correlación previo a la estimación y selección de variables basada en criterios estadísticos, complementados por el efecto regularizador de las distribuciones a priori $\beta_k \sim \mathcal{N}(0, 1)$, que penalizan moderadamente los coeficientes de gran magnitud y estabilizan la estimación en presencia de predictores correlacionados.

La estimación del vector β a partir de los datos proporciona información sobre cuáles características del segmento están más fuertemente asociadas con la densidad poblacional. Esta información puede utilizarse para orientar la actualización cartográfica, priorizar la recolección de covariables en futuros operativos censales y validar la consistencia de las fuentes utilizadas con los patrones demográficos observados en el territorio.

5.2.2 Efectos aleatorios

Los efectos aleatorios capturan la variabilidad sistemática entre unidades territoriales de nivel superior que no es explicada por las covariables auxiliares incluidas en los efectos fijos. Esta variabilidad puede deberse a factores institucionales no medidos —diferencias en la capacidad operativa de los equipos censales entre provincias, por ejemplo—, a condiciones locales no capturadas por las fuentes disponibles, o a características territoriales latentes que afectan simultáneamente a múltiples segmentos de una misma unidad.

Sea $\mathbf{Z}_{obs}$ la matriz de indicadores de dimensión $D_{obs} \times Q$, donde Q es el número de unidades territoriales de nivel superior consideradas. El elemento $z_{i,j}$ vale uno si el segmento i pertenece a la unidad territorial j y cero en caso contrario. Análogamente, $\mathbf{Z}_{tot}$ es la matriz de indicadores de dimensión $D \times Q$ para el conjunto completo de segmentos. La contribución de los efectos aleatorios al predictor lineal del segmento i es:

$$(\mathbf{Z}_{obs}\gamma)_i = \sum_{j=1}^Q z_{i,j} \gamma_j = \gamma_{j(i)}$$

donde $j(i)$ denota la unidad territorial a la que pertenece el segmento i . Dado que cada segmento pertenece a exactamente una unidad territorial, la contribución de los efectos aleatorios es simplemente el coeficiente $\gamma_{j(i)}$ correspondiente a su territorio.

La distribución a priori jerárquica $\gamma_j \sim \mathcal{N}(0, \sigma_U^2)$ regula el comportamiento de los efectos aleatorios a través del hiperparámetro σ_U . Cuando σ_U es pequeño, el modelo impone que los efectos aleatorios sean cercanos a cero, lo que es equivalente a una especificación sin ajustes territoriales específicos. Cuando σ_U es grande, los efectos aleatorios pueden tomar valores sustanciales, capturando diferencias importantes entre territorios no explicadas por las covariables. La estimación conjunta de σ_U y γ permite que el modelo aprenda automáticamente el grado de heterogeneidad territorial presente en los datos.

Una propiedad fundamental de la estructura jerárquica es el préstamo de fortaleza entre segmentos de un mismo territorio. Los segmentos con escasa información —conteos muy bajos, alta variabilidad en el conteo ob-

servado o baja cobertura censal— son estabilizados por la información de los demás segmentos de la misma unidad territorial, a través del efecto aleatorio compartido $\gamma_{j(i)}$. Simultáneamente, los efectos fijos proveen información de todos los segmentos del país para estimar el vector β , que contribuye a la predicción en segmentos con poca o ninguna cobertura censal. Este mecanismo de préstamo de información entre dominios constituye una de las principales ventajas del enfoque jerárquico bayesiano sobre los métodos de estimación directa.

La estructura de efectos aleatorios puede extenderse a múltiples niveles territoriales. En las aplicaciones sobre censos de América Latina y el Caribe desarrolladas en el marco de este libro, los efectos aleatorios se han especificado sobre provincias, departamentos o regiones, que constituyen la unidad administrativa intermedia más relevante para la gestión censal. En países con censos de alta resolución cartográfica y disponibilidad de datos administrativos a nivel de municipio, es posible incorporar efectos aleatorios anidados que capturen simultáneamente variabilidad regional y municipal, a costa de mayor complejidad computacional y mayor exigencia de información.

5.2.3 Interacciones

El predictor lineal en su forma básica representa efectos aditivos y lineales de las covariables sobre el logaritmo de la densidad poblacional. En determinados contextos, la relación entre las covariables y la densidad puede presentar patrones no lineales o interacciones que requieren representación explícita en el modelo.

Las interacciones entre covariables se incorporan mediante la inclusión de productos entre variables estandarizadas en la matriz $\mathbf{X}_{obs}$. Si $\tilde{x}_{i,k}$ y $\tilde{x}_{i,l}$ son dos covariables estandarizadas, su término de interacción se define como:

$$\tilde{x}_{i,kl} = \tilde{x}_{i,k} \cdot \tilde{x}_{i,l}$$

El predictor lineal extendido con interacciones incluye un coeficiente adicional β_{kl} con distribución a priori $\beta_{kl} \sim \mathcal{N}(0, 1)$, tratando el término de interacción de manera simétrica a los efectos principales. Esta formulación es apropiada cuando las covariables están estandarizadas, ya que garantiza que los términos de interacción operen en una escala comparable a los efectos principales.

En el contexto de la estimación de conteos censales, las interacciones de mayor relevancia sustantiva suelen involucrar combinaciones entre variables de uso del suelo y clasificaciones territoriales —la interacción entre luminosidad nocturna y la condición urbano-rural puede capturar diferencias en el patrón de ocupación habitacional según el tipo de asentamiento— o entre variables demográficas y socioeconómicas, como la relación entre el tamaño medio del hogar y el acceso a servicios públicos, cuya dirección puede variar sistemáticamente entre contextos urbanos y rurales.

Las interacciones entre efectos fijos y efectos aleatorios, conocidas como efectos de pendiente aleatoria, permiten que la relación de una covariable con la densidad varíe entre territorios. En esta especificación extendida, el coeficiente de la covariable k en el territorio j es $\beta_k + \nu_{j,k}$, donde $\nu_{j,k}$ representa la desviación específica del territorio respecto al efecto promedio nacional. Esta extensión aumenta la flexibilidad del modelo a costa de mayor dimensionalidad y puede resultar útil cuando se sospecha que el efecto de un predictor varía sistemáticamente entre regiones del país.

La inclusión de términos de interacción debe equilibrar la mejora en el ajuste del modelo con el riesgo de sobreajuste en datos de alta dimensión. En la práctica, la selección de interacciones relevantes se evalúa mediante criterios de comparación de modelos como el criterio LOO-CV o el WAIC, cuyas bases se desarrollan en el capítulo dedicado al diagnóstico y validación.

5.2.4 Sobredispersión, offset y alternativas distribucionales

El diseño del modelo Poisson-lognormal incorpora tres elementos adicionales que merecen consideración específica: el mecanismo de control de sobredispersión a través de la distribución log-normal, el uso del número de estructuras como offset del proceso de conteo, y las alternativas distribucionales consideradas frente al modelo propuesto.

El offset de estructuras habitacionales. El número de estructuras habitacionales V_i desempeña el papel de offset en el modelo: escala la intensidad del proceso de Poisson de manera proporcional al tamaño del segmento en términos de unidades habitacionales. Formalmente, el modelo puede reescribirse como:

$$\log(\lambda_i) = \log(\delta_i) + \log(V_i) = \mu_i + \varepsilon_i + \log(V_i)$$

donde $\varepsilon_i = \log(\delta_i) - \mu_i \sim \mathcal{N}(0, \sigma^2)$ es el error log-normal. El término $\log(V_i)$ actúa como offset con coeficiente fijado en uno, lo que equivale a modelar la densidad —y no el conteo total— como función de las covariables. Esta parametrización es estadísticamente más apropiada que incluir $\log(V_i)$ como covariable con coeficiente libre, ya que el número de estructuras debe considerarse una referencia de escala del proceso y no un predictor ordinario del logaritmo de la densidad.

La fuente del offset puede variar según la disponibilidad de información. En segmentos con preconteo operativo, V_i corresponde directamente al número de viviendas registradas durante la actualización cartográfica previa al censo. En segmentos sin preconteo o con preconteo desactualizado por cambios demográficos recientes, V_i puede aproximarse mediante el número de estructuras identificadas en imágenes satelitales. La calidad de la estimación final depende directamente de la precisión de V_i , dado que errores en el offset se propagan directamente hacia las predicciones de conteo en todo el conjunto de segmentos.

El mecanismo de sobredispersión log-normal. La inclusión de la densidad latente δ_i con distribución log-normal constituye el principal mecanismo de control de sobredispersión del modelo. Bajo un modelo de Poisson puro sin densidad latente y con predictor lineal fijo, se tendría $\text{Var}(Y_i) = \mathbb{E}[Y_i] = \lambda_i$. La introducción de δ_i log-normal rompe esta restricción de equidispersión e induce la varianza marginal presentada en la sección anterior, cuyo exceso sobre la media es estrictamente positivo para $\sigma > 0$. El parámetro σ controla directamente este exceso: a mayor σ , mayor sobredispersión relativa. Esta parametrización permite que el modelo se adapte automáticamente al nivel de variabilidad presente en los datos, sin requerir la especificación a priori del grado de sobredispersión.

Restricción de la densidad en predicción. En la implementación práctica del modelo, la densidad predicha para segmentos no observados se trunca superiormente con el objetivo de evitar predicciones demográficamente implausibles en segmentos con alto valor del predictor lineal. Concretamente, se aplica la restricción:

$$\tilde{\delta}_i = \min(\delta_i^*, \delta_{\max})$$

donde δ_i^* es la densidad generada por la distribución log-normal predictiva y $\delta_{\max}$ es un valor máximo admisible definido a partir del conocimiento experto sobre los rangos plausibles de ocupación habitacional en el contexto regional. En la práctica, $\delta_{\max}$ se determina a partir de la distribución empírica de las densidades observadas en $\mathcal{S}_{obs}$: un valor habitual es el percentil 99 de $\{\delta_i : i \in \mathcal{S}_{obs}\}$ o un umbral redondo —por ejemplo, 20 personas por estructura— que refleje el máximo demográficamente plausible para el país en cuestión. Esta restricción previene que la combinación de un predictor lineal alto y variabilidad log-normal genere densidades

que, multiplicadas por el número de estructuras, produzcan conteos individuales que superen toda referencia demográfica razonable.

Alternativas distribucionales. El modelo binomial negativo constituye la alternativa distribucional más natural al modelo Poisson-lognormal para el tratamiento de la sobredispersión. Bajo esta especificación, el conteo observado sigue directamente una distribución binomial negativa con media μ_i y parámetro de dispersión ϕ :

$$Y_i \mid \mu_i, \phi \sim \text{NegBin}(\mu_i, \phi), \quad \text{Var}(Y_i) = \mu_i + \frac{\mu_i^2}{\phi}$$

donde $\mu_i = \exp(\mathbf{x}_i^\top \beta + \mathbf{z}_i^\top \gamma) \cdot V_i$ incorpora el offset de estructuras. La diferencia fundamental respecto al modelo Poisson-lognormal reside en que la binomial negativa modela la sobredispersión mediante un único parámetro global ϕ , mientras que la log-normal permite heterogeneidad individual de la densidad a través del parámetro latente δ_i . Esta última propiedad hace del modelo Poisson-lognormal una opción más flexible para contextos con alta variabilidad territorial y disponibilidad de información a nivel de estructura habitacional.

Un modelo de Poisson con efectos aleatorios gaussianos no estructurados en el predictor lineal —sin el componente de densidad latente— constituye una alternativa computacionalmente más sencilla que puede resultar apropiada cuando la sobredispersión es moderada. En ese caso, el predictor lineal incluye un término de error no estructurado $u_i \sim \mathcal{N}(0, \sigma_u^2)$ que absorbe la variabilidad residual no capturada por los efectos fijos ni por los efectos aleatorios territoriales:

$$\log(\lambda_i) = \mathbf{x}_i^\top \beta + \mathbf{z}_i^\top \gamma + u_i + \log(V_i)$$

La elección entre estas especificaciones debe fundamentarse en el diagnóstico exploratorio de los datos —en particular, en la relación empírica entre la media y la varianza de los conteos por segmento— y en la comparación posterior mediante criterios de información. En contextos con elevada variabilidad territorial, alta proporción de segmentos con baja cobertura y disponibilidad de información sobre el número de estructuras, el modelo Poisson-lognormal con offset representa la especificación estadísticamente más apropiada para la estimación subnacional de conteos poblacionales en segmentos censales, y ha mostrado buen desempeño en las aplicaciones desarrolladas sobre censos de América Latina y el Caribe que sirven de referencia para este libro.

Inferencia Bayesiana e Implementación Computacional

El capítulo anterior estableció la especificación probabilística completa del modelo Poisson-lognormal: la distribución log-normal para la densidad latente de personas por estructura, la distribución de Poisson para los conteos observados, el predictor lineal con efectos fijos y aleatorios, y las distribuciones a priori débilmente informativas para todos los parámetros (Gelman et al. 2013). Esa especificación define la distribución posterior

$$p(\theta, \delta \mid \mathbf{Y}_{obs}) \propto p(\mathbf{Y}_{obs}, \delta \mid \beta, \gamma, \sigma) \cdot p(\gamma \mid \sigma_U) \cdot p(\beta) \cdot p(\sigma) \cdot p(\sigma_U)$$

pero no la hace analíticamente tratable: la combinación entre Poisson y log-normal no tiene forma cerrada en ninguno de los parámetros, y la dimensión del espacio parametral —que incluye D_{obs} densidades latentes más los $P + Q + 2$ parámetros estructurales— puede superar varios miles de dimensiones en aplicaciones censales reales.

El presente capítulo cierra esa brecha entre la especificación y la inferencia. La herramienta central es la simulación Monte Carlo por cadenas de Markov (MCMC), y dentro de ella el algoritmo de Monte Carlo Hamiltoniano (HMC) con el muestreador adaptativo NUTS (Hoffman y Gelman 2014), cuya implementación en Stan (Carpenter et al. 2017) permite obtener muestras de alta calidad de distribuciones posteriores complejas de manera eficiente. El capítulo se organiza en dos secciones: la primera describe los fundamentos del método de simulación y su implementación en Stan, ilustrada con las aplicaciones desarrolladas en cinco países del Caribe y América Latina en el marco de proyectos de asistencia técnica de CEPAL; la segunda describe el procedimiento para derivar estimaciones, intervalos de credibilidad y agregaciones territoriales.

6.1 Métodos de simulación

6.1.1 Cadenas de Markov Monte Carlo

El principio fundamental de la inferencia MCMC es aproximar la distribución posterior $p(\theta \mid \mathbf{Y})$ mediante una colección de muestras $\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(T)}$ generadas por una cadena de Markov ergódica cuya distribución estacionaria es precisamente la distribución posterior (Tierney 1994). Una vez que la cadena ha convergido a su distribución estacionaria, las muestras pueden tratarse como realizaciones aproximadas de la distribución posterior y utilizarse para calcular cualquier cantidad de interés mediante promedios de Monte Carlo.

Formalmente, para cualquier función $g(\theta)$ cuadrado-integrable respecto a la distribución posterior, el estimador de Monte Carlo

$$\hat{g}_T = \frac{1}{T} \sum_{t=1}^T g(\theta^{(t)})$$

converge casi seguramente a $\mathbb{E}[g(\theta) \mid \mathbf{Y}]$ cuando $T \rightarrow \infty$, por la ley fuerte de los grandes números para cadenas de Markov ergódicas. La tasa de convergencia depende de la correlación entre muestras consecutivas: cadenas con alta autocorrelación requieren mayor número de iteraciones para alcanzar la misma precisión que cadenas con baja autocorrelación.

Los métodos de Metropolis-Hastings y sus variantes, que dominaron la práctica bayesiana computacional desde la década de 1990, generan cadenas cuya eficiencia decrece rápidamente con la dimensión del espacio paramétrico. En modelos de alta dimensión como el Poisson-lognormal aplicado a miles de segmentos censales, la exploración aleatoria del espacio parametral produce cadenas altamente correlacionadas que requieren un número prohibitivo de iteraciones para converger. El algoritmo HMC resuelve este problema de manera fundamental al incorporar información de gradiente para guiar la exploración del espacio paramétrico (Neal 2011).

6.1.2 Monte Carlo Hamiltoniano y el algoritmo NUTS

El Monte Carlo Hamiltoniano fue introducido originalmente en el contexto de la física de partículas bajo el nombre de *Hybrid Monte Carlo* (Duane et al. 1987) y adaptado a la estadística bayesiana por Neal (2011). La idea central es transformar el problema de muestreo de la distribución posterior en un problema de simulación de dinámica hamiltoniana. El espacio parametral se interpreta como un espacio de posición, y se introduce un vector de momento p del mismo tamaño que θ . La energía del sistema se define como la función hamiltoniana:

$$H(\theta, p) = -\log p(\theta \mid \mathbf{Y}) + \frac{1}{2} p^\top M^{-1} p$$

donde M es una matriz de masa que actúa como preconditionador. La dinámica hamiltoniana conserva H y genera trayectorias que exploran regiones de alta densidad posterior de manera mucho más eficiente que los saltos aleatorios, ya que el gradiente de $\log p(\theta \mid \mathbf{Y})$ guía al sistema hacia regiones de mayor probabilidad.

En la práctica, la dinámica hamiltoniana se simula discretizando el tiempo con el integrador leapfrog, que alterna actualizaciones de la posición y el momento mediante pasos de tamaño ε :

$$p^{(t+\varepsilon/2)} = p^{(t)} + \frac{\varepsilon}{2} \nabla_{\theta} \log p(\theta^{(t)} \mid \mathbf{Y})$$

$$\theta^{(t+\varepsilon)} = \theta^{(t)} + \varepsilon M^{-1} p^{(t+\varepsilon/2)}$$

$$p^{(t+\varepsilon)} = p^{(t+\varepsilon/2)} + \frac{\varepsilon}{2} \nabla_{\theta} \log p(\theta^{(t+\varepsilon)} \mid \mathbf{Y})$$

Una introducción conceptual accesible a la mecánica de HMC, orientada a la práctica estadística bayesiana, puede encontrarse en Betancourt (2017). El análisis más detallado de las propiedades teóricas del método y su implementación en el contexto de modelos jerárquicos se encuentra en Neal (2011) y en el capítulo 12 de Gelman et al. (2013).

El algoritmo NUTS (Hoffman y Gelman 2014) resuelve el problema de elegir automáticamente el número de pasos leapfrog en cada iteración. La selección manual de este hiperparámetro en HMC estándar requiere ajuste fino; NUTS elimina esta necesidad mediante un criterio de parada automático que detiene la simulación cuando la trayectoria empieza a retroceder —a hacer un *U-turn* en el espacio parametral—, indicando que continuar la trayectoria no aportaría información adicional sobre la distribución posterior. El tamaño de paso ε se ajusta

automáticamente durante la fase de calentamiento mediante un algoritmo de tipo dual-averaging para alcanzar una tasa de aceptación objetivo en torno al 65–80 %.

Las ventajas de HMC-NUTS sobre los métodos clásicos son decisivas para modelos de alta dimensión. En tanto que los métodos tipo Gibbs o Metropolis-Hastings presentan un tamaño efectivo de muestra que crece aproximadamente como $T/\sqrt{d}$ con d dimensiones, HMC-NUTS escala mucho más favorablemente —en ciertos regímenes aproximadamente como $T/d^{1/4}$ — lo que hace factible la inferencia en modelos con miles de parámetros latentes como los que surgen en el contexto de la estimación subnacional de población (Betancourt 2017). Esta propiedad ha sido un factor determinante en la adopción de Stan como plataforma de estimación en los proyectos de estimación censal de CEPAL descritos en la sección 6.1.3.

6.1.3 Implementación en Stan

Stan es un lenguaje de programación probabilística que compila modelos en código C++ optimizado e implementa HMC-NUTS con calibración automática de hiperparámetros (Carpenter et al. 2017). La interfaz con R se realiza a través del paquete `rstan` (Stan Development Team 2023), que permite especificar el modelo en el lenguaje propio de Stan y gestionar la compilación, ejecución y extracción de resultados desde R.

Un programa Stan se organiza en bloques con funciones específicas. El bloque `data` declara las cantidades conocidas que se pasan desde R al modelo. El bloque `parameters` declara los parámetros desconocidos sobre los que se realiza la inferencia. El bloque `transformed parameters` define cantidades deterministas calculadas a partir de los parámetros. El bloque `model` define la distribución posterior a través de sus componentes log-verosimilitud y log-prior. El bloque `generated quantities` define cantidades que se calculan a partir de las muestras posteriores una vez completado el muestreo, incluyendo predicciones para nuevas observaciones.

El código Stan del modelo Poisson-lognormal, desarrollado en el marco de los proyectos de asistencia técnica de CEPAL y aplicado en Costa Rica, Barbados, Jamaica, Dominica y República Dominicana, tiene la siguiente estructura:

```
data {
  int<lower=1> D_obs;           // Segmentos observados en el censo
  int<lower=1> D_tot;          // Total de segmentos en el país
  int<lower=1> P;              // Número de covariables
  int<lower=1> Q;              // Número de efectos aleatorios
  array[D_obs] int<lower=0> Y_obs; // Conteos poblacionales observados
  array[D_obs] int<lower=0> V_obs; // Estructuras en segmentos observados
  array[D_tot] int<lower=0> V_tot; // Estructuras en todos los segmentos
  matrix[D_obs, P] X_obs;      // Covariables en segmentos observados
  matrix[D_tot, P] X_tot;      // Covariables en todos los segmentos
  matrix[D_obs, Q] Z_obs;      // Indicadores de efectos aleatorios (observadas)
  matrix[D_tot, Q] Z_tot;      // Indicadores de efectos aleatorios (todas)
}

parameters {
  vector[P]      beta;         // Coeficientes de efectos fijos
  vector[Q]      gamma;        // Coeficientes de efectos aleatorios
  real<lower=0>   sigma;        // Escala de la distribución log-normal
  real<lower=0>   sigmaU;       // Escala de los efectos aleatorios
```

```

    vector<lower=0>[D_obs] densidad; // Densidades latentes en segmentos observados
}

transformed parameters {
    vector[D_obs] lp; // Predictor Lineal
    vector<lower=0>[D_obs] lambda; // Parámetro Poisson

    lp = X_obs * beta + Z_obs * gamma;

    for (d in 1:D_obs)
        lambda[d] = fmin(fmax(1, densidad[d] * V_obs[d]), 10000000);
}

model {
    // Distribuciones a priori
    beta ~ normal(0, 1);
    gamma ~ normal(0, sigmaU);
    sigma ~ cauchy(0, 2.5);
    sigmaU ~ normal(0, 1);

    // Verosimilitud
    Y_obs ~ poisson(lambda);
    densidad ~ lognormal(lp, sigma);
}

generated quantities {
    vector[D_tot] lp_tot;
    array[D_tot] real<lower=0> densidad_hat;
    vector<lower=0>[D_tot] lambda2;
    array[D_tot] int<lower=0> Y_tot;
    vector[D_obs] log_lik; // Log-verosimilitud puntual (LOO/WAIC)

    lp_tot = X_tot * beta + Z_tot * gamma;

    for (d in 1:D_tot) {
        densidad_hat[d] = lognormal_rng(lp_tot[d], sigma);
        lambda2[d] = fmin(fmax(1, densidad_hat[d] * V_tot[d]), 10000000);
        Y_tot[d] = poisson_rng(lambda2[d]);
    }

    for (d in 1:D_obs)
        log_lik[d] = poisson_lpmf(Y_obs[d] | lambda[d]);
}

```

Cada bloque cumple una función precisa en relación con la especificación matemática del capítulo anterior. El bloque data recibe las ocho matrices y vectores que constituyen los insumos del modelo: dimensiones del

problema (D_{obs}, D_{tot}, P, Q) , conteos y estructuras observados, y las matrices de diseño para efectos fijos y aleatorios. El bloque `parameters` declara los cinco grupos de parámetros desconocidos $\{\beta, \gamma, \sigma, \sigma_U, \delta\}$; la restricción `lower=0` en `sigma`, `sigmaU` y `densidad` garantiza que Stan opere en el espacio transformado correspondiente, con la transformación logarítmica aplicada automáticamente durante el muestreo.

En el bloque `transformed parameters` se calcula el predictor lineal $\mathbf{lp} = \mathbf{X}_{obs}\beta + \mathbf{Z}_{obs}\gamma$ y se construye el parámetro de intensidad Poisson $\lambda_d = \delta_d \cdot V_d$. La función `fmin(fmax(1, ...), 10000000)` implementa la restricción de la intensidad a un rango numéricamente estable: impide intensidades menores que uno y previene desbordamientos aritméticos en segmentos con predictor lineal muy alto.

El bloque `model` transcribe directamente las especificaciones probabilísticas del capítulo anterior. La línea `Y_obs ~ poisson(lambda)` acumula la log-verosimilitud de Poisson; `densidad ~ lognormal(lp, sigma)` acumula la contribución log-normal de las densidades latentes incluyendo el jacobiano correspondiente; y las distribuciones a priori reflejan las elecciones débilmente informativas discutidas en el capítulo anterior, siguiendo las recomendaciones de Gelman et al. (2013) y McElreath (2020) para modelos jerárquicos.

El bloque `generated quantities` implementa la predicción fuera de muestra. Para cada segmento del conjunto completo $\mathcal{S}$ se calcula el predictor lineal con las covariables de todos los segmentos, se genera una muestra de la densidad predictiva $\tilde{\delta}_d \sim \text{LogNormal}(\text{lp}_{\text{tot}_d}, \sigma)$ y se genera un conteo predictivo $\tilde{Y}_d \sim \text{Poisson}(\tilde{\delta}_d \cdot V_d)$. Este bloque se ejecuta una vez por muestra de la distribución posterior, de modo que la colección de matrices `Y_tot` y `densidad_hat` a lo largo de las T iteraciones constituye directamente la distribución predictiva posterior. Adicionalmente, el bloque calcula el vector `log_lik` con la log-verosimilitud puntual de Poisson evaluada en cada segmento observado $-\log p(Y_i | \delta_i, V_i)$ para $i \in \mathcal{S}_{obs}$, requerido posteriormente para el cálculo de los criterios LOO y WAIC.

6.1.4 Configuración de cadenas, muestras e iteraciones

La ejecución del modelo Stan desde R requiere configurar cuatro parámetros principales: el número de cadenas, el número de iteraciones totales, el número de iteraciones de calentamiento y los parámetros de control del algoritmo (Gelman et al. 2013, cap. 11):

```
library(rstan)
library(bayesplot)
library(loo)

# Habilitar paralelización y caché de modelos compilados
options(mc.cores = parallel::detectCores())
rstan::rstan_options(auto_write = TRUE)

# Ajustar el modelo
stan_model <- rstan::stan(
  file = "00_function/Modelo_ECLAC_V02_fin.stan",
  data = list_par,
  iter = 2000,
  warmup = 1500,
  chains = 4,
  control = list(max_treedepth = 15)
)
```

El parámetro `iter` fija el número total de iteraciones por cadena, incluyendo el calentamiento. De las 2 000 iteraciones totales por cadena, 1 500 corresponden a la fase de calentamiento y 500 a la fase de inferencia. Con 4 cadenas en paralelo, el conjunto de muestras útiles comprende $4 \times 500 = 2\,000$ muestras de la distribución posterior. En aplicaciones censales con alta dimensión latente — D_{obs} del orden de miles de segmentos— esta configuración es un punto de partida razonable que puede refinarse en función de los diagnósticos de convergencia descritos en el capítulo siguiente.

El uso de múltiples cadenas independientes, iniciadas desde puntos dispersos del espacio paramétrico, es una práctica estándar en inferencia MCMC (Gelman y Rubin 1992). La comparación entre cadenas permite detectar problemas de convergencia que una cadena única no puede revelar: si todas las cadenas convergen a la misma región de alta densidad posterior, existe mayor confianza en que están explorando adecuadamente la distribución objetivo. El diagnóstico formal basado en la comparación de varianza entre cadenas e intra-cadena, el estadístico $\hat{R}$ (Gelman y Rubin 1992; Vehtari et al. 2021), cuyo fundamento matemático se documenta en dichas referencias, se reporta de forma sistemática junto con el tamaño efectivo de muestra en el resumen posterior presentado en la sección siguiente.

La fase de calentamiento cumple tres funciones en Stan. Primera: el algoritmo NUTS ajusta adaptativamente el tamaño de paso ε para alcanzar la tasa de aceptación objetivo. Segunda: se estima la matriz de masa M que actúa como métrica del espacio paramétrico; Stan utiliza por defecto una métrica euclidiana diagonal cuyos elementos se estiman a partir de la varianza empírica de las muestras de calentamiento. Tercera: la cadena se aproxima a la región de alta densidad posterior, descartando las muestras iniciales que pueden estar lejos del modo. Las muestras de la fase de calentamiento no son utilizables para inferencia porque los hiperparámetros del algoritmo aún están siendo ajustados.

El parámetro `max_treedepth = 15` controla la profundidad máxima del árbol binomial que construye NUTS en cada iteración. Un árbol de profundidad L equivale a 2^L evaluaciones del leapfrog, lo que permite trayectorias de gran alcance en distribuciones posteriores con geometría compleja. El valor por defecto en Stan es 10; aumentarlo a 15 es recomendable en modelos con alta dimensionalidad latente o correlaciones posteriores fuertes, al costo de mayor tiempo de cómputo por iteración. Si durante la ejecución Stan registra advertencias de tipo `maximum treedepth exceeded`, se debe aumentar este parámetro o revisar la parametrización del modelo.

6.1.5 Paralelización y eficiencia computacional

La línea `options(mc.cores = parallel::detectCores())` configura la ejecución de las cuatro cadenas en paralelo, utilizando tantos núcleos del procesador como estén disponibles. La opción `rs-tan_options(auto_write = TRUE)` permite que Stan almacene en disco el modelo compilado en C++, de modo que sucesivas ejecuciones del mismo modelo reutilizan el código compilado y evitan el tiempo de compilación —que puede ser de 30 a 90 segundos según la complejidad del modelo— en cada llamada a `stan()`.

En aplicaciones con D_{obs} del orden de varios miles de segmentos, el costo computacional dominante por iteración proviene de la evaluación del gradiente del logaritmo de la distribución conjunta respecto a los parámetros latentes δ . Stan calcula estos gradientes mediante diferenciación automática sobre el grafo computacional del modelo (Carpenter et al. 2017), lo que garantiza gradientes exactos al costo de un factor constante —típicamente entre 2 y 5— sobre el tiempo de evaluación de la log-densidad.

El manejo de memoria es relevante cuando el bloque `generated quantities` genera matrices de predicción de dimensión $D_{tot} \times T$. Es recomendable guardar el objeto Stan en disco inmediatamente tras la ejecución para evitar recomputaciones:

```
# Guardar el objeto ajustado
saveRDS(stan_model,
        file = "Data/modelo/fit_pob_bayes_lognormal.rds")

# Cargar para análisis posteriores sin reejecutar el modelo
stan_model <- readRDS("Data/modelo/fit_pob_bayes_lognormal.rds")
```

6.2 Distribución posterior y estimaciones

6.2.1 Estimaciones puntuales y resumen posterior

Una vez obtenidas las muestras de la distribución posterior, el objeto `stan_model` generado por `rstan::stan()` concentra toda la información inferencial del modelo. La función `summary()` extrae para cada parámetro las estadísticas de resumen posterior más relevantes: media, error estándar de Monte Carlo, desviación estándar, percentiles y los diagnósticos de convergencia $\hat{R}$ (Vehtari et al. 2021) y tamaño efectivo de muestra (Gelman y Rubin 1992):

```
# Resumen de todos los parámetros
params <- summary(stan_model)$summary

# Resumen específico de parámetros de interés
densidad_obs <- summary(stan_model, pars = "densidad")$summary
densidad_pred <- summary(stan_model, pars = "densidad_hat")$summary
Y_tot_pred <- summary(stan_model, pars = "Y_tot")$summary
```

Cada fila de estas matrices de resumen corresponde a un parámetro o cantidad generada, y las columnas reportan las siguientes estadísticas:

Columna	Descripción
mean	Media posterior $\hat{\theta} = \mathbb{E}[\theta \mathbf{Y}]$
se_mean	Error estándar de Monte Carlo $\hat{\sigma}_{\theta} / \sqrt{n_{eff}}$
sd	Desviación estándar posterior
2.5 %, 97.5 %	Intervalo de credibilidad al 95 %
50 %	Mediana posterior
n_eff	Tamaño efectivo de muestra
Rhat	Estadístico de convergencia $\hat{R}$

Para los conteos predichos `Y_tot`, la media posterior y la mediana posterior constituyen las dos estimaciones puntuales naturales. La media es el estimador de Bayes bajo pérdida cuadrática y suele preferirse para agregaciones. La mediana es el estimador de Bayes bajo pérdida absoluta y es más robusta a colas pesadas de la distribución predictiva (Gelman et al. 2013). La diferencia entre ambas estimaciones a nivel nacional —obtenida con `sum(Y_tot_pred[, "mean"])` y `sum(Y_tot_pred[, "50%"])` respectivamente— cuantifica la asimetría agregada de la distribución predictiva y debe documentarse en los reportes técnicos.

6.2.2 Extracción de muestras e intervalos de credibilidad

La función `rstan::extract()` extrae las muestras brutas de la distribución posterior en forma de arreglos, lo que permite calcular cualquier funcional que no esté incluido en el resumen estándar:

```
# Extraer muestras posteriores de los parámetros de interés
posterior_samples <- rstan::extract(
  stan_model,
  pars = c("densidad", "Y_tot", "densidad_hat")
)

# densidad_post: matriz de dimensión T x D_obs
densidad_post <- posterior_samples$densidad

# Y_tot_samp: matriz de dimensión T x D_tot
Y_tot_samp <- posterior_samples$Y_tot
```

El intervalo de credibilidad al 95 % para el conteo del segmento d se calcula como:

$$IC_{95\%}(Y_d) = [F_{Y_d}^{-1}(0,025), F_{Y_d}^{-1}(0,975)]$$

donde $F_{Y_d}^{-1}$ denota el cuantil empírico de las T muestras de $Y_tot_samp[, d]$. A diferencia de los intervalos de confianza frecuentistas, el intervalo de credibilidad tiene una interpretación probabilística directa: dada la información observada y el modelo, la probabilidad posterior de que Y_d caiga en ese intervalo es 0.95 (Gelman et al. 2013). Esta propiedad facilita la comunicación de la incertidumbre a usuarios institucionales no especializados en estadística.

6.2.3 Estimaciones a nivel de segmento censal

La predicción del conteo poblacional para cada segmento del país combina la información directa del censo con las predicciones del modelo según el estado de cobertura del operativo censal:

```
library(tidyverse)

# Extraer predicciones como data frame
df_y_pred <- data.frame(t(Y_tot_samp))
colnames(df_y_pred) <- paste0("pred_cont_", seq_len(ncol(df_y_pred)))

# Unir con metadatos del segmento
df_y_pred <- data_model %>%
  select(ED:Status) %>%
  bind_cols(df_y_pred)

pred_cols <- grep("^pred_cont_", names(df_y_pred), value = TRUE)
```

```
# Calcular estimación puntual y medidas de incertidumbre por segmento
estimaciones_segmento <- df_y_pred %>%
  rowwise() %>%
  mutate(
    pob_media = mean(c_across(all_of(pred_cols))),
    pob_mediana = median(c_across(all_of(pred_cols))),
    pob_sd = sd(c_across(all_of(pred_cols))),
    pob_li_95 = quantile(c_across(all_of(pred_cols)), 0.025),
    pob_ls_95 = quantile(c_across(all_of(pred_cols)), 0.975)
  ) %>%
  ungroup()
```

La estimación definitiva del conteo de cada segmento aplica la siguiente regla según el estado de cobertura:

```
estimaciones_segmento <- estimaciones_segmento %>%
  mutate(
    pob_final = case_when(
      # Cobertura completa: se usa directamente el conteo censal
      Status == "Completed-full" ~ T_pers,
      # Sin cobertura: se usa la predicción del modelo
      Status == "Not Attempted" ~ pob_media,
      # Cobertura parcial con subenumeración: se usa la predicción
      Status %in% c("Completed-with refusals", "Completed-partial") &
        T_pers < pob_media ~ pob_media,
      # Cobertura parcial sin subenumeración evidente: se mantiene el observado
      Status %in% c("Completed-with refusals", "Completed-partial") &
        T_pers >= pob_media ~ T_pers,
      TRUE ~ NA_real_
    )
  )
```

Esta regla garantiza coherencia operativa y refleja la naturaleza unidireccional del error de cobertura: la omisión genera subenumeración, no sobreconteo. Los segmentos con cobertura completa no son modificados por el modelo; los no abordados reciben íntegramente la predicción bayesiana; los parcialmente cubiertos son tratados según el principio de dominancia descrito en Mercer et al. (2015) para contextos similares de integración de múltiples fuentes.

6.2.4 Agregación a niveles geográficos superiores

La distribución posterior del total de población en cualquier unidad geográfica de nivel superior se obtiene sumando los conteos de los segmentos que la componen a través de cada muestra de la distribución predictiva. Esta propiedad de coherencia por agregación es una de las ventajas del enfoque probabilístico respecto a los métodos de estimación directa (Rao y Molina 2015):

```

# Agregación a nivel parroquial con intervalo de credibilidad
estimaciones_parroquia <- df_y_pred %>%
  group_by(parish) %>%
  summarise(
    across(all_of(pred_cols), sum, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  rowwise() %>%
  mutate(
    tot_pob_media = mean(c_across(all_of(pred_cols))),
    tot_pob_sd    = sd(c_across(all_of(pred_cols))),
    tot_pob_li_95 = quantile(c_across(all_of(pred_cols)), 0.025),
    tot_pob_ls_95 = quantile(c_across(all_of(pred_cols)), 0.975),
    len_ic       = tot_pob_ls_95 - tot_pob_li_95
  ) %>%
  ungroup()

# Total nacional con intervalo de credibilidad
estimacion_nacional <- df_y_pred %>%
  summarise(across(all_of(pred_cols), sum, na.rm = TRUE)) %>%
  pivot_longer(everything(), names_to = "iteracion", values_to = "total_pob") %>%
  summarise(
    media    = mean(total_pob),
    sd       = sd(total_pob),
    li_95    = quantile(total_pob, 0.025),
    ls_95    = quantile(total_pob, 0.975),
    mediana  = median(total_pob)
  )

```

La amplitud del intervalo de credibilidad del total nacional refleja simultáneamente la incertidumbre sobre los parámetros del modelo y la variabilidad estocástica del proceso de Poisson en cada segmento. En aplicaciones prácticas, este intervalo es usualmente estrecho en comparación con el total estimado porque la mayor parte de la variabilidad individual se cancela en la suma; pero puede ser sustancialmente amplio para unidades geográficas con pocos segmentos y baja cobertura censal.

6.2.5 Verificación predictiva posterior

La verificación de la capacidad del modelo para reproducir los patrones observados en los datos se realiza mediante la comparación de la distribución predictiva posterior con los datos observados (Gabry et al. 2019). En el contexto del modelo Poisson-lognormal, es más informativo verificar la capacidad predictiva sobre la densidad $\delta_i = Y_i/V_i$ que directamente sobre los conteos, ya que la densidad es la cantidad central del modelo y su distribución no depende del número de estructuras:

```

# Subconjunto aleatorio de muestras de densidad
densidad_post <- posterior_samples$densidad

```

```

idx_muestra <- sample(nrow(densidad_post), 500)
densidad_rep <- densidad_post[idx_muestra, ]

# Gráfico de verificación predictiva posterior
ppc_dens <- bayesplot::ppc_dens_overlay(
  y = as.numeric(Y_obs / V_obs),
  yrep = densidad_rep
)

# Verificación sobre los conteos brutos
ppc_pers <- bayesplot::ppc_dens_overlay(
  y = as.numeric(Y_obs),
  yrep = t(t(densidad_rep) * V_obs)
)

ppc_dens | ppc_pers

```

En este gráfico (Gabry y Mahr 2022), la línea sólida corresponde a la distribución empírica de los datos observados y las líneas semitransparentes representan las distribuciones predictivas generadas por las muestras posteriores. Un modelo bien especificado produce líneas predictivas que envuelven razonablemente bien la distribución observada sin exceso ni defecto sistemático. Desviaciones importantes señalan limitaciones del modelo que pueden orientar la reformulación del predictor lineal o el cambio de la distribución de la densidad latente (Gabry et al. 2019).

6.2.6 Criterios de información LOO y WAIC

Los criterios de comparación de modelos permiten seleccionar entre especificaciones alternativas sin recurrir a validación cruzada explícita (Vehtari et al. 2017). El criterio LOO-CV y el WAIC (Watanabe 2010) se calculan a partir de la log-verosimilitud evaluada en cada muestra posterior:

```

# Extraer log-verosimilitud puntual (una columna por segmento observado)
log_lik_mat <- loo::extract_log_lik(stan_model,
                                   parameter_name = "log_lik")

# WAIC y LOO-CV
waic_result <- loo::waic(log_lik_mat)
loo_result <- loo::loo(log_lik_mat)

print(waic_result)
print(loo_result)

# Comparar dos especificaciones alternativas
loo::loo_compare(loo_modelo_1, loo_modelo_2)

```

Valores más altos de elpd-LOO (*expected log predictive density*) indican mejor capacidad predictiva fuera de muestra (Vehtari et al. 2017). En la comparación entre modelos, una diferencia en elpd superior al doble de su

error estándar se interpreta como evidencia de diferencia predictiva sustancial. La comparación entre LOO y WAIC en presencia de observaciones influyentes —frecuentes en segmentos con conteos extremos— se discute en Piironen y Vehtari (2017), que concluye que LOO es más robusto en esos contextos y debe ser el criterio principal para selección del modelo final.

6.3 Resumen

Este capítulo describió el ciclo completo de inferencia computacional para el modelo Poisson-lognormal: desde los fundamentos del algoritmo HMC-NUTS (Hoffman y Gelman 2014; Betancourt 2017), pasando por la implementación en Stan (Carpenter et al. 2017) con los cinco bloques del programa, hasta el procedimiento de extracción de estimaciones puntuales, intervalos de credibilidad y agregaciones territoriales en R mediante `rstan` (Stan Development Team 2023), `bayesplot` (Gabry y Mahr 2022) y `loo` (Vehtari et al. 2022, 2017). Las aplicaciones en Costa Rica, Barbados, Jamaica, Dominica y República Dominicana ilustraron cómo los parámetros de implementación —selección de covariables, fuente del offset, umbral de densidad y configuración MCMC— se adaptan al contexto de cada operativo censal sin alterar la especificación estadística del modelo. El capítulo incluyó además el diagnóstico de convergencia mediante los estadísticos $\hat{R}$ y ESS (Vehtari et al. 2021; Gelman y Rubin 1992), la validación predictiva posterior (Gabry et al. 2019) y la selección entre modelos alternativos mediante los criterios LOO y WAIC (Vehtari et al. 2017; Watanabe 2010). El capítulo siguiente profundiza en estos diagnósticos —trazas, autocorrelación y diagnósticos específicos de HMC, residuos bayesianos y calibración, criterios formales de aceptación de modelos— y añade la validación externa frente a proyecciones demográficas, registros administrativos independientes y coherencia geoespacial, como verificación final antes de la publicación de estimaciones oficiales.

Diagnóstico y Validación del Modelo

El capítulo anterior estableció el procedimiento de estimación del modelo Poisson-lognormal mediante HMC-NUTS en Stan y presentó, de forma introductoria, tres herramientas de verificación: el estadístico $\hat{R}$ y el tamaño efectivo de muestra reportados por `summary()`, la verificación predictiva posterior mediante superposición de densidades y los criterios de información LOO y WAIC. Ninguna estimación bayesiana debe considerarse válida por el solo hecho de haber sido producida por el muestreador: las muestras posteriores pueden provenir de cadenas que no convergieron a la distribución objetivo, el modelo puede ajustar razonablemente la media de los datos pero fallar en reproducir su variabilidad o su forma, y una especificación puede superar los diagnósticos internos de ajuste y, sin embargo, ser inconsistente con fuentes de información externas al propio modelo.

Este capítulo profundiza en esas tres líneas de verificación y añade una cuarta, ausente en el capítulo anterior: la validación externa, que contrasta las estimaciones del modelo con fuentes independientes de los datos utilizados en la estimación. La estructura se organiza en cuatro secciones: diagnóstico de convergencia MCMC, validación predictiva posterior, selección y comparación de modelos, y validación externa. El objetivo transversal es establecer criterios explícitos y reproducibles para decidir cuándo un modelo puede considerarse adecuado para su uso en la producción de estimaciones oficiales de población, y cuándo debe ser reformulado.

7.1 Diagnóstico de convergencia MCMC

El diagnóstico de convergencia es la primera verificación que debe realizarse sobre cualquier ajuste MCMC, con prioridad sobre cualquier interpretación sustantiva de los parámetros. Si las cadenas no han convergido a la distribución posterior estacionaria, las muestras no son representativas de $p(\theta, \delta \mid \mathbf{Y}_{obs})$ y cualquier estimación puntual, intervalo de credibilidad o criterio de comparación de modelos calculado a partir de ellas carece de validez.

7.1.1 Estadístico R-hat

El estadístico $\hat{R}$, propuesto originalmente por Gelman y Rubin (1992), compara la variabilidad entre cadenas con la variabilidad dentro de cada cadena. Sea $\theta_{t,j}$ la muestra t de la cadena j , con $t = 1, \dots, n$ e $j = 1, \dots, m$, tras descartar el calentamiento. La varianza dentro de las cadenas se calcula como:

$$W = \frac{1}{m} \sum_{j=1}^m s_j^2, \quad s_j^2 = \frac{1}{n-1} \sum_{t=1}^n (\theta_{t,j} - \bar{\theta}_j)^2$$

donde $\bar{\theta}_j$ es la media de la cadena j . La varianza entre cadenas se calcula como:

$$B = \frac{n}{m-1} \sum_{j=1}^m (\bar{\theta}_{\cdot j} - \bar{\theta}_{\cdot\cdot})^2$$

donde $\bar{\theta}_{\cdot\cdot} = \frac{1}{m} \sum_j \bar{\theta}_{\cdot j}$ es la media global. La varianza marginal posterior se estima combinando ambas fuentes:

$$\hat{V} = \frac{n-1}{n} W + \frac{1}{n} B$$

y el estadístico de convergencia se define como:

$$\hat{R} = \sqrt{\frac{\hat{V}}{W}}$$

Cuando las cadenas han convergido a la misma distribución estacionaria, $\hat{V}$ y W estiman la misma cantidad y $\hat{R} \rightarrow 1$. Valores de $\hat{R}$ sustancialmente mayores que 1 indican que las cadenas todavía exploran regiones distintas del espacio parametral y que se requieren más iteraciones, una reparametrización del modelo o una revisión de las distribuciones a priori.

La versión clásica de $\hat{R}$ presenta limitaciones cuando la distribución posterior tiene colas pesadas o es asimétrica, dado que la varianza puede no converger de forma estable. Vehtari et al. (2021) propone una versión mejorada, el $\hat{R}$ ranking-normalizado y plegado (*rank-normalized, folded $\hat{R}$*), que transforma las muestras a rangos normalizados antes de aplicar la fórmula anterior y calcula el diagnóstico por separado sobre las muestras originales y sobre su versión plegada respecto a la mediana, con el fin de detectar simultáneamente problemas de convergencia en la localización y en la escala de la distribución. Esta es la versión implementada por defecto en versiones recientes de Stan y del paquete posterior, y es la que reporta `summary()` sobre un objeto `stanfit`.

El umbral tradicionalmente utilizado en la práctica ha sido $\hat{R} < 1.1$; sin embargo, Vehtari et al. (2021) recomienda un criterio más estricto, $\hat{R} < 1.01$, dado que el diagnóstico ranking-normalizado es más sensible a problemas de convergencia residuales que la versión clásica. En aplicaciones censales con miles de densidades latentes δ_i , es recomendable exigir que la totalidad de los parámetros —no solo los estructurales β, γ, σ y σ_U — satisfagan este umbral antes de proceder al análisis de resultados:

```
library(posterior)

rhat_vals <- summary(stan_model)$summary[, "Rhat"]

# Parámetros que no satisfacen el umbral recomendado
problematicos <- rhat_vals[rhat_vals > 1.01]
length(problematicos)
```

7.1.2 Tamaño efectivo de muestra (ESS)

Las muestras generadas por una cadena de Markov están autocorrelacionadas: muestras consecutivas son más similares entre sí que muestras independientes de la distribución posterior. El tamaño efectivo de muestra (*Effective Sample Size*, ESS) cuantifica cuántas muestras independientes equivalen, en términos de precisión de

Monte Carlo, al conjunto de muestras autocorrelacionadas disponibles. Para una cantidad escalar θ con autocorrelación $\hat{\rho}_t$ en el retraso t , estimada combinando las m cadenas, el tamaño efectivo de muestra se define como:

$$n_{eff} = \frac{mn}{1 + 2 \sum_{t=1}^{\infty} \hat{\rho}_t}$$

donde mn es el número total de muestras disponibles tras el calentamiento. Cuanto mayor es la autocorrelación, menor es n_{eff} en relación con mn , y mayor es el error estándar de Monte Carlo de cualquier estimación basada en esas muestras, tal como refleja la columna `se_mean` del resumen posterior introducida en el capítulo anterior.

Al igual que con $\hat{R}$, Vehtari et al. (2021) muestra que un único valor de ESS puede ser engañoso cuando la distribución posterior es asimétrica o de colas pesadas, dado que la mezcla de la cadena puede ser buena en el centro de la distribución y deficiente en las colas. Por esta razón se recomienda reportar dos cantidades: el **Bulk-ESS**, que mide la eficiencia de muestreo en la región central de la distribución (relevante para la estimación de medias y medianas), y el **Tail-ESS**, que mide la eficiencia en las colas (relevante para la estimación de los cuantiles 2.5 % y 97.5 % que definen los intervalos de credibilidad). Un modelo puede tener un Bulk-ESS adecuado y, simultáneamente, un Tail-ESS insuficiente para reportar intervalos de credibilidad confiables.

Como regla práctica, se recomienda un ESS mínimo de 400 muestras efectivas —tanto Bulk como Tail— por cada cantidad de interés, independientemente del número de cadenas o iteraciones totales utilizadas:

```
library(posterior)

draws_array <- as_draws_array(stan_model)

ess_bulk <- apply(draws_array, 3, ess_bulk)
ess_tail <- apply(draws_array, 3, ess_tail)

# Parámetros con ESS insuficiente
which(ess_bulk < 400 | ess_tail < 400)
```

Cuando el ESS es insuficiente, las alternativas incluyen aumentar el número de iteraciones post-calentamiento, mejorar la parametrización del modelo —por ejemplo, mediante la parametrización no centrada de los efectos aleatorios jerárquicos, que suele reducir sustancialmente la autocorrelación cuando σ_U es pequeño— o revisar si el modelo está correctamente identificado.

7.1.3 Trace plots, autocorrelación y diagnósticos específicos de HMC

La inspección visual complementa los diagnósticos numéricos y permite detectar patrones de no convergencia que un estadístico agregado puede no capturar completamente. El *trace plot* representa la secuencia de valores muestreados de un parámetro a lo largo de las iteraciones, superponiendo las distintas cadenas:

```
library(bayesplot)

mcmc_trace(
  as.array(stan_model),
```

```
pars = c("sigma", "sigmaU", "beta[1]", "beta[2]")
)
```

Un patrón de convergencia adecuado se caracteriza por cadenas que oscilan establemente alrededor de un valor común, sin tendencias sistemáticas ni saltos entre regiones distintas del espacio parametral —el patrón informalmente descrito como “*fat hairy caterpillar*” (oruga peluda y gruesa)—. Cadenas que exhiben tendencias, que permanecen estancadas en un valor durante tramos prolongados, o que exploran regiones claramente distintas entre sí, son indicativas de no convergencia y deben acompañarse de $\hat{R} > 1.01$ en el diagnóstico numérico correspondiente.

La función de autocorrelación (ACF) cuantifica la correlación entre muestras separadas por t iteraciones:

```
mcmc_acf(
  as.array(stan_model),
  pars = c("sigma", "sigmaU"),
  lags = 20
)
```

Una autocorrelación que decae rápidamente hacia cero es deseable; una autocorrelación que permanece alta incluso a retrasos grandes indica una cadena con mezcla deficiente, consistente con un ESS bajo.

Más allá de los diagnósticos genéricos de MCMC, el algoritmo HMC-NUTS provee diagnósticos adicionales específicos de su mecánica interna que deben revisarse sistemáticamente. Las **transiciones divergentes** ocurren cuando el integrador leapfrog introduce un error numérico excesivo durante la simulación de la dinámica hamiltoniana, típicamente en regiones de la distribución posterior con curvatura muy pronunciada (Betancourt 2017). Un número elevado de divergencias señala que el muestreador no está explorando correctamente esas regiones, lo que puede sesgar sistemáticamente las estimaciones asociadas:

```
rstan::check_hmc_diagnostics(stan_model)

# Número de transiciones divergentes por cadena
rstan::get_num_divergent(stan_model)

# Iteraciones que alcanzaron la profundidad máxima del árbol
rstan::get_num_max_treedepth(stan_model)
```

En el modelo Poisson-lognormal, las divergencias tienden a concentrarse en segmentos con densidad latente δ_i extrema —conteos muy bajos combinados con un número reducido de estructuras, o viceversa— donde la verosimilitud es poco informativa y la distribución a priori log-normal domina localmente la geometría posterior. Cuando el número de divergencias es elevado, las estrategias de mitigación incluyen aumentar el parámetro `adapt_delta` de Stan por encima de su valor por defecto (0.8), lo que reduce el tamaño de paso ε y mejora la precisión numérica del integrador a costa de mayor tiempo de cómputo, o reparametrizar el modelo para reducir la curvatura de la posterior.

Un segundo diagnóstico específico de HMC es la fracción de información faltante basada en energía (E-BFMI, *Energy Bayesian Fraction of Missing Information*), que evalúa si la distribución marginal de la energía hamiltoniana explorada por la cadena es consistente con una exploración eficiente (Betancourt 2017). Valores de

E-BFMI inferiores a 0.2 son indicativos de una exploración deficiente de las colas de la distribución posterior, incluso en ausencia de divergencias o de valores altos de $\hat{R}$.

Finalmente, como complemento a $\hat{R}$ y al ESS, Geweke (1992) propone un diagnóstico de convergencia aplicable a una única cadena, basado en la comparación de las medias estimadas en dos segmentos no superpuestos de la secuencia —típicamente el primer 10 % y el último 50 % de las iteraciones post-calentamiento—. Bajo convergencia, ambos segmentos deben estimar la misma cantidad, y el estadístico:

$$Z_G = \frac{\bar{\theta}_A - \bar{\theta}_B}{\sqrt{\widehat{\text{Var}}(\bar{\theta}_A) + \widehat{\text{Var}}(\bar{\theta}_B)}}$$

—donde $\bar{\theta}_A$ y $\bar{\theta}_B$ son las medias muestrales de cada segmento y sus varianzas se estiman mediante métodos espectrales que corrigen por autocorrelación— se distribuye aproximadamente $\mathcal{N}(0, 1)$ si la cadena ha alcanzado su distribución estacionaria. Aunque ha sido en gran medida desplazado por $\hat{R}$ y el ESS en la práctica moderna con múltiples cadenas, el diagnóstico de Geweke resulta útil como verificación adicional de estacionariedad dentro de cada cadena individual.

7.2 Validación predictiva posterior

Un modelo puede satisfacer todos los diagnósticos de convergencia y, sin embargo, ser inadecuado para describir los datos observados. La validación predictiva posterior evalúa esta segunda dimensión: la capacidad del modelo ajustado para generar datos simulados que se asemejen a los datos reales.

7.2.1 Posterior predictive checks (PPC)

El principio general de la verificación predictiva posterior (Gelman et al. 2013) consiste en comparar los datos observados $\mathbf{Y}_{obs}$ con réplicas $\mathbf{Y}^{rep}$ generadas a partir de la distribución predictiva posterior:

$$p(\mathbf{Y}^{rep} | \mathbf{Y}_{obs}) = \int p(\mathbf{Y}^{rep} | \theta) p(\theta | \mathbf{Y}_{obs}) d\theta$$

Para una función de prueba $T(\cdot)$ —una media, una desviación estándar, una proporción de ceros o cualquier estadístico relevante para el problema—, el valor predictivo posterior se estima como la proporción de réplicas cuyo estadístico iguala o supera al observado:

$$p_B = \Pr(T(\mathbf{Y}^{rep}) \geq T(\mathbf{Y}_{obs}) | \mathbf{Y}_{obs}) \approx \frac{1}{T} \sum_{t=1}^T \mathbb{1}\{T(\mathbf{Y}^{rep,(t)}) \geq T(\mathbf{Y}_{obs})\}$$

Valores de p_B cercanos a 0 o a 1 indican que el estadístico observado se ubica en una región de baja densidad predictiva, evidenciando una discrepancia sistemática entre el modelo y los datos en la dimensión capturada por $T(\cdot)$.

Más allá de la superposición de densidades presentada en el capítulo anterior, resulta informativo evaluar estadísticos de prueba específicos mediante `bayesplot::ppc_stat()`:

```
library(bayesplot)

lambda_post <- rstan::extract(stan_model, pars = "lambda")$lambda
Y_rep <- matrix(
  rpois(length(lambda_post), lambda = as.numeric(lambda_post)),
  nrow = nrow(lambda_post)
)

# Verificación de la media, la desviación estándar y la proporción de ceros
ppc_stat(y = Y_obs, yrep = Y_rep, stat = "mean")
ppc_stat(y = Y_obs, yrep = Y_rep, stat = "sd")
ppc_stat(y = Y_obs, yrep = Y_rep,
  stat = function(y) mean(y == 0))
```

La verificación desagregada por subgrupos —segmentos urbanos frente a rurales, o segmentos clasificados según el nivel de cobertura definido en el capítulo de preparación de insumos— es particularmente relevante en el contexto censal, dado que un modelo puede ajustar adecuadamente el comportamiento agregado de los conteos y, sin embargo, subestimar sistemáticamente la variabilidad en un subconjunto específico de segmentos con características territoriales particulares:

```
ppc_stat_grouped(
  y = Y_obs, yrep = Y_rep,
  group = data_model$area_tipo,
  stat = "mean"
)
```

7.2.2 Residuos bayesianos

El análisis de residuos permite identificar segmentos individuales cuyo conteo observado es inconsistente con la predicción del modelo. A diferencia de los residuos de Pearson utilizados en el diagnóstico exploratorio del capítulo de preparación de insumos —que se basan en un único valor ajustado sin incertidumbre—, el residuo bayesiano incorpora la distribución predictiva posterior completa. Para el segmento i , el residuo estandarizado se define como:

$$r_i = \frac{Y_i - \mathbb{E}[\tilde{Y}_i | \mathbf{Y}_{obs}]}{\sqrt{\text{Var}(\tilde{Y}_i | \mathbf{Y}_{obs})}}$$

donde $\mathbb{E}[\tilde{Y}_i | \mathbf{Y}_{obs}]$ y $\text{Var}(\tilde{Y}_i | \mathbf{Y}_{obs})$ se estiman empíricamente a partir de las columnas correspondientes de la matriz $\mathbf{Y_rep}$ generada en la sección anterior:

```
residuos_bayes <- (Y_obs - colMeans(Y_rep)) / apply(Y_rep, 2, sd)

# Segmentos con residuo estandarizado de magnitud considerable
```

```
segmentos_atipicos <- which(abs(residuos_bayes) > 3)

hist(residuos_bayes, breaks = 40,
     main = "Distribución de residuos bayesianos estandarizados",
     xlab = "Residuo estandarizado")
```

Bajo un modelo correctamente especificado, la distribución de r_i debe aproximarse a una distribución normal estándar. Concentraciones sistemáticas de residuos positivos o negativos en determinados estratos territoriales —por ejemplo, subestimación sistemática en segmentos de baja cobertura censal— señalan una falla de especificación que puede requerir la incorporación de covariables adicionales o de efectos aleatorios de nivel más desagregado.

7.2.3 Comparación con conteos observados y calibración

Un modelo predictivo bien calibrado produce intervalos de credibilidad cuya cobertura empírica se aproxima a su nivel nominal: aproximadamente el 95 % de los conteos observados deben ubicarse dentro de sus intervalos de credibilidad al 95 % correspondientes. La tasa de cobertura empírica se calcula directamente sobre los segmentos observados:

$$\text{Cobertura}_{95\%} = \frac{1}{D_{obs}} \sum_{i \in \mathcal{S}_{obs}} \mathbb{1}\{Y_i \in [IC_{2.5\%,i}, IC_{97.5\%,i}]\}$$

```
ic_inferior <- apply(Y_rep, 2, quantile, probs = 0.025)
ic_superior <- apply(Y_rep, 2, quantile, probs = 0.975)

cobertura_95 <- mean(Y_obs >= ic_inferior & Y_obs <= ic_superior)
```

Una cobertura empírica sustancialmente inferior al 95 % indica que los intervalos de credibilidad son demasiado estrechos —el modelo subestima la incertidumbre real— mientras que una cobertura muy superior al 95 % indica intervalos excesivamente anchos, que si bien no son incorrectos, resultan poco informativos para la toma de decisiones. Esta noción de calibración debe complementarse con la de nitidez (*sharpness*): entre dos modelos igualmente calibrados, se prefiere aquel cuyas distribuciones predictivas sean más concentradas (Gneiting y Raftery 2007). El objetivo de la validación predictiva no es, por tanto, maximizar la amplitud de los intervalos para garantizar cobertura, sino maximizar la nitidez sujeta a calibración adecuada —principio conocido como *maximización de la nitidez sujeta a calibración* (Gneiting y Raftery 2007)—, que constituye el criterio rector tanto de la validación predictiva posterior como de los criterios de información desarrollados en la sección siguiente.

7.3 Selección y comparación de modelos

Cuando existen especificaciones alternativas del modelo —distintos subconjuntos de covariables, distintas estructuras de efectos aleatorios o distribuciones alternativas para la sobredispersión, como las discutidas en el capítulo de especificación del modelo—, es necesario un criterio formal para seleccionar la especificación final.

7.3.1 Criterio Leave-One-Out (LOO-CV) y diagnóstico de Pareto k

El criterio de validación cruzada dejando uno fuera (*Leave-One-Out Cross-Validation*, LOO-CV) estima la capacidad predictiva del modelo sobre datos no utilizados en su ajuste, aproximando el reajuste exacto del modelo sin la observación i mediante muestreo por importancia con suavizado de Pareto (PSIS) (Vehtari et al. 2017):

$$\widehat{\text{elpd}}_{\text{loo}} = \sum_{i \in \mathcal{S}_{\text{obs}}} \log \left(\frac{\sum_{t=1}^T w_i^{(t)} p(Y_i | \theta^{(t)})}{\sum_{t=1}^T w_i^{(t)}} \right)$$

donde $w_i^{(t)}$ son los pesos de importancia suavizados para la observación i en la muestra t . El procedimiento PSIS ajusta una distribución de Pareto generalizada a la cola de los pesos de importancia brutos y utiliza el parámetro de forma estimado $\hat{k}_i$ como diagnóstico de la fiabilidad de la aproximación para cada observación:

```
log_lik_mat <- loo::extract_log_lik(stan_model, parameter_name = "log_lik")
loo_result <- loo::loo(log_lik_mat)

print(loo_result)
loo::pareto_k_table(loo_result)

# Segmentos con aproximación PSIS poco confiable
loo::pareto_k_ids(loo_result, threshold = 0.7)
```

Valores $\hat{k}_i < 0.5$ indican una aproximación fiable; valores entre 0.5 y 0.7 son aceptables pero con mayor varianza de estimación; valores $\hat{k}_i > 0.7$ indican que la aproximación de importancia no es confiable para esa observación, típicamente porque su exclusión modificaría sustancialmente la distribución posterior (Vehtari et al. 2017). En el modelo Poisson-lognormal, los segmentos con $\hat{k}_i$ elevado suelen coincidir con los residuos bayesianos atípicos identificados en la sección anterior. Cuando el número de observaciones con $\hat{k}_i > 0.7$ es reducido, se recomienda recalcular el ajuste exacto de validación cruzada únicamente para esas observaciones mediante refit directo del modelo, en lugar de descartar el diagnóstico LOO en su totalidad.

7.3.2 Widely Applicable Information Criterion (WAIC)

El WAIC (Watanabe 2010) constituye una alternativa asintóticamente equivalente al LOO-CV bajo condiciones de regularidad del modelo, calculada directamente a partir de la log-verosimilitud puntual sin requerir muestreo por importancia. Se compone de la densidad predictiva log puntual esperada:

$$\text{lpd} = \sum_{i \in \mathcal{S}_{\text{obs}}} \log \left(\frac{1}{T} \sum_{t=1}^T p(Y_i | \theta^{(t)}) \right)$$

y de una penalización por el número efectivo de parámetros, estimada a partir de la varianza posterior de la log-verosimilitud puntual:

$$p_{\text{WAIC}} = \sum_{i \in \mathcal{S}_{\text{obs}}} \text{Var}_t(\log p(Y_i | \theta^{(t)}))$$

El criterio, en escala de devianza, se define como:

$$\text{WAIC} = -2 (\text{lpd} - p_{\text{WAIC}})$$

```
waic_result <- loo::waic(log_lik_mat)
print(waic_result)
```

Piironen y Vehtari (2017) muestra que, en presencia de observaciones influyentes —frecuentes en modelos de conteo con segmentos de intensidad extrema, como los que surgen en el modelo Poisson-lognormal—, el LOO-CV mediante PSIS es más robusto que el WAIC, cuya estimación de p_{WAIC} puede ser inestable cuando la varianza posterior de la log-verosimilitud puntual es elevada. En consecuencia, el LOO-CV debe considerarse el criterio principal, reportando el WAIC como verificación complementaria y no como criterio primario de decisión.

7.3.3 Criterio de elección del modelo final

La comparación entre especificaciones alternativas se realiza mediante la diferencia en elpd estimado y su error estándar:

```
loo_modelo_1 <- loo::loo(log_lik_mat_1)
loo_modelo_2 <- loo::loo(log_lik_mat_2)

comparacion <- loo::loo_compare(loo_modelo_1, loo_modelo_2)
print(comparacion)
```

Como se estableció en el capítulo anterior, una diferencia en elpd superior en magnitud al doble de su error estándar (elpd_diff frente a se_diff) se interpreta como evidencia de una diferencia predictiva sustancial entre modelos. Este criterio debe aplicarse únicamente cuando el diagnóstico de Pareto $\hat{k}$ indica que la comparación es confiable para la mayoría de las observaciones; si un número apreciable de segmentos presenta $\hat{k}_i > 0.7$ en cualquiera de los modelos comparados, la diferencia estimada debe interpretarse con cautela.

Como complemento a los criterios de información —que evalúan el ajuste global de la distribución predictiva— es recomendable evaluar una regla de puntuación propia (*proper scoring rule*) orientada específicamente a la calidad de las predicciones puntuales para conteos, como el *ranked probability score* (Gneiting y Raftery 2007):

$$\text{RPS}_i = \sum_{k=0}^{K_{\max}} \left(F_{\hat{Y}_i}(k) - \mathbb{1}\{Y_i \leq k\} \right)^2$$

donde $F_{\hat{Y}_i}$ es la función de distribución acumulada empírica de la distribución predictiva posterior del segmento i y $K_{\max}$ es un límite superior de conteo suficientemente grande para acumular prácticamente toda la masa de probabilidad predictiva. Un RPS promedio menor indica mejor desempeño predictivo puntual, y su cómputo por segmento permite identificar patrones territoriales de bajo desempeño que los criterios agregados como LOO y WAIC pueden no revelar.

La decisión final sobre el modelo debe integrar los tres elementos desarrollados en este capítulo: convergencia satisfactoria en la totalidad de los parámetros ($\hat{R} < 1.01$, ESS Bulk y Tail superiores a 400, ausencia de divergencias relevantes), validación predictiva posterior adecuada (calibración cercana al 95 % nominal, ausencia

de patrones sistemáticos en los residuos bayesianos) y desempeño predictivo superior o equivalente en los criterios LOO, WAIC y RPS frente a especificaciones alternativas. Ningún criterio aislado es suficiente: un modelo puede exhibir buena convergencia y aun así ajustar deficientemente los datos, o puede ajustar bien los datos observados y ser inconsistente con información externa, cuestión que se aborda en la sección siguiente.

7.4 Validación externa

Los diagnósticos de convergencia y de ajuste interno descritos hasta este punto evalúan la coherencia del modelo con los propios datos utilizados en su estimación. La validación externa contrasta las estimaciones resultantes con fuentes de información independientes del proceso de ajuste, y constituye la verificación final antes de la publicación de estimaciones oficiales de población.

7.4.1 Consistencia con proyecciones demográficas

Los países de América Latina y el Caribe producen habitualmente proyecciones demográficas oficiales mediante métodos de cohortes-componentes, independientes de los modelos bayesianos de estimación subnacional desarrollados en este libro. Aunque estas proyecciones no están exentas de error, constituyen una referencia externa útil para evaluar la plausibilidad agregada de las estimaciones del modelo en niveles geográficos intermedios y en el nivel nacional. La discrepancia relativa entre la estimación del modelo y la proyección oficial para una unidad geográfica j se define como:

$$\Delta_j = \frac{\hat{N}_j - N_j^{proy}}{N_j^{proy}}$$

donde $\hat{N}_j$ es la agregación de las predicciones posteriores del modelo para la unidad j y N_j^{proy} es la proyección demográfica oficial correspondiente. Discrepancias sistemáticas y de gran magnitud —convencionalmente, superiores al 5 % en valor absoluto— ameritan investigación adicional: pueden reflejar un error genuino del modelo, pero también pueden señalar que la proyección demográfica de referencia está desactualizada respecto a la dinámica poblacional reciente del territorio, particularmente en contextos de migración interna acelerada.

```
discrepancia <- estimaciones_parroquia %>%
  left_join(proyecciones_oficiales, by = "parish") %>%
  mutate(delta = (tot_pob_media - poblacion_proyectada) / poblacion_proyectada)

discrepancia %>%
  filter(abs(delta) > 0.05) %>%
  arrange(desc(abs(delta)))
```

Las recomendaciones de CEPAL para los censos de la ronda 2020 (CEPAL 2023) enfatizan la necesidad de conciliar los resultados censales —y, por extensión, cualquier estimación derivada de ellos mediante modelamiento— con las proyecciones demográficas oficiales del país, documentando explícitamente las discrepancias identificadas y sus posibles causas metodológicas u operativas. La validación cruzada entre estimaciones basadas en modelos y proyecciones demográficas independientes ha sido aplicada con enfoques metodológicos afines en otros contextos de estimación en áreas pequeñas con relevancia demográfica y

sanitaria, como la estimación espaciotemporal de la mortalidad infantil en contextos de datos limitados (Wakefield et al. 2019), donde la comparación sistemática con fuentes externas independientes constituye igualmente un componente central del proceso de validación.

7.4.2 Comparación con registros administrativos independientes

Cuando el modelo incorpora registros administrativos como covariables —padrones electorales, afiliación a salud, programas sociales, según lo descrito en el capítulo de integración de fuentes—, dichos registros no pueden emplearse simultáneamente como fuente de validación externa, dado que ya forman parte de la información utilizada en la estimación. Sin embargo, es habitual que existan registros administrativos adicionales, no incorporados como covariables por razones de cobertura parcial, actualización deficiente o disponibilidad tardía, que pueden reservarse específicamente para la validación externa del modelo.

La comparación se realiza mediante la razón entre la predicción del modelo y el conteo del registro reservado:

$$\rho_i = \frac{\hat{N}_i}{A_i^{(val)}}$$

donde $A_i^{(val)}$ es el conteo del registro administrativo reservado para el segmento i . Dado que ningún registro administrativo captura la totalidad de la población —su tasa de cobertura relativa $c_{i,r}$ es, por construcción, menor o igual a uno—, se espera que ρ_i se ubique sistemáticamente por encima de uno y dentro de un rango plausible determinado por la naturaleza del registro utilizado; valores de ρ_i inferiores a uno, o con una dispersión territorial inconsistente con la cobertura esperada del registro, señalan posibles problemas de especificación del modelo o de calidad del registro de referencia.

7.4.3 Evaluación de coherencia geoespacial

La distribución espacial de la población presenta continuidad territorial: segmentos geográficamente próximos tienden a presentar características demográficas similares, tal como se discutió en el capítulo de integración de fuentes al introducir los efectos espaciales aleatorios de tipo CAR (Banerjee et al. 2015). Un modelo correctamente especificado debe capturar esta continuidad a través de sus covariables y efectos aleatorios territoriales, de modo que los residuos bayesianos no exhiban autocorrelación espacial remanente.

El índice de Moran cuantifica la autocorrelación espacial de los residuos r_i definidos en la sección de validación predictiva posterior:

$$I = \frac{D_{obs}}{\sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij} (r_i - \bar{r}) (r_j - \bar{r})}{\sum_i (r_i - \bar{r})^2}$$

donde w_{ij} es un peso de vecindad —típicamente igual a uno si los segmentos i y j son geográficamente contiguos y cero en caso contrario— y $\bar{r}$ es la media de los residuos sobre los segmentos observados. Valores de I cercanos a cero son consistentes con ausencia de autocorrelación espacial residual; valores positivos y estadísticamente significativos indican que segmentos vecinos comparten errores sistemáticos del modelo no capturados por las covariables ni por los efectos aleatorios territoriales incluidos:

```
library(spdep)

vecinos <- poly2nb(segmentos_sf)
pesos   <- nb2listw(vecinos, style = "W", zero.policy = TRUE)

moran.test(residuos_bayes, listw = pesos, zero.policy = TRUE)
```

Cuando el índice de Moran señala autocorrelación espacial residual relevante, las alternativas de especificación incluyen la incorporación de efectos aleatorios espacialmente estructurados de tipo CAR en el predictor lineal —en lugar de, o adicionalmente a, los efectos aleatorios no estructurados por unidad territorial definidos en el capítulo de especificación del modelo—, o la inclusión de covariables adicionales capaces de explicar el patrón espacial observado en los residuos.

Calibración y Benchmarking Subnacional

El capítulo anterior estableció los criterios de convergencia, validación predictiva y validación externa que un modelo Poisson-lognormal debe satisfacer antes de que sus estimaciones puedan utilizarse en la producción de estadísticas oficiales de población. Sin embargo, la validación de un modelo no resuelve por sí sola un problema adicional, frecuente en la práctica institucional: los organismos nacionales de estadística suelen requerir que las estimaciones subnacionales, al agregarse, coincidan exactamente con totales de referencia fijados de manera independiente al modelo —un total nacional publicado oficialmente, una cifra departamental proveniente de un recuento preliminar de mayor confiabilidad, o una proyección demográfica considerada autoridad institucional para efectos de asignación presupuestaria—. Este capítulo desarrolla el conjunto de técnicas conocidas como *calibración* o *benchmarking*, orientadas a conciliar las estimaciones del modelo con dichos totales de control, preservando en la mayor medida posible la información distribucional aportada por el modelo bayesiano.

La estructura del capítulo comprende tres secciones. La primera examina por qué surge la necesidad de calibración y distingue formalmente la coherencia jerárquica interna del modelo —ya garantizada por construcción, según se estableció en el capítulo de especificación del modelo— de la coherencia externa frente a totales de control, que no está garantizada y constituye el objeto propio del benchmarking. La segunda presenta los métodos de calibración: el ajuste proporcional clásico, el ajuste ponderado por precisión y su extensión aditiva a la distribución posterior completa, junto con su aplicación práctica en jerarquías territoriales anidadas. La tercera evalúa el impacto de la calibración sobre las estimaciones puntuales y sobre los intervalos de credibilidad.

8.1 Benchmarking con proyecciones poblacionales

8.1.1 Necesidad de coherencia entre niveles geográficos

Los organismos nacionales de estadística no publican estimaciones de población de manera aislada: cada nueva cifra se inserta en un sistema de referencias previamente establecidas —conteos censales anteriores, proyecciones demográficas oficiales, cifras utilizadas en la asignación de recursos fiscales o en la delimitación de circunscripciones electorales—. Cuando el total nacional o departamental implícito en las estimaciones de un modelo bayesiano de estimación subnacional difiere de estas cifras de referencia, la discrepancia genera un problema que trasciende lo estrictamente estadístico: dos totales distintos y no reconciliados para la misma población generan confusión institucional, erosionan la confianza pública en las estadísticas oficiales y pueden ser incompatibles con compromisos legales o presupuestarios previamente adquiridos sobre la base de la cifra de referencia.

Esta necesidad de coherencia con totales externos es un problema clásico dentro de la Estimación en Áreas Pequeñas (Rao y Molina 2015), habitualmente abordado bajo el término *benchmarking*. La particularidad del enfoque bayesiano desarrollado en este libro es que dicho ajuste debe realizarse preservando la coherencia probabilística de las estimaciones: no solo el valor puntual, sino la distribución posterior completa, incluidos los intervalos de credibilidad, deben ajustarse de manera consistente con el nuevo total exigido.

8.1.2 Restricciones de consistencia jerárquica

Es necesario distinguir dos nociones de coherencia que, aunque relacionadas, tienen naturaleza distinta. La primera es la **coherencia jerárquica interna** del modelo, definida formalmente en el capítulo de modelo para conteos poblacionales: dado que las predicciones $\tilde{Y}_i^{(t)}$ para cada segmento se generan dentro de la misma muestra posterior t , su agregación es automáticamente consistente entre niveles geográficos para cualquier muestra individual:

$$\hat{N}_k^{(3),(t)} = \sum_{i \in \mathcal{S}_k} \tilde{Y}_i^{(t)}, \quad \hat{N}_j^{(2),(t)} = \sum_{k: k \subset j} \hat{N}_k^{(3),(t)}$$

Esta propiedad no requiere ningún procedimiento adicional: es una consecuencia directa de sumar predicciones generadas conjuntamente a partir del mismo vector de parámetros $\theta^{(t)}$, y se mantiene exactamente en cada una de las T muestras posteriores.

La segunda noción es la **coherencia externa** frente a un total de control N_j^* que no proviene del modelo —una cifra oficial, una proyección demográfica institucional o un recuento independiente—. En general, el total implícito en el modelo:

$$\hat{N}_{j,+} = \mathbb{E}[\hat{N}_j^{(2)} \mid \mathbf{Y}_{obs}] \approx \frac{1}{T} \sum_{t=1}^T \hat{N}_j^{(2),(t)}$$

no coincide exactamente con N_j^* , y no existe razón estadística para esperar que lo haga: el modelo y el total de control son, casi siempre, dos estimaciones distintas de la misma cantidad, obtenidas por procedimientos independientes. Es esta segunda forma de incoherencia —y no la primera, que ya está resuelta por construcción— la que constituye el objeto del benchmarking. Un aspecto crítico que se retoma en la sección de aplicación práctica es que la calibración externa, al modificar los totales de un nivel geográfico, puede romper la coherencia jerárquica interna con los niveles adyacentes si no se propaga de manera consistente a través de la jerarquía territorial.

8.1.3 Relación entre estimaciones locales y totales conocidos

Formalmente, sea N^* el total de control conocido para un conjunto de K unidades geográficas de un mismo nivel —departamentos dentro de un país, municipios dentro de un departamento— y sean $\hat{N}_1, \dots, \hat{N}_K$ las estimaciones puntuales del modelo para cada unidad, con $\hat{N}_+ = \sum_{k=1}^K \hat{N}_k$ su suma. La discrepancia de benchmarking se define como:

$$\Delta = N^* - \hat{N}_+$$

El problema de calibración consiste en construir un conjunto de estimaciones ajustadas $\hat{N}_1^{bench}, \dots, \hat{N}_K^{bench}$ que satisfagan exactamente la restricción de suma $\sum_{k=1}^K \hat{N}_k^{bench} = N^*$, minimizando simultáneamente la distorsión introducida sobre la información distribucional original del modelo. La forma en que se distribuye Δ entre las K unidades —de manera uniforme, proporcional al tamaño de cada unidad, o proporcional a su incertidumbre— es precisamente lo que distingue a los distintos métodos de benchmarking desarrollados en la sección siguiente.

8.2 Métodos de benchmarking

8.2.1 Benchmarking proporcional

El método más simple y de mayor tradición en la práctica de oficinas de estadística es el ajuste proporcional (*ratio benchmarking*), que distribuye la discrepancia Δ en proporción al tamaño relativo de cada unidad. El factor de ajuste se define como:

$$\phi = \frac{N^*}{\hat{N}_+}$$

y la estimación calibrada de cada unidad es:

$$\hat{N}_k^{bench} = \hat{N}_k \cdot \phi = \hat{N}_k \cdot \frac{N^*}{\hat{N}_+}$$

Por construcción, $\sum_{k=1}^K \hat{N}_k^{bench} = \phi \sum_{k=1}^K \hat{N}_k = \phi \hat{N}_+ = N^*$, de modo que la restricción de suma se satisface exactamente. El método preserva las proporciones relativas entre unidades —si $\hat{N}_a/\hat{N}_b = 2$ antes del ajuste, la misma razón se mantiene después—, lo que lo hace fácil de comunicar e implementar. Su principal limitación es que aplica el mismo factor multiplicativo ϕ a todas las unidades, sin distinguir entre aquellas cuya estimación es precisa —con posterior concentrada y $\text{Var}(\hat{N}_k) \mid \mathbf{Y}_{obs}$ pequeña, típicamente unidades con buena cobertura censal directa— y aquellas cuya estimación depende casi enteramente de la estructura jerárquica del modelo, con incertidumbre considerablemente mayor. El ajuste proporcional penaliza a ambos tipos de unidad por igual, en contraste con el principio de que la información más incierta debería absorber una proporción mayor de cualquier corrección externa.

```
benchmarking_proporcional <- function(N_hat, N_control) {
  phi <- N_control / sum(N_hat)
  N_hat * phi
}

N_bench_prop <- benchmarking_proporcional(
  N_hat = estimaciones_departamento$tot_pob_media,
  N_control = total_oficial_pais
)
```

8.2.2 Benchmarking por razones de ajuste

El benchmarking ponderado por precisión corrige la limitación anterior distribuyendo la discrepancia Δ en proporción a la incertidumbre relativa de cada unidad, en lugar de en proporción a su tamaño. Formalmente, la estimación calibrada se obtiene como solución al problema de minimización:

$$\min_{\hat{N}_1^{bench}, \dots, \hat{N}_K^{bench}} \sum_{k=1}^K \frac{(\hat{N}_k^{bench} - \hat{N}_k)^2}{w_k} \quad \text{sujeto a} \quad \sum_{k=1}^K \hat{N}_k^{bench} = N^*$$

donde $w_k > 0$ es un peso que refleja la incertidumbre de la estimación de la unidad k . La solución, obtenida mediante multiplicadores de Lagrange, es:

$$\hat{N}_k^{bench} = \hat{N}_k + w_k \cdot \frac{\Delta}{\sum_{j=1}^K w_j}$$

En el marco bayesiano desarrollado en este libro, el peso natural es la varianza posterior de la predicción de cada unidad, directamente disponible a partir de las muestras MCMC sin necesidad de aproximaciones asintóticas externas, a diferencia del enfoque frecuentista clásico de SAE:

$$w_k = \text{Var}(\hat{N}_k | \mathbf{Y}_{obs}) \approx \frac{1}{T-1} \sum_{t=1}^T (\hat{N}_k^{(t)} - \hat{N}_k)^2$$

Bajo esta especificación, las unidades con mayor incertidumbre posterior —típicamente aquellas con menor cobertura censal directa y mayor dependencia de la estructura jerárquica del modelo— absorben una proporción mayor de la discrepancia Δ , mientras que las unidades con estimaciones precisas se modifican mínimamente. Dos casos particulares merecen mención: si $w_k \propto \hat{N}_k$, la fórmula se reduce aproximadamente al ajuste proporcional de la subsección anterior; si $w_k = 1$ para todo k , la discrepancia se distribuye en partes iguales entre las unidades, independientemente de su tamaño o precisión.

```
benchmarking_ponderado <- function(N_hat, N_control, pesos) {
  delta <- N_control - sum(N_hat)
  N_hat + pesos * (delta / sum(pesos))
}

# Pesos basados en la varianza posterior de cada unidad
varianzas_post <- apply(N_hat_samples, 2, var)

N_bench_pond <- benchmarking_ponderado(
  N_hat      = estimaciones_departamento$tot_pob_media,
  N_control  = total_oficial_pais,
  pesos      = varianzas_post
)
```

8.2.3 Benchmarking aditivo con restricciones de suma

Los dos métodos anteriores calibran únicamente la estimación puntual, dejando sin ajustar la distribución posterior completa. Esto es insuficiente en un marco bayesiano: si solo se recalibra la media posterior y los intervalos de credibilidad se calculan sobre las muestras originales sin ajustar, la incertidumbre reportada resulta inconsistente con la estimación puntual calibrada. La extensión adecuada consiste en aplicar el ajuste a cada una de las T muestras de la distribución predictiva posterior, de manera que la restricción de suma se satisfaga en cada muestra individual y no solo en la media.

El ajuste proporcional por muestra se define como:

$$\tilde{N}_k^{bench,(t)} = \tilde{N}_k^{(t)} \cdot \frac{N^*}{\sum_{j=1}^K \tilde{N}_j^{(t)}}, \quad t = 1, \dots, T$$

Nótese que el factor de ajuste $\phi^{(t)} = N^* / \sum_j \tilde{N}_j^{(t)}$ varía entre muestras, dado que el total agregado del modelo fluctúa de una muestra posterior a otra como consecuencia del proceso de Poisson subyacente. Esta variación del factor de ajuste entre muestras es precisamente lo que permite que la incertidumbre del proceso de calibración se propague correctamente hacia los intervalos de credibilidad calibrados.

El ajuste aditivo ponderado por muestra sigue la misma lógica que el benchmarking por razones de ajuste, aplicado ahora sobre cada muestra individual:

$$\tilde{N}_k^{bench,(t)} = \tilde{N}_k^{(t)} + w_k \cdot \frac{N^* - \sum_{j=1}^K \tilde{N}_j^{(t)}}{\sum_{j=1}^K w_j}, \quad t = 1, \dots, T$$

```
# Matriz de muestras posteriores: T filas x K columnas (unidades geográficas)
calibrar_muestras_proporcional <- function(N_samples, N_control) {
  totales_muestra <- rowSums(N_samples)
  phi_t <- N_control / totales_muestra
  N_samples * phi_t
}

calibrar_muestras_aditivo <- function(N_samples, N_control, pesos) {
  totales_muestra <- rowSums(N_samples)
  delta_t <- N_control - totales_muestra
  ajuste_t <- outer(delta_t, pesos / sum(pesos))
  N_samples + ajuste_t
}

N_bench_samples <- calibrar_muestras_aditivo(
  N_samples = N_hat_samples,
  N_control = total_oficial_pais,
  pesos      = varianzas_post
)
```

8.2.4 Aplicación práctica a distintos niveles geográficos

En aplicaciones reales, los totales de control suelen estar disponibles en más de un nivel geográfico simultáneamente —un total nacional legalmente establecido y, en algunos países, totales departamentales derivados de recuentos preliminares independientes—. Calibrar cada nivel de manera aislada, sin coordinación, reintroduce el problema de incoherencia jerárquica que la agregación conjunta de muestras posteriores había resuelto automáticamente: si los municipios se calibran contra sus propios totales departamentales de control y, por separado, los departamentos se calibran contra el total nacional de control, no hay garantía de que la suma de los municipios calibrados coincida con el departamento ya calibrado.

La solución consiste en aplicar la calibración de manera secuencial y descendente a través de la jerarquía territorial: primero se calibra el nivel más agregado disponible frente a su total de control —típicamente el nacional—;

a continuación, dentro de cada unidad de ese nivel ya calibrada, se calibran sus unidades subordinadas de manera que sumen exactamente al valor recién calibrado del nivel superior, y así sucesivamente hasta el nivel de segmento censal. De esta manera, la coherencia jerárquica interna, temporalmente alterada por la calibración externa del nivel superior, se restablece en cada paso descendente:

```
library(tidyverse)

calibracion_jerarquica <- function(df_segmentos, total_nacional) {

  # Paso 1: calibrar departamentos contra el total nacional
  dptos <- df_segmentos %>%
    group_by(departamento) %>%
    summarise(N_hat = sum(pob_media), .groups = "drop") %>%
    mutate(
      phi_dpto = total_nacional / sum(N_hat),
      N_dpto_bench = N_hat * phi_dpto
    )

  # Paso 2: calibrar municipios contra el total departamental ya calibrado
  df_segmentos %>%
    left_join(dptos %>% select(departamento, N_dpto_bench), by = "departamento") %>%
    group_by(departamento, municipio) %>%
    mutate(N_mun_hat = sum(pob_media)) %>%
    group_by(departamento) %>%
    mutate(phi_mun = N_dpto_bench / sum(N_mun_hat)) %>%
    ungroup() %>%
    mutate(pob_bench = pob_media * phi_mun)
}
```

Este procedimiento garantiza que, tras la calibración, los conteos de segmento sumen exactamente a sus municipios, los municipios a sus departamentos y los departamentos al total nacional de control, restableciendo la coherencia jerárquica completa del sistema de estimaciones bajo la restricción externa impuesta.

8.3 Evaluación del impacto del benchmarking

La calibración modifica las estimaciones producidas por un modelo previamente validado, y esta modificación debe documentarse y evaluarse explícitamente, tanto en su efecto sobre las estimaciones puntuales como sobre la incertidumbre reportada.

8.3.1 Cambio en estimaciones puntuales

El cambio relativo introducido por la calibración en la unidad k se define como:

$$\kappa_k = \frac{\hat{N}_k^{bench} - \hat{N}_k}{\hat{N}_k}$$

Bajo el ajuste proporcional, $\kappa_k = \phi - 1$ es idéntico para todas las unidades, independientemente de su tamaño o de la precisión de su estimación. Bajo el ajuste ponderado por precisión, κ_k varía sistemáticamente entre unidades: se espera una relación positiva entre κ_k y la incertidumbre posterior relativa de la unidad, de modo que las unidades con estimaciones más precisas —mayor cobertura censal directa— exhiban valores de κ_k cercanos a cero, mientras que las unidades con mayor dependencia de la estructura jerárquica del modelo absorban una proporción mayor del ajuste:

```
cambio_relativo <- estimaciones_departamento %>%
  mutate(
    kappa_prop = (N_bench_prop - tot_pob_media) / tot_pob_media,
    kappa_pond = (N_bench_pond - tot_pob_media) / tot_pob_media
  )

# Relación entre el cambio relativo y la incertidumbre posterior
ggplot(cambio_relativo, aes(x = tot_pob_sd / tot_pob_media, y = kappa_pond)) +
  geom_point() +
  labs(x = "Coeficiente de variación posterior",
       y = "Cambio relativo tras calibración ponderada")
```

Un patrón en el que las unidades con mayor coeficiente de variación posterior muestran mayores valores de $|\kappa_k|$ confirma que el ajuste ponderado está operando de acuerdo con el principio que lo motiva: concentrar la corrección donde la información propia del modelo es más débil. La ausencia de este patrón —o su presencia inversa, con grandes correcciones sobre unidades de alta precisión— señala que los pesos utilizados no reflejan adecuadamente la incertidumbre relativa de las unidades y debe revisarse su especificación.

8.3.2 Intervalos de credibilidad post-calibración

Cuando la calibración se aplica a cada muestra de la distribución posterior, según el procedimiento descrito en la sección de benchmarking aditivo, los intervalos de credibilidad calibrados se obtienen directamente de los cuantiles empíricos de las muestras ajustadas $\tilde{N}_k^{bench,(t)}$:

```
ic_bench <- apply(N_bench_samples, 2, quantile, probs = c(0.025, 0.975))
```

El efecto de la calibración sobre la amplitud de los intervalos depende de la fuente de incertidumbre del total de control. Cuando N^* se trata como una constante exactamente conocida y sin incertidumbre propia —el caso más frecuente en la práctica, dado que suele tratarse de una cifra oficial fijada administrativamente—, la calibración desplaza la localización de la distribución de cada unidad sin alterar sustancialmente su dispersión relativa, dado que el factor de ajuste $\phi^{(t)}$ o el término aditivo se aplican de manera común a través de las unidades dentro de cada muestra t , preservando en gran medida la estructura de covarianza entre unidades capturada por el modelo original. La longitud relativa del intervalo calibrado respecto al original constituye un indicador simple de este efecto:

$$\text{Longitud relativa}_k = \frac{IC_{97.5\%,k}^{bench} - IC_{2.5\%,k}^{bench}}{IC_{97.5\%,k} - IC_{2.5\%,k}}$$

Valores cercanos a uno indican que la calibración no distorsiona significativamente la incertidumbre relativa entre unidades; valores sistemáticamente distintos de uno, particularmente si se concentran en unidades específicas, ameritan una revisión de los pesos de calibración utilizados. Es importante notar que la calibración no puede, ni debe, entenderse como un mecanismo para reducir artificialmente la incertidumbre reportada: cualquier intervalo de credibilidad calculado a partir de una recalibración exclusivamente sobre la estimación puntual —sin propagar el ajuste a través de las muestras de la distribución posterior completa, como se advirtió en la sección de benchmarking aditivo— produce una subestimación espuria de la incertidumbre y debe evitarse. La calibración correctamente implementada conserva, en la medida de lo posible, las propiedades de calibración probabilística —cobertura empírica cercana al nivel nominal— evaluadas para el modelo original en el capítulo de diagnóstico y validación, y esta propiedad debe verificarse nuevamente sobre las estimaciones calibradas antes de su publicación.

Conclusiones y Recomendaciones Institucionales

Los capítulos precedentes desarrollaron, de manera progresiva, un marco metodológico completo para la estimación bayesiana de conteos poblacionales subnacionales: la formulación conceptual del problema de cobertura censal, la identificación e integración de fuentes auxiliares de información, la especificación formal del modelo Poisson-lognormal jerárquico, su implementación computacional mediante HMC-NUTS en Stan, el conjunto de diagnósticos de convergencia y validación que determinan la aptitud de un modelo para su uso institucional, y los procedimientos de calibración que concilian las estimaciones del modelo con totales de control externos. Este capítulo final no introduce nuevos elementos técnicos, sino que sintetiza los hallazgos metodológicos centrales, traduce dichos hallazgos en recomendaciones concretas para los organismos nacionales de estadística de América Latina y el Caribe, examina el rol que los organismos internacionales desempeñan en la transferencia de esta metodología, y discute con honestidad las limitaciones del enfoque y las condiciones institucionales necesarias para su aplicación.

9.1 Principales hallazgos metodológicos

El primer hallazgo central de este libro es que los conteos censales, particularmente en niveles territoriales pequeños, no deben tratarse como mediciones exactas de la población, sino como observaciones parciales de un proceso de enumeración sujeto a errores sistemáticos de cobertura, cuya magnitud y distribución espacial no son homogéneas. Esta reinterpretación —desarrollada en el capítulo de enfoque general— tiene una consecuencia metodológica directa: el problema de estimación subnacional no puede resolverse mediante la sola conciliación aritmética de los conteos observados, sino que requiere un marco probabilístico capaz de representar explícitamente la incertidumbre asociada a la enumeración y de incorporar información auxiliar independiente del propio operativo censal.

El segundo hallazgo es que el enfoque bayesiano jerárquico satisface simultáneamente los cuatro requerimientos que un modelo de estimación subnacional debe cumplir —naturaleza discreta de los conteos, incorporación de información heterogénea, coherencia entre niveles geográficos y cuantificación explícita de la incertidumbre—, sin necesidad de mecanismos ad hoc para cada uno de ellos por separado. La estructura jerárquica permite el préstamo de fuerza estadística entre segmentos de un mismo territorio, estabilizando las estimaciones en dominios con información escasa; la formulación Poisson-lognormal captura de manera natural la sobredispersión presente en los conteos censales sin recurrir a correcciones post hoc; y la agregación de muestras posteriores conjuntas garantiza, por construcción, la coherencia interna entre segmentos, municipios, departamentos y el total nacional.

El tercer hallazgo, desarrollado en el capítulo de integración de fuentes, es que la disponibilidad creciente de covariables satelitales y registros administrativos en la región ha ampliado sustancialmente el conjunto de información auxiliar utilizable para predecir la distribución poblacional en segmentos sin cobertura censal directa, sin que ello elimine la necesidad de un marco de integración probabilístico riguroso: la heterogeneidad en

la cobertura, la definición y la actualidad temporal de estas fuentes exige un tratamiento estadístico explícito de sus limitaciones, y no su incorporación mecánica como predictores adicionales.

El cuarto hallazgo es de naturaleza computacional: la viabilidad práctica de ajustar modelos jerárquicos con miles de densidades latentes —una por cada segmento censal del país— depende críticamente de algoritmos de muestreo que escalen adecuadamente con la dimensión del espacio parametral. La adopción de HMC-NUTS mediante Stan, documentada en el capítulo de inferencia bayesiana, no es una elección computacional incidental, sino una condición habilitante para que el enfoque jerárquico bayesiano sea aplicable a problemas de la escala real que enfrentan los censos nacionales de la región.

El quinto hallazgo, quizás el menos discutido en la literatura aplicada de estimación poblacional, es que ningún modelo bayesiano debe considerarse listo para su uso institucional por el solo hecho de haber producido muestras posteriores. El marco de validación desarrollado en el capítulo de diagnóstico —convergencia MCMC, validación predictiva posterior, criterios de comparación de modelos y validación externa frente a fuentes independientes— constituye un componente tan integral de la metodología como la especificación del modelo mismo, y su omisión compromete la confiabilidad de cualquier estimación resultante, independientemente de la sofisticación estadística del modelo subyacente.

Finalmente, el sexto hallazgo es que la validez estadística de un modelo y su aceptabilidad institucional son dimensiones relacionadas pero distintas: un modelo puede satisfacer plenamente los criterios de convergencia y validación desarrollados en este libro y, sin embargo, producir totales agregados incompatibles con cifras de referencia previamente establecidas por razones legales, presupuestarias o de continuidad estadística. El marco de calibración y benchmarking desarrollado en el capítulo anterior reconoce esta tensión de manera explícita y provee mecanismos para resolverla sin sacrificar la coherencia probabilística de las estimaciones.

9.2 Recomendaciones para organismos nacionales de estadística

De los hallazgos anteriores se desprenden recomendaciones concretas para los institutos nacionales de estadística que consideren adoptar, total o parcialmente, la metodología desarrollada en este libro.

Invertir en la construcción y mantenimiento de fuentes auxiliares. La calidad predictiva del modelo depende directamente de la disponibilidad de covariables auxiliares confiables —preconteos operativos actualizados, registros administrativos con cobertura territorial adecuada, productos satelitales procesados a nivel de segmento censal—. Esta inversión debe planificarse con anticipación al operativo censal y mantenerse durante el período intercensal, dado que muchas de estas fuentes pierden vigencia con el tiempo.

Desarrollar capacidad técnica interna en modelamiento bayesiano computacional. La implementación de los modelos descritos en este libro requiere personal con formación en programación probabilística —particularmente en Stan y su interfaz con R— y en los fundamentos estadísticos de la inferencia bayesiana jerárquica. Esta capacidad no puede sostenerse únicamente mediante asistencia técnica externa puntual; requiere formación continua del personal técnico permanente de la institución.

Adoptar protocolos formales y documentados de validación. Ningún modelo debe transitar de la fase de estimación a la fase de publicación oficial sin haber superado explícitamente los diagnósticos de convergencia, validación predictiva y validación externa descritos en el capítulo de diagnóstico y validación. Se recomienda que cada institución establezca umbrales institucionales explícitos —por ejemplo, sobre el estadístico $\hat{R}$, el tamaño efectivo de muestra o la cobertura empírica de los intervalos de credibilidad— y documente sistemáticamente los casos en que dichos umbrales no se satisfacen plenamente, junto con las decisiones adoptadas al respecto.

Definir de manera anticipada la política institucional de calibración. La decisión sobre qué totales de control se utilizarán para el benchmarking, en qué niveles geográficos se aplicará y con qué ponderación, debe formar parte del diseño metodológico del proyecto de estimación desde su inicio, y no resolverse de manera improvisada una vez producidas las estimaciones del modelo. Esta decisión tiene componentes tanto técnicos como institucionales, y debe involucrar a las áreas responsables de la coherencia entre operaciones estadísticas del organismo.

Priorizar la reproducibilidad y la documentación técnica. El uso de herramientas de documentación reproducible —como R Markdown, knitr y bookdown (Xie 2015), empleadas en la propia elaboración de este libro— permite que la especificación completa del modelo, el código de ajuste y los criterios de validación queden documentados de manera verificable y auditable por terceros, un requisito cada vez más exigido a las estadísticas oficiales por los estándares internacionales de calidad y transparencia metodológica.

9.3 Rol de organismos internacionales en la transferencia metodológica

La experiencia acumulada en la aplicación de esta metodología en Costa Rica, Barbados, Jamaica, Dominica y República Dominicana, documentada a lo largo de este libro, ilustra el papel que los organismos internacionales de cooperación estadística —y en particular la Comisión Económica para América Latina y el Caribe— desempeñan en la transferencia de metodologías estadísticas avanzadas hacia contextos institucionales con capacidades técnicas heterogéneas.

En primer lugar, los organismos internacionales cumplen una función de estandarización metodológica regional. La heterogeneidad de criterios de segmentación censal, definiciones de cobertura y disponibilidad de registros administrativos entre países de la región, documentada en los capítulos de enfoque general e integración de fuentes, dificulta la comparabilidad directa de las estimaciones subnacionales entre países. La asistencia técnica coordinada desde un organismo regional permite converger hacia especificaciones metodológicas comunes —como el modelo Poisson-lognormal desarrollado en este libro— adaptables a las particularidades de cada operativo censal nacional, sin sacrificar la comparabilidad regional de los principios metodológicos subyacentes.

En segundo lugar, estos organismos facilitan la cooperación técnica horizontal entre países de capacidad estadística desigual. La codificación explícita de la metodología en un documento técnico de referencia, acompañada de código reproducible, reduce la dependencia de cada país respecto de la disponibilidad puntual de expertos individuales y permite que el conocimiento metodológico se transfiera de manera sistemática entre proyectos sucesivos de asistencia técnica, incluyendo la posibilidad de cooperación sur-sur entre institutos nacionales de estadística de la región que enfrentan problemas metodológicos similares.

En tercer lugar, los organismos internacionales cumplen una función de acompañamiento institucional que trasciende la asistencia técnica estrictamente estadística: la adopción de metodologías bayesianas jerárquicas en la producción oficial de estadísticas requiere procesos de validación institucional, capacitación del personal técnico permanente y, en muchos casos, ajustes normativos o procedimentales relacionados con la publicación de estimaciones basadas en modelos, en lugar de conteos censales directos. El acompañamiento sostenido de un organismo con mandato regional facilita la gestión de estos procesos institucionales, que exceden el ámbito estrictamente técnico de la especificación del modelo.

Finalmente, la sistematización de recomendaciones metodológicas regionales para los censos de la ronda 2020 y posteriores (CEPAL 2023) provee un marco de referencia institucional dentro del cual metodologías como la

desarrollada en este libro pueden insertarse de manera coherente con los estándares de calidad y las prácticas de conciliación demográfica ya establecidas para los sistemas estadísticos de la región.

9.4 Limitaciones del enfoque y condiciones para su aplicación

La adopción responsable de la metodología desarrollada en este libro exige reconocer explícitamente sus limitaciones y las condiciones bajo las cuales su aplicación resulta apropiada.

Dependencia de la calidad de las fuentes auxiliares. El desempeño predictivo del modelo en segmentos sin cobertura censal directa depende enteramente de la calidad y pertinencia de las covariables auxiliares disponibles. En contextos donde los preconteos operativos están desactualizados, los registros administrativos presentan cobertura territorial deficiente, o los productos satelitales no han sido validados con información de campo, la capacidad predictiva del modelo se ve sustancialmente limitada, y ningún refinamiento en la especificación estadística puede compensar la ausencia de información auxiliar genuinamente informativa.

Costo computacional en aplicaciones de gran escala. La inferencia mediante HMC-NUTS sobre modelos con decenas o cientos de miles de densidades latentes —la escala de un censo nacional completo en países de mayor población— puede requerir tiempos de cómputo considerables, incluso con paralelización de cadenas. En estos contextos, puede ser necesario explorar alternativas de inferencia aproximada, como los métodos de aproximación de Laplace integrada anidada o los métodos variacionales, cuya evaluación comparativa frente a la inferencia MCMC completa no ha sido desarrollada en este libro y constituye una línea de trabajo futura relevante para la escalabilidad de la metodología.

Supuesto de independencia condicional entre fuentes. La formulación de verosimilitud conjunta presentada en el capítulo de integración de fuentes supone independencia condicional entre las distintas fuentes de información dado el parámetro de población subyacente. Este supuesto puede no sostenerse cuando distintas fuentes comparten errores territoriales comunes no observados —por ejemplo, si tanto el preconteo operativo como un registro administrativo específico presentan cobertura deficiente en las mismas zonas de difícil acceso—. Si bien esta limitación puede mitigarse parcialmente mediante efectos aleatorios compartidos, como se señaló en su momento, una caracterización más completa de la estructura de dependencia entre fuentes permanece como un área de desarrollo metodológico abierto.

Direccionalidad del error de cobertura. La regla de estimación final presentada en el capítulo de inferencia bayesiana asume que el error de cobertura censal es unidireccional —la omisión genera subenumeración, no sobreconteo—, de modo que los segmentos con cobertura completa no son ajustados por el modelo. Este supuesto es razonable en la generalidad de los contextos censales de la región, pero puede no sostenerse en operativos con problemas significativos de duplicación de registros, situación que requeriría una reformulación de dicha regla de decisión.

Requerimientos institucionales previos. Finalmente, la aplicación de esta metodología presupone condiciones institucionales que no están garantizadas en todos los sistemas estadísticos de la región: capacidad técnica interna sostenida, voluntad institucional para adoptar estimaciones basadas en modelos como complemento —y no sustituto— del operativo censal tradicional, marcos normativos que permitan la publicación de estimaciones calibradas frente a totales de control, y continuidad institucional suficiente para mantener actualizadas las fuentes auxiliares entre rondas censales sucesivas. La ausencia de alguna de estas condiciones no invalida la metodología, pero exige una adaptación cuidadosa de su implementación al contexto institucional específico de cada país, y en algunos casos puede justificar una adopción gradual o parcial, iniciando por los componentes de menor exigencia técnica e institucional antes de avanzar hacia la implementación completa del marco

jerárquico bayesiano desarrollado en este libro.

Banerjee, Sudipto, Bradley P. Carlin, y Alan E. Gelfand. 2015. *Hierarchical Modeling and Analysis for Spatial Data*. 2nd ed. Chapman; Hall/CRC.

Betancourt, Michael. 2017. «A Conceptual Introduction to Hamiltonian Monte Carlo». *arXiv preprint*.

Carpenter, Bob, Andrew Gelman, Matthew D. Hoffman, et al. 2017. «Stan: A Probabilistic Programming Language». *Journal of Statistical Software* 76 (1): 1-32. <https://doi.org/10.18637/jss.v076.i01>.

CEPAL. 2023. *Recomendaciones para los censos de población y vivienda en América Latina: revisión 2020*. LC/CEA.10/3. Comisión Económica para América Latina y el Caribe.

Duane, Simon, Anthony D. Kennedy, Brian J. Pendleton, y Duncan Roweth. 1987. «Hybrid Monte Carlo». *Physics Letters B* 195 (2): 216-22.

Gabry, Jonah, y Tristan Mahr. 2022. *bayesplot: Plotting for Bayesian Models*. <https://mc-stan.org/bayesplot/>.

Gabry, Jonah, Daniel Simpson, Aki Vehtari, Michael Betancourt, y Andrew Gelman. 2019. «Visualization in Bayesian Workflow». *Journal of the Royal Statistical Society: Series A* 182 (2): 389-402. <https://doi.org/10.1111/rssa.12378>.

Gelman, Andrew, John B. Carlin, Hal S. Stern, David B. Dunson, Aki Vehtari, y Donald B. Rubin. 2013. *Bayesian Data Analysis*. 3rd ed. Chapman; Hall/CRC.

Gelman, Andrew, y Donald B. Rubin. 1992. «Inference from Iterative Simulation Using Multiple Sequences». *Statistical Science* 7 (4): 457-72.

Geweke, John. 1992. *Evaluating the Accuracy of Sampling-Based Approaches to the Calculation of Posterior Moments*. 169-93.

Gneiting, Tilmann, y Adrian E. Raftery. 2007. «Strictly Proper Scoring Rules, Prediction, and Estimation». *Journal of the American Statistical Association* 102 (477): 359-78.

Hoffman, Matthew D., y Andrew Gelman. 2014. «The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo». *Journal of Machine Learning Research* 15: 1593-623.

McElreath, Richard. 2020. *Statistical Rethinking: A Bayesian Course with Examples in R and Stan*. 2nd ed. Chapman; Hall/CRC.

Mercer, Laina, Jon Wakefield, Cici Chen, y Thomas Lumley. 2015. «Space-Time Smoothing of Complex Survey Data: Small Area Inclusion Probabilities and Total Population Counts». *The Annals of Applied Statistics* 9 (4): 1889-917.

Neal, Radford M. 2011. *MCMC Using Hamiltonian Dynamics*. Editado por Steve Brooks, Andrew Gelman, Galin L. Jones, y Xiao-Li Meng. Chapman; Hall/CRC.

- Piironen, Juho, y Aki Vehtari. 2017. «Comparison of Bayesian Predictive Methods for Model Selection». *Statistics and Computing* 27 (3): 711-35.
- Rao, J. N. K., y Isabel Molina. 2015. *Small Area Estimation*. 2nd ed. John Wiley & Sons.
- Stan Development Team. 2023. *RStan: the R interface to Stan*. <https://mc-stan.org/>.
- Tierney, Luke. 1994. «Markov Chains for Exploring Posterior Distributions». *The Annals of Statistics* 22 (4): 1701-28.
- Vehtari, Aki, Jonah Gabry, Mans Magnusson, et al. 2022. *loo: Efficient Leave-One-Out Cross-Validation and WAIC for Bayesian Models*. <https://mc-stan.org/loo/>.
- Vehtari, Aki, Andrew Gelman, y Jonah Gabry. 2017. «Practical Bayesian Model Evaluation Using Leave-One-Out Cross-Validation and WAIC». *Statistics and Computing* 27 (5): 1413-32. <https://doi.org/10.1007/s11222-016-9696-4>.
- Vehtari, Aki, Andrew Gelman, Daniel Simpson, Bob Carpenter, y Paul-Christian Bürkner. 2021. «Rank-Normalization, Folding, and Localization: An Improved $\hat{R}$ for Assessing Convergence of MCMC». *Bayesian Analysis* 16 (2): 667-718. <https://doi.org/10.1214/20-BA1221>.
- Wakefield, Jon, Taylor Okonek, y Jon Pedersen. 2019. «Estimating Under-Five Mortality in Space and Time in a Developing World Context». *Statistical Science* 34 (1): 1-19.
- Watanabe, Sumio. 2010. «Asymptotic Equivalence of Bayes Cross Validation and Widely Applicable Information Criterion in Singular Learning Theory». *Journal of Machine Learning Research* 11: 3571-94.
- Xie, Yihui. 2015. *Dynamic Documents with R and knitr*. 2nd ed. Chapman; Hall/CRC. <http://yihui.org/knitr/>.