

Modelos Bayesianos de Población para América Latina y el Caribe

Implementación, Validación y Aplicación Subnacional

Andrés Gutiérrez¹ Stalyn Guerrero²

junio de 2026

¹Experto Regional en Estadísticas Sociales, CEPAL. andres.gutierrez@cepal.org

²Consultor, CEPAL. guerrerostalyn@gmail.com

Índice general

Prefacio	5
Introducción	7
1 Enfoque General de los Modelos de Población	9
1.1 Producción de conteos censales	9
1.1.1 Producción subnacional	10
1.1.2 Desagregación por sexo y edad	11
1.1.3 Uso en marcos muestrales	11
1.1.4 Definición de dominios	12
1.2 Indicadores de interés	13
1.2.1 Conteos poblacionales	13
1.2.2 Tasas derivadas	15
1.2.3 Estructuras etarias	16
1.3 Formulación del problema de subcobertura, no respuesta y omisión censal	18
2 Integración de Fuentes de Información	21
2.1 Principios de modelamiento	21
2.1.1 Modelos de conteo	21
2.1.2 Requerimientos de estimación subnacional	22
2.1.3 Justificación del enfoque bayesiano	23
2.1.4 Integración de múltiples fuentes	24
2.1.5 Relación con Small Area Estimation	24
2.2 Identificación de fuentes	25
2.2.1 Medición de cobertura a nivel de segmento	25
2.2.2 Preconteos y segmentación	26
2.2.3 Registros administrativos (variables proxy)	26
2.2.4 Fuentes satelitales	27
2.3 Variables explicativas	28
2.3.1 Variables demográficas	28
2.3.2 Variables socioeconómicas	29
2.3.3 Variables espaciales	29
3 Preparación de Imágenes Satelitales	31
3.1 Fuentes de datos satelitales (Landsat, Sentinel, MODIS)	31
3.2 Preprocesamiento y correcciones atmosféricas	31
3.3 Extracción de características (NDVI, índices espectrales)	31
3.4 Validación con datos de campo	31
3.5 Generación de capas para el modelo	31

4	Preparación de Insumos para Modelamiento	33
4.1	Estandarización de fuentes	33
4.1.1	Homologación de variables	33
4.1.2	Normalización de variables	34
4.2	Evaluación de cobertura	35
4.2.1	Tasa de cobertura por segmento	35
4.2.2	Clasificación de segmentos	36
4.3	Construcción de la variable dependiente	36
4.3.1	Conteos agregados	37
4.3.2	Tasas poblacionales	37
4.3.3	Transformaciones	37
4.3.4	Definición de población base	38
4.3.5	Escalamiento	38
4.4	Diagnóstico exploratorio	39
4.4.1	Distribución de conteos	39
4.4.2	Outliers	40
4.4.3	Relación entre variables	41
5	Modelo para Conteos Poblacionales	43
5.1	Modelo Poisson-lognormal	43
5.1.1	Definición formal	43
5.1.2	Función de verosimilitud	45
5.1.3	Distribuciones a priori	46
5.1.4	Distribución posterior	47
5.1.5	Interpretación de parámetros	48
5.2	Componentes del modelo	49
5.2.1	Efectos fijos	49
5.2.2	Efectos aleatorios	50
5.2.3	Interacciones	51
5.2.4	Sobredispersión, offset y alternativas distribucionales	51

Índice de figuras

Índice de cuadros

Prefacio

Este libro expone el marco metodológico y computacional para la producción de estimaciones de población subnacional mediante modelos bayesianos jerárquicos. Surge de la experiencia acumulada en proyectos de asistencia técnica a institutos nacionales de estadística de América Latina y el Caribe, en el marco de las actividades de cooperación estadística de la Comisión Económica para América Latina y el Caribe (CEPAL).

La motivación central es práctica: los censos de población proporcionan conteos que, en unidades geográficas pequeñas, presentan errores de cobertura sistemáticos y difíciles de cuantificar con los métodos de conciliación demográfica tradicionales. La integración de fuentes modernas de información —preconteos operativos, registros administrativos e imágenes satelitales— en un marco probabilístico coherente ofrece una respuesta metodológica rigurosa a este problema.

El libro combina fundamentos estadísticos formales con implementación computacional reproducible en R y Stan, y está dirigido a estadísticos y demógrafos de organismos nacionales e internacionales con formación cuantitativa de nivel avanzado.

Cómo compilar este libro

```
# HTML interactivo
bookdown::render_book("index.Rmd", "bookdown::gitbook")

# PDF
bookdown::render_book("index.Rmd", "bookdown::pdf_book")

# Word (.docx)
bookdown::render_book("index.Rmd", "bookdown::word_document2")
```

Introducción

La producción de conteos poblacionales constituye uno de los procesos estadísticos más complejos y estratégicos desarrollados por los institutos nacionales de estadística. Los censos de población y vivienda no solo permiten cuantificar el tamaño de la población, sino también establecer la estructura demográfica, definir marcos de referencia territoriales y generar la base operativa para una gran parte de las estadísticas oficiales producidas posteriormente por los países.

A nivel subnacional, los conteos censales son utilizados en procesos de planificación territorial, asignación presupuestal, focalización de programas sociales, construcción de marcos muestrales, producción de indicadores sociales y elaboración de proyecciones demográficas. La calidad de estas aplicaciones depende directamente de la precisión y coherencia de los conteos poblacionales observados en cada unidad geográfica.

Sin embargo, la producción censal enfrenta limitaciones estructurales asociadas a errores de cobertura, omisión, duplicación y clasificación territorial. Estos problemas no se distribuyen homogéneamente en el territorio. Por el contrario, suelen concentrarse en áreas con alta dispersión poblacional, asentamientos informales, zonas rurales de difícil acceso, territorios indígenas y contextos urbanos con elevada movilidad poblacional.

Como consecuencia, los conteos observados durante el operativo censal no necesariamente representan la población verdadera presente en cada unidad geográfica. Esta situación se vuelve particularmente crítica en niveles territoriales pequeños, donde errores relativamente reducidos en términos absolutos pueden generar distorsiones importantes en tasas, indicadores derivados y procesos de asignación institucional.

Frente a este problema, los sistemas estadísticos modernos han comenzado a incorporar metodologías de integración de múltiples fuentes de información orientadas a fortalecer, ajustar y validar los conteos censales. Entre estas fuentes se incluyen preconteos operativos, registros administrativos, cartografía censal, imágenes satelitales y modelos espaciales derivados de información georreferenciada.

En este contexto, los modelos bayesianos jerárquicos ofrecen un marco probabilístico flexible para representar explícitamente la incertidumbre asociada al proceso de enumeración poblacional y combinar información procedente de distintas fuentes bajo un esquema coherente de inferencia estadística.

Enfoque General de los Modelos de Población

1.1 Producción de conteos censales

La producción de conteos poblacionales constituye uno de los procesos más relevantes dentro de los sistemas estadísticos nacionales. A través de los censos de población y vivienda, los países construyen la base demográfica utilizada para la planificación pública, la elaboración de indicadores sociales, la construcción de marcos muestrales y la formulación de políticas territoriales. En términos operativos y metodológicos, el censo representa la única operación estadística diseñada para enumerar exhaustivamente la población residente dentro de un territorio nacional bajo un mismo marco conceptual, temporal y geográfico.

Los conteos censales no solo permiten conocer cuántas personas habitan un país, sino también cómo se distribuyen territorialmente y cómo se estructuran según características demográficas básicas como sexo y edad. Esta información es utilizada posteriormente en una gran variedad de procesos institucionales: proyecciones demográficas, encuestas de hogares, sistemas de focalización social, distribución presupuestaria, delimitación administrativa y producción de estadísticas subnacionales.

En la práctica, la producción censal implica mucho más que el levantamiento de información en campo. Detrás de los conteos publicados existe una estructura compleja de actualización cartográfica, segmentación territorial, logística operativa, capacitación, validación y conciliación estadística. Cada una de estas etapas introduce potenciales fuentes de error que afectan la calidad final de las estimaciones poblacionales.

Uno de los principales desafíos de los censos modernos corresponde a los problemas de cobertura. La enumeración de la población nunca es perfecta. Existen personas que no son censadas, viviendas que no son visitadas, individuos registrados más de una vez o registros asignados incorrectamente a un territorio distinto. Estos problemas tienden a concentrarse en determinados contextos territoriales y sociales: áreas rurales dispersas, asentamientos informales, territorios indígenas, zonas fronterizas o áreas urbanas con alta movilidad poblacional.

En América Latina y el Caribe, estas dificultades adquieren una dimensión particularmente importante debido a la elevada heterogeneidad territorial de la región. Los países presentan diferencias sustanciales en capacidad operativa, actualización cartográfica, infraestructura estadística y disponibilidad de registros administrativos. Adicionalmente, muchos territorios enfrentan condiciones geográficas complejas que dificultan las labores de enumeración y supervisión censal.

La ronda censal de 2020 evidenció nuevamente estas limitaciones. Diversos países experimentaron retrasos operativos asociados a restricciones presupuestarias, conflictos sociales y efectos derivados de la pandemia de COVID-19. Como resultado, varios sistemas estadísticos enfrentaron dificultades para mantener continuidad temporal y coherencia territorial en sus conteos poblacionales.

A medida que aumenta el nivel de desagregación geográfica, los problemas de cobertura se vuelven más visibles. Mientras que a nivel nacional algunos errores pueden compensarse parcialmente entre regiones, en niveles territoriales pequeños las omisiones o duplicaciones generan distorsiones importantes sobre indicadores

demográficos y sociales. Esto afecta directamente la capacidad de los gobiernos para asignar recursos, diseñar programas y producir estadísticas territoriales consistentes.

En este contexto, la producción moderna de conteos poblacionales requiere complementar el operativo censal tradicional con mecanismos de validación, integración de fuentes auxiliares y modelamiento estadístico. Los modelos bayesianos de población surgen precisamente como una respuesta metodológica a este problema, permitiendo integrar información proveniente de distintas fuentes y representar explícitamente la incertidumbre asociada a los conteos observados.

1.1.1 Producción subnacional

Aunque los censos generan un conteo nacional de población, gran parte de su utilidad práctica se concentra en la producción de información subnacional. Los gobiernos requieren estadísticas desagregadas para departamentos, provincias, municipios, áreas urbanas y rurales, sectores censales y segmentos operativos. Es en estas escalas territoriales donde se ejecutan la mayoría de políticas públicas y procesos administrativos.

La producción subnacional implica construir conteos consistentes entre distintos niveles geográficos. Los totales municipales deben coincidir con los agregados departamentales, y estos, a su vez, con los conteos nacionales. Esta coherencia territorial constituye uno de los principios fundamentales de la estadística oficial.

Sin embargo, garantizar dicha consistencia no es un proceso trivial. A medida que disminuye el tamaño poblacional de las unidades geográficas, aumentan proporcionalmente los efectos de los errores de cobertura. En áreas pequeñas, la omisión de algunos hogares o viviendas puede alterar significativamente indicadores derivados como tasas de dependencia, razones de masculinidad o estructuras etarias.

La calidad de los conteos subnacionales depende críticamente de la cartografía censal y de los procesos de segmentación territorial. Antes del levantamiento censal, los países deben actualizar mapas, identificar viviendas, definir rutas operativas y dividir el territorio en unidades de trabajo relativamente homogéneas. Estas unidades, conocidas generalmente como segmentos censales, constituyen la base operativa del operativo de campo.

En América Latina y el Caribe, la definición de segmentos presenta importantes diferencias metodológicas entre países. Algunos sistemas censales utilizan criterios asociados al número esperado de viviendas, mientras que otros priorizan continuidad espacial, accesibilidad geográfica o carga operativa del censista. Como resultado, las unidades territoriales utilizadas en los censos no siempre son comparables entre países.

Otro aspecto relevante corresponde a la diferencia entre censos de hecho y censos de derecho. En países como Bolivia, Paraguay y Colombia, los operativos censales han sido implementados bajo esquemas de censo de hecho, donde las personas son contabilizadas en el lugar donde se encuentran durante el momento censal. En contraste, los censos de derecho buscan registrar a las personas según su residencia habitual.

Esta diferencia conceptual tiene implicaciones importantes sobre movilidad territorial, cobertura diferencial y consistencia espacial. En contextos con alta movilidad poblacional, los censos de hecho pueden generar concentraciones temporales de población en determinadas áreas, mientras que los censos de derecho requieren procedimientos más complejos para validar residencia habitual y evitar duplicaciones.

La producción subnacional también enfrenta desafíos asociados al crecimiento urbano acelerado y a la expansión de asentamientos informales. En muchas ciudades de la región, los procesos de urbanización ocurren más rápidamente que la actualización cartográfica oficial, generando sectores con viviendas no registradas o límites territoriales desactualizados. Esto afecta directamente la cobertura del operativo y la calidad de los conteos resultantes.

Desde la perspectiva estadística, los conteos subnacionales deben entenderse como observaciones imperfectas de una población subyacente cuya magnitud real no es completamente observable. Esta situación motiva el uso de modelos probabilísticos capaces de integrar múltiples fuentes de información, representar explícitamente la incertidumbre y garantizar coherencia entre niveles territoriales.

1.1.2 Desagregación por sexo y edad

Uno de los principales aportes de los censos de población consiste en la posibilidad de caracterizar la estructura demográfica de la población. Los conteos no solo se producen para áreas geográficas, sino también para distintos grupos de edad y sexo. Esta desagregación constituye un insumo fundamental para el análisis demográfico, la formulación de políticas públicas y la elaboración de proyecciones poblacionales.

La distribución por edad y sexo condiciona directamente múltiples dimensiones del desarrollo social y económico. La demanda de servicios educativos, sistemas de salud, programas de protección social y mercados laborales depende estrechamente de la estructura etaria de la población. Del mismo modo, indicadores como envejecimiento, dependencia demográfica o fecundidad requieren información detallada sobre composición poblacional.

En términos operativos, la producción de conteos por sexo y edad incrementa considerablemente la complejidad del proceso censal. Los errores de cobertura no afectan de manera homogénea a todos los grupos poblacionales. En América Latina y el Caribe, las tasas de omisión suelen ser más elevadas en niños pequeños, hombres jóvenes, población indígena, migrantes y habitantes de zonas rurales dispersas.

Estas diferencias generan distorsiones importantes en la estructura observada de la población. En niveles territoriales pequeños, incluso pequeñas omisiones pueden alterar significativamente indicadores demográficos derivados. Por esta razón, los sistemas estadísticos implementan procedimientos de validación y ajuste orientados a identificar inconsistencias en la distribución por sexo y edad.

La desagregación etaria también constituye un componente central de los procesos de proyección demográfica. Los métodos cohortes-componentes utilizados por la mayoría de países requieren información detallada sobre estructura poblacional para modelar nacimientos, defunciones y migración. Como consecuencia, errores en la distribución censal inicial pueden propagarse a lo largo de toda la serie de proyecciones futuras.

En el contexto del modelamiento bayesiano, la estructura por sexo y edad puede incorporarse mediante modelos jerárquicos que permiten compartir información entre grupos relacionados y estabilizar estimaciones en dominios con baja densidad poblacional. Esto resulta especialmente útil en áreas pequeñas donde la variabilidad observada puede ser considerablemente alta.

1.1.3 Uso en marcos muestrales

Los conteos censales constituyen la principal base para la construcción de marcos muestrales utilizados en encuestas de hogares y otras operaciones estadísticas. Los sectores y segmentos definidos durante el operativo censal son utilizados posteriormente como unidades primarias de muestreo en gran parte de las encuestas nacionales desarrolladas por los institutos de estadística.

La calidad de un marco muestral depende directamente de la calidad de los conteos censales y de la actualización cartográfica asociada. Cuando existen omisiones territoriales, viviendas no registradas o límites desactualizados, los diseños muestrales pueden introducir sesgos de cobertura y pérdida de eficiencia estadística.

En América Latina y el Caribe, muchos marcos muestrales permanecen vigentes durante periodos intercensales prolongados. Durante estos intervalos, los cambios demográficos y territoriales pueden modificar sustancialmente la distribución espacial de la población. La expansión urbana, la migración interna y la transformación de áreas rurales generan desactualizaciones progresivas en las unidades de muestreo originalmente construidas a partir del censo.

La segmentación censal también cumple un papel operativo fundamental en la implementación de encuestas probabilísticas. Las unidades territoriales utilizadas durante el censo suelen redefinirse y reorganizarse para optimizar costos operativos, carga de trabajo y precisión estadística. Como resultado, la calidad de la información censal afecta directamente el desempeño posterior de múltiples sistemas de encuestas.

En este contexto, mejorar la calidad de los conteos subnacionales no solo fortalece las estadísticas demográficas, sino también toda la infraestructura estadística utilizada posteriormente por los países para producir información social y económica.

1.1.4 Definición de dominios

La producción de estadísticas poblacionales requiere definir dominios geográficos y demográficos sobre los cuales se generan estimaciones e indicadores. Estos dominios corresponden a distintos niveles territoriales utilizados para organización administrativa, planificación pública y análisis estadístico.

El nivel nacional constituye el agregado principal del sistema estadístico y funciona como referencia para la producción de indicadores macrodemográficos y proyecciones oficiales. Sin embargo, gran parte de las decisiones operativas se realizan en escalas territoriales inferiores.

El nivel intermedio, conformado generalmente por departamentos, provincias o estados, representa uno de los principales niveles de descentralización administrativa en América Latina y el Caribe. En estos territorios se ejecutan programas regionales, se distribuyen recursos fiscales y se implementan estrategias sectoriales de salud, educación e infraestructura.

La diferenciación urbano-rural constituye además una dimensión central en la producción estadística regional. Las brechas territoriales entre áreas urbanas y rurales continúan siendo una de las principales características demográficas y socioeconómicas de la región. Como consecuencia, muchos indicadores poblacionales requieren desagregación específica según tipo de área.

A nivel local, los municipios representan una de las principales unidades de gestión territorial. En este nivel se concentran procesos de planeación urbana, focalización social, administración tributaria y provisión de servicios públicos. La precisión de los conteos municipales afecta directamente la asignación presupuestaria y la medición de múltiples indicadores sociales.

Finalmente, el segmento censal constituye la unidad operativa básica del levantamiento. Estas unidades poseen alta resolución espacial y permiten representar con mayor detalle la heterogeneidad territorial. Sin embargo, también presentan mayor sensibilidad a errores de cobertura y problemas de consistencia espacial.

En países como Bolivia, Paraguay y Colombia, los segmentos censales adquieren especial importancia debido a la implementación de censos de hecho y a la necesidad de coordinar operativos intensivos de corta duración. En este contexto, la calidad de la segmentación territorial condiciona directamente la cobertura del operativo y la precisión de los conteos finales.

Desde la perspectiva del modelamiento estadístico, los distintos dominios territoriales conforman una estructura jerárquica de información donde las estimaciones deben mantener coherencia entre niveles geográficos.

Esta jerarquía constituye uno de los elementos centrales en el desarrollo posterior de modelos bayesianos subnacionales orientados a integración de fuentes y ajuste de cobertura.

1.2 Indicadores de interés

La producción de conteos censales tiene como propósito central generar información estadística que permita caracterizar la dinámica demográfica y territorial de la población. A partir de los datos censales es posible construir un amplio conjunto de indicadores utilizados en procesos de planificación, evaluación de políticas públicas, asignación presupuestaria y análisis socioeconómico.

Los indicadores derivados de los censos no solo describen el tamaño de la población, sino también su distribución espacial, estructura etaria, composición por sexo y condiciones territoriales. Estos indicadores constituyen además el punto de partida para procesos posteriores de estimación, proyección demográfica y construcción de estadísticas oficiales.

En América Latina y el Caribe, la creciente demanda de información subnacional ha incrementado la necesidad de producir indicadores con alta desagregación territorial. Los gobiernos requieren estadísticas consistentes para departamentos, municipios, áreas urbanas y rurales, e incluso niveles operativos más pequeños como sectores y segmentos censales.

Sin embargo, la producción de indicadores en dominios pequeños enfrenta limitaciones importantes asociadas a errores de cobertura, omisión censal y variabilidad espacial de los conteos. En consecuencia, muchos indicadores derivados presentan altos niveles de inestabilidad cuando se calculan directamente a partir de los conteos observados.

En este contexto, resulta fundamental distinguir entre:

- conteos poblacionales básicos;
- tasas derivadas;
- y estructuras demográficas.

Cada uno de estos componentes presenta características particulares en términos de interpretación, sensibilidad a errores de cobertura y comportamiento territorial.

1.2.1 Conteos poblacionales

Los conteos poblacionales constituyen el núcleo de la producción estadística demográfica. A través de ellos, los países cuantifican la población presente o residente dentro de un territorio y construyen la base sobre la cual se desarrollan posteriormente las proyecciones demográficas, los marcos muestrales, los indicadores sociales y gran parte de las estadísticas oficiales utilizadas en procesos de planificación pública.

Estos conteos son producidos para múltiples niveles de desagregación territorial y demográfica. En términos generales, la información censal se organiza para el nivel nacional, departamentos o provincias, municipios, áreas urbanas y rurales, así como para distintos grupos de edad y sexo. Esta estructura jerárquica permite caracterizar la distribución espacial de la población y construir estadísticas coherentes entre distintos niveles administrativos.

Sea $N_{i,s,e}$ el número de personas en el dominio geográfico i , sexo $s \in \{M, F\}$ (masculino, femenino) y grupo de edad $e \in \{1, \dots, E\}$. El conteo total de población para una unidad geográfica se obtiene por agregación sobre sexo y edad:

$$N_i = \sum_{s \in \{M, F\}} \sum_{e=1}^E N_{i,s,e}$$

mientras que la población nacional corresponde a la suma sobre todos los dominios territoriales:

$$N = \sum_{i=1}^I N_i$$

La coherencia jerárquica exige que los conteos en niveles inferiores sean consistentes con los totales de los niveles superiores. Denotando con superíndice el nivel jerárquico — $N_j^{(2)}$ para un departamento j , $N_k^{(3)}$ para un municipio k y $N_\ell^{(4)}$ para un segmento ℓ — las restricciones de consistencia son:

$$N_j^{(2)} = \sum_{k: k \subset j} N_k^{(3)}, \quad N_k^{(3)} = \sum_{\ell: \ell \subset k} N_\ell^{(4)}$$

donde la notación $k \subset j$ indica que el municipio k pertenece al departamento j .

Esta coherencia jerárquica es esencial para garantizar la comparabilidad y consistencia de las estadísticas oficiales.

En la práctica, los conteos poblacionales pueden entenderse en distintos niveles. Los conteos observados corresponden directamente a la enumeración realizada durante el operativo censal. Posteriormente, algunos países incorporan procesos de conciliación y ajuste orientados a corregir problemas de cobertura o inconsistencias demográficas. Finalmente, en contextos donde existen limitaciones operativas o necesidad de actualización intercensal, los conteos pueden complementarse mediante procedimientos de estimación estadística e integración de múltiples fuentes de información.

Uno de los principales desafíos asociados a los conteos poblacionales corresponde a su sensibilidad frente a errores de cobertura territorial. A medida que aumenta el nivel de desagregación geográfica, incluso pequeñas omisiones pueden generar distorsiones importantes sobre indicadores derivados. Este problema es particularmente visible en municipios pequeños, áreas rurales dispersas o segmentos censales con baja densidad poblacional, donde la omisión de algunos hogares puede modificar significativamente estructuras etarias, tasas de dependencia o indicadores sociales.

En América Latina y el Caribe, estas dificultades adquieren una relevancia especial debido a la heterogeneidad territorial de la región. La expansión urbana acelerada, el crecimiento de asentamientos informales, la movilidad poblacional y las diferencias en capacidad operativa entre países generan importantes desafíos para la actualización cartográfica y la cobertura completa del operativo censal. Como consecuencia, la precisión espacial de los conteos puede variar considerablemente entre territorios.

Desde una perspectiva estadística, los conteos poblacionales no deben interpretarse como valores exactos libres de error, sino como observaciones sujetas a incertidumbre y condicionadas por las limitaciones propias del operativo censal. Esta interpretación resulta fundamental para el desarrollo posterior de modelos proba-

bilísticos de población, donde los conteos observados se entienden como aproximaciones de una población subyacente no completamente observable.

1.2.2 Tasas derivadas

A partir de los conteos poblacionales es posible construir un amplio conjunto de tasas e indicadores utilizados para describir dinámicas demográficas, caracterizar condiciones territoriales y apoyar procesos de planificación pública. Mientras los conteos absolutos permiten cuantificar el tamaño de la población, las tasas derivadas facilitan la comparación entre territorios con estructuras y magnitudes poblacionales diferentes.

Este tipo de indicadores resulta fundamental para el análisis territorial, ya que permite transformar los conteos censales en medidas comparables entre regiones, municipios o áreas urbanas y rurales. De esta manera, es posible evaluar fenómenos asociados a concentración poblacional, envejecimiento, dependencia demográfica o composición por sexo bajo una escala relativa más adecuada para el análisis estadístico.

Entre los indicadores más utilizados se encuentran la densidad poblacional, las tasas de dependencia, las razones de masculinidad y los índices de envejecimiento. Cada uno de ellos resume distintas dimensiones de la estructura demográfica y constituye un insumo importante para la toma de decisiones institucionales.

La densidad poblacional permite medir la relación entre población y superficie territorial. Para un territorio (i), esta puede expresarse como:

$$D_i = \frac{N_i}{A_i}$$

donde N_i representa la población observada y A_i el área geográfica correspondiente. Este indicador es ampliamente utilizado en procesos de planificación urbana, expansión de infraestructura, análisis ambiental y organización de servicios públicos.

Por su parte, la razón de masculinidad describe la relación entre población masculina y femenina dentro de un territorio determinado:

$$RM_i = \frac{N_{i,M}}{N_{i,F}} \times 100$$

donde $N_{i,M} = \sum_e N_{i,M,e}$ es la población masculina y $N_{i,F} = \sum_e N_{i,F,e}$ la femenina del territorio i . Este indicador permite identificar desequilibrios demográficos asociados a migración, envejecimiento o cambios en la estructura poblacional.

Otro indicador ampliamente utilizado corresponde a la tasa de dependencia demográfica, la cual relaciona la población potencialmente dependiente con la población en edades productivas:

$$TD_i = \frac{N_{i,[0,14]} + N_{i,[65+]}}{N_{i,[15,64]}} \times 100$$

donde $N_{i,[a,b]} = \sum_s \sum_{e: e \in [a,b]} N_{i,s,e}$ denota la población del territorio i en el intervalo de edad $[a, b]$. De manera complementaria, el índice de envejecimiento evalúa el peso relativo de la población adulta mayor frente a la población joven:

$$IE_i = \frac{N_{i,[65+]}}{N_{i,[0,14]}} \times 100$$

Estos indicadores desempeñan un papel central en la planificación territorial y sectorial. Su utilización es frecuente en procesos de asignación presupuestaria, focalización de programas sociales, evaluación de necesidades de infraestructura y análisis de demanda potencial de servicios públicos.

Sin embargo, las tasas derivadas presentan una sensibilidad considerable frente a errores de cobertura censal. Debido a que muchas de ellas se construyen como razones entre subgrupos poblacionales específicos, pequeñas omisiones o inconsistencias pueden generar fluctuaciones importantes en los resultados observados. Este fenómeno se vuelve particularmente evidente en dominios geográficos pequeños, donde diferencias reducidas en los conteos absolutos producen variaciones relativamente grandes en los indicadores derivados.

En municipios con baja población o segmentos censales reducidos, las tasas pueden presentar comportamientos altamente inestables, especialmente cuando existen problemas de omisión diferencial por edad, sexo o localización territorial. En América Latina y el Caribe, estas dificultades suelen amplificarse debido a la heterogeneidad territorial, la expansión metropolitana acelerada, los procesos migratorios y las diferencias operativas observadas entre países y regiones.

Como consecuencia, la producción de indicadores subnacionales requiere mecanismos de validación y ajuste orientados a mejorar estabilidad estadística y coherencia territorial. Desde esta perspectiva, los enfoques de modelamiento permiten complementar los métodos tradicionales mediante estrategias que incorporan integración de información auxiliar y representación explícita de la incertidumbre asociada a los conteos base.

1.2.3 Estructuras etarias

La estructura por edad de la población constituye uno de los componentes centrales del análisis demográfico. Su estudio permite comprender los cambios asociados a fecundidad, mortalidad, migración, envejecimiento y transición demográfica, así como las diferencias territoriales en la dinámica poblacional de los países.

Los censos de población representan la principal fuente de información para caracterizar estas estructuras con altos niveles de desagregación geográfica. A partir de los conteos por edad y sexo es posible construir pirámides poblacionales, relaciones de dependencia, índices de envejecimiento y proyecciones demográficas, elementos fundamentales para la planificación social y económica.

Sea $N_{i,e} = \sum_{s \in \{M,F\}} N_{i,s,e}$ la población del área i en el grupo de edad e , obtenida por suma sobre ambos sexos. La participación relativa de cada grupo etario dentro de la población total del territorio puede expresarse como:

$$p_{i,e} = \frac{N_{i,e}}{N_i}$$

donde $N_i = \sum_{e=1}^E N_{i,e}$ es la población total del territorio. Por construcción, $\sum_{e=1}^E p_{i,e} = 1$.

En la práctica, la estructura etaria suele organizarse utilizando grupos quinquenales de edad:

$$0 - 4, 5 - 9, 10 - 14, \dots, 80+$$

debido a que esta agrupación proporciona mayor estabilidad demográfica y facilita la comparabilidad entre países y periodos censales. Adicionalmente, los grupos quinquenales constituyen la base utilizada en la mayoría

de modelos de proyección poblacional y análisis demográficos oficiales.

Los indicadores de cambio demográfico más utilizados se expresan directamente en términos de $N_{i,[a,b]}$. El índice de envejecimiento relaciona la población adulta mayor con la población joven:

$$IE_i = \frac{N_{i,[65+]}}{N_{i,[0,14]}} \times 100$$

La tasa de dependencia demográfica total evalúa la presión potencial sobre la población en edades productivas y coincide con TD_i definida en la sección anterior:

$$TD_i = \frac{N_{i,[0,14]} + N_{i,[65+]}}{N_{i,[15,64]}} \times 100$$

Estos indicadores son ampliamente utilizados en procesos de planificación pública debido a que permiten anticipar necesidades asociadas a educación, salud, protección social, empleo e infraestructura. Territorios con estructuras jóvenes suelen demandar mayores inversiones en sistemas educativos y servicios materno-infantiles, mientras que áreas con envejecimiento avanzado requieren una mayor capacidad de atención en salud y sistemas de cuidado.

En América Latina y el Caribe, la estructura etaria presenta fuertes contrastes territoriales. Mientras algunas áreas metropolitanas muestran procesos avanzados de envejecimiento poblacional y reducción de fecundidad, otras regiones mantienen estructuras considerablemente más jóvenes asociadas a mayores niveles de natalidad y menor transición demográfica. Estas diferencias reflejan la elevada heterogeneidad demográfica de la región y generan importantes desafíos para la producción de estadísticas subnacionales comparables.

La construcción de estructuras etarias confiables enfrenta además importantes limitaciones operativas. Los errores de cobertura censal no afectan homogéneamente a todos los grupos de edad. En muchos países de la región, la omisión censal tiende a concentrarse en niños pequeños, hombres jóvenes, migrantes, población indígena y habitantes de zonas rurales dispersas. Como consecuencia, la distribución observada por edad puede diferir significativamente de la estructura poblacional verdadera.

Este problema se intensifica en dominios geográficos pequeños. En municipios con baja población o segmentos censales reducidos, pequeñas diferencias en los conteos observados pueden modificar considerablemente la forma de la estructura etaria y generar indicadores altamente inestables. La variabilidad observada suele aumentar aún más cuando los grupos poblacionales son desagregados simultáneamente por edad, sexo y localización territorial.

Adicionalmente, las estructuras etarias cumplen un papel central en los procesos de proyección demográfica y estimación intercensal. Los modelos cohortes-componentes utilizados por la mayoría de oficinas nacionales de estadística dependen directamente de la calidad de la distribución inicial por edad y sexo. En consecuencia, errores presentes en los conteos censales pueden propagarse hacia estimaciones futuras y afectar la consistencia temporal de las proyecciones oficiales.

Desde la perspectiva del modelamiento estadístico, las estructuras etarias pueden entenderse como realizaciones sujetas a incertidumbre y error de cobertura. Bajo este enfoque, los modelos bayesianos jerárquicos permiten incorporar dependencia entre grupos de edad relacionados, estabilizar estimaciones en áreas con información limitada e integrar múltiples fuentes auxiliares para mejorar la coherencia territorial y demográfica de las estimaciones poblacionales.

1.3 Formulación del problema de subcobertura, no respuesta y omisión censal

Uno de los principales desafíos de los censos modernos corresponde a los problemas de cobertura asociados al operativo de enumeración. Aunque el objetivo conceptual del censo consiste en registrar exhaustivamente toda la población presente o residente dentro del territorio nacional, en la práctica siempre existen diferencias entre la población efectivamente observada y la población real presente en el territorio.

Estas diferencias surgen por múltiples razones. Algunas personas no son censadas, ciertas viviendas quedan fuera del operativo, algunos registros son duplicados y, en otros casos, existen errores en la asignación territorial de la información recolectada. Como resultado, los conteos censales deben entenderse como realizaciones observadas de un proceso de enumeración sujeto a limitaciones operativas, errores cartográficos y dificultades de cobertura.

Formalmente, sea $Y_{i,s,e}$ el conteo observado en el operativo censal para el territorio i , sexo s y grupo de edad e , y sea $N_{i,s,e}$ la población verdadera correspondiente. La relación entre ambos puede representarse como:

$$Y_{i,s,e} = N_{i,s,e} - O_{i,s,e} + D_{i,s,e} + C_{i,s,e}$$

donde $O_{i,s,e}$ representa la omisión censal, $D_{i,s,e}$ la duplicación de personas y $C_{i,s,e}$ los errores asociados a clasificación o asignación territorial. Bajo esta formulación, los conteos observados no constituyen una medición exacta de la población, sino una aproximación afectada por distintos mecanismos de error.

En América Latina y el Caribe, la subcobertura censal presenta además una marcada heterogeneidad territorial. La omisión no ocurre aleatoriamente sobre la población ni sobre el territorio. Por el contrario, suele concentrarse en contextos específicos como asentamientos informales, zonas rurales dispersas, territorios indígenas, áreas de frontera o sectores urbanos con elevada movilidad residencial. Estas características generan patrones espaciales de cobertura diferencial que afectan directamente la calidad de los conteos subnacionales.

La no respuesta constituye un problema adicional dentro del proceso censal. Incluso cuando una vivienda logra ser efectivamente enumerada, algunas variables pueden quedar incompletas debido a ausencia de informantes, rechazo parcial, inconsistencias durante la entrevista o errores de captura. Este fenómeno afecta particularmente variables socioeconómicas y laborales, reduciendo la completitud analítica de la información censal.

La combinación entre subcobertura, omisión y no respuesta produce efectos acumulativos sobre múltiples procesos estadísticos posteriores. Las proyecciones demográficas, la construcción de marcos muestrales, la estimación de indicadores sociales y los procesos de focalización territorial dependen directamente de la calidad de los conteos base. En consecuencia, errores relativamente pequeños en la enumeración pueden propagarse posteriormente hacia distintas operaciones estadísticas oficiales.

Estos problemas adquieren una relevancia aún mayor en niveles geográficos pequeños. En municipios con baja población o segmentos censales reducidos, la omisión de un número limitado de viviendas puede alterar significativamente las estructuras poblacionales observadas. Este fenómeno se intensifica cuando los errores de cobertura afectan diferencialmente determinados grupos de edad, sexo o condiciones socioeconómicas.

Adicionalmente, la rápida transformación territorial observada en muchos países de la región ha incrementado la complejidad operativa de los censos. La expansión urbana acelerada, el crecimiento de asentamientos informales y los procesos migratorios dificultan la actualización cartográfica permanente y reducen la capacidad de cobertura completa del operativo censal.

Frente a este escenario, los sistemas estadísticos han comenzado a complementar los enfoques tradicionales de conciliación censal mediante estrategias de integración de múltiples fuentes de información. Los registros ad-

ministrativos, las imágenes satelitales, los preconteos operativos y otras fuentes auxiliares permiten identificar inconsistencias territoriales y fortalecer la estimación de poblaciones subenumeradas.

En este libro, el interés principal no se centra en modelar directamente tasas de cobertura, sino en estimar conteos poblacionales en segmentos censales donde existen problemas de cobertura, omisión o inconsistencias territoriales. Bajo esta perspectiva, los conteos observados se interpretan como información parcial sobre una población subyacente cuya magnitud real debe inferirse utilizando información auxiliar y estructuras jerárquicas coherentes con la organización territorial del censo.

Desde esta perspectiva, los modelos bayesianos ofrecen un marco flexible para integrar múltiples fuentes de información, representar explícitamente la incertidumbre asociada a los conteos observados y estabilizar estimaciones en dominios geográficos pequeños. Los capítulos posteriores desarrollan estos elementos metodológicos y presentan estrategias orientadas específicamente a la estimación subnacional de conteos poblacionales en segmentos censales bajo esquemas probabilísticos modernos.

Integración de Fuentes de Información

La estimación de conteos poblacionales en unidades territoriales pequeñas no puede resolverse adecuadamente mediante el análisis directo de los datos censales. Las limitaciones de cobertura, la variabilidad asociada a dominios con baja densidad poblacional y la disponibilidad creciente de información auxiliar de distinta naturaleza hacen necesario un marco metodológico que integre múltiples fuentes bajo un esquema estadístico coherente.

Este capítulo presenta los principios de modelamiento que fundamentan los modelos bayesianos de estimación subnacional, describe las principales fuentes de información disponibles en América Latina y el Caribe y caracteriza las variables explicativas utilizadas para predecir la distribución espacial de la población.

2.1 Principios de modelamiento

Los modelos estadísticos utilizados para la estimación subnacional de conteos poblacionales deben ser capaces de representar adecuadamente la naturaleza discreta y no negativa de los datos, de incorporar información auxiliar proveniente de fuentes heterogéneas, de producir estimaciones coherentes entre niveles territoriales y de cuantificar explícitamente la incertidumbre de las estimaciones resultantes. El cumplimiento de estos requisitos condiciona tanto la elección de la familia distribucional del modelo como el marco inferencial adoptado.

2.1.1 Modelos de conteo

Los conteos poblacionales son variables aleatorias discretas no negativas. Esta naturaleza fundamental distingue el problema de estimación subnacional de los problemas de regresión con variables continuas y exige el uso de modelos de probabilidad apropiados para datos de conteo.

La distribución de Poisson constituye el punto de partida canónico para el modelamiento de conteos. Si Y_i denota el conteo observado en el segmento i , el modelo de Poisson establece:

$$Y_i | \lambda_i \sim \text{Poisson}(\lambda_i)$$

donde $\lambda_i > 0$ es el parámetro de intensidad, que representa simultáneamente la media y la varianza de la distribución. La función de masa de probabilidad es:

$$P(Y_i = y | \lambda_i) = \frac{e^{-\lambda_i} \lambda_i^y}{y!}, \quad y = 0, 1, 2, \dots$$

La parametrización log-lineal del modelo relaciona el logaritmo de la intensidad con un predictor lineal de covariables:

$$\log(\lambda_i) = \mathbf{x}_i^\top \beta + u_i$$

donde $\mathbf{x}_i$ es el vector de covariables auxiliares del segmento i , β es el vector de coeficientes y u_i es un efecto aleatorio que captura la variabilidad no explicada por las covariables.

Un supuesto fundamental del modelo de Poisson es la equidispersión: $\mathbb{E}[Y_i | \lambda_i] = \text{Var}(Y_i | \lambda_i) = \lambda_i$. En la práctica, los conteos poblacionales suelen exhibir sobredispersión, es decir, una varianza observada mayor a la media. Este fenómeno puede originarse en heterogeneidad no observada entre segmentos, clustering espacial o errores de especificación del predictor.

Para tratar la sobredispersión, el modelo binomial negativo introduce un parámetro adicional $\phi > 0$ que controla la varianza:

$$Y_i | \mu_i, \phi \sim \text{NegBin}(\mu_i, \phi)$$

con función de masa de probabilidad:

$$P(Y_i = y | \mu_i, \phi) = \binom{y + \phi - 1}{y} \left(\frac{\phi}{\phi + \mu_i} \right)^\phi \left(\frac{\mu_i}{\phi + \mu_i} \right)^y$$

En este caso, $\mathbb{E}[Y_i] = \mu_i$ y $\text{Var}(Y_i) = \mu_i + \mu_i^2 / \phi$. A medida que $\phi \rightarrow \infty$, la distribución binomial negativa converge hacia la Poisson.

Alternativamente, la sobredispersión puede modelarse mediante la inclusión de efectos aleatorios con distribución gamma en el predictor de Poisson. Si $\lambda_i = \mu_i \cdot \gamma_i$ con $\gamma_i \sim \text{Gamma}(\phi, \phi)$, la distribución marginal de Y_i resulta binomial negativa con parámetros (μ_i, ϕ) . Esta representación facilita la interpretación de los efectos aleatorios como multiplicadores de la intensidad esperada en cada segmento.

En contextos de modelamiento jerárquico, la elección entre Poisson y binomial negativa debe fundamentarse tanto en consideraciones estadísticas —diagnóstico de sobredispersión— como en la disponibilidad de información auxiliar: una especificación más rica de covariables puede reducir la sobredispersión aparente al explicar parte de la heterogeneidad entre segmentos.

2.1.2 Requerimientos de estimación subnacional

La estimación de conteos en niveles territoriales pequeños impone requerimientos adicionales que van más allá de la simple elección de una distribución de probabilidad. Estos requerimientos se derivan de la naturaleza jerárquica del problema y de las condiciones operativas en las que se producen los datos.

Coherencia jerárquica. Las estimaciones en niveles inferiores deben ser consistentes con los totales conocidos o estimados en niveles superiores. Si $\hat{N}_k^{(3)}$ denota la estimación del municipio k y $\hat{N}_j^{(2)}$ la del departamento j , la coherencia exige:

$$\hat{N}_j^{(2)} = \sum_{k: k \subset j} \hat{N}_k^{(3)}$$

Esta restricción de coherencia entre niveles es fundamental para garantizar la consistencia interna del sistema estadístico y constituye un criterio de validación esencial de cualquier modelo de estimación subnacional.

Estimación en dominios pequeños. En segmentos censales con baja densidad poblacional, los conteos observados son altamente variables y presentan elevada incertidumbre. En estos dominios, los estimadores directos basados únicamente en la información del segmento son insuficientes y deben complementarse con información auxiliar proveniente de otras fuentes o de dominios relacionados.

Propagación de incertidumbre. Las estimaciones subnacionales deben acompañarse de medidas de incertidumbre que reflejen adecuadamente la variabilidad del proceso. En contextos donde los conteos observados son escasos o de baja calidad, la incertidumbre puede ser considerable, y su cuantificación explícita es esencial para el uso responsable de las estimaciones en procesos de planificación y asignación de recursos.

Estabilidad temporal. Cuando se dispone de información de periodos censales anteriores, el modelo debe ser capaz de incorporar dicha información de forma coherente, reconociendo que la población cambia en el tiempo y que la relevancia de la información histórica decrece a medida que aumenta el intervalo temporal.

2.1.3 Justificación del enfoque bayesiano

El enfoque bayesiano ofrece un marco de inferencia particularmente apropiado para la estimación subnacional de conteos poblacionales. Sus ventajas frente a los métodos frecuentistas se derivan directamente de las características del problema.

Representación explícita de la incertidumbre. En el paradigma bayesiano, todos los parámetros desconocidos se tratan como variables aleatorias cuya incertidumbre se cuantifica mediante distribuciones de probabilidad. La distribución posterior $p(\theta \mid \mathbf{Y})$ encapsula el estado de conocimiento sobre la población en cada segmento dado el conjunto de datos observados:

$$p(\theta \mid \mathbf{Y}) \propto p(\mathbf{Y} \mid \theta) p(\theta)$$

Esta representación permite calcular intervalos de credibilidad, probabilidades de excedencia y cualquier otra cantidad de interés derivada de la distribución posterior.

Incorporación de información previa. Las distribuciones a priori permiten incorporar conocimiento demográfico sustantivo sobre la estructura de la población, restricciones de positividad, información de censos anteriores o expertos en el área. A diferencia de los métodos frecuentistas, el marco bayesiano provee un mecanismo formal para integrar esta información de manera coherente con los datos observados.

Estimación simultánea de múltiples dominios. Los modelos jerárquicos bayesianos permiten estimar simultáneamente la población en todos los segmentos, compartiendo información entre dominios relacionados. Los parámetros del nivel superior —como los coeficientes de las covariables— se estiman a partir de la información conjunta de todos los segmentos, lo que permite que los dominios con mejor cobertura contribuyan a estabilizar las estimaciones en dominios con datos limitados.

Coherencia probabilística. Las estimaciones bayesianas son coherentes por construcción: cualquier función de los parámetros puede estimarse a partir de la distribución posterior, y los intervalos de credibilidad tienen interpretación probabilística directa. Esta propiedad es especialmente valiosa cuando se requiere reportar incertidumbre a distintos niveles de desagregación territorial.

La estimación de la distribución posterior en modelos complejos se realiza mediante métodos de Monte Carlo por cadenas de Markov (MCMC). Entre los algoritmos más utilizados en la práctica se encuentran el muestreo de Gibbs, el algoritmo de Metropolis-Hastings y, más recientemente, el método de Monte Carlo Hamiltoniano

(HMC) implementado en Stan. Estos algoritmos permiten obtener muestras de la distribución posterior en modelos con alta dimensionalidad y estructuras jerárquicas complejas.

2.1.4 Integración de múltiples fuentes

El marco bayesiano provee un mecanismo natural para integrar información proveniente de múltiples fuentes bajo un esquema probabilístico coherente. La integración se realiza a través de la función de verosimilitud, que puede descomponerse en contribuciones de distintas fuentes de información, y a través de las distribuciones a priori, que capturan conocimiento previo sobre los parámetros.

Supóngase que se dispone de tres fuentes de información para el segmento i : el conteo censal observado $Y_i^{(C)}$, el preconteo operativo $Y_i^{(P)}$ y un conteo derivado de registros administrativos $Y_i^{(A)}$. Bajo el supuesto de independencia condicional entre fuentes dado el parámetro de población N_i , la verosimilitud conjunta puede escribirse como:

$$p(Y_i^{(C)}, Y_i^{(P)}, Y_i^{(A)} | N_i, \theta) = p(Y_i^{(C)} | N_i, \theta^{(C)}) \cdot p(Y_i^{(P)} | N_i, \theta^{(P)}) \cdot p(Y_i^{(A)} | N_i, \theta^{(A)})$$

donde $\theta^{(C)}$, $\theta^{(P)}$ y $\theta^{(A)}$ son los parámetros específicos de cada modelo de medición. Esta factorización permite modelar de forma separada las características de cada fuente —su cobertura, sus sesgos y su variabilidad— sin imponer restricciones artificiosas de equivalencia entre ellas.

El supuesto de independencia condicional entre fuentes es una simplificación que puede no ser siempre válida. En la práctica, distintas fuentes pueden compartir errores comunes asociados a factores territoriales no observados. Este problema puede mitigarse parcialmente mediante la inclusión de efectos aleatorios compartidos entre fuentes en el modelo jerárquico.

2.1.5 Relación con Small Area Estimation

Los modelos bayesianos de estimación poblacional subnacional se inscriben dentro del campo más amplio de la Estimación en Áreas Pequeñas (*Small Area Estimation*, SAE). Este campo metodológico desarrolla métodos estadísticos orientados a producir estimaciones confiables en dominios con tamaño muestral insuficiente para la estimación directa.

Los modelos SAE se clasifican generalmente en dos grandes categorías según el nivel en el que se especifica la estructura del modelo:

Modelos a nivel de área. Estos modelos operan sobre estadísticos agregados calculados para cada dominio. El modelo de Fay-Herriot es el referente clásico: se postula que la estimación directa $\hat{\theta}_i$ del parámetro de interés θ_i en el área i satisface:

$$\hat{\theta}_i = \theta_i + e_i, \quad e_i | \sigma_i^2 \sim \mathcal{N}(0, \sigma_i^2)$$

donde σ_i^2 se supone conocido, y el modelo de enlace conecta θ_i con las covariables auxiliares:

$$\theta_i = \mathbf{x}_i^\top \beta + u_i, \quad u_i \sim \mathcal{N}(0, \sigma_u^2)$$

Modelos a nivel de unidad. Estos modelos incorporan información a nivel de observación individual. El modelo de Battese-Harter-Fuller es el referente en este caso, y permite explotar la variabilidad dentro de los dominios para mejorar la estimación.

En el contexto de la estimación de conteos poblacionales censales, los modelos más apropiados son generalmente de nivel de área, dado que la información disponible suele estar agregada a nivel de segmento. La extensión bayesiana del modelo de Fay-Herriot para conteos —utilizando distribuciones de Poisson o binomial negativa en lugar de la distribución normal— constituye la base de los modelos desarrollados en los capítulos siguientes.

Una diferencia importante entre el enfoque SAE clásico y el bayesiano reside en el tratamiento de los hiperparámetros del modelo, como la varianza de los efectos aleatorios σ_u^2 . En el enfoque frecuentista, estos se estiman mediante máxima verosimilitud restringida (REML). En el enfoque bayesiano, se les asigna una distribución a priori y se estiman conjuntamente con los demás parámetros, lo que permite propagar su incertidumbre hacia las estimaciones finales.

2.2 Identificación de fuentes

La calidad de los modelos bayesianos de estimación subnacional depende críticamente de la disponibilidad y pertinencia de las fuentes de información auxiliar incorporadas. En América Latina y el Caribe, el conjunto de fuentes disponibles varía considerablemente entre países, pero puede organizarse en cuatro categorías principales: medición de cobertura censal, preconteos operativos, registros administrativos y fuentes satelitales.

2.2.1 Medición de cobertura a nivel de segmento

La cobertura censal es el primer elemento que debe caracterizarse antes de iniciar cualquier proceso de estimación subnacional. La cobertura hace referencia a la proporción de la población real que fue efectivamente enumerada durante el operativo censal. Su complemento —la tasa de omisión censal— cuantifica la fracción de la población no observada.

Formalmente, sea N_i la población verdadera del segmento i y $Y_i^{(C)}$ el conteo observado durante el censo. La tasa de cobertura del segmento se define como:

$$c_i = \frac{Y_i^{(C)}}{N_i}$$

y la tasa de omisión correspondiente como $\omega_i = 1 - c_i$. Dado que N_i no es directamente observable, la estimación de c_i requiere el uso de métodos indirectos o información auxiliar.

En la práctica, la medición de cobertura a nivel de segmento se realiza a través de tres mecanismos principales. El primero consiste en encuestas postcensales de cobertura, diseñadas específicamente para estimar la tasa de omisión mediante una operación de campo independiente al censo. El segundo utiliza métodos de conciliación demográfica que comparan los conteos censales con proyecciones independientes basadas en estadísticas vitales. El tercero emplea técnicas de captura-recaptura que cruzan el padrón censal con registros administrativos para estimar la población no observada.

La heterogeneidad espacial de la cobertura censal es una característica sistemática en todos los países de la región. La cobertura tiende a ser menor en áreas rurales dispersas, asentamientos informales, zonas de difícil acceso, territorios indígenas y contextos urbanos con alta movilidad residencial. Esta heterogeneidad espacial

motiva la necesidad de modelar la tasa de cobertura como una función de características territoriales observables.

Bajo el marco bayesiano, la cobertura del segmento puede modelarse como un parámetro latente con distribución a priori que refleje el conocimiento previo sobre su variabilidad entre segmentos. La incorporación de covariables territoriales como predictores de la cobertura permite que el modelo utilice la información disponible para estimar la omisión diferencial entre dominios.

2.2.2 Preconteos y segmentación

Los preconteos operativos constituyen una de las fuentes auxiliares más directamente vinculadas a la estimación de la población en segmentos censales. Estas operaciones, realizadas durante la fase de actualización cartográfica previa al levantamiento censal, producen información sobre el número aproximado de viviendas o estructuras habitacionales presentes en cada unidad operativa.

La segmentación censal es el proceso mediante el cual el territorio nacional se divide en unidades operativas de trabajo, denominadas segmentos o áreas de enumeración. Cada segmento es asignado a un censista y está diseñado para ser enumerable en el tiempo operativo disponible. Los criterios de segmentación varían entre países: algunos utilizan como criterio el número esperado de viviendas, otros priorizan continuidad espacial o accesibilidad geográfica.

Sea P_i el preconteo de viviendas registrado en el segmento i durante la actualización cartográfica. La relación entre el preconteo y la población esperada puede expresarse mediante un modelo de regresión log-lineal:

$$\log(N_i) = \alpha_0 + \alpha_1 \log(P_i) + \eta_i$$

donde α_0 y α_1 son parámetros a estimar y η_i es un error residual que captura la variabilidad no explicada por el preconteo. El parámetro α_1 puede interpretarse como la elasticidad de la población respecto al preconteo: si $\alpha_1 = 1$, la relación entre viviendas y personas es proporcional; si $\alpha_1 > 1$, segmentos con más viviendas tienen mayor tamaño medio de hogar.

El preconteo es especialmente valioso en contextos donde el operativo censal no logró cobertura completa, dado que provee una señal anticipada sobre la magnitud poblacional esperada que es independiente del proceso de enumeración. Su principal limitación es la distancia temporal entre la actualización cartográfica y el momento censal: en contextos con crecimiento urbano acelerado, los preconteos pueden quedar desactualizados rápidamente.

2.2.3 Registros administrativos (variables proxy)

Los registros administrativos son bases de datos generadas por entidades gubernamentales como resultado de sus funciones institucionales. A diferencia de los censos, no tienen por objetivo la medición estadística de la población, sino la gestión de servicios, beneficios o trámites administrativos. Sin embargo, en la medida en que su cobertura es razonablemente alta y su definición territorial compatible con los segmentos censales, pueden utilizarse como variables proxy de la magnitud poblacional.

Entre los registros administrativos más utilizados en modelos de estimación subnacional en América Latina y el Caribe se encuentran:

Registros civiles. Los sistemas de registro de nacimientos, defunciones y matrimonios proporcionan información sobre eventos demográficos ocurridos en el territorio. La densidad de nacimientos o defunciones por unidad territorial es un indicador parcial de la magnitud y composición de la población subyacente.

Padrones electorales. Los padrones de electores habilitados para votar proporcionan un conteo de personas adultas registradas con dirección conocida en cada territorio. Su cobertura está condicionada por la participación en el sistema electoral y puede ser incompleta en poblaciones jóvenes, migrantes o con baja interacción institucional.

Registros de afiliación a sistemas de salud y seguridad social. Los sistemas de salud pública o los registros de afiliación a la seguridad social contienen información sobre personas que acceden regularmente a servicios institucionales. Su cobertura depende del grado de formalidad laboral y del acceso efectivo a los servicios en cada territorio.

Registros de beneficiarios de programas sociales. Los padrones de beneficiarios de programas de transferencias condicionadas u otros programas sociales focalizados proporcionan información sobre hogares en situación de vulnerabilidad. Aunque su cobertura no es universal, pueden ser especialmente informativos en áreas con alta concentración de población en condición de pobreza.

Sea $A_{i,r}$ el conteo proveniente del registro r para el segmento i . Su uso como variable explicativa en el modelo de estimación se justifica por la correlación esperada con la población subyacente N_i :

$$A_{i,r} \approx c_{i,r} \cdot N_i$$

donde $c_{i,r} \in (0, 1]$ es la tasa de cobertura del registro r en el segmento i . La transformación logarítmica $\log(A_{i,r} + 1)$ estabiliza la varianza y facilita la incorporación de estos conteos como predictores en el modelo log-lineal.

2.2.4 Fuentes satelitales

Las imágenes satelitales y los productos de percepción remota han ampliado considerablemente el conjunto de covariables disponibles para la estimación poblacional subnacional. Su principal ventaja es la cobertura territorial universal, la continuidad temporal y la independencia respecto a los sistemas estadísticos institucionales.

Las fuentes satelitales más utilizadas en estimación poblacional pueden agruparse en las siguientes categorías:

Luminosidad nocturna. Los datos de radiance nocturna capturados por sensores satelitales, como el producto VIIRS-DNB de la NOAA, permiten identificar áreas con presencia de iluminación artificial. La intensidad lumínica nocturna está correlacionada con la actividad económica y la densidad de asentamientos humanos permanentes. Sea L_i el valor medio de luminosidad nocturna en el segmento i ; su transformación logarítmica $\log(L_i + 1)$ es utilizada frecuentemente como predictor de la población.

Área construida y cobertura urbana. Los productos de clasificación de uso del suelo derivados de imágenes ópticas como Sentinel-2 o Landsat permiten estimar la proporción de área construida dentro de cada segmento. El producto Global Human Settlement Layer (GHSL) de la Comisión Europea ofrece estimaciones de área construida a resolución de 100 metros con cobertura global.

Índice de vegetación de diferencia normalizada (NDVI). El NDVI mide la densidad y vitalidad de la vegetación a partir de la reflectancia en bandas del infrarrojo cercano y el rojo visible. Valores bajos de NDVI en áreas

no áridas generalmente indican presencia de infraestructura construida y asentamientos urbanos, mientras que valores altos corresponden a áreas con cobertura vegetal densa.

Temperatura superficial terrestre (LST). Las islas de calor urbano, reflejadas en valores elevados de temperatura superficial, constituyen un indicador indirecto de densidad de infraestructura y actividad humana.

Modelos digitales de elevación. La topografía del terreno condiciona la distribución espacial de la población. Los modelos de elevación digital como SRTM o ALOS permiten derivar variables como altitud media, pendiente y orientación del terreno, que están correlacionadas con la densidad y distribución de los asentamientos humanos.

La integración de covariables satelitales en el modelo requiere procesar las imágenes hasta el nivel del segmento censal, lo que implica operaciones de reproyección, remuestreo y estadísticas zonales. La resolución espacial de las imágenes debe ser compatible con el tamaño de los segmentos: resoluciones muy gruesas pueden introducir errores de asignación en segmentos pequeños, mientras que resoluciones muy finas pueden aumentar el costo computacional sin beneficio estadístico apreciable.

2.3 Variables explicativas

La calidad predictiva del modelo de estimación subnacional depende directamente de la selección y construcción de las variables explicativas incorporadas como covariables. Estas variables pueden organizarse en tres grandes grupos según su naturaleza conceptual: variables demográficas, variables socioeconómicas y variables espaciales.

2.3.1 Variables demográficas

Las variables demográficas capturan características de la estructura y dinámica de la población que están directamente relacionadas con la magnitud y distribución de los conteos en cada segmento.

Estructura por sexo y edad. La composición demográfica de la población condiciona la demanda de servicios y la organización territorial de los asentamientos. La proporción de población en edades productivas (15–64 años), la proporción de adultos mayores (65 años y más) y la proporción de niños menores de 15 años son indicadores relevantes de la estructura etaria del segmento. Formalmente:

$$p_{i,[a,b]} = \frac{N_{i,[a,b]}}{N_i}, \quad \sum_e p_{i,e} = 1$$

Razón de masculinidad. La distribución por sexo puede ser informativa en contextos con migración diferencial o actividades económicas con sesgo de género. La razón de masculinidad $RM_i = N_{i,M}/N_{i,F} \times 100$ puede utilizarse como predictor complementario.

Tasa de fecundidad implícita. En territorios con registros de nacimientos disponibles, la relación entre nacimientos registrados y población femenina en edad reproductiva proporciona una estimación indirecta de la dinámica de crecimiento natural del segmento.

Tamaño medio del hogar. El número promedio de personas por vivienda constituye un multiplicador fundamental en la relación entre el preconteo de viviendas y la estimación de personas. En América Latina y el

Caribe, el tamaño medio del hogar presenta heterogeneidad territorial significativa, con valores más altos en áreas rurales y en hogares con mayor número de hijos.

2.3.2 Variables socioeconómicas

Las condiciones socioeconómicas del territorio están correlacionadas con la densidad de población, la calidad de la enumeración censal y la cobertura de los registros administrativos. Su incorporación como covariables permite al modelo capturar parte de la heterogeneidad no observada entre segmentos.

Índice de necesidades básicas insatisfechas (NBI). El NBI resume un conjunto de carencias básicas del hogar —acceso a agua potable, saneamiento, educación, hacinamiento, calidad de la vivienda— en un indicador sintético de pobreza estructural. Territorios con altos niveles de NBI suelen presentar mayor omisión censal y menor cobertura de registros administrativos.

Indicadores de acceso a servicios. La proporción de hogares con acceso a servicios públicos como electricidad, agua potable, alcantarillado o internet está correlacionada tanto con la densidad poblacional como con la cobertura censal. El acceso a servicios refleja el nivel de integración del territorio a la infraestructura formal del Estado.

Nivel educativo de la población. El nivel de instrucción promedio de la población adulta del segmento, derivado de censos anteriores o de registros de matrícula escolar, puede utilizarse como indicador proxy de características socioeconómicas del territorio.

Actividad económica predominante. La clasificación del segmento según la actividad económica predominante —agropecuaria, industrial, comercial, servicios— condiciona la estructura demográfica esperada y los patrones de movilidad residencial. Esta clasificación puede derivarse de cartografía censal o de imágenes satelitales.

2.3.3 Variables espaciales

Las variables espaciales capturan la posición geográfica del segmento y sus relaciones de vecindad con el entorno territorial. Su incorporación permite al modelo explotar la continuidad espacial de la distribución poblacional y modelar explícitamente la dependencia entre segmentos geográficamente cercanos.

Distancia a centros urbanos. La distancia euclidiana o por red vial desde el centroide del segmento hasta el centro urbano más cercano es un predictor relevante de la densidad y tipo de asentamiento. Segmentos más próximos a centros urbanos tienden a presentar mayor densidad poblacional, mayor acceso a servicios y mayor cobertura de registros administrativos.

Accesibilidad y tiempos de desplazamiento. El tiempo de desplazamiento por carretera hasta el centro urbano o el hospital más cercano, derivado de modelos de redes viales, es un indicador de accesibilidad territorial con mayor valor predictivo que la distancia euclidiana en contextos con topografía compleja o infraestructura vial deficiente.

Altitud y topografía. La altitud media del segmento, la pendiente del terreno y la variabilidad topográfica interna condicionan la viabilidad de asentamientos humanos y la densidad de población esperable. Las variables topográficas derivadas de modelos digitales de elevación son especialmente relevantes en países con territorios montañosos.

Efectos espaciales aleatorios. Más allá de las covariables observadas, la distribución espacial de la población presenta autocorrelación espacial que puede ser capturada mediante efectos aleatorios estructurados. Los modelos de efectos espaciales, como el modelo condicional autorregresivo (CAR), permiten modelar explícitamente la dependencia entre segmentos vecinos:

$$u_i \mid \mathbf{u}_{-i} \sim \mathcal{N}\left(\frac{\sum_{j \sim i} u_j}{n_i}, \frac{\sigma_u^2}{n_i}\right)$$

donde la notación $j \sim i$ indica que el segmento j es vecino del segmento i y n_i es el número de vecinos. Este modelo impone que el efecto aleatorio de cada segmento sea similar al promedio de sus vecinos, reflejando la continuidad espacial de las características no observadas que determinan la densidad poblacional.

La selección final del conjunto de variables explicativas debe fundamentarse en criterios de disponibilidad territorial —las variables deben estar disponibles para todos los segmentos—, pertinencia conceptual, capacidad predictiva demostrada y ausencia de multicolinealidad severa entre predictores. Los capítulos siguientes presentan la especificación formal de los modelos que integran estas variables en un esquema bayesiano jerárquico orientado a la estimación de conteos poblacionales subnacionales.

Preparación de Imágenes Satelitales

- 3.1 Fuentes de datos satelitales (Landsat, Sentinel, MODIS)**
- 3.2 Preprocesamiento y correcciones atmosféricas**
- 3.3 Extracción de características (NDVI, índices espectrales)**
- 3.4 Validación con datos de campo**
- 3.5 Generación de capas para el modelo**

Preparación de Insumos para Modelamiento

La construcción de un modelo bayesiano de estimación subnacional requiere, como condición previa, disponer de un conjunto de insumos analíticos preparados con criterios estadísticos explícitos y documentados. La calidad de las estimaciones finales depende no solo de la sofisticación del modelo, sino fundamentalmente de la coherencia, completitud y representatividad de los datos que lo alimentan.

Este capítulo describe el proceso de preparación de insumos en cuatro etapas secuenciales: la estandarización de las fuentes de información, la evaluación de cobertura por segmento, la construcción de la variable dependiente y el diagnóstico exploratorio de los datos. Cada etapa introduce operaciones estadísticas específicas cuya omisión puede comprometer la validez de las inferencias posteriores.

4.1 Estandarización de fuentes

Las fuentes de información descritas en el capítulo anterior provienen de sistemas institucionales con distintas definiciones operativas, unidades de medida, fechas de referencia y marcos territoriales. Su incorporación conjunta en un modelo estadístico exige un proceso previo de estandarización que garantice la comparabilidad entre fuentes y la compatibilidad con los dominios de estimación definidos.

4.1.1 Homologación de variables

La homologación consiste en establecer correspondencias semánticas y operativas entre variables provenientes de distintas fuentes que miden conceptos equivalentes o relacionados bajo definiciones diferentes. Este proceso es necesario porque los sistemas administrativos, los registros satelitales y los datos censales utilizan nomenclaturas, clasificaciones y criterios de asignación territorial que no siempre son directamente comparables.

Compatibilización de marcos territoriales. El primer paso en la homologación es garantizar que todas las fuentes estén referenciadas al mismo marco geográfico. En América Latina y el Caribe, los distintos registros administrativos suelen estar organizados por municipios, provincias o códigos postales que no coinciden directamente con los segmentos censales. Sea $\mathcal{S} = \{1, 2, \dots, I\}$ el conjunto de segmentos del operativo censal y $\mathcal{U} = \{1, 2, \dots, J\}$ las unidades geográficas del registro administrativo. La asignación de cada registro al segmento correspondiente requiere construir una función de mapeo $\phi : \mathcal{U} \rightarrow \mathcal{S}$ basada en la intersección espacial entre las geometrías de ambos marcos.

Cuando las unidades del registro son más grandes que los segmentos censales, la desagregación territorial se realiza mediante ponderación por área o por densidad de viviendas. Si la unidad administrativa j contiene m_{ij} segmentos, la estimación del conteo administrativo para el segmento i se obtiene como:

$$\hat{A}_i = A_j \cdot \frac{w_{ij}}{\sum_{k: k \subset j} w_{kj}}$$

donde A_j es el conteo total del registro en la unidad j y w_{ij} es el peso asignado al segmento i dentro de la unidad j , que puede ser proporcional al área, al número de viviendas del preconteo o a la población proyectada.

Homologación de definiciones de población. Las distintas fuentes pueden diferir en la definición de la unidad de observación. Los censos cuentan personas según residencia habitual o presencia en el momento censal, los padrones electorales registran ciudadanos habilitados para votar, los sistemas de salud registran afiliados activos y los registros civiles registran eventos vitales. La homologación requiere documentar explícitamente estas diferencias y construir factores de ajuste que permitan aproximar cada fuente a la definición censal de referencia.

Compatibilización temporal. Las fuentes de información tienen distintas fechas de referencia. El preconteo puede haberse realizado entre seis y dieciocho meses antes del momento censal. Los registros administrativos corresponden al cierre de un ejercicio fiscal o al corte de un padrón en una fecha específica. Las imágenes satelitales capturan el territorio en distintos momentos a lo largo del año. La compatibilización temporal consiste en seleccionar o construir versiones de cada fuente que sean lo más próximas posible al momento censal de referencia, documentando el desfase temporal residual como fuente de incertidumbre adicional.

4.1.2 Normalización de variables

Una vez homologadas, las variables auxiliares presentan distribuciones con escalas y dispersiones heterogéneas que dificultan la estimación numérica de los coeficientes y la interpretación comparada de los efectos. La normalización transforma las variables a una escala común que facilita la estimación y mejora el comportamiento computacional de los algoritmos de inferencia.

Estandarización por media y desviación estándar. Para una variable continua $x_{i,k}$ medida en el segmento i , la estandarización produce:

$$\tilde{x}_{i,k} = \frac{x_{i,k} - \bar{x}_k}{s_k}$$

donde $\bar{x}_k = \frac{1}{I} \sum_{i=1}^I x_{i,k}$ es la media y $s_k = \sqrt{\frac{1}{I-1} \sum_{i=1}^I (x_{i,k} - \bar{x}_k)^2}$ es la desviación estándar de la variable calculadas sobre todos los segmentos. Bajo esta transformación, $\tilde{x}_{i,k}$ tiene media cero y desviación estándar uno, y el coeficiente β_k se interpreta como el cambio esperado en el logaritmo de la población por unidad de desviación estándar en la covariable k .

Transformación logarítmica. Las variables de conteo y magnitud —número de viviendas, conteos de registros administrativos, áreas construidas— presentan distribuciones fuertemente asimétricas con cola derecha pesada. La transformación logarítmica reduce la asimetría y aproxima la distribución a la normalidad:

$$\tilde{x}_{i,k} = \log(x_{i,k} + 1)$$

La constante +1 garantiza que la transformación esté definida para valores cero, lo cual es frecuente en covariables de conteo en segmentos con baja densidad poblacional.

Normalización al intervalo unitario. Para variables que representan proporciones o índices con interpretación intrínseca en el rango $[0, 1]$, como tasas de cobertura o índices de vegetación, puede ser preferible la normalización min-max:

$$\tilde{x}_{i,k} = \frac{x_{i,k} - \min_i(x_{i,k})}{\max_i(x_{i,k}) - \min_i(x_{i,k})}$$

Esta transformación preserva la interpretación original de la variable y facilita la especificación de distribuciones a priori informativas sobre los coeficientes.

Tratamiento de valores faltantes. La presencia de valores faltantes en las covariables auxiliares debe ser resuelta antes de la estimación. Las estrategias más comunes incluyen la imputación por la mediana o la media del grupo territorial al que pertenece el segmento, la imputación mediante modelos de regresión utilizando covariables con cobertura completa, y la imputación múltiple para propagar la incertidumbre asociada a los valores faltantes hacia las estimaciones finales.

4.2 Evaluación de cobertura

La evaluación de cobertura censal por segmento es un paso crítico previo a la estimación. Permite identificar los dominios con información deficiente, cuantificar el grado de omisión territorial y establecer una clasificación de los segmentos que oriente las decisiones de modelamiento.

4.2.1 Tasa de cobertura por segmento

La tasa de cobertura de un segmento censal mide la proporción de la población verdadera que fue efectivamente enumerada durante el operativo. Dado que la población verdadera N_i no es directamente observable, la estimación de la tasa de cobertura requiere una referencia externa independiente del conteo censal.

Sea R_i una estimación de referencia de la población del segmento i obtenida a partir de una fuente auxiliar confiable, como un preconteo operativo ajustado o una proyección demográfica intercensal. La tasa de cobertura estimada para el segmento i se define como:

$$\hat{c}_i = \frac{Y_i^{(C)}}{R_i}$$

donde $Y_i^{(C)}$ es el conteo censal observado en el segmento. Un valor $\hat{c}_i < 1$ indica subcobertura —el operativo no logró enumerar toda la población de referencia— mientras que $\hat{c}_i > 1$ puede indicar sobrecobertura, duplicación de registros o inconsistencias en la referencia utilizada.

En la práctica, la tasa de cobertura puede estimarse también mediante métodos de captura-recaptura cuando se dispone de dos fuentes de información independientes para el mismo segmento. Si $Y_i^{(C)}$ es el conteo censal y A_i es el conteo de un registro administrativo, y si M_i es el número de personas identificadas en ambas fuentes, la estimación de Chapman para la población total es:

$$\hat{N}_i^{CR} = \frac{(Y_i^{(C)} + 1)(A_i + 1)}{M_i + 1} - 1$$

y la tasa de cobertura del censo respecto a esta estimación:

$$\hat{c}_i^{CR} = \frac{Y_i^{(C)}}{\hat{N}_i^{CR}}$$

Este estimador requiere el supuesto de independencia entre ambas fuentes, condición que puede ser violada cuando la propensión a ser registrado en el censo y en el registro administrativo están correlacionadas con características del individuo o del territorio.

La distribución de las tasas de cobertura entre segmentos permite identificar patrones espaciales de omisión diferencial. El coeficiente de variación de $\hat{c}_i$ entre segmentos es un indicador de la heterogeneidad territorial de la cobertura. Valores elevados de este coeficiente indican que la omisión censal no es aleatoria y que un modelo que ignore esta heterogeneidad producirá estimaciones sesgadas.

4.2.2 Clasificación de segmentos

La clasificación de los segmentos según su nivel de cobertura permite diseñar estrategias diferenciadas de estimación y validación. Una tipología operativa agrupa los segmentos en tres categorías:

Segmentos con cobertura aceptable ($\hat{c}_i \geq c^*$): el conteo censal observado es suficientemente representativo de la población subyacente y puede utilizarse como variable dependiente del modelo sin ajuste previo. El umbral c^* se fija típicamente entre 0.85 y 0.95, dependiendo de los estándares de calidad del sistema estadístico.

Segmentos con cobertura parcial ($c_{**} \leq \hat{c}_i < c^*$): el conteo censal presenta omisión detectable pero el segmento fue efectivamente enumerado. Estos segmentos ingresan al modelo con un peso reducido o con un indicador de calidad que refleja la mayor incertidumbre de su conteo. El umbral inferior c_{**} se sitúa típicamente entre 0.60 y 0.75.

Segmentos con cobertura insuficiente ($\hat{c}_i < c_{**}$): el operativo censal no alcanzó una enumeración mínimamente representativa. Estos segmentos son tratados como dominios sin información propia y su estimación depende enteramente de las covariables auxiliares y de la estructura jerárquica del modelo.

Formalmente, la clasificación puede expresarse mediante la variable indicadora:

$$\kappa_i = \begin{cases} 2 & \text{si } \hat{c}_i \geq c^* \\ 1 & \text{si } c_{**} \leq \hat{c}_i < c^* \\ 0 & \text{si } \hat{c}_i < c_{**} \end{cases}$$

Esta clasificación se incorpora al modelo mediante pesos de verosimilitud o mediante la especificación diferenciada de la varianza del error de medición según la categoría del segmento.

4.3 Construcción de la variable dependiente

La variable dependiente del modelo de estimación subnacional es el conteo poblacional que se desea estimar en cada segmento. Su construcción no es un proceso trivial: requiere decisiones explícitas sobre la agregación de categorías, las transformaciones aplicadas y la definición de la población de referencia.

4.3.1 Conteos agregados

El conteo agregado para el segmento i se construye sumando los conteos censales observados sobre los grupos de sexo y edad de interés. Sea $Y_{i,s,e}^{(C)}$ el conteo censal del segmento i , sexo s y grupo de edad e . El conteo total del segmento es:

$$Y_i = \sum_{s \in \{M,F\}} \sum_{e=1}^E Y_{i,s,e}^{(C)}$$

Cuando el objetivo es estimar conteos desagregados por sexo o grupo etario, la variable dependiente se construye para cada celda demográfica de interés:

$$Y_{i,s,e} = Y_{i,s,e}^{(C)}, \quad s \in \{M,F\}, \quad e = 1, \dots, E$$

y el modelo se estima de forma separada para cada celda o mediante un modelo conjunto que impone coherencia entre celdas a través de una estructura jerárquica compartida.

La decisión sobre el nivel de desagregación de la variable dependiente tiene implicaciones directas sobre el tamaño del problema de estimación y la disponibilidad de información. A mayor desagregación, mayor es el número de celdas con conteos pequeños o nulos, lo que incrementa la dependencia del modelo respecto a las covariables auxiliares y a la estructura jerárquica.

4.3.2 Tasas poblacionales

En algunos contextos, la variable de interés no es el conteo absoluto sino una tasa relativa que expresa la magnitud de un subgrupo poblacional como proporción del total. Sea $Y_i^{(g)}$ el conteo del grupo de interés g en el segmento i y Y_i el total del segmento. La tasa poblacional se define como:

$$\pi_i^{(g)} = \frac{Y_i^{(g)}}{Y_i}$$

Las tasas poblacionales son especialmente relevantes cuando el objetivo es comparar la composición demográfica entre segmentos con magnitudes poblacionales muy distintas. Sin embargo, en dominios con conteos pequeños, las tasas presentan elevada variabilidad aleatoria que puede distorsionar la comparación territorial.

El modelamiento de tasas en el contexto bayesiano utiliza frecuentemente la distribución beta como modelo para la variable dependiente cuando $\pi_i^{(g)} \in (0, 1)$, o modelos binomiales cuando se dispone del denominador exacto:

$$Y_i^{(g)} \mid \pi_i^{(g)}, Y_i \sim \text{Binomial}(Y_i, \pi_i^{(g)})$$

4.3.3 Transformaciones

Las transformaciones de la variable dependiente buscan estabilizar la varianza, aproximar la distribución a la normalidad o linealizar la relación entre la variable de respuesta y los predictores. En el contexto de conteos poblacionales, las transformaciones más utilizadas son las siguientes.

Transformación logarítmica. La transformación $\log(Y_i + 1)$ es la más frecuentemente utilizada en modelos log-lineales de conteo. Estabiliza la varianza en distribuciones de Poisson y permite interpretar los efectos de las covariables en términos de cambios porcentuales en la población esperada.

Transformación raíz cuadrada. La transformación $\sqrt{Y_i}$ tiene la propiedad de estabilizar la varianza en distribuciones de Poisson, dado que $\text{Var}(\sqrt{Y_i}) \approx 1/4$ cuando λ_i es grande. Es menos utilizada que la logarítmica pero puede ser apropiada cuando los conteos son muy pequeños y la transformación logarítmica introduce distorsiones.

Transformación de potencia de Box-Cox. Para una búsqueda más sistemática de la transformación estabilizadora de varianza, la familia de transformaciones de Box-Cox parametriza el tipo de transformación mediante un parámetro λ_{BC} :

$$Y_i^{(\lambda_{BC})} = \begin{cases} \frac{Y_i^{\lambda_{BC}} - 1}{\lambda_{BC}} & \text{si } \lambda_{BC} \neq 0 \\ \log(Y_i) & \text{si } \lambda_{BC} = 0 \end{cases}$$

El parámetro λ_{BC} puede estimarse por máxima verosimilitud como parte del proceso de especificación del modelo. Los valores $\lambda_{BC} = 0$ (logarítmica) y $\lambda_{BC} = 0.5$ (raíz cuadrada) son los más frecuentes en la práctica.

4.3.4 Definición de población base

La población base define el universo de referencia sobre el cual se construye el conteo de interés. Su especificación correcta es fundamental para garantizar la comparabilidad entre segmentos y la coherencia con los totales de niveles superiores.

La definición de población base más común en censos de población es la población residente habitual: el conjunto de personas cuya residencia principal está localizada en el segmento en el momento del censo. Sin embargo, algunos censos implementan el criterio de población de hecho, que contabiliza a las personas presentes en el segmento durante el momento censal, independientemente de su residencia habitual.

Formalmente, la población base $\mathcal{P}_i$ del segmento i puede definirse bajo distintos criterios:

- **Población residente:** $\mathcal{P}_i = \{j : \text{residencia habitual de } j \text{ está en } i\}$
- **Población de hecho:** $\mathcal{P}_i = \{j : j \text{ está físicamente presente en } i \text{ en el momento censal}\}$
- **Población en hogares particulares:** excluye a las personas en colectividades institucionales (hospitales, cárceles, cuarteles).
- **Población civil:** excluye adicionalmente al personal militar.

La elección de la población base afecta la coherencia de los conteos en territorios con alta movilidad diurna, presencia de instituciones totales o frontera entre áreas urbanas y rurales. El modelo de estimación debe adoptarse para la misma definición de población base utilizada en el operativo censal.

4.3.5 Escalamiento

El escalamiento de los conteos es necesario cuando se trabaja simultáneamente con segmentos de tamaño muy heterogéneo o cuando se requiere comparar estimaciones entre países o periodos censales con distintas magnitudes poblacionales.

El escalamiento por tamaño esperado utiliza una referencia R_i para expresar el conteo observado como una proporción de la población esperada:

$$z_i = \frac{Y_i}{R_i}$$

donde R_i puede ser el preconteo ajustado, la proyección demográfica intercensal u otro estimador de referencia. La variable escalada z_i puede interpretarse como un factor de cobertura relativa y tiene la ventaja de reducir la dependencia del modelo respecto al tamaño absoluto de cada segmento.

El escalamiento por exposición es especialmente útil cuando la variable dependiente representa un conteo sobre un denominador que varía entre segmentos. En el modelo de Poisson, esta escala se incorpora mediante el término de offset:

$$\log(\lambda_i) = \log(R_i) + \mathbf{x}_i^\top \beta + u_i$$

donde $\log(R_i)$ es el offset —una constante conocida que ajusta la intensidad esperada por el tamaño de la exposición del segmento— y los coeficientes β se interpretan como efectos sobre la tasa por unidad de exposición.

4.4 Diagnóstico exploratorio

Antes de ajustar el modelo bayesiano, es indispensable realizar un análisis exploratorio sistemático de los datos preparados. Este diagnóstico permite verificar la coherencia interna de los insumos, identificar observaciones atípicas, evaluar la capacidad predictiva de las covariables y detectar posibles violaciones de los supuestos del modelo.

4.4.1 Distribución de conteos

El análisis de la distribución de los conteos observados Y_i permite caracterizar la variabilidad entre segmentos y evaluar la adecuación de las familias distribucionales consideradas para el modelamiento.

Los estadísticos descriptivos básicos —media, mediana, desviación estándar, coeficientes de asimetría y curtosis— proveen una caracterización inicial de la distribución. La comparación entre la media y la varianza muestral:

$$\bar{Y} = \frac{1}{I} \sum_{i=1}^I Y_i, \quad S_Y^2 = \frac{1}{I-1} \sum_{i=1}^I (Y_i - \bar{Y})^2$$

ofrece un diagnóstico informal de sobredispersión: si $S_Y^2 \gg \bar{Y}$, la distribución de Poisson puede ser insuficiente y el modelo binomial negativo resulta más apropiado. El índice de dispersión $D = S_Y^2 / \bar{Y}$ cuantifica el grado de sobredispersión; valores superiores a 1.5 o 2 suelen justificar el uso de modelos más flexibles.

```
resumen_conteos <- data.frame(
  n_segmentos = length(Y),
  media       = mean(Y),
```

```

    mediana      = median(Y),
    desv_est     = sd(Y),
    asimetria    = moments::skewness(Y),
    curtosis     = moments::kurtosis(Y),
    indice_disp  = var(Y) / mean(Y)
  )

  hist(log(Y + 1),
       breaks = 40,
       main   = "Distribución de log(Y + 1) por segmento",
       xlab   = "log(conteo + 1)",
       col    = "#CBD5E1",
       border  = "white")

```

La visualización de la distribución debe realizarse tanto en escala original como en escala logarítmica. En la escala original, la distribución suele ser fuertemente asimétrica con cola derecha pesada; en la escala logarítmica, la distribución es más simétrica y permite evaluar si la especificación log-lineal es adecuada.

La proporción de ceros en los conteos es otro indicador relevante. Un exceso de ceros respecto a lo esperado bajo el modelo de Poisson puede indicar la presencia de segmentos genuinamente deshabitados, problemas de cobertura en áreas con baja densidad, o la necesidad de incorporar un componente de inflación de ceros en el modelo.

4.4.2 Outliers

La identificación de observaciones atípicas en los conteos y en las covariables auxiliares es fundamental para evitar que estas observaciones dominen la estimación de los parámetros del modelo. En el contexto de datos de conteo, los outliers pueden manifestarse como valores excepcionalmente altos o bajos en relación con la tendencia general de los datos, o como combinaciones inusuales de conteo y covariables.

Detección basada en residuos del modelo nulo. Un modelo de regresión de Poisson sin covariables permite obtener residuos de Pearson para cada segmento:

$$r_i^P = \frac{Y_i - \hat{\lambda}_i}{\sqrt{\hat{\lambda}_i}}$$

donde $\hat{\lambda}_i = \exp(\hat{\alpha})$ con $\hat{\alpha} = \log(\bar{Y})$. Segmentos con $|r_i^P| > 3$ son candidatos a revisión como observaciones atípicas.

Detección basada en la distancia de Cook. En el modelo log-lineal con covariables, la distancia de Cook D_i cuantifica la influencia del segmento i sobre el vector de coeficientes estimados. Valores elevados de D_i indican que la exclusión del segmento i modificaría sustancialmente los coeficientes del modelo.

Detección multivariada. Las observaciones atípicas en el espacio de covariables pueden identificarse mediante la distancia de Mahalanobis:

$$d_i^2 = (\mathbf{x}_i - \bar{\mathbf{x}})^\top \hat{\Sigma}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}})$$

donde $\bar{\mathbf{x}}$ es el vector de medias y $\hat{\Sigma}$ es la matriz de covarianza muestral de las covariables. Bajo normalidad multivariada, $d_i^2 \sim \chi_p^2$, y valores superiores al percentil 97.5 de esta distribución son indicativos de observaciones atípicas en el espacio de covariables.

```
lambda_nulo      <- mean(Y)
residuos_p       <- (Y - lambda_nulo) / sqrt(lambda_nulo)
segmentos_outlier <- which(abs(residuos_p) > 3)

X_mat  <- as.matrix(covariables_std)
d2_mah <- mahalanobis(X_mat, colMeans(X_mat), cov(X_mat))
p_valor <- pchisq(d2_mah, df = ncol(X_mat), lower.tail = FALSE)
outliers_multivariados <- which(p_valor < 0.025)
```

Una vez identificadas, las observaciones atípicas deben revisarse para determinar si corresponden a errores de procesamiento, a características genuinas del territorio o a problemas de cobertura del operativo. La decisión sobre su tratamiento —corrección, exclusión o inclusión con peso reducido— debe documentarse explícitamente.

4.4.3 Relación entre variables

El análisis de la relación entre la variable dependiente y las covariables auxiliares permite evaluar la pertinencia predictiva de cada fuente de información y orientar las decisiones de especificación del modelo.

Correlación con los conteos. La correlación de Pearson entre $\log(Y_i + 1)$ y cada covariable estandarizada $\tilde{x}_{i,k}$ proporciona una medida lineal de la asociación bivariada. Covariables con correlación superior a 0.5 en valor absoluto suelen tener valor predictivo relevante; covariables con correlación inferior a 0.1 pueden ser candidatas a exclusión del modelo.

Diagramas de dispersión. La representación gráfica de $\log(Y_i + 1)$ contra cada covariable permite detectar relaciones no lineales, patrones de heteroscedasticidad y grupos de segmentos con comportamiento diferenciado. La adición de una curva de suavizado no paramétrico (LOESS) facilita la identificación de estructuras no lineales que podrían requerir transformaciones adicionales de las covariables.

Correlación entre covariables. La matriz de correlación entre las covariables auxiliares permite identificar pares con alta colinealidad. Correlaciones superiores a 0.85 en valor absoluto indican que dos covariables aportan información casi redundante. Los factores de inflación de varianza (VIF) son una herramienta complementaria para el diagnóstico de multicolinealidad:

$$\text{VIF}_k = \frac{1}{1 - R_k^2}$$

donde R_k^2 es el coeficiente de determinación obtenido al regresar la covariable k sobre el resto de covariables. Valores de $\text{VIF}_k > 10$ son indicativos de multicolinealidad problemática.

```
library(corrplot)
cor_mat <- cor(cbind(log_Y = log(Y + 1), covariables_std),
               method = "pearson")
```

```
corrplot(cor_mat,
         method = "color",
         type = "upper",
         addCoef.col = "black",
         number.cex = 0.7,
         tl.cex = 0.8)

modelo_ols <- lm(log(Y + 1) ~ ., data = as.data.frame(covariables_std))
car::vif(modelo_ols)
```

Análisis por estrato territorial. La relación entre la variable dependiente y las covariables puede variar entre distintos estratos territoriales —urbano/rural, región geográfica, nivel de cobertura—. La exploración estratificada permite detectar interacciones relevantes que podrían justificar la inclusión de términos de interacción o la estimación diferenciada de coeficientes por grupo.

La documentación sistemática de los resultados del diagnóstico exploratorio es un insumo esencial para la especificación del modelo. Las decisiones sobre transformaciones, exclusión de covariables, tratamiento de outliers y estratificación del análisis deben fundamentarse en este diagnóstico y quedar registradas para garantizar la reproducibilidad y auditabilidad de las estimaciones finales.

Modelo para Conteos Poblacionales

Los capítulos precedentes han establecido el marco conceptual de la estimación subnacional, identificado las fuentes de información disponibles, descrito los procedimientos de preparación de imágenes satelitales y detallado el proceso de construcción de los insumos analíticos. Sobre esta base, el presente capítulo introduce la especificación formal del modelo estadístico que integra dichos elementos bajo un esquema probabilístico coherente, orientado a estimar los conteos de población en segmentos censales con cobertura parcial o incompleta.

La formulación adoptada debe satisfacer los requerimientos establecidos en capítulos anteriores: representar adecuadamente la naturaleza discreta y no negativa de los conteos, incorporar información auxiliar de fuentes heterogéneas, producir estimaciones en dominios sin cobertura directa y cuantificar explícitamente la incertidumbre de los resultados. Frente a estos requerimientos, un modelo de Poisson simple resulta insuficiente cuando los datos exhiben sobredispersión o cuando se dispone de información de referencia sobre el número de estructuras habitacionales en cada segmento. La extensión log-normal del modelo de Poisson, articulada con una estructura jerárquica de efectos aleatorios, responde a estas limitaciones de manera estadísticamente coherente.

El modelo propuesto opera en dos niveles. En el primer nivel, la densidad poblacional —definida como el número de personas por estructura habitacional— se representa mediante una distribución log-normal cuyo parámetro de localización es función lineal de covariables auxiliares y efectos aleatorios territoriales. En el segundo nivel, los conteos de población observados se modelan como realizaciones de una distribución de Poisson cuyo parámetro de intensidad resulta del producto entre la densidad estimada y el número de estructuras en cada segmento. Esta arquitectura de dos etapas constituye el modelo Poisson-lognormal y provee un mecanismo natural de control de la sobredispersión mientras mantiene la interpretabilidad de los parámetros.

La estructura del capítulo se organiza en dos secciones principales. La primera presenta la especificación probabilística completa del modelo: definición formal, función de verosimilitud, distribuciones a priori, distribución posterior e interpretación de parámetros. La segunda describe en detalle los componentes del modelo: efectos fijos, efectos aleatorios, mecanismos de interacción y elementos adicionales como el offset, la sobredispersión y las alternativas distribucionales consideradas en el diseño.

5.1 Modelo Poisson-lognormal

5.1.1 Definición formal

La especificación del modelo parte de dos cantidades fundamentales definidas para cada segmento censal i perteneciente al conjunto $\mathcal{S} = \{1, 2, \dots, D\}$ de todos los segmentos del país. La primera es el conteo de población observado Y_i , disponible únicamente para los segmentos que alcanzaron cobertura efectiva durante el operativo censal. La segunda es el número de estructuras habitacionales V_i , derivado del preconteo operativo o de fuentes satelitales de área construida, y disponible para todos los segmentos del país.

Sea $\mathcal{S}_{obs} \subset \mathcal{S}$ el subconjunto de segmentos con información censal observada, de cardinalidad $D_{obs} = |\mathcal{S}_{obs}|$. El modelo distingue explícitamente entre estos dos conjuntos: los parámetros se estiman a partir de $\mathcal{S}_{obs}$ y se utilizan posteriormente para generar predicciones sobre la totalidad de $\mathcal{S}$, incluyendo los segmentos no observados en el operativo censal.

El elemento central del modelo es la densidad poblacional δ_i , definida como el número esperado de personas por estructura habitacional en el segmento i :

$$\delta_i = \frac{N_i}{V_i}$$

donde N_i denota la población verdadera del segmento, tal como se definió en el capítulo de conceptos generales. Esta cantidad no es directamente observable sino que debe inferirse a partir de la información disponible. La densidad δ_i representa una medida de intensidad específica de ocupación habitacional que permite comparar segmentos con distinto número de estructuras bajo una escala común y facilita la incorporación del número de viviendas como referencia natural del proceso de conteo.

El modelo Poisson-lognormal se formula mediante dos componentes probabilísticos anidados. En el primer nivel, la densidad latente δ_i sigue una distribución log-normal con parámetro de localización μ_i y parámetro de escala σ :

$$\delta_i \mid \mu_i, \sigma \sim \text{LogNormal}(\mu_i, \sigma), \quad i \in \mathcal{S}_{obs}$$

La distribución log-normal garantiza que $\delta_i > 0$ por construcción, lo cual es consistente con la interpretación de δ_i como densidad de personas por estructura. El parámetro μ_i captura la localización de la distribución en escala logarítmica y es modelado como función lineal de las covariables disponibles para el segmento. El parámetro $\sigma > 0$ controla la dispersión de las densidades alrededor de dicha localización.

En el segundo nivel, los conteos de población se modelan como realizaciones de una distribución de Poisson cuyo parámetro de intensidad es el producto entre la densidad estimada y el número de estructuras del segmento:

$$Y_i \mid \delta_i, V_i \sim \text{Poisson}(\lambda_i), \quad \lambda_i = \delta_i \cdot V_i, \quad i \in \mathcal{S}_{obs}$$

Esta parametrización incorpora el número de estructuras V_i como referencia natural de escala. Segmentos con mayor número de estructuras tienen, en igualdad de condiciones, una intensidad esperada proporcionalmente mayor. El parámetro de localización de la densidad sigue un predictor lineal de la forma:

$$\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \mathbf{z}_i^\top \boldsymbol{\gamma}$$

donde $\mathbf{x}_i \in \mathbb{R}^P$ es el vector de covariables auxiliares estandarizadas del segmento i , $\boldsymbol{\beta} \in \mathbb{R}^P$ es el vector de coeficientes de efectos fijos, $\mathbf{z}_i \in \{0, 1\}^Q$ es el vector de indicadores para los efectos aleatorios territoriales y $\boldsymbol{\gamma} \in \mathbb{R}^Q$ es el vector de coeficientes de efectos aleatorios. La dimensión P corresponde al número de covariables auxiliares seleccionadas y Q al número de unidades territoriales de nivel superior —provincias, departamentos o regiones— en las que se anidan los segmentos.

El conjunto de parámetros estructurales del modelo es $\theta = \{\boldsymbol{\beta}, \boldsymbol{\gamma}, \sigma, \sigma_U\}$, donde $\sigma_U > 0$ es el hiperparámetro que controla la variabilidad de los efectos aleatorios, cuya especificación se detalla en la sección de distribuciones a

priori. Adicionalmente, $\delta = \{\delta_i : i \in \mathcal{S}_{obs}\}$ es el vector de densidades latentes para los segmentos observados, que se trata como conjunto de parámetros latentes en la inferencia bayesiana de manera conjunta con θ .

5.1.2 Función de verosimilitud

La función de verosimilitud del modelo Poisson-lognormal se construye sobre la información disponible en los segmentos observados $\mathcal{S}_{obs}$. Dado que las densidades δ_i son tratadas como parámetros latentes, la verosimilitud conjunta factoriza sobre segmentos bajo el supuesto de independencia condicional entre observaciones dado el vector de parámetros θ :

$$p(\mathbf{Y}_{obs}, \delta \mid \theta) = \prod_{i \in \mathcal{S}_{obs}} p(Y_i \mid \delta_i, V_i) \cdot p(\delta_i \mid \mu_i, \sigma)$$

donde $\mathbf{Y}_{obs} = \{Y_i : i \in \mathcal{S}_{obs}\}$ es el vector de conteos observados. Expandiendo cada factor con sus formas funcionales explícitas:

$$p(\mathbf{Y}_{obs}, \delta \mid \theta) = \prod_{i \in \mathcal{S}_{obs}} \frac{e^{-\delta_i V_i} (\delta_i V_i)^{Y_i}}{Y_i!} \cdot \frac{1}{\delta_i \sigma \sqrt{2\pi}} \exp\left(-\frac{(\log \delta_i - \mu_i)^2}{2\sigma^2}\right)$$

La verosimilitud log-conjunta, omitiendo constantes respecto a los parámetros, adopta la forma:

$$\log p(\mathbf{Y}_{obs}, \delta \mid \theta) = \sum_{i \in \mathcal{S}_{obs}} \left[Y_i \log(\delta_i V_i) - \delta_i V_i - \log \delta_i - \frac{(\log \delta_i - \mu_i)^2}{2\sigma^2} - \log \sigma \right]$$

Esta expresión pone de manifiesto la naturaleza jerárquica del modelo: el primer par de términos corresponde a la contribución de la distribución de Poisson para los conteos observados, mientras que los términos restantes corresponden a la contribución de la distribución log-normal para las densidades latentes. El término $-\log \delta_i$ proviene del jacobiano de la densidad log-normal —resultado de la transformación entre la escala multiplicativa de δ_i y la escala logarítmica— y garantiza la corrección del volumen en el cambio de variables. Ambas contribuciones están conectadas a través del parámetro δ_i , cuya estimación equilibra simultáneamente el ajuste a los conteos observados y la regularización impuesta por el modelo de densidad.

Una propiedad relevante de esta formulación es que la distribución marginal de Y_i , obtenida al integrar δ_i de la expresión conjunta, resulta en una mezcla de Poisson con distribución de mezcla log-normal. Esta mezcla genera mayor dispersión que la Poisson pura. Formalmente, si $\delta_i \sim \text{LogNormal}(\mu_i, \sigma)$ y $Y_i \mid \delta_i \sim \text{Poisson}(\delta_i V_i)$, entonces la media y la varianza marginales del conteo son:

$$\mathbb{E}[Y_i] = V_i \exp\left(\mu_i + \frac{\sigma^2}{2}\right)$$

$$\text{Var}(Y_i) = \mathbb{E}[Y_i] + V_i^2 e^{2\mu_i + \sigma^2} (e^{\sigma^2} - 1)$$

Dado que $\text{Var}(Y_i) > \mathbb{E}[Y_i]$ siempre que $\sigma > 0$, el modelo Poisson-lognormal es inherentemente sobredisperso respecto a la distribución de Poisson pura, con el grado de sobredispersión controlado por el parámetro σ . Esta propiedad lo hace apropiado para datos censales donde la varianza observada supera sistemáticamente la esperada bajo el supuesto de equidispersión.

5.1.3 Distribuciones a priori

La especificación bayesiana del modelo requiere asignar distribuciones a priori a todos los parámetros desconocidos. En el contexto del modelo Poisson-lognormal, el conjunto de parámetros a los que se asignan distribuciones a priori incluye los coeficientes de efectos fijos β , los coeficientes de efectos aleatorios γ , el parámetro de escala de la densidad σ y el hiperparámetro de variabilidad de los efectos aleatorios σ_U .

La elección de distribuciones a priori débilmente informativas ofrece un equilibrio entre la ausencia de información fuerte sobre los parámetros y la estabilización del proceso de estimación. Bajo este enfoque, las distribuciones a priori incorporan restricciones de signo y magnitud consistentes con el conocimiento sustantivo del problema sin imponer concentración excesiva sobre valores específicos. Esta estrategia resulta especialmente adecuada en modelos con alta dimensionalidad paramétrica, donde las distribuciones no informativas pueden generar problemas de identificación o inestabilidad en la inferencia.

Para los coeficientes de efectos fijos se adopta una distribución normal centrada en cero con varianza unitaria:

$$\beta_k \sim \mathcal{N}(0, 1), \quad k = 1, \dots, P$$

Esta distribución a priori es apropiada cuando las covariables han sido previamente estandarizadas, de modo que un coeficiente con valor absoluto superior a dos corresponde a un efecto sustancialmente grande en términos de la escala de las covariables. La centrada en cero refleja la ausencia de conocimiento previo sobre la dirección del efecto de cada covariable, mientras que la varianza unitaria actúa como regularización suave que favorece efectos de magnitud moderada.

Para los coeficientes de efectos aleatorios se adopta una distribución normal jerárquica con varianza controlada por el hiperparámetro σ_U :

$$\gamma_j \sim \mathcal{N}(0, \sigma_U^2), \quad j = 1, \dots, Q$$

Esta especificación introduce una estructura de encogimiento sobre los efectos aleatorios: territorios con información escasa son atraídos hacia el promedio global capturado por los efectos fijos, mientras que territorios con información abundante y patrón sistemáticamente distinto pueden mantener efectos locales de mayor magnitud. El grado de encogimiento está regulado por σ_U , que a su vez es un parámetro desconocido al que se asigna una distribución a priori.

Para el hiperparámetro de variabilidad de los efectos aleatorios se adopta una distribución normal positiva:

$$\sigma_U \sim \mathcal{N}^+(0, 1)$$

Esta elección permite que el modelo aprenda la magnitud de la variabilidad territorial a partir de los datos, sin imponer un valor fijo. La distribución normal positiva asigna probabilidad significativa a valores cercanos a cero —compatibles con un modelo sin efectos aleatorios relevantes— mientras permite valores mayores si los datos los respaldan.

Para el parámetro de escala de la densidad se adopta una distribución de Cauchy positiva:

$$\sigma \sim \text{Cauchy}^+(0, 2, 5)$$

La distribución de Cauchy positiva presenta colas más pesadas que la distribución exponencial o que la gamma inversa, lo que permite una amplia dispersión a priori sin concentrar excesiva probabilidad en valores pequeños. Esta propiedad es útil cuando la variabilidad real de las densidades entre segmentos es sustancialmente alta, como suele ocurrir en contextos con marcada heterogeneidad territorial y cobertura censal diferencial.

5.1.4 Distribución posterior

La distribución posterior del modelo Poisson-lognormal combina la verosimilitud conjunta con las distribuciones a priori de todos los parámetros. Aplicando el teorema de Bayes, la distribución posterior conjunta sobre los parámetros estructurales θ y las densidades latentes δ es proporcional al producto de la verosimilitud y las previas:

$$p(\theta, \delta \mid \mathbf{Y}_{obs}) \propto p(\mathbf{Y}_{obs}, \delta \mid \beta, \gamma, \sigma) \cdot p(\gamma \mid \sigma_U) \cdot p(\beta) \cdot p(\sigma) \cdot p(\sigma_U)$$

Expandiendo cada componente con sus formas funcionales específicas:

$$p(\theta, \delta \mid \mathbf{Y}_{obs}) \propto \left[\prod_{i \in \mathcal{S}_{obs}} \text{Poisson}(Y_i \mid \delta_i V_i) \cdot \text{LogNormal}(\delta_i \mid \mu_i, \sigma) \right] \cdot \prod_{j=1}^Q \mathcal{N}(\gamma_j \mid 0, \sigma_U^2) \cdot \prod_{k=1}^P \mathcal{N}(\beta_k \mid 0, 1) \cdot p(\sigma) \cdot p(\sigma_U)$$

La distribución posterior no tiene forma analítica cerrada debido a la combinación de la distribución de Poisson para los conteos y la distribución log-normal para las densidades latentes. En consecuencia, la inferencia se realiza mediante métodos de Monte Carlo por cadenas de Markov (MCMC), específicamente mediante el algoritmo de Monte Carlo Hamiltoniano implementado en Stan, cuya descripción se desarrolla en el capítulo siguiente.

Las cantidades de interés inferencial se derivan directamente de la distribución posterior conjunta $p(\theta, \delta \mid \mathbf{Y}_{obs})$. Para cada segmento $i \in \mathcal{S}_{obs}$, la estimación puntual de la densidad poblacional se obtiene como la media posterior:

$$\hat{\delta}_i = \mathbb{E}[\delta_i \mid \mathbf{Y}_{obs}] \approx \frac{1}{T} \sum_{t=1}^T \delta_i^{(t)}$$

donde $\delta_i^{(1)}, \dots, \delta_i^{(T)}$ son las muestras de la distribución posterior generadas mediante MCMC. Para los segmentos no observados $i \in \mathcal{S} \setminus \mathcal{S}_{obs}$, la predicción se obtiene generando muestras de la distribución predictiva posterior en el bloque de cantidades generadas del modelo:

$$\tilde{\delta}_i^{(t)} \sim \text{LogNormal}(\mu_i^{(t)}, \sigma^{(t)}), \quad \tilde{Y}_i^{(t)} \sim \text{Poisson}(\tilde{\delta}_i^{(t)} \cdot V_i)$$

donde $\mu_i^{(t)} = \mathbf{x}_i^\top \beta^{(t)} + \mathbf{z}_i^\top \gamma^{(t)}$ se evalúa utilizando los parámetros de la muestra t . Esta predicción se realiza sobre la totalidad de $\mathcal{S}$, lo que permite obtener estimaciones de población para todos los segmentos del país, incluidos aquellos sin cobertura censal directa.

La estimación del total de población de un nivel geográfico superior —municipio, departamento o país— se obtiene agregando las distribuciones predictivas posteriores de los segmentos que lo componen. Si $\mathcal{S}_k \subset \mathcal{S}$

denota el conjunto de segmentos del municipio k , el conteo total estimado para ese municipio —denominado nivel 3 en la jerarquía geográfica censal, donde el nivel 1 corresponde al segmento y el nivel 2 a la localidad— es:

$$\hat{N}_k^{(3)} = \sum_{i \in \mathcal{S}_k} \hat{N}_i, \quad \hat{N}_i = \begin{cases} Y_i + \hat{Y}_i^{(aus)} & \text{si } i \in \mathcal{S}_{obs} \\ \tilde{Y}_i & \text{si } i \notin \mathcal{S}_{obs} \end{cases}$$

donde $\hat{Y}_i^{(aus)}$ representa la predicción para las personas no observadas dentro de un segmento con cobertura parcial y $\tilde{Y}_i$ la predicción completa para segmentos sin cobertura. La incertidumbre de esta agregación se cuantifica mediante la distribución posterior del total, cuya varianza refleja simultáneamente la incertidumbre sobre los parámetros del modelo y la variabilidad del proceso de Poisson.

5.1.5 Interpretación de parámetros

La interpretación de los parámetros del modelo Poisson-lognormal requiere considerar la escala en la que opera cada componente. Dado que la densidad poblacional δ_i sigue una distribución log-normal, el predictor lineal μ_i actúa sobre el logaritmo de la densidad, lo que implica que los coeficientes β y γ se interpretan en escala logarítmica.

Para los coeficientes de efectos fijos, el coeficiente β_k representa el cambio esperado en el logaritmo de la densidad poblacional asociado a un incremento de una desviación estándar en la covariable estandarizada $\tilde{x}_{i,k}$, manteniendo constantes las demás covariables y los efectos aleatorios. Dado que $\mathbb{E}[\log \delta_i \mid \mu_i, \sigma] = \mu_i$ para la distribución log-normal, la derivada parcial del predictor lineal respecto a la covariable k es directamente:

$$\beta_k = \frac{\partial \mu_i}{\partial \tilde{x}_{i,k}}$$

En escala multiplicativa, $\exp(\beta_k)$ representa el factor por el cual se multiplica la densidad mediana cuando la covariable k aumenta en una desviación estándar. Valores de $\beta_k > 0$ indican que el segmento tiende a tener mayor densidad poblacional a medida que crece la covariable correspondiente; valores negativos indican la relación contraria.

Para los efectos aleatorios, el coeficiente γ_j representa el ajuste territorial específico de la unidad geográfica superior j una vez que el efecto de las covariables ha sido controlado. En escala multiplicativa, $\exp(\gamma_j)$ es el factor por el cual se ajusta la densidad de todos los segmentos pertenecientes al territorio j respecto al nivel implícito en los efectos fijos. La distribución a priori $\gamma_j \sim \mathcal{N}(0, \sigma_U^2)$ impone que estos ajustes se concentren alrededor de cero con una variabilidad determinada por σ_U , lo que produce el efecto de encogimiento sobre territorios con escasa información.

El parámetro σ controla la dispersión de las densidades δ_i alrededor de su media condicional $\exp(\mu_i + \sigma^2/2)$. En escala logarítmica, σ corresponde a la desviación estándar de $\log \delta_i$; valores grandes de σ indican alta heterogeneidad residual en las densidades no explicada por las covariables ni por los efectos aleatorios. El hiperparámetro σ_U cuantifica, por su parte, la dispersión de los efectos aleatorios entre unidades territoriales: valores grandes de σ_U indican que los territorios presentan densidades sistemáticamente distintas incluso después de controlar por las covariables auxiliares.

Finalmente, la densidad latente δ_i tiene una interpretación demográfica directa: representa el número estimado de personas por estructura habitacional en el segmento i . Este parámetro puede utilizarse para comparar

la intensidad de ocupación habitacional entre segmentos, identificar áreas de alta concentración y construir predicciones de población condicionadas al número de estructuras disponibles. Su distribución posterior provee una medida de incertidumbre que refleja tanto la variabilidad del conteo observado como la posición del segmento en la distribución log-normal especificada por el modelo.

5.2 Componentes del modelo

La especificación completa del modelo Poisson-lognormal requiere detallar la construcción de cada uno de sus componentes estructurales. El predictor lineal $\mu_i = \mathbf{x}_i^\top \beta + \mathbf{z}_i^\top \gamma$ integra dos tipos de información: efectos sistemáticos capturados por las covariables auxiliares a través de los efectos fijos, y ajustes territoriales no explicados por dichas covariables a través de los efectos aleatorios. Estos componentes interactúan con el offset de estructuras V_i y con el mecanismo de sobredispersión log-normal para producir estimaciones coherentes en el conjunto completo de segmentos.

5.2.1 Efectos fijos

Los efectos fijos del modelo capturan la relación sistemática entre las covariables auxiliares y la densidad poblacional. Sea $\mathbf{X}_{obs}$ la matriz de covariables de dimensión $D_{obs} \times P$, donde la fila i corresponde al vector $\mathbf{x}_i^\top$ del segmento observado i y las columnas corresponden a las P covariables seleccionadas tras el proceso de preparación de insumos descrito en el capítulo anterior. Análogamente, $\mathbf{X}_{tot}$ es la matriz de covariables de dimensión $D \times P$ que contiene los vectores de covariables para la totalidad de los segmentos del país, incluyendo aquellos no observados en el operativo censal.

El predictor lineal de efectos fijos para el segmento i es:

$$(\mathbf{X}_{obs}\beta)_i = \sum_{k=1}^P \beta_k \tilde{x}_{i,k}$$

donde $\tilde{x}_{i,k}$ denota la versión estandarizada de la covariable k en el segmento i , construida mediante las transformaciones descritas en el capítulo anterior: estandarización por media y desviación estándar para variables continuas simétricas, transformación logarítmica para variables de conteo con cola derecha, o normalización al intervalo unitario para índices y proporciones.

Las covariables incorporadas en $\mathbf{X}_{obs}$ se organizan en las tres categorías descritas en el capítulo de integración de fuentes. Las variables demográficas incluyen el tamaño medio del hogar, la razón de masculinidad y las proporciones de grupos etarios específicos. Las variables socioeconómicas incluyen índices de necesidades básicas insatisfechas, tasas de acceso a servicios públicos —electricidad, agua potable, internet— y conteos provenientes de registros administrativos como padrones electorales o afiliados a sistemas de salud. Las variables espaciales de origen satelital incluyen la luminosidad nocturna media del segmento L_i , el área construida derivada del producto Global Human Settlement Layer, la proporción de distintas categorías de cobertura de suelo, la pendiente media del terreno y la altitud media sobre el nivel del mar.

Un aspecto crítico en la especificación de los efectos fijos es el tratamiento de la multicolinealidad entre covariables. Dado que muchas de las fuentes auxiliares descritas están correlacionadas entre sí —la luminosidad nocturna y el área construida tienden a ser altas en las mismas zonas urbanas, y el número de registros administrativos crece con la población—, la inclusión simultánea de variables altamente correlacionadas puede

dificultar la estimación individual de los coeficientes. En la práctica, esto se aborda mediante análisis de correlación previo a la estimación y selección de variables basada en criterios estadísticos, complementados por el efecto regularizador de las distribuciones a priori $\beta_k \sim \mathcal{N}(0, 1)$, que penalizan moderadamente los coeficientes de gran magnitud y estabilizan la estimación en presencia de predictores correlacionados.

La estimación del vector β a partir de los datos proporciona información sobre cuáles características del segmento están más fuertemente asociadas con la densidad poblacional. Esta información puede utilizarse para orientar la actualización cartográfica, priorizar la recolección de covariables en futuros operativos censales y validar la consistencia de las fuentes utilizadas con los patrones demográficos observados en el territorio.

5.2.2 Efectos aleatorios

Los efectos aleatorios capturan la variabilidad sistemática entre unidades territoriales de nivel superior que no es explicada por las covariables auxiliares incluidas en los efectos fijos. Esta variabilidad puede deberse a factores institucionales no medidos —diferencias en la capacidad operativa de los equipos censales entre provincias, por ejemplo—, a condiciones locales no capturadas por las fuentes disponibles, o a características territoriales latentes que afectan simultáneamente a múltiples segmentos de una misma unidad.

Sea $\mathbf{Z}_{obs}$ la matriz de indicadores de dimensión $D_{obs} \times Q$, donde Q es el número de unidades territoriales de nivel superior consideradas. El elemento $z_{i,j}$ vale uno si el segmento i pertenece a la unidad territorial j y cero en caso contrario. Análogamente, $\mathbf{Z}_{tot}$ es la matriz de indicadores de dimensión $D \times Q$ para el conjunto completo de segmentos. La contribución de los efectos aleatorios al predictor lineal del segmento i es:

$$(\mathbf{Z}_{obs}\gamma)_i = \sum_{j=1}^Q z_{i,j} \gamma_j = \gamma_{j(i)}$$

donde $j(i)$ denota la unidad territorial a la que pertenece el segmento i . Dado que cada segmento pertenece a exactamente una unidad territorial, la contribución de los efectos aleatorios es simplemente el coeficiente $\gamma_{j(i)}$ correspondiente a su territorio.

La distribución a priori jerárquica $\gamma_j \sim \mathcal{N}(0, \sigma_U^2)$ regula el comportamiento de los efectos aleatorios a través del hiperparámetro σ_U . Cuando σ_U es pequeño, el modelo impone que los efectos aleatorios sean cercanos a cero, lo que es equivalente a una especificación sin ajustes territoriales específicos. Cuando σ_U es grande, los efectos aleatorios pueden tomar valores sustanciales, capturando diferencias importantes entre territorios no explicadas por las covariables. La estimación conjunta de σ_U y γ permite que el modelo aprenda automáticamente el grado de heterogeneidad territorial presente en los datos.

Una propiedad fundamental de la estructura jerárquica es el préstamo de fortaleza entre segmentos de un mismo territorio. Los segmentos con escasa información —conteos muy bajos, alta variabilidad en el conteo observado o baja cobertura censal— son estabilizados por la información de los demás segmentos de la misma unidad territorial, a través del efecto aleatorio compartido $\gamma_{j(i)}$. Simultáneamente, los efectos fijos proveen información de todos los segmentos del país para estimar el vector β , que contribuye a la predicción en segmentos con poca o ninguna cobertura censal. Este mecanismo de préstamo de información entre dominios constituye una de las principales ventajas del enfoque jerárquico bayesiano sobre los métodos de estimación directa.

La estructura de efectos aleatorios puede extenderse a múltiples niveles territoriales. En las aplicaciones sobre censos de América Latina y el Caribe desarrolladas en el marco de este libro, los efectos aleatorios se han especificado sobre provincias, departamentos o regiones, que constituyen la unidad administrativa intermedia más

relevante para la gestión censal. En países con censos de alta resolución cartográfica y disponibilidad de datos administrativos a nivel de municipio, es posible incorporar efectos aleatorios anidados que capturen simultáneamente variabilidad regional y municipal, a costa de mayor complejidad computacional y mayor exigencia de información.

5.2.3 Interacciones

El predictor lineal en su forma básica representa efectos aditivos y lineales de las covariables sobre el logaritmo de la densidad poblacional. En determinados contextos, la relación entre las covariables y la densidad puede presentar patrones no lineales o interacciones que requieren representación explícita en el modelo.

Las interacciones entre covariables se incorporan mediante la inclusión de productos entre variables estandarizadas en la matriz $\mathbf{X}_{obs}$. Si $\tilde{x}_{i,k}$ y $\tilde{x}_{i,l}$ son dos covariables estandarizadas, su término de interacción se define como:

$$\tilde{x}_{i,kl} = \tilde{x}_{i,k} \cdot \tilde{x}_{i,l}$$

El predictor lineal extendido con interacciones incluye un coeficiente adicional β_{kl} con distribución a priori $\beta_{kl} \sim \mathcal{N}(0, 1)$, tratando el término de interacción de manera simétrica a los efectos principales. Esta formulación es apropiada cuando las covariables están estandarizadas, ya que garantiza que los términos de interacción operen en una escala comparable a los efectos principales.

En el contexto de la estimación de conteos censales, las interacciones de mayor relevancia sustantiva suelen involucrar combinaciones entre variables de uso del suelo y clasificaciones territoriales —la interacción entre luminosidad nocturna y la condición urbano-rural puede capturar diferencias en el patrón de ocupación habitacional según el tipo de asentamiento— o entre variables demográficas y socioeconómicas, como la relación entre el tamaño medio del hogar y el acceso a servicios públicos, cuya dirección puede variar sistemáticamente entre contextos urbanos y rurales.

Las interacciones entre efectos fijos y efectos aleatorios, conocidas como efectos de pendiente aleatoria, permiten que la relación de una covariable con la densidad varíe entre territorios. En esta especificación extendida, el coeficiente de la covariable k en el territorio j es $\beta_k + v_{j,k}$, donde $v_{j,k}$ representa la desviación específica del territorio respecto al efecto promedio nacional. Esta extensión aumenta la flexibilidad del modelo a costa de mayor dimensionalidad y puede resultar útil cuando se sospecha que el efecto de un predictor varía sistemáticamente entre regiones del país.

La inclusión de términos de interacción debe equilibrar la mejora en el ajuste del modelo con el riesgo de sobreajuste en datos de alta dimensión. En la práctica, la selección de interacciones relevantes se evalúa mediante criterios de comparación de modelos como el criterio LOO-CV o el WAIC, cuyas bases se desarrollan en el capítulo dedicado al diagnóstico y validación.

5.2.4 Sobredispersión, offset y alternativas distribucionales

El diseño del modelo Poisson-lognormal incorpora tres elementos adicionales que merecen consideración específica: el mecanismo de control de sobredispersión a través de la distribución log-normal, el uso del número de estructuras como offset del proceso de conteo, y las alternativas distribucionales consideradas frente al modelo propuesto.

El offset de estructuras habitacionales. El número de estructuras habitacionales V_i desempeña el papel de offset en el modelo: escala la intensidad del proceso de Poisson de manera proporcional al tamaño del segmento en términos de unidades habitacionales. Formalmente, el modelo puede reescribirse como:

$$\log(\lambda_i) = \log(\delta_i) + \log(V_i) = \mu_i + \varepsilon_i + \log(V_i)$$

donde $\varepsilon_i = \log(\delta_i) - \mu_i \sim \mathcal{N}(0, \sigma^2)$ es el error log-normal. El término $\log(V_i)$ actúa como offset con coeficiente fijado en uno, lo que equivale a modelar la densidad —y no el conteo total— como función de las covariables. Esta parametrización es estadísticamente más apropiada que incluir $\log(V_i)$ como covariable con coeficiente libre, ya que el número de estructuras debe considerarse una referencia de escala del proceso y no un predictor ordinario del logaritmo de la densidad.

La fuente del offset puede variar según la disponibilidad de información. En segmentos con preconteo operativo, V_i corresponde directamente al número de viviendas registradas durante la actualización cartográfica previa al censo. En segmentos sin preconteo o con preconteo desactualizado por cambios demográficos recientes, V_i puede aproximarse mediante el número de estructuras identificadas en imágenes satelitales. La calidad de la estimación final depende directamente de la precisión de V_i , dado que errores en el offset se propagan directamente hacia las predicciones de conteo en todo el conjunto de segmentos.

El mecanismo de sobredispersión log-normal. La inclusión de la densidad latente δ_i con distribución log-normal constituye el principal mecanismo de control de sobredispersión del modelo. Bajo un modelo de Poisson puro sin densidad latente y con predictor lineal fijo, se tendría $\text{Var}(Y_i) = \mathbb{E}[Y_i] = \lambda_i$. La introducción de δ_i log-normal rompe esta restricción de equidispersión e induce la varianza marginal presentada en la sección anterior, cuyo exceso sobre la media es estrictamente positivo para $\sigma > 0$. El parámetro σ controla directamente este exceso: a mayor σ , mayor sobredispersión relativa. Esta parametrización permite que el modelo se adapte automáticamente al nivel de variabilidad presente en los datos, sin requerir la especificación a priori del grado de sobredispersión.

Restricción de la densidad en predicción. En la implementación práctica del modelo, la densidad predicha para segmentos no observados se trunca superiormente con el objetivo de evitar predicciones demográficamente implausibles en segmentos con alto valor del predictor lineal. Concretamente, se aplica la restricción:

$$\tilde{\delta}_i = \min(\delta_i^*, \delta_{\max})$$

donde δ_i^* es la densidad generada por la distribución log-normal predictiva y $\delta_{\max}$ es un valor máximo admisible definido a partir del conocimiento experto sobre los rangos plausibles de ocupación habitacional en el contexto regional. En la práctica, $\delta_{\max}$ se determina a partir de la distribución empírica de las densidades observadas en $\mathcal{S}_{obs}$: un valor habitual es el percentil 99 de $\{\delta_i : i \in \mathcal{S}_{obs}\}$ o un umbral redondo —por ejemplo, 20 personas por estructura— que refleje el máximo demográficamente plausible para el país en cuestión. Esta restricción previene que la combinación de un predictor lineal alto y variabilidad log-normal genere densidades que, multiplicadas por el número de estructuras, produzcan conteos individuales que superen toda referencia demográfica razonable.

Alternativas distribucionales. El modelo binomial negativo constituye la alternativa distribucional más natural al modelo Poisson-lognormal para el tratamiento de la sobredispersión. Bajo esta especificación, el conteo observado sigue directamente una distribución binomial negativa con media μ_i y parámetro de dispersión ϕ :

$$Y_i \mid \mu_i, \phi \sim \text{NegBin}(\mu_i, \phi), \quad \text{Var}(Y_i) = \mu_i + \frac{\mu_i^2}{\phi}$$

donde $\mu_i = \exp(\mathbf{x}_i^\top \beta + \mathbf{z}_i^\top \gamma) \cdot V_i$ incorpora el offset de estructuras. La diferencia fundamental respecto al modelo Poisson-lognormal reside en que la binomial negativa modela la sobredispersión mediante un único parámetro global ϕ , mientras que la log-normal permite heterogeneidad individual de la densidad a través del parámetro latente δ_i . Esta última propiedad hace del modelo Poisson-lognormal una opción más flexible para contextos con alta variabilidad territorial y disponibilidad de información a nivel de estructura habitacional.

Un modelo de Poisson con efectos aleatorios gaussianos no estructurados en el predictor lineal —sin el componente de densidad latente— constituye una alternativa computacionalmente más sencilla que puede resultar apropiada cuando la sobredispersión es moderada. En ese caso, el predictor lineal incluye un término de error no estructurado $u_i \sim \mathcal{N}(0, \sigma_u^2)$ que absorbe la variabilidad residual no capturada por los efectos fijos ni por los efectos aleatorios territoriales:

$$\log(\lambda_i) = \mathbf{x}_i^\top \beta + \mathbf{z}_i^\top \gamma + u_i + \log(V_i)$$

La elección entre estas especificaciones debe fundamentarse en el diagnóstico exploratorio de los datos —en particular, en la relación empírica entre la media y la varianza de los conteos por segmento— y en la comparación posterior mediante criterios de información. En contextos con elevada variabilidad territorial, alta proporción de segmentos con baja cobertura y disponibilidad de información sobre el número de estructuras, el modelo Poisson-lognormal con offset representa la especificación estadísticamente más apropiada para la estimación subnacional de conteos poblacionales en segmentos censales, y ha mostrado buen desempeño en las aplicaciones desarrolladas sobre censos de América Latina y el Caribe que sirven de referencia para este libro.