

Modelos Bayesianos de Población para América Latina y el Caribe

Implementación, Validación y Aplicación Subnacional

Andrés Gutiérrez¹ Stalyn Guerrero²

mayo de 2026

¹Experto Regional en Estadísticas Sociales, CEPAL. andres.gutierrez@cepal.org

²Consultor, CEPAL. guerrerostalyn@gmail.com

Índice general

Prefacio	5
Introducción	7
1 Enfoque General de los Modelos de Población	9
1.1 Producción de conteos censales	9
1.1.1 Producción subnacional	10
1.1.2 Desagregación por sexo y edad	11
1.1.3 Uso en marcos muestrales	11
1.1.4 Definición de dominios	12
1.2 Indicadores de interés	13
1.2.1 Conteos poblacionales	13
1.2.2 Tasas derivadas	15
1.2.3 Estructuras etarias	16
1.3 Formulación del problema de subcobertura, no respuesta y omisión censal	18
2 Integración de Fuentes de Información	21
2.1 Principios de modelamiento	21
2.1.1 Modelos de conteo	21
2.1.2 Requerimientos de estimación subnacional	22
2.1.3 Justificación del enfoque bayesiano	23
2.1.4 Integración de múltiples fuentes	24
2.1.5 Relación con Small Area Estimation	24
2.2 Identificación de fuentes	25
2.2.1 Medición de cobertura a nivel de segmento	25
2.2.2 Preconteos y segmentación	26
2.2.3 Registros administrativos (variables proxy)	26
2.2.4 Fuentes satelitales	27
2.3 Variables explicativas	28
2.3.1 Variables demográficas	28
2.3.2 Variables socioeconómicas	29
2.3.3 Variables espaciales	29
3 Preparación de Imágenes Satelitales	31
3.1 Fuentes de datos satelitales (Landsat, Sentinel, MODIS)	31
3.2 Preprocesamiento y correcciones atmosféricas	31
3.3 Extracción de características (NDVI, índices espectrales)	31
3.4 Validación con datos de campo	31
3.5 Generación de capas para el modelo	31

4	Preparación de Insumos para Modelamiento	33
4.1	Estandarización de fuentes	33
4.1.1	Homologación de variables	33
4.1.2	Normalización de variables	34
4.2	Evaluación de cobertura	35
4.2.1	Tasa de cobertura por segmento	35
4.2.2	Clasificación de segmentos	36
4.3	Construcción de la variable dependiente	36
4.3.1	Conteos agregados	37
4.3.2	Tasas poblacionales	37
4.3.3	Transformaciones	37
4.3.4	Definición de población base	38
4.3.5	Escalamiento	38
4.4	Diagnóstico exploratorio	39
4.4.1	Distribución de conteos	39
4.4.2	Outliers	40
4.4.3	Relación entre variables	41

Índice de figuras

Índice de cuadros

Prefacio

Este libro expone el marco metodológico y computacional para la producción de estimaciones de población subnacional mediante modelos bayesianos jerárquicos. Surge de la experiencia acumulada en proyectos de asistencia técnica a institutos nacionales de estadística de América Latina y el Caribe, en el marco de las actividades de cooperación estadística de la Comisión Económica para América Latina y el Caribe (CEPAL).

La motivación central es práctica: los censos de población proporcionan conteos que, en unidades geográficas pequeñas, presentan errores de cobertura sistemáticos y difíciles de cuantificar con los métodos de conciliación demográfica tradicionales. La integración de fuentes modernas de información —preconteos operativos, registros administrativos e imágenes satelitales— en un marco probabilístico coherente ofrece una respuesta metodológica rigurosa a este problema.

El libro combina fundamentos estadísticos formales con implementación computacional reproducible en R y Stan, y está dirigido a estadísticos y demógrafos de organismos nacionales e internacionales con formación cuantitativa de nivel avanzado.

Cómo compilar este libro

```
# HTML interactivo
bookdown::render_book("index.Rmd", "bookdown::gitbook")

# PDF
bookdown::render_book("index.Rmd", "bookdown::pdf_book")

# Word (.docx)
bookdown::render_book("index.Rmd", "bookdown::word_document2")
```

Introducción

La producción de conteos poblacionales constituye uno de los procesos estadísticos más complejos y estratégicos desarrollados por los institutos nacionales de estadística. Los censos de población y vivienda no solo permiten cuantificar el tamaño de la población, sino también establecer la estructura demográfica, definir marcos de referencia territoriales y generar la base operativa para una gran parte de las estadísticas oficiales producidas posteriormente por los países.

A nivel subnacional, los conteos censales son utilizados en procesos de planificación territorial, asignación presupuestal, focalización de programas sociales, construcción de marcos muestrales, producción de indicadores sociales y elaboración de proyecciones demográficas. La calidad de estas aplicaciones depende directamente de la precisión y coherencia de los conteos poblacionales observados en cada unidad geográfica.

Sin embargo, la producción censal enfrenta limitaciones estructurales asociadas a errores de cobertura, omisión, duplicación y clasificación territorial. Estos problemas no se distribuyen homogéneamente en el territorio. Por el contrario, suelen concentrarse en áreas con alta dispersión poblacional, asentamientos informales, zonas rurales de difícil acceso, territorios indígenas y contextos urbanos con elevada movilidad poblacional.

Como consecuencia, los conteos observados durante el operativo censal no necesariamente representan la población verdadera presente en cada unidad geográfica. Esta situación se vuelve particularmente crítica en niveles territoriales pequeños, donde errores relativamente reducidos en términos absolutos pueden generar distorsiones importantes en tasas, indicadores derivados y procesos de asignación institucional.

Frente a este problema, los sistemas estadísticos modernos han comenzado a incorporar metodologías de integración de múltiples fuentes de información orientadas a fortalecer, ajustar y validar los conteos censales. Entre estas fuentes se incluyen preconteos operativos, registros administrativos, cartografía censal, imágenes satelitales y modelos espaciales derivados de información georreferenciada.

En este contexto, los modelos bayesianos jerárquicos ofrecen un marco probabilístico flexible para representar explícitamente la incertidumbre asociada al proceso de enumeración poblacional y combinar información procedente de distintas fuentes bajo un esquema coherente de inferencia estadística.

Enfoque General de los Modelos de Población

1.1 Producción de conteos censales

La producción de conteos poblacionales constituye uno de los procesos más relevantes dentro de los sistemas estadísticos nacionales. A través de los censos de población y vivienda, los países construyen la base demográfica utilizada para la planificación pública, la elaboración de indicadores sociales, la construcción de marcos muestrales y la formulación de políticas territoriales. En términos operativos y metodológicos, el censo representa la única operación estadística diseñada para enumerar exhaustivamente la población residente dentro de un territorio nacional bajo un mismo marco conceptual, temporal y geográfico.

Los conteos censales no solo permiten conocer cuántas personas habitan un país, sino también cómo se distribuyen territorialmente y cómo se estructuran según características demográficas básicas como sexo y edad. Esta información es utilizada posteriormente en una gran variedad de procesos institucionales: proyecciones demográficas, encuestas de hogares, sistemas de focalización social, distribución presupuestaria, delimitación administrativa y producción de estadísticas subnacionales.

En la práctica, la producción censal implica mucho más que el levantamiento de información en campo. Detrás de los conteos publicados existe una estructura compleja de actualización cartográfica, segmentación territorial, logística operativa, capacitación, validación y conciliación estadística. Cada una de estas etapas introduce potenciales fuentes de error que afectan la calidad final de las estimaciones poblacionales.

Uno de los principales desafíos de los censos modernos corresponde a los problemas de cobertura. La enumeración de la población nunca es perfecta. Existen personas que no son censadas, viviendas que no son visitadas, individuos registrados más de una vez o registros asignados incorrectamente a un territorio distinto. Estos problemas tienden a concentrarse en determinados contextos territoriales y sociales: áreas rurales dispersas, asentamientos informales, territorios indígenas, zonas fronterizas o áreas urbanas con alta movilidad poblacional.

En América Latina y el Caribe, estas dificultades adquieren una dimensión particularmente importante debido a la elevada heterogeneidad territorial de la región. Los países presentan diferencias sustanciales en capacidad operativa, actualización cartográfica, infraestructura estadística y disponibilidad de registros administrativos. Adicionalmente, muchos territorios enfrentan condiciones geográficas complejas que dificultan las labores de enumeración y supervisión censal.

La ronda censal de 2020 evidenció nuevamente estas limitaciones. Diversos países experimentaron retrasos operativos asociados a restricciones presupuestarias, conflictos sociales y efectos derivados de la pandemia de COVID-19. Como resultado, varios sistemas estadísticos enfrentaron dificultades para mantener continuidad temporal y coherencia territorial en sus conteos poblacionales.

A medida que aumenta el nivel de desagregación geográfica, los problemas de cobertura se vuelven más visibles. Mientras que a nivel nacional algunos errores pueden compensarse parcialmente entre regiones, en niveles territoriales pequeños las omisiones o duplicaciones generan distorsiones importantes sobre indicadores

demográficos y sociales. Esto afecta directamente la capacidad de los gobiernos para asignar recursos, diseñar programas y producir estadísticas territoriales consistentes.

En este contexto, la producción moderna de conteos poblacionales requiere complementar el operativo censal tradicional con mecanismos de validación, integración de fuentes auxiliares y modelamiento estadístico. Los modelos bayesianos de población surgen precisamente como una respuesta metodológica a este problema, permitiendo integrar información proveniente de distintas fuentes y representar explícitamente la incertidumbre asociada a los conteos observados.

1.1.1 Producción subnacional

Aunque los censos generan un conteo nacional de población, gran parte de su utilidad práctica se concentra en la producción de información subnacional. Los gobiernos requieren estadísticas desagregadas para departamentos, provincias, municipios, áreas urbanas y rurales, sectores censales y segmentos operativos. Es en estas escalas territoriales donde se ejecutan la mayoría de políticas públicas y procesos administrativos.

La producción subnacional implica construir conteos consistentes entre distintos niveles geográficos. Los totales municipales deben coincidir con los agregados departamentales, y estos, a su vez, con los conteos nacionales. Esta coherencia territorial constituye uno de los principios fundamentales de la estadística oficial.

Sin embargo, garantizar dicha consistencia no es un proceso trivial. A medida que disminuye el tamaño poblacional de las unidades geográficas, aumentan proporcionalmente los efectos de los errores de cobertura. En áreas pequeñas, la omisión de algunos hogares o viviendas puede alterar significativamente indicadores derivados como tasas de dependencia, razones de masculinidad o estructuras etarias.

La calidad de los conteos subnacionales depende críticamente de la cartografía censal y de los procesos de segmentación territorial. Antes del levantamiento censal, los países deben actualizar mapas, identificar viviendas, definir rutas operativas y dividir el territorio en unidades de trabajo relativamente homogéneas. Estas unidades, conocidas generalmente como segmentos censales, constituyen la base operativa del operativo de campo.

En América Latina y el Caribe, la definición de segmentos presenta importantes diferencias metodológicas entre países. Algunos sistemas censales utilizan criterios asociados al número esperado de viviendas, mientras que otros priorizan continuidad espacial, accesibilidad geográfica o carga operativa del censista. Como resultado, las unidades territoriales utilizadas en los censos no siempre son comparables entre países.

Otro aspecto relevante corresponde a la diferencia entre censos de hecho y censos de derecho. En países como Bolivia, Paraguay y Colombia, los operativos censales han sido implementados bajo esquemas de censo de hecho, donde las personas son contabilizadas en el lugar donde se encuentran durante el momento censal. En contraste, los censos de derecho buscan registrar a las personas según su residencia habitual.

Esta diferencia conceptual tiene implicaciones importantes sobre movilidad territorial, cobertura diferencial y consistencia espacial. En contextos con alta movilidad poblacional, los censos de hecho pueden generar concentraciones temporales de población en determinadas áreas, mientras que los censos de derecho requieren procedimientos más complejos para validar residencia habitual y evitar duplicaciones.

La producción subnacional también enfrenta desafíos asociados al crecimiento urbano acelerado y a la expansión de asentamientos informales. En muchas ciudades de la región, los procesos de urbanización ocurren más rápidamente que la actualización cartográfica oficial, generando sectores con viviendas no registradas o límites territoriales desactualizados. Esto afecta directamente la cobertura del operativo y la calidad de los conteos resultantes.

Desde la perspectiva estadística, los conteos subnacionales deben entenderse como observaciones imperfectas de una población subyacente cuya magnitud real no es completamente observable. Esta situación motiva el uso de modelos probabilísticos capaces de integrar múltiples fuentes de información, representar explícitamente la incertidumbre y garantizar coherencia entre niveles territoriales.

1.1.2 Desagregación por sexo y edad

Uno de los principales aportes de los censos de población consiste en la posibilidad de caracterizar la estructura demográfica de la población. Los conteos no solo se producen para áreas geográficas, sino también para distintos grupos de edad y sexo. Esta desagregación constituye un insumo fundamental para el análisis demográfico, la formulación de políticas públicas y la elaboración de proyecciones poblacionales.

La distribución por edad y sexo condiciona directamente múltiples dimensiones del desarrollo social y económico. La demanda de servicios educativos, sistemas de salud, programas de protección social y mercados laborales depende estrechamente de la estructura etaria de la población. Del mismo modo, indicadores como envejecimiento, dependencia demográfica o fecundidad requieren información detallada sobre composición poblacional.

En términos operativos, la producción de conteos por sexo y edad incrementa considerablemente la complejidad del proceso censal. Los errores de cobertura no afectan de manera homogénea a todos los grupos poblacionales. En América Latina y el Caribe, las tasas de omisión suelen ser más elevadas en niños pequeños, hombres jóvenes, población indígena, migrantes y habitantes de zonas rurales dispersas.

Estas diferencias generan distorsiones importantes en la estructura observada de la población. En niveles territoriales pequeños, incluso pequeñas omisiones pueden alterar significativamente indicadores demográficos derivados. Por esta razón, los sistemas estadísticos implementan procedimientos de validación y ajuste orientados a identificar inconsistencias en la distribución por sexo y edad.

La desagregación etaria también constituye un componente central de los procesos de proyección demográfica. Los métodos cohortes-componentes utilizados por la mayoría de países requieren información detallada sobre estructura poblacional para modelar nacimientos, defunciones y migración. Como consecuencia, errores en la distribución censal inicial pueden propagarse a lo largo de toda la serie de proyecciones futuras.

En el contexto del modelamiento bayesiano, la estructura por sexo y edad puede incorporarse mediante modelos jerárquicos que permiten compartir información entre grupos relacionados y estabilizar estimaciones en dominios con baja densidad poblacional. Esto resulta especialmente útil en áreas pequeñas donde la variabilidad observada puede ser considerablemente alta.

1.1.3 Uso en marcos muestrales

Los conteos censales constituyen la principal base para la construcción de marcos muestrales utilizados en encuestas de hogares y otras operaciones estadísticas. Los sectores y segmentos definidos durante el operativo censal son utilizados posteriormente como unidades primarias de muestreo en gran parte de las encuestas nacionales desarrolladas por los institutos de estadística.

La calidad de un marco muestral depende directamente de la calidad de los conteos censales y de la actualización cartográfica asociada. Cuando existen omisiones territoriales, viviendas no registradas o límites desactualizados, los diseños muestrales pueden introducir sesgos de cobertura y pérdida de eficiencia estadística.

En América Latina y el Caribe, muchos marcos muestrales permanecen vigentes durante periodos intercensales prolongados. Durante estos intervalos, los cambios demográficos y territoriales pueden modificar sustancialmente la distribución espacial de la población. La expansión urbana, la migración interna y la transformación de áreas rurales generan desactualizaciones progresivas en las unidades de muestreo originalmente construidas a partir del censo.

La segmentación censal también cumple un papel operativo fundamental en la implementación de encuestas probabilísticas. Las unidades territoriales utilizadas durante el censo suelen redefinirse y reorganizarse para optimizar costos operativos, carga de trabajo y precisión estadística. Como resultado, la calidad de la información censal afecta directamente el desempeño posterior de múltiples sistemas de encuestas.

En este contexto, mejorar la calidad de los conteos subnacionales no solo fortalece las estadísticas demográficas, sino también toda la infraestructura estadística utilizada posteriormente por los países para producir información social y económica.

1.1.4 Definición de dominios

La producción de estadísticas poblacionales requiere definir dominios geográficos y demográficos sobre los cuales se generan estimaciones e indicadores. Estos dominios corresponden a distintos niveles territoriales utilizados para organización administrativa, planificación pública y análisis estadístico.

El nivel nacional constituye el agregado principal del sistema estadístico y funciona como referencia para la producción de indicadores macrodemográficos y proyecciones oficiales. Sin embargo, gran parte de las decisiones operativas se realizan en escalas territoriales inferiores.

El nivel intermedio, conformado generalmente por departamentos, provincias o estados, representa uno de los principales niveles de descentralización administrativa en América Latina y el Caribe. En estos territorios se ejecutan programas regionales, se distribuyen recursos fiscales y se implementan estrategias sectoriales de salud, educación e infraestructura.

La diferenciación urbano-rural constituye además una dimensión central en la producción estadística regional. Las brechas territoriales entre áreas urbanas y rurales continúan siendo una de las principales características demográficas y socioeconómicas de la región. Como consecuencia, muchos indicadores poblacionales requieren desagregación específica según tipo de área.

A nivel local, los municipios representan una de las principales unidades de gestión territorial. En este nivel se concentran procesos de planeación urbana, focalización social, administración tributaria y provisión de servicios públicos. La precisión de los conteos municipales afecta directamente la asignación presupuestaria y la medición de múltiples indicadores sociales.

Finalmente, el segmento censal constituye la unidad operativa básica del levantamiento. Estas unidades poseen alta resolución espacial y permiten representar con mayor detalle la heterogeneidad territorial. Sin embargo, también presentan mayor sensibilidad a errores de cobertura y problemas de consistencia espacial.

En países como Bolivia, Paraguay y Colombia, los segmentos censales adquieren especial importancia debido a la implementación de censos de hecho y a la necesidad de coordinar operativos intensivos de corta duración. En este contexto, la calidad de la segmentación territorial condiciona directamente la cobertura del operativo y la precisión de los conteos finales.

Desde la perspectiva del modelamiento estadístico, los distintos dominios territoriales conforman una estructura jerárquica de información donde las estimaciones deben mantener coherencia entre niveles geográficos.

Esta jerarquía constituye uno de los elementos centrales en el desarrollo posterior de modelos bayesianos subnacionales orientados a integración de fuentes y ajuste de cobertura.

1.2 Indicadores de interés

La producción de conteos censales tiene como propósito central generar información estadística que permita caracterizar la dinámica demográfica y territorial de la población. A partir de los datos censales es posible construir un amplio conjunto de indicadores utilizados en procesos de planificación, evaluación de políticas públicas, asignación presupuestaria y análisis socioeconómico.

Los indicadores derivados de los censos no solo describen el tamaño de la población, sino también su distribución espacial, estructura etaria, composición por sexo y condiciones territoriales. Estos indicadores constituyen además el punto de partida para procesos posteriores de estimación, proyección demográfica y construcción de estadísticas oficiales.

En América Latina y el Caribe, la creciente demanda de información subnacional ha incrementado la necesidad de producir indicadores con alta desagregación territorial. Los gobiernos requieren estadísticas consistentes para departamentos, municipios, áreas urbanas y rurales, e incluso niveles operativos más pequeños como sectores y segmentos censales.

Sin embargo, la producción de indicadores en dominios pequeños enfrenta limitaciones importantes asociadas a errores de cobertura, omisión censal y variabilidad espacial de los conteos. En consecuencia, muchos indicadores derivados presentan altos niveles de inestabilidad cuando se calculan directamente a partir de los conteos observados.

En este contexto, resulta fundamental distinguir entre:

- conteos poblacionales básicos;
- tasas derivadas;
- y estructuras demográficas.

Cada uno de estos componentes presenta características particulares en términos de interpretación, sensibilidad a errores de cobertura y comportamiento territorial.

1.2.1 Conteos poblacionales

Los conteos poblacionales constituyen el núcleo de la producción estadística demográfica. A través de ellos, los países cuantifican la población presente o residente dentro de un territorio y construyen la base sobre la cual se desarrollan posteriormente las proyecciones demográficas, los marcos muestrales, los indicadores sociales y gran parte de las estadísticas oficiales utilizadas en procesos de planificación pública.

Estos conteos son producidos para múltiples niveles de desagregación territorial y demográfica. En términos generales, la información censal se organiza para el nivel nacional, departamentos o provincias, municipios, áreas urbanas y rurales, así como para distintos grupos de edad y sexo. Esta estructura jerárquica permite caracterizar la distribución espacial de la población y construir estadísticas coherentes entre distintos niveles administrativos.

Sea $N_{i,s,e}$ el número de personas en el dominio geográfico i , sexo $s \in \{M, F\}$ (masculino, femenino) y grupo de edad $e \in \{1, \dots, E\}$. El conteo total de población para una unidad geográfica se obtiene por agregación sobre sexo y edad:

$$N_i = \sum_{s \in \{M, F\}} \sum_{e=1}^E N_{i,s,e}$$

mientras que la población nacional corresponde a la suma sobre todos los dominios territoriales:

$$N = \sum_{i=1}^I N_i$$

La coherencia jerárquica exige que los conteos en niveles inferiores sean consistentes con los totales de los niveles superiores. Denotando con superíndice el nivel jerárquico — $N_j^{(2)}$ para un departamento j , $N_k^{(3)}$ para un municipio k y $N_\ell^{(4)}$ para un segmento ℓ — las restricciones de consistencia son:

$$N_j^{(2)} = \sum_{k: k \subset j} N_k^{(3)}, \quad N_k^{(3)} = \sum_{\ell: \ell \subset k} N_\ell^{(4)}$$

donde la notación $k \subset j$ indica que el municipio k pertenece al departamento j .

Esta coherencia jerárquica es esencial para garantizar la comparabilidad y consistencia de las estadísticas oficiales.

En la práctica, los conteos poblacionales pueden entenderse en distintos niveles. Los conteos observados corresponden directamente a la enumeración realizada durante el operativo censal. Posteriormente, algunos países incorporan procesos de conciliación y ajuste orientados a corregir problemas de cobertura o inconsistencias demográficas. Finalmente, en contextos donde existen limitaciones operativas o necesidad de actualización intercensal, los conteos pueden complementarse mediante procedimientos de estimación estadística e integración de múltiples fuentes de información.

Uno de los principales desafíos asociados a los conteos poblacionales corresponde a su sensibilidad frente a errores de cobertura territorial. A medida que aumenta el nivel de desagregación geográfica, incluso pequeñas omisiones pueden generar distorsiones importantes sobre indicadores derivados. Este problema es particularmente visible en municipios pequeños, áreas rurales dispersas o segmentos censales con baja densidad poblacional, donde la omisión de algunos hogares puede modificar significativamente estructuras etarias, tasas de dependencia o indicadores sociales.

En América Latina y el Caribe, estas dificultades adquieren una relevancia especial debido a la heterogeneidad territorial de la región. La expansión urbana acelerada, el crecimiento de asentamientos informales, la movilidad poblacional y las diferencias en capacidad operativa entre países generan importantes desafíos para la actualización cartográfica y la cobertura completa del operativo censal. Como consecuencia, la precisión espacial de los conteos puede variar considerablemente entre territorios.

Desde una perspectiva estadística, los conteos poblacionales no deben interpretarse como valores exactos libres de error, sino como observaciones sujetas a incertidumbre y condicionadas por las limitaciones propias del operativo censal. Esta interpretación resulta fundamental para el desarrollo posterior de modelos proba-

bilísticos de población, donde los conteos observados se entienden como aproximaciones de una población subyacente no completamente observable.

1.2.2 Tasas derivadas

A partir de los conteos poblacionales es posible construir un amplio conjunto de tasas e indicadores utilizados para describir dinámicas demográficas, caracterizar condiciones territoriales y apoyar procesos de planificación pública. Mientras los conteos absolutos permiten cuantificar el tamaño de la población, las tasas derivadas facilitan la comparación entre territorios con estructuras y magnitudes poblacionales diferentes.

Este tipo de indicadores resulta fundamental para el análisis territorial, ya que permite transformar los conteos censales en medidas comparables entre regiones, municipios o áreas urbanas y rurales. De esta manera, es posible evaluar fenómenos asociados a concentración poblacional, envejecimiento, dependencia demográfica o composición por sexo bajo una escala relativa más adecuada para el análisis estadístico.

Entre los indicadores más utilizados se encuentran la densidad poblacional, las tasas de dependencia, las razones de masculinidad y los índices de envejecimiento. Cada uno de ellos resume distintas dimensiones de la estructura demográfica y constituye un insumo importante para la toma de decisiones institucionales.

La densidad poblacional permite medir la relación entre población y superficie territorial. Para un territorio (i), esta puede expresarse como:

$$D_i = \frac{N_i}{A_i}$$

donde N_i representa la población observada y A_i el área geográfica correspondiente. Este indicador es ampliamente utilizado en procesos de planificación urbana, expansión de infraestructura, análisis ambiental y organización de servicios públicos.

Por su parte, la razón de masculinidad describe la relación entre población masculina y femenina dentro de un territorio determinado:

$$RM_i = \frac{N_{i,M}}{N_{i,F}} \times 100$$

donde $N_{i,M} = \sum_e N_{i,M,e}$ es la población masculina y $N_{i,F} = \sum_e N_{i,F,e}$ la femenina del territorio i . Este indicador permite identificar desequilibrios demográficos asociados a migración, envejecimiento o cambios en la estructura poblacional.

Otro indicador ampliamente utilizado corresponde a la tasa de dependencia demográfica, la cual relaciona la población potencialmente dependiente con la población en edades productivas:

$$TD_i = \frac{N_{i,[0,14]} + N_{i,[65+]}}{N_{i,[15,64]}} \times 100$$

donde $N_{i,[a,b]} = \sum_s \sum_{e: e \in [a,b]} N_{i,s,e}$ denota la población del territorio i en el intervalo de edad $[a, b]$. De manera complementaria, el índice de envejecimiento evalúa el peso relativo de la población adulta mayor frente a la población joven:

$$IE_i = \frac{N_{i,[65+]}}{N_{i,[0,14]}} \times 100$$

Estos indicadores desempeñan un papel central en la planificación territorial y sectorial. Su utilización es frecuente en procesos de asignación presupuestaria, focalización de programas sociales, evaluación de necesidades de infraestructura y análisis de demanda potencial de servicios públicos.

Sin embargo, las tasas derivadas presentan una sensibilidad considerable frente a errores de cobertura censal. Debido a que muchas de ellas se construyen como razones entre subgrupos poblacionales específicos, pequeñas omisiones o inconsistencias pueden generar fluctuaciones importantes en los resultados observados. Este fenómeno se vuelve particularmente evidente en dominios geográficos pequeños, donde diferencias reducidas en los conteos absolutos producen variaciones relativamente grandes en los indicadores derivados.

En municipios con baja población o segmentos censales reducidos, las tasas pueden presentar comportamientos altamente inestables, especialmente cuando existen problemas de omisión diferencial por edad, sexo o localización territorial. En América Latina y el Caribe, estas dificultades suelen amplificarse debido a la heterogeneidad territorial, la expansión metropolitana acelerada, los procesos migratorios y las diferencias operativas observadas entre países y regiones.

Como consecuencia, la producción de indicadores subnacionales requiere mecanismos de validación y ajuste orientados a mejorar estabilidad estadística y coherencia territorial. Desde esta perspectiva, los enfoques de modelamiento permiten complementar los métodos tradicionales mediante estrategias que incorporan integración de información auxiliar y representación explícita de la incertidumbre asociada a los conteos base.

1.2.3 Estructuras etarias

La estructura por edad de la población constituye uno de los componentes centrales del análisis demográfico. Su estudio permite comprender los cambios asociados a fecundidad, mortalidad, migración, envejecimiento y transición demográfica, así como las diferencias territoriales en la dinámica poblacional de los países.

Los censos de población representan la principal fuente de información para caracterizar estas estructuras con altos niveles de desagregación geográfica. A partir de los conteos por edad y sexo es posible construir pirámides poblacionales, relaciones de dependencia, índices de envejecimiento y proyecciones demográficas, elementos fundamentales para la planificación social y económica.

Sea $N_{i,e} = \sum_{s \in \{M,F\}} N_{i,s,e}$ la población del área i en el grupo de edad e , obtenida por suma sobre ambos sexos. La participación relativa de cada grupo etario dentro de la población total del territorio puede expresarse como:

$$p_{i,e} = \frac{N_{i,e}}{N_i}$$

donde $N_i = \sum_{e=1}^E N_{i,e}$ es la población total del territorio. Por construcción, $\sum_{e=1}^E p_{i,e} = 1$.

En la práctica, la estructura etaria suele organizarse utilizando grupos quinquenales de edad:

$$0 - 4, 5 - 9, 10 - 14, \dots, 80+$$

debido a que esta agrupación proporciona mayor estabilidad demográfica y facilita la comparabilidad entre países y periodos censales. Adicionalmente, los grupos quinquenales constituyen la base utilizada en la mayoría

de modelos de proyección poblacional y análisis demográficos oficiales.

Los indicadores de cambio demográfico más utilizados se expresan directamente en términos de $N_{i,[a,b]}$. El índice de envejecimiento relaciona la población adulta mayor con la población joven:

$$IE_i = \frac{N_{i,[65+]}}{N_{i,[0,14]}} \times 100$$

La tasa de dependencia demográfica total evalúa la presión potencial sobre la población en edades productivas y coincide con TD_i definida en la sección anterior:

$$TD_i = \frac{N_{i,[0,14]} + N_{i,[65+]}}{N_{i,[15,64]}} \times 100$$

Estos indicadores son ampliamente utilizados en procesos de planificación pública debido a que permiten anticipar necesidades asociadas a educación, salud, protección social, empleo e infraestructura. Territorios con estructuras jóvenes suelen demandar mayores inversiones en sistemas educativos y servicios materno-infantiles, mientras que áreas con envejecimiento avanzado requieren una mayor capacidad de atención en salud y sistemas de cuidado.

En América Latina y el Caribe, la estructura etaria presenta fuertes contrastes territoriales. Mientras algunas áreas metropolitanas muestran procesos avanzados de envejecimiento poblacional y reducción de fecundidad, otras regiones mantienen estructuras considerablemente más jóvenes asociadas a mayores niveles de natalidad y menor transición demográfica. Estas diferencias reflejan la elevada heterogeneidad demográfica de la región y generan importantes desafíos para la producción de estadísticas subnacionales comparables.

La construcción de estructuras etarias confiables enfrenta además importantes limitaciones operativas. Los errores de cobertura censal no afectan homogéneamente a todos los grupos de edad. En muchos países de la región, la omisión censal tiende a concentrarse en niños pequeños, hombres jóvenes, migrantes, población indígena y habitantes de zonas rurales dispersas. Como consecuencia, la distribución observada por edad puede diferir significativamente de la estructura poblacional verdadera.

Este problema se intensifica en dominios geográficos pequeños. En municipios con baja población o segmentos censales reducidos, pequeñas diferencias en los conteos observados pueden modificar considerablemente la forma de la estructura etaria y generar indicadores altamente inestables. La variabilidad observada suele aumentar aún más cuando los grupos poblacionales son desagregados simultáneamente por edad, sexo y localización territorial.

Adicionalmente, las estructuras etarias cumplen un papel central en los procesos de proyección demográfica y estimación intercensal. Los modelos cohortes-componentes utilizados por la mayoría de oficinas nacionales de estadística dependen directamente de la calidad de la distribución inicial por edad y sexo. En consecuencia, errores presentes en los conteos censales pueden propagarse hacia estimaciones futuras y afectar la consistencia temporal de las proyecciones oficiales.

Desde la perspectiva del modelamiento estadístico, las estructuras etarias pueden entenderse como realizaciones sujetas a incertidumbre y error de cobertura. Bajo este enfoque, los modelos bayesianos jerárquicos permiten incorporar dependencia entre grupos de edad relacionados, estabilizar estimaciones en áreas con información limitada e integrar múltiples fuentes auxiliares para mejorar la coherencia territorial y demográfica de las estimaciones poblacionales.

1.3 Formulación del problema de subcobertura, no respuesta y omisión censal

Uno de los principales desafíos de los censos modernos corresponde a los problemas de cobertura asociados al operativo de enumeración. Aunque el objetivo conceptual del censo consiste en registrar exhaustivamente toda la población presente o residente dentro del territorio nacional, en la práctica siempre existen diferencias entre la población efectivamente observada y la población real presente en el territorio.

Estas diferencias surgen por múltiples razones. Algunas personas no son censadas, ciertas viviendas quedan fuera del operativo, algunos registros son duplicados y, en otros casos, existen errores en la asignación territorial de la información recolectada. Como resultado, los conteos censales deben entenderse como realizaciones observadas de un proceso de enumeración sujeto a limitaciones operativas, errores cartográficos y dificultades de cobertura.

Formalmente, sea $Y_{i,s,e}$ el conteo observado en el operativo censal para el territorio i , sexo s y grupo de edad e , y sea $N_{i,s,e}$ la población verdadera correspondiente. La relación entre ambos puede representarse como:

$$Y_{i,s,e} = N_{i,s,e} - O_{i,s,e} + D_{i,s,e} + C_{i,s,e}$$

donde $O_{i,s,e}$ representa la omisión censal, $D_{i,s,e}$ la duplicación de personas y $C_{i,s,e}$ los errores asociados a clasificación o asignación territorial. Bajo esta formulación, los conteos observados no constituyen una medición exacta de la población, sino una aproximación afectada por distintos mecanismos de error.

En América Latina y el Caribe, la subcobertura censal presenta además una marcada heterogeneidad territorial. La omisión no ocurre aleatoriamente sobre la población ni sobre el territorio. Por el contrario, suele concentrarse en contextos específicos como asentamientos informales, zonas rurales dispersas, territorios indígenas, áreas de frontera o sectores urbanos con elevada movilidad residencial. Estas características generan patrones espaciales de cobertura diferencial que afectan directamente la calidad de los conteos subnacionales.

La no respuesta constituye un problema adicional dentro del proceso censal. Incluso cuando una vivienda logra ser efectivamente enumerada, algunas variables pueden quedar incompletas debido a ausencia de informantes, rechazo parcial, inconsistencias durante la entrevista o errores de captura. Este fenómeno afecta particularmente variables socioeconómicas y laborales, reduciendo la completitud analítica de la información censal.

La combinación entre subcobertura, omisión y no respuesta produce efectos acumulativos sobre múltiples procesos estadísticos posteriores. Las proyecciones demográficas, la construcción de marcos muestrales, la estimación de indicadores sociales y los procesos de focalización territorial dependen directamente de la calidad de los conteos base. En consecuencia, errores relativamente pequeños en la enumeración pueden propagarse posteriormente hacia distintas operaciones estadísticas oficiales.

Estos problemas adquieren una relevancia aún mayor en niveles geográficos pequeños. En municipios con baja población o segmentos censales reducidos, la omisión de un número limitado de viviendas puede alterar significativamente las estructuras poblacionales observadas. Este fenómeno se intensifica cuando los errores de cobertura afectan diferencialmente determinados grupos de edad, sexo o condiciones socioeconómicas.

Adicionalmente, la rápida transformación territorial observada en muchos países de la región ha incrementado la complejidad operativa de los censos. La expansión urbana acelerada, el crecimiento de asentamientos informales y los procesos migratorios dificultan la actualización cartográfica permanente y reducen la capacidad de cobertura completa del operativo censal.

Frente a este escenario, los sistemas estadísticos han comenzado a complementar los enfoques tradicionales de conciliación censal mediante estrategias de integración de múltiples fuentes de información. Los registros ad-

ministrativos, las imágenes satelitales, los preconteos operativos y otras fuentes auxiliares permiten identificar inconsistencias territoriales y fortalecer la estimación de poblaciones subenumeradas.

En este libro, el interés principal no se centra en modelar directamente tasas de cobertura, sino en estimar conteos poblacionales en segmentos censales donde existen problemas de cobertura, omisión o inconsistencias territoriales. Bajo esta perspectiva, los conteos observados se interpretan como información parcial sobre una población subyacente cuya magnitud real debe inferirse utilizando información auxiliar y estructuras jerárquicas coherentes con la organización territorial del censo.

Desde esta perspectiva, los modelos bayesianos ofrecen un marco flexible para integrar múltiples fuentes de información, representar explícitamente la incertidumbre asociada a los conteos observados y estabilizar estimaciones en dominios geográficos pequeños. Los capítulos posteriores desarrollan estos elementos metodológicos y presentan estrategias orientadas específicamente a la estimación subnacional de conteos poblacionales en segmentos censales bajo esquemas probabilísticos modernos.

Integración de Fuentes de Información

La estimación de conteos poblacionales en unidades territoriales pequeñas no puede resolverse adecuadamente mediante el análisis directo de los datos censales. Las limitaciones de cobertura, la variabilidad asociada a dominios con baja densidad poblacional y la disponibilidad creciente de información auxiliar de distinta naturaleza hacen necesario un marco metodológico que integre múltiples fuentes bajo un esquema estadístico coherente.

Este capítulo presenta los principios de modelamiento que fundamentan los modelos bayesianos de estimación subnacional, describe las principales fuentes de información disponibles en América Latina y el Caribe y caracteriza las variables explicativas utilizadas para predecir la distribución espacial de la población.

2.1 Principios de modelamiento

Los modelos estadísticos utilizados para la estimación subnacional de conteos poblacionales deben ser capaces de representar adecuadamente la naturaleza discreta y no negativa de los datos, de incorporar información auxiliar proveniente de fuentes heterogéneas, de producir estimaciones coherentes entre niveles territoriales y de cuantificar explícitamente la incertidumbre de las estimaciones resultantes. El cumplimiento de estos requisitos condiciona tanto la elección de la familia distribucional del modelo como el marco inferencial adoptado.

2.1.1 Modelos de conteo

Los conteos poblacionales son variables aleatorias discretas no negativas. Esta naturaleza fundamental distingue el problema de estimación subnacional de los problemas de regresión con variables continuas y exige el uso de modelos de probabilidad apropiados para datos de conteo.

La distribución de Poisson constituye el punto de partida canónico para el modelamiento de conteos. Si Y_i denota el conteo observado en el segmento i , el modelo de Poisson establece:

$$Y_i | \lambda_i \sim \text{Poisson}(\lambda_i)$$

donde $\lambda_i > 0$ es el parámetro de intensidad, que representa simultáneamente la media y la varianza de la distribución. La función de masa de probabilidad es:

$$P(Y_i = y | \lambda_i) = \frac{e^{-\lambda_i} \lambda_i^y}{y!}, \quad y = 0, 1, 2, \dots$$

La parametrización log-lineal del modelo relaciona el logaritmo de la intensidad con un predictor lineal de covariables:

$$\log(\lambda_i) = \mathbf{x}_i^\top \beta + u_i$$

donde $\mathbf{x}_i$ es el vector de covariables auxiliares del segmento i , β es el vector de coeficientes y u_i es un efecto aleatorio que captura la variabilidad no explicada por las covariables.

Un supuesto fundamental del modelo de Poisson es la equidispersión: $\mathbb{E}[Y_i | \lambda_i] = \text{Var}(Y_i | \lambda_i) = \lambda_i$. En la práctica, los conteos poblacionales suelen exhibir sobredispersión, es decir, una varianza observada mayor a la media. Este fenómeno puede originarse en heterogeneidad no observada entre segmentos, clustering espacial o errores de especificación del predictor.

Para tratar la sobredispersión, el modelo binomial negativo introduce un parámetro adicional $\phi > 0$ que controla la varianza:

$$Y_i | \mu_i, \phi \sim \text{NegBin}(\mu_i, \phi)$$

con función de masa de probabilidad:

$$P(Y_i = y | \mu_i, \phi) = \binom{y + \phi - 1}{y} \left(\frac{\phi}{\phi + \mu_i} \right)^\phi \left(\frac{\mu_i}{\phi + \mu_i} \right)^y$$

En este caso, $\mathbb{E}[Y_i] = \mu_i$ y $\text{Var}(Y_i) = \mu_i + \mu_i^2 / \phi$. A medida que $\phi \rightarrow \infty$, la distribución binomial negativa converge hacia la Poisson.

Alternativamente, la sobredispersión puede modelarse mediante la inclusión de efectos aleatorios con distribución gamma en el predictor de Poisson. Si $\lambda_i = \mu_i \cdot \gamma_i$ con $\gamma_i \sim \text{Gamma}(\phi, \phi)$, la distribución marginal de Y_i resulta binomial negativa con parámetros (μ_i, ϕ) . Esta representación facilita la interpretación de los efectos aleatorios como multiplicadores de la intensidad esperada en cada segmento.

En contextos de modelamiento jerárquico, la elección entre Poisson y binomial negativa debe fundamentarse tanto en consideraciones estadísticas —diagnóstico de sobredispersión— como en la disponibilidad de información auxiliar: una especificación más rica de covariables puede reducir la sobredispersión aparente al explicar parte de la heterogeneidad entre segmentos.

2.1.2 Requerimientos de estimación subnacional

La estimación de conteos en niveles territoriales pequeños impone requerimientos adicionales que van más allá de la simple elección de una distribución de probabilidad. Estos requerimientos se derivan de la naturaleza jerárquica del problema y de las condiciones operativas en las que se producen los datos.

Coherencia jerárquica. Las estimaciones en niveles inferiores deben ser consistentes con los totales conocidos o estimados en niveles superiores. Si $\hat{N}_k^{(3)}$ denota la estimación del municipio k y $\hat{N}_j^{(2)}$ la del departamento j , la coherencia exige:

$$\hat{N}_j^{(2)} = \sum_{k: k \subset j} \hat{N}_k^{(3)}$$

Esta restricción de coherencia entre niveles es fundamental para garantizar la consistencia interna del sistema estadístico y constituye un criterio de validación esencial de cualquier modelo de estimación subnacional.

Estimación en dominios pequeños. En segmentos censales con baja densidad poblacional, los conteos observados son altamente variables y presentan elevada incertidumbre. En estos dominios, los estimadores directos basados únicamente en la información del segmento son insuficientes y deben complementarse con información auxiliar proveniente de otras fuentes o de dominios relacionados.

Propagación de incertidumbre. Las estimaciones subnacionales deben acompañarse de medidas de incertidumbre que reflejen adecuadamente la variabilidad del proceso. En contextos donde los conteos observados son escasos o de baja calidad, la incertidumbre puede ser considerable, y su cuantificación explícita es esencial para el uso responsable de las estimaciones en procesos de planificación y asignación de recursos.

Estabilidad temporal. Cuando se dispone de información de periodos censales anteriores, el modelo debe ser capaz de incorporar dicha información de forma coherente, reconociendo que la población cambia en el tiempo y que la relevancia de la información histórica decrece a medida que aumenta el intervalo temporal.

2.1.3 Justificación del enfoque bayesiano

El enfoque bayesiano ofrece un marco de inferencia particularmente apropiado para la estimación subnacional de conteos poblacionales. Sus ventajas frente a los métodos frecuentistas se derivan directamente de las características del problema.

Representación explícita de la incertidumbre. En el paradigma bayesiano, todos los parámetros desconocidos se tratan como variables aleatorias cuya incertidumbre se cuantifica mediante distribuciones de probabilidad. La distribución posterior $p(\theta \mid \mathbf{Y})$ encapsula el estado de conocimiento sobre la población en cada segmento dado el conjunto de datos observados:

$$p(\theta \mid \mathbf{Y}) \propto p(\mathbf{Y} \mid \theta) p(\theta)$$

Esta representación permite calcular intervalos de credibilidad, probabilidades de excedencia y cualquier otra cantidad de interés derivada de la distribución posterior.

Incorporación de información previa. Las distribuciones a priori permiten incorporar conocimiento demográfico sustantivo sobre la estructura de la población, restricciones de positividad, información de censos anteriores o expertos en el área. A diferencia de los métodos frecuentistas, el marco bayesiano provee un mecanismo formal para integrar esta información de manera coherente con los datos observados.

Estimación simultánea de múltiples dominios. Los modelos jerárquicos bayesianos permiten estimar simultáneamente la población en todos los segmentos, compartiendo información entre dominios relacionados. Los parámetros del nivel superior —como los coeficientes de las covariables— se estiman a partir de la información conjunta de todos los segmentos, lo que permite que los dominios con mejor cobertura contribuyan a estabilizar las estimaciones en dominios con datos limitados.

Coherencia probabilística. Las estimaciones bayesianas son coherentes por construcción: cualquier función de los parámetros puede estimarse a partir de la distribución posterior, y los intervalos de credibilidad tienen interpretación probabilística directa. Esta propiedad es especialmente valiosa cuando se requiere reportar incertidumbre a distintos niveles de desagregación territorial.

La estimación de la distribución posterior en modelos complejos se realiza mediante métodos de Monte Carlo por cadenas de Markov (MCMC). Entre los algoritmos más utilizados en la práctica se encuentran el muestreo de Gibbs, el algoritmo de Metropolis-Hastings y, más recientemente, el método de Monte Carlo Hamiltoniano

(HMC) implementado en Stan. Estos algoritmos permiten obtener muestras de la distribución posterior en modelos con alta dimensionalidad y estructuras jerárquicas complejas.

2.1.4 Integración de múltiples fuentes

El marco bayesiano provee un mecanismo natural para integrar información proveniente de múltiples fuentes bajo un esquema probabilístico coherente. La integración se realiza a través de la función de verosimilitud, que puede descomponerse en contribuciones de distintas fuentes de información, y a través de las distribuciones a priori, que capturan conocimiento previo sobre los parámetros.

Supóngase que se dispone de tres fuentes de información para el segmento i : el conteo censal observado $Y_i^{(C)}$, el preconteo operativo $Y_i^{(P)}$ y un conteo derivado de registros administrativos $Y_i^{(A)}$. Bajo el supuesto de independencia condicional entre fuentes dado el parámetro de población N_i , la verosimilitud conjunta puede escribirse como:

$$p(Y_i^{(C)}, Y_i^{(P)}, Y_i^{(A)} | N_i, \theta) = p(Y_i^{(C)} | N_i, \theta^{(C)}) \cdot p(Y_i^{(P)} | N_i, \theta^{(P)}) \cdot p(Y_i^{(A)} | N_i, \theta^{(A)})$$

donde $\theta^{(C)}$, $\theta^{(P)}$ y $\theta^{(A)}$ son los parámetros específicos de cada modelo de medición. Esta factorización permite modelar de forma separada las características de cada fuente —su cobertura, sus sesgos y su variabilidad— sin imponer restricciones artificiosas de equivalencia entre ellas.

El supuesto de independencia condicional entre fuentes es una simplificación que puede no ser siempre válida. En la práctica, distintas fuentes pueden compartir errores comunes asociados a factores territoriales no observados. Este problema puede mitigarse parcialmente mediante la inclusión de efectos aleatorios compartidos entre fuentes en el modelo jerárquico.

2.1.5 Relación con Small Area Estimation

Los modelos bayesianos de estimación poblacional subnacional se inscriben dentro del campo más amplio de la Estimación en Áreas Pequeñas (*Small Area Estimation*, SAE). Este campo metodológico desarrolla métodos estadísticos orientados a producir estimaciones confiables en dominios con tamaño muestral insuficiente para la estimación directa.

Los modelos SAE se clasifican generalmente en dos grandes categorías según el nivel en el que se especifica la estructura del modelo:

Modelos a nivel de área. Estos modelos operan sobre estadísticos agregados calculados para cada dominio. El modelo de Fay-Herriot es el referente clásico: se postula que la estimación directa $\hat{\theta}_i$ del parámetro de interés θ_i en el área i satisface:

$$\hat{\theta}_i = \theta_i + e_i, \quad e_i | \sigma_i^2 \sim \mathcal{N}(0, \sigma_i^2)$$

donde σ_i^2 se supone conocido, y el modelo de enlace conecta θ_i con las covariables auxiliares:

$$\theta_i = \mathbf{x}_i^\top \beta + u_i, \quad u_i \sim \mathcal{N}(0, \sigma_u^2)$$

Modelos a nivel de unidad. Estos modelos incorporan información a nivel de observación individual. El modelo de Battese-Harter-Fuller es el referente en este caso, y permite explotar la variabilidad dentro de los dominios para mejorar la estimación.

En el contexto de la estimación de conteos poblacionales censales, los modelos más apropiados son generalmente de nivel de área, dado que la información disponible suele estar agregada a nivel de segmento. La extensión bayesiana del modelo de Fay-Herriot para conteos —utilizando distribuciones de Poisson o binomial negativa en lugar de la distribución normal— constituye la base de los modelos desarrollados en los capítulos siguientes.

Una diferencia importante entre el enfoque SAE clásico y el bayesiano reside en el tratamiento de los hiperparámetros del modelo, como la varianza de los efectos aleatorios σ_u^2 . En el enfoque frecuentista, estos se estiman mediante máxima verosimilitud restringida (REML). En el enfoque bayesiano, se les asigna una distribución a priori y se estiman conjuntamente con los demás parámetros, lo que permite propagar su incertidumbre hacia las estimaciones finales.

2.2 Identificación de fuentes

La calidad de los modelos bayesianos de estimación subnacional depende críticamente de la disponibilidad y pertinencia de las fuentes de información auxiliar incorporadas. En América Latina y el Caribe, el conjunto de fuentes disponibles varía considerablemente entre países, pero puede organizarse en cuatro categorías principales: medición de cobertura censal, preconteos operativos, registros administrativos y fuentes satelitales.

2.2.1 Medición de cobertura a nivel de segmento

La cobertura censal es el primer elemento que debe caracterizarse antes de iniciar cualquier proceso de estimación subnacional. La cobertura hace referencia a la proporción de la población real que fue efectivamente enumerada durante el operativo censal. Su complemento —la tasa de omisión censal— cuantifica la fracción de la población no observada.

Formalmente, sea N_i la población verdadera del segmento i y $Y_i^{(C)}$ el conteo observado durante el censo. La tasa de cobertura del segmento se define como:

$$c_i = \frac{Y_i^{(C)}}{N_i}$$

y la tasa de omisión correspondiente como $\omega_i = 1 - c_i$. Dado que N_i no es directamente observable, la estimación de c_i requiere el uso de métodos indirectos o información auxiliar.

En la práctica, la medición de cobertura a nivel de segmento se realiza a través de tres mecanismos principales. El primero consiste en encuestas postcensales de cobertura, diseñadas específicamente para estimar la tasa de omisión mediante una operación de campo independiente al censo. El segundo utiliza métodos de conciliación demográfica que comparan los conteos censales con proyecciones independientes basadas en estadísticas vitales. El tercero emplea técnicas de captura-recaptura que cruzan el padrón censal con registros administrativos para estimar la población no observada.

La heterogeneidad espacial de la cobertura censal es una característica sistemática en todos los países de la región. La cobertura tiende a ser menor en áreas rurales dispersas, asentamientos informales, zonas de difícil acceso, territorios indígenas y contextos urbanos con alta movilidad residencial. Esta heterogeneidad espacial

motiva la necesidad de modelar la tasa de cobertura como una función de características territoriales observables.

Bajo el marco bayesiano, la cobertura del segmento puede modelarse como un parámetro latente con distribución a priori que refleje el conocimiento previo sobre su variabilidad entre segmentos. La incorporación de covariables territoriales como predictores de la cobertura permite que el modelo utilice la información disponible para estimar la omisión diferencial entre dominios.

2.2.2 Preconteos y segmentación

Los preconteos operativos constituyen una de las fuentes auxiliares más directamente vinculadas a la estimación de la población en segmentos censales. Estas operaciones, realizadas durante la fase de actualización cartográfica previa al levantamiento censal, producen información sobre el número aproximado de viviendas o estructuras habitacionales presentes en cada unidad operativa.

La segmentación censal es el proceso mediante el cual el territorio nacional se divide en unidades operativas de trabajo, denominadas segmentos o áreas de enumeración. Cada segmento es asignado a un censista y está diseñado para ser enumerable en el tiempo operativo disponible. Los criterios de segmentación varían entre países: algunos utilizan como criterio el número esperado de viviendas, otros priorizan continuidad espacial o accesibilidad geográfica.

Sea P_i el preconteo de viviendas registrado en el segmento i durante la actualización cartográfica. La relación entre el preconteo y la población esperada puede expresarse mediante un modelo de regresión log-lineal:

$$\log(N_i) = \alpha_0 + \alpha_1 \log(P_i) + \eta_i$$

donde α_0 y α_1 son parámetros a estimar y η_i es un error residual que captura la variabilidad no explicada por el preconteo. El parámetro α_1 puede interpretarse como la elasticidad de la población respecto al preconteo: si $\alpha_1 = 1$, la relación entre viviendas y personas es proporcional; si $\alpha_1 > 1$, segmentos con más viviendas tienen mayor tamaño medio de hogar.

El preconteo es especialmente valioso en contextos donde el operativo censal no logró cobertura completa, dado que provee una señal anticipada sobre la magnitud poblacional esperada que es independiente del proceso de enumeración. Su principal limitación es la distancia temporal entre la actualización cartográfica y el momento censal: en contextos con crecimiento urbano acelerado, los preconteos pueden quedar desactualizados rápidamente.

2.2.3 Registros administrativos (variables proxy)

Los registros administrativos son bases de datos generadas por entidades gubernamentales como resultado de sus funciones institucionales. A diferencia de los censos, no tienen por objetivo la medición estadística de la población, sino la gestión de servicios, beneficios o trámites administrativos. Sin embargo, en la medida en que su cobertura es razonablemente alta y su definición territorial compatible con los segmentos censales, pueden utilizarse como variables proxy de la magnitud poblacional.

Entre los registros administrativos más utilizados en modelos de estimación subnacional en América Latina y el Caribe se encuentran:

Registros civiles. Los sistemas de registro de nacimientos, defunciones y matrimonios proporcionan información sobre eventos demográficos ocurridos en el territorio. La densidad de nacimientos o defunciones por unidad territorial es un indicador parcial de la magnitud y composición de la población subyacente.

Padrones electorales. Los padrones de electores habilitados para votar proporcionan un conteo de personas adultas registradas con dirección conocida en cada territorio. Su cobertura está condicionada por la participación en el sistema electoral y puede ser incompleta en poblaciones jóvenes, migrantes o con baja interacción institucional.

Registros de afiliación a sistemas de salud y seguridad social. Los sistemas de salud pública o los registros de afiliación a la seguridad social contienen información sobre personas que acceden regularmente a servicios institucionales. Su cobertura depende del grado de formalidad laboral y del acceso efectivo a los servicios en cada territorio.

Registros de beneficiarios de programas sociales. Los padrones de beneficiarios de programas de transferencias condicionadas u otros programas sociales focalizados proporcionan información sobre hogares en situación de vulnerabilidad. Aunque su cobertura no es universal, pueden ser especialmente informativos en áreas con alta concentración de población en condición de pobreza.

Sea $A_{i,r}$ el conteo proveniente del registro r para el segmento i . Su uso como variable explicativa en el modelo de estimación se justifica por la correlación esperada con la población subyacente N_i :

$$A_{i,r} \approx c_{i,r} \cdot N_i$$

donde $c_{i,r} \in (0, 1]$ es la tasa de cobertura del registro r en el segmento i . La transformación logarítmica $\log(A_{i,r} + 1)$ estabiliza la varianza y facilita la incorporación de estos conteos como predictores en el modelo log-lineal.

2.2.4 Fuentes satelitales

Las imágenes satelitales y los productos de percepción remota han ampliado considerablemente el conjunto de covariables disponibles para la estimación poblacional subnacional. Su principal ventaja es la cobertura territorial universal, la continuidad temporal y la independencia respecto a los sistemas estadísticos institucionales.

Las fuentes satelitales más utilizadas en estimación poblacional pueden agruparse en las siguientes categorías:

Luminosidad nocturna. Los datos de radiance nocturna capturados por sensores satelitales, como el producto VIIRS-DNB de la NOAA, permiten identificar áreas con presencia de iluminación artificial. La intensidad lumínica nocturna está correlacionada con la actividad económica y la densidad de asentamientos humanos permanentes. Sea L_i el valor medio de luminosidad nocturna en el segmento i ; su transformación logarítmica $\log(L_i + 1)$ es utilizada frecuentemente como predictor de la población.

Área construida y cobertura urbana. Los productos de clasificación de uso del suelo derivados de imágenes ópticas como Sentinel-2 o Landsat permiten estimar la proporción de área construida dentro de cada segmento. El producto Global Human Settlement Layer (GHSL) de la Comisión Europea ofrece estimaciones de área construida a resolución de 100 metros con cobertura global.

Índice de vegetación de diferencia normalizada (NDVI). El NDVI mide la densidad y vitalidad de la vegetación a partir de la reflectancia en bandas del infrarrojo cercano y el rojo visible. Valores bajos de NDVI en áreas

no áridas generalmente indican presencia de infraestructura construida y asentamientos urbanos, mientras que valores altos corresponden a áreas con cobertura vegetal densa.

Temperatura superficial terrestre (LST). Las islas de calor urbano, reflejadas en valores elevados de temperatura superficial, constituyen un indicador indirecto de densidad de infraestructura y actividad humana.

Modelos digitales de elevación. La topografía del terreno condiciona la distribución espacial de la población. Los modelos de elevación digital como SRTM o ALOS permiten derivar variables como altitud media, pendiente y orientación del terreno, que están correlacionadas con la densidad y distribución de los asentamientos humanos.

La integración de covariables satelitales en el modelo requiere procesar las imágenes hasta el nivel del segmento censal, lo que implica operaciones de reproyección, remuestreo y estadísticas zonales. La resolución espacial de las imágenes debe ser compatible con el tamaño de los segmentos: resoluciones muy gruesas pueden introducir errores de asignación en segmentos pequeños, mientras que resoluciones muy finas pueden aumentar el costo computacional sin beneficio estadístico apreciable.

2.3 Variables explicativas

La calidad predictiva del modelo de estimación subnacional depende directamente de la selección y construcción de las variables explicativas incorporadas como covariables. Estas variables pueden organizarse en tres grandes grupos según su naturaleza conceptual: variables demográficas, variables socioeconómicas y variables espaciales.

2.3.1 Variables demográficas

Las variables demográficas capturan características de la estructura y dinámica de la población que están directamente relacionadas con la magnitud y distribución de los conteos en cada segmento.

Estructura por sexo y edad. La composición demográfica de la población condiciona la demanda de servicios y la organización territorial de los asentamientos. La proporción de población en edades productivas (15–64 años), la proporción de adultos mayores (65 años y más) y la proporción de niños menores de 15 años son indicadores relevantes de la estructura etaria del segmento. Formalmente:

$$p_{i,[a,b]} = \frac{N_{i,[a,b]}}{N_i}, \quad \sum_e p_{i,e} = 1$$

Razón de masculinidad. La distribución por sexo puede ser informativa en contextos con migración diferencial o actividades económicas con sesgo de género. La razón de masculinidad $RM_i = N_{i,M}/N_{i,F} \times 100$ puede utilizarse como predictor complementario.

Tasa de fecundidad implícita. En territorios con registros de nacimientos disponibles, la relación entre nacimientos registrados y población femenina en edad reproductiva proporciona una estimación indirecta de la dinámica de crecimiento natural del segmento.

Tamaño medio del hogar. El número promedio de personas por vivienda constituye un multiplicador fundamental en la relación entre el preconteo de viviendas y la estimación de personas. En América Latina y el

Caribe, el tamaño medio del hogar presenta heterogeneidad territorial significativa, con valores más altos en áreas rurales y en hogares con mayor número de hijos.

2.3.2 Variables socioeconómicas

Las condiciones socioeconómicas del territorio están correlacionadas con la densidad de población, la calidad de la enumeración censal y la cobertura de los registros administrativos. Su incorporación como covariables permite al modelo capturar parte de la heterogeneidad no observada entre segmentos.

Índice de necesidades básicas insatisfechas (NBI). El NBI resume un conjunto de carencias básicas del hogar —acceso a agua potable, saneamiento, educación, hacinamiento, calidad de la vivienda— en un indicador sintético de pobreza estructural. Territorios con altos niveles de NBI suelen presentar mayor omisión censal y menor cobertura de registros administrativos.

Indicadores de acceso a servicios. La proporción de hogares con acceso a servicios públicos como electricidad, agua potable, alcantarillado o internet está correlacionada tanto con la densidad poblacional como con la cobertura censal. El acceso a servicios refleja el nivel de integración del territorio a la infraestructura formal del Estado.

Nivel educativo de la población. El nivel de instrucción promedio de la población adulta del segmento, derivado de censos anteriores o de registros de matrícula escolar, puede utilizarse como indicador proxy de características socioeconómicas del territorio.

Actividad económica predominante. La clasificación del segmento según la actividad económica predominante —agropecuaria, industrial, comercial, servicios— condiciona la estructura demográfica esperada y los patrones de movilidad residencial. Esta clasificación puede derivarse de cartografía censal o de imágenes satelitales.

2.3.3 Variables espaciales

Las variables espaciales capturan la posición geográfica del segmento y sus relaciones de vecindad con el entorno territorial. Su incorporación permite al modelo explotar la continuidad espacial de la distribución poblacional y modelar explícitamente la dependencia entre segmentos geográficamente cercanos.

Distancia a centros urbanos. La distancia euclidiana o por red vial desde el centroide del segmento hasta el centro urbano más cercano es un predictor relevante de la densidad y tipo de asentamiento. Segmentos más próximos a centros urbanos tienden a presentar mayor densidad poblacional, mayor acceso a servicios y mayor cobertura de registros administrativos.

Accesibilidad y tiempos de desplazamiento. El tiempo de desplazamiento por carretera hasta el centro urbano o el hospital más cercano, derivado de modelos de redes viales, es un indicador de accesibilidad territorial con mayor valor predictivo que la distancia euclidiana en contextos con topografía compleja o infraestructura vial deficiente.

Altitud y topografía. La altitud media del segmento, la pendiente del terreno y la variabilidad topográfica interna condicionan la viabilidad de asentamientos humanos y la densidad de población esperable. Las variables topográficas derivadas de modelos digitales de elevación son especialmente relevantes en países con territorios montañosos.

Efectos espaciales aleatorios. Más allá de las covariables observadas, la distribución espacial de la población presenta autocorrelación espacial que puede ser capturada mediante efectos aleatorios estructurados. Los modelos de efectos espaciales, como el modelo condicional autorregresivo (CAR), permiten modelar explícitamente la dependencia entre segmentos vecinos:

$$u_i \mid \mathbf{u}_{-i} \sim \mathcal{N}\left(\frac{\sum_{j \sim i} u_j}{n_i}, \frac{\sigma_u^2}{n_i}\right)$$

donde la notación $j \sim i$ indica que el segmento j es vecino del segmento i y n_i es el número de vecinos. Este modelo impone que el efecto aleatorio de cada segmento sea similar al promedio de sus vecinos, reflejando la continuidad espacial de las características no observadas que determinan la densidad poblacional.

La selección final del conjunto de variables explicativas debe fundamentarse en criterios de disponibilidad territorial —las variables deben estar disponibles para todos los segmentos—, pertinencia conceptual, capacidad predictiva demostrada y ausencia de multicolinealidad severa entre predictores. Los capítulos siguientes presentan la especificación formal de los modelos que integran estas variables en un esquema bayesiano jerárquico orientado a la estimación de conteos poblacionales subnacionales.

Preparación de Imágenes Satelitales

- 3.1 Fuentes de datos satelitales (Landsat, Sentinel, MODIS)**
- 3.2 Preprocesamiento y correcciones atmosféricas**
- 3.3 Extracción de características (NDVI, índices espectrales)**
- 3.4 Validación con datos de campo**
- 3.5 Generación de capas para el modelo**

Preparación de Insumos para Modelamiento

La construcción de un modelo bayesiano de estimación subnacional requiere, como condición previa, disponer de un conjunto de insumos analíticos preparados con criterios estadísticos explícitos y documentados. La calidad de las estimaciones finales depende no solo de la sofisticación del modelo, sino fundamentalmente de la coherencia, completitud y representatividad de los datos que lo alimentan.

Este capítulo describe el proceso de preparación de insumos en cuatro etapas secuenciales: la estandarización de las fuentes de información, la evaluación de cobertura por segmento, la construcción de la variable dependiente y el diagnóstico exploratorio de los datos. Cada etapa introduce operaciones estadísticas específicas cuya omisión puede comprometer la validez de las inferencias posteriores.

4.1 Estandarización de fuentes

Las fuentes de información descritas en el capítulo anterior provienen de sistemas institucionales con distintas definiciones operativas, unidades de medida, fechas de referencia y marcos territoriales. Su incorporación conjunta en un modelo estadístico exige un proceso previo de estandarización que garantice la comparabilidad entre fuentes y la compatibilidad con los dominios de estimación definidos.

4.1.1 Homologación de variables

La homologación consiste en establecer correspondencias semánticas y operativas entre variables provenientes de distintas fuentes que miden conceptos equivalentes o relacionados bajo definiciones diferentes. Este proceso es necesario porque los sistemas administrativos, los registros satelitales y los datos censales utilizan nomenclaturas, clasificaciones y criterios de asignación territorial que no siempre son directamente comparables.

Compatibilización de marcos territoriales. El primer paso en la homologación es garantizar que todas las fuentes estén referenciadas al mismo marco geográfico. En América Latina y el Caribe, los distintos registros administrativos suelen estar organizados por municipios, provincias o códigos postales que no coinciden directamente con los segmentos censales. Sea $\mathcal{S} = \{1, 2, \dots, I\}$ el conjunto de segmentos del operativo censal y $\mathcal{U} = \{1, 2, \dots, J\}$ las unidades geográficas del registro administrativo. La asignación de cada registro al segmento correspondiente requiere construir una función de mapeo $\phi : \mathcal{U} \rightarrow \mathcal{S}$ basada en la intersección espacial entre las geometrías de ambos marcos.

Cuando las unidades del registro son más grandes que los segmentos censales, la desagregación territorial se realiza mediante ponderación por área o por densidad de viviendas. Si la unidad administrativa j contiene m_{ij} segmentos, la estimación del conteo administrativo para el segmento i se obtiene como:

$$\hat{A}_i = A_j \cdot \frac{w_{ij}}{\sum_{k: k \subset j} w_{kj}}$$

donde A_j es el conteo total del registro en la unidad j y w_{ij} es el peso asignado al segmento i dentro de la unidad j , que puede ser proporcional al área, al número de viviendas del preconteo o a la población proyectada.

Homologación de definiciones de población. Las distintas fuentes pueden diferir en la definición de la unidad de observación. Los censos cuentan personas según residencia habitual o presencia en el momento censal, los padrones electorales registran ciudadanos habilitados para votar, los sistemas de salud registran afiliados activos y los registros civiles registran eventos vitales. La homologación requiere documentar explícitamente estas diferencias y construir factores de ajuste que permitan aproximar cada fuente a la definición censal de referencia.

Compatibilización temporal. Las fuentes de información tienen distintas fechas de referencia. El preconteo puede haberse realizado entre seis y dieciocho meses antes del momento censal. Los registros administrativos corresponden al cierre de un ejercicio fiscal o al corte de un padrón en una fecha específica. Las imágenes satelitales capturan el territorio en distintos momentos a lo largo del año. La compatibilización temporal consiste en seleccionar o construir versiones de cada fuente que sean lo más próximas posible al momento censal de referencia, documentando el desfase temporal residual como fuente de incertidumbre adicional.

4.1.2 Normalización de variables

Una vez homologadas, las variables auxiliares presentan distribuciones con escalas y dispersiones heterogéneas que dificultan la estimación numérica de los coeficientes y la interpretación comparada de los efectos. La normalización transforma las variables a una escala común que facilita la estimación y mejora el comportamiento computacional de los algoritmos de inferencia.

Estandarización por media y desviación estándar. Para una variable continua $x_{i,k}$ medida en el segmento i , la estandarización produce:

$$\tilde{x}_{i,k} = \frac{x_{i,k} - \bar{x}_k}{s_k}$$

donde $\bar{x}_k = \frac{1}{I} \sum_{i=1}^I x_{i,k}$ es la media y $s_k = \sqrt{\frac{1}{I-1} \sum_{i=1}^I (x_{i,k} - \bar{x}_k)^2}$ es la desviación estándar de la variable calculadas sobre todos los segmentos. Bajo esta transformación, $\tilde{x}_{i,k}$ tiene media cero y desviación estándar uno, y el coeficiente β_k se interpreta como el cambio esperado en el logaritmo de la población por unidad de desviación estándar en la covariable k .

Transformación logarítmica. Las variables de conteo y magnitud —número de viviendas, conteos de registros administrativos, áreas construidas— presentan distribuciones fuertemente asimétricas con cola derecha pesada. La transformación logarítmica reduce la asimetría y aproxima la distribución a la normalidad:

$$\tilde{x}_{i,k} = \log(x_{i,k} + 1)$$

La constante +1 garantiza que la transformación esté definida para valores cero, lo cual es frecuente en covariables de conteo en segmentos con baja densidad poblacional.

Normalización al intervalo unitario. Para variables que representan proporciones o índices con interpretación intrínseca en el rango $[0, 1]$, como tasas de cobertura o índices de vegetación, puede ser preferible la normalización min-max:

$$\tilde{x}_{i,k} = \frac{x_{i,k} - \min_i(x_{i,k})}{\max_i(x_{i,k}) - \min_i(x_{i,k})}$$

Esta transformación preserva la interpretación original de la variable y facilita la especificación de distribuciones a priori informativas sobre los coeficientes.

Tratamiento de valores faltantes. La presencia de valores faltantes en las covariables auxiliares debe ser resuelta antes de la estimación. Las estrategias más comunes incluyen la imputación por la mediana o la media del grupo territorial al que pertenece el segmento, la imputación mediante modelos de regresión utilizando covariables con cobertura completa, y la imputación múltiple para propagar la incertidumbre asociada a los valores faltantes hacia las estimaciones finales.

4.2 Evaluación de cobertura

La evaluación de cobertura censal por segmento es un paso crítico previo a la estimación. Permite identificar los dominios con información deficiente, cuantificar el grado de omisión territorial y establecer una clasificación de los segmentos que oriente las decisiones de modelamiento.

4.2.1 Tasa de cobertura por segmento

La tasa de cobertura de un segmento censal mide la proporción de la población verdadera que fue efectivamente enumerada durante el operativo. Dado que la población verdadera N_i no es directamente observable, la estimación de la tasa de cobertura requiere una referencia externa independiente del conteo censal.

Sea R_i una estimación de referencia de la población del segmento i obtenida a partir de una fuente auxiliar confiable, como un preconteo operativo ajustado o una proyección demográfica intercensal. La tasa de cobertura estimada para el segmento i se define como:

$$\hat{c}_i = \frac{Y_i^{(C)}}{R_i}$$

donde $Y_i^{(C)}$ es el conteo censal observado en el segmento. Un valor $\hat{c}_i < 1$ indica subcobertura —el operativo no logró enumerar toda la población de referencia— mientras que $\hat{c}_i > 1$ puede indicar sobrecobertura, duplicación de registros o inconsistencias en la referencia utilizada.

En la práctica, la tasa de cobertura puede estimarse también mediante métodos de captura-recaptura cuando se dispone de dos fuentes de información independientes para el mismo segmento. Si $Y_i^{(C)}$ es el conteo censal y A_i es el conteo de un registro administrativo, y si M_i es el número de personas identificadas en ambas fuentes, la estimación de Chapman para la población total es:

$$\hat{N}_i^{CR} = \frac{(Y_i^{(C)} + 1)(A_i + 1)}{M_i + 1} - 1$$

y la tasa de cobertura del censo respecto a esta estimación:

$$\hat{c}_i^{CR} = \frac{Y_i^{(C)}}{\hat{N}_i^{CR}}$$

Este estimador requiere el supuesto de independencia entre ambas fuentes, condición que puede ser violada cuando la propensión a ser registrado en el censo y en el registro administrativo están correlacionadas con características del individuo o del territorio.

La distribución de las tasas de cobertura entre segmentos permite identificar patrones espaciales de omisión diferencial. El coeficiente de variación de $\hat{c}_i$ entre segmentos es un indicador de la heterogeneidad territorial de la cobertura. Valores elevados de este coeficiente indican que la omisión censal no es aleatoria y que un modelo que ignore esta heterogeneidad producirá estimaciones sesgadas.

4.2.2 Clasificación de segmentos

La clasificación de los segmentos según su nivel de cobertura permite diseñar estrategias diferenciadas de estimación y validación. Una tipología operativa agrupa los segmentos en tres categorías:

Segmentos con cobertura aceptable ($\hat{c}_i \geq c^*$): el conteo censal observado es suficientemente representativo de la población subyacente y puede utilizarse como variable dependiente del modelo sin ajuste previo. El umbral c^* se fija típicamente entre 0.85 y 0.95, dependiendo de los estándares de calidad del sistema estadístico.

Segmentos con cobertura parcial ($c_{**} \leq \hat{c}_i < c^*$): el conteo censal presenta omisión detectable pero el segmento fue efectivamente enumerado. Estos segmentos ingresan al modelo con un peso reducido o con un indicador de calidad que refleja la mayor incertidumbre de su conteo. El umbral inferior c_{**} se sitúa típicamente entre 0.60 y 0.75.

Segmentos con cobertura insuficiente ($\hat{c}_i < c_{**}$): el operativo censal no alcanzó una enumeración mínimamente representativa. Estos segmentos son tratados como dominios sin información propia y su estimación depende enteramente de las covariables auxiliares y de la estructura jerárquica del modelo.

Formalmente, la clasificación puede expresarse mediante la variable indicadora:

$$\kappa_i = \begin{cases} 2 & \text{si } \hat{c}_i \geq c^* \\ 1 & \text{si } c_{**} \leq \hat{c}_i < c^* \\ 0 & \text{si } \hat{c}_i < c_{**} \end{cases}$$

Esta clasificación se incorpora al modelo mediante pesos de verosimilitud o mediante la especificación diferenciada de la varianza del error de medición según la categoría del segmento.

4.3 Construcción de la variable dependiente

La variable dependiente del modelo de estimación subnacional es el conteo poblacional que se desea estimar en cada segmento. Su construcción no es un proceso trivial: requiere decisiones explícitas sobre la agregación de categorías, las transformaciones aplicadas y la definición de la población de referencia.

4.3.1 Conteos agregados

El conteo agregado para el segmento i se construye sumando los conteos censales observados sobre los grupos de sexo y edad de interés. Sea $Y_{i,s,e}^{(C)}$ el conteo censal del segmento i , sexo s y grupo de edad e . El conteo total del segmento es:

$$Y_i = \sum_{s \in \{M,F\}} \sum_{e=1}^E Y_{i,s,e}^{(C)}$$

Cuando el objetivo es estimar conteos desagregados por sexo o grupo etario, la variable dependiente se construye para cada celda demográfica de interés:

$$Y_{i,s,e} = Y_{i,s,e}^{(C)}, \quad s \in \{M,F\}, \quad e = 1, \dots, E$$

y el modelo se estima de forma separada para cada celda o mediante un modelo conjunto que impone coherencia entre celdas a través de una estructura jerárquica compartida.

La decisión sobre el nivel de desagregación de la variable dependiente tiene implicaciones directas sobre el tamaño del problema de estimación y la disponibilidad de información. A mayor desagregación, mayor es el número de celdas con conteos pequeños o nulos, lo que incrementa la dependencia del modelo respecto a las covariables auxiliares y a la estructura jerárquica.

4.3.2 Tasas poblacionales

En algunos contextos, la variable de interés no es el conteo absoluto sino una tasa relativa que expresa la magnitud de un subgrupo poblacional como proporción del total. Sea $Y_i^{(g)}$ el conteo del grupo de interés g en el segmento i y Y_i el total del segmento. La tasa poblacional se define como:

$$\pi_i^{(g)} = \frac{Y_i^{(g)}}{Y_i}$$

Las tasas poblacionales son especialmente relevantes cuando el objetivo es comparar la composición demográfica entre segmentos con magnitudes poblacionales muy distintas. Sin embargo, en dominios con conteos pequeños, las tasas presentan elevada variabilidad aleatoria que puede distorsionar la comparación territorial.

El modelamiento de tasas en el contexto bayesiano utiliza frecuentemente la distribución beta como modelo para la variable dependiente cuando $\pi_i^{(g)} \in (0, 1)$, o modelos binomiales cuando se dispone del denominador exacto:

$$Y_i^{(g)} \mid \pi_i^{(g)}, Y_i \sim \text{Binomial}(Y_i, \pi_i^{(g)})$$

4.3.3 Transformaciones

Las transformaciones de la variable dependiente buscan estabilizar la varianza, aproximar la distribución a la normalidad o linealizar la relación entre la variable de respuesta y los predictores. En el contexto de conteos poblacionales, las transformaciones más utilizadas son las siguientes.

Transformación logarítmica. La transformación $\log(Y_i + 1)$ es la más frecuentemente utilizada en modelos log-lineales de conteo. Estabiliza la varianza en distribuciones de Poisson y permite interpretar los efectos de las covariables en términos de cambios porcentuales en la población esperada.

Transformación raíz cuadrada. La transformación $\sqrt{Y_i}$ tiene la propiedad de estabilizar la varianza en distribuciones de Poisson, dado que $\text{Var}(\sqrt{Y_i}) \approx 1/4$ cuando λ_i es grande. Es menos utilizada que la logarítmica pero puede ser apropiada cuando los conteos son muy pequeños y la transformación logarítmica introduce distorsiones.

Transformación de potencia de Box-Cox. Para una búsqueda más sistemática de la transformación estabilizadora de varianza, la familia de transformaciones de Box-Cox parametriza el tipo de transformación mediante un parámetro λ_{BC} :

$$Y_i^{(\lambda_{BC})} = \begin{cases} \frac{Y_i^{\lambda_{BC}} - 1}{\lambda_{BC}} & \text{si } \lambda_{BC} \neq 0 \\ \log(Y_i) & \text{si } \lambda_{BC} = 0 \end{cases}$$

El parámetro λ_{BC} puede estimarse por máxima verosimilitud como parte del proceso de especificación del modelo. Los valores $\lambda_{BC} = 0$ (logarítmica) y $\lambda_{BC} = 0.5$ (raíz cuadrada) son los más frecuentes en la práctica.

4.3.4 Definición de población base

La población base define el universo de referencia sobre el cual se construye el conteo de interés. Su especificación correcta es fundamental para garantizar la comparabilidad entre segmentos y la coherencia con los totales de niveles superiores.

La definición de población base más común en censos de población es la población residente habitual: el conjunto de personas cuya residencia principal está localizada en el segmento en el momento del censo. Sin embargo, algunos censos implementan el criterio de población de hecho, que contabiliza a las personas presentes en el segmento durante el momento censal, independientemente de su residencia habitual.

Formalmente, la población base $\mathcal{P}_i$ del segmento i puede definirse bajo distintos criterios:

- **Población residente:** $\mathcal{P}_i = \{j : \text{residencia habitual de } j \text{ está en } i\}$
- **Población de hecho:** $\mathcal{P}_i = \{j : j \text{ está físicamente presente en } i \text{ en el momento censal}\}$
- **Población en hogares particulares:** excluye a las personas en colectividades institucionales (hospitales, cárceles, cuarteles).
- **Población civil:** excluye adicionalmente al personal militar.

La elección de la población base afecta la coherencia de los conteos en territorios con alta movilidad diurna, presencia de instituciones totales o frontera entre áreas urbanas y rurales. El modelo de estimación debe adoptarse para la misma definición de población base utilizada en el operativo censal.

4.3.5 Escalamiento

El escalamiento de los conteos es necesario cuando se trabaja simultáneamente con segmentos de tamaño muy heterogéneo o cuando se requiere comparar estimaciones entre países o periodos censales con distintas magnitudes poblacionales.

El escalamiento por tamaño esperado utiliza una referencia R_i para expresar el conteo observado como una proporción de la población esperada:

$$z_i = \frac{Y_i}{R_i}$$

donde R_i puede ser el preconteo ajustado, la proyección demográfica intercensal u otro estimador de referencia. La variable escalada z_i puede interpretarse como un factor de cobertura relativa y tiene la ventaja de reducir la dependencia del modelo respecto al tamaño absoluto de cada segmento.

El escalamiento por exposición es especialmente útil cuando la variable dependiente representa un conteo sobre un denominador que varía entre segmentos. En el modelo de Poisson, esta escala se incorpora mediante el término de offset:

$$\log(\lambda_i) = \log(R_i) + \mathbf{x}_i^T \beta + u_i$$

donde $\log(R_i)$ es el offset —una constante conocida que ajusta la intensidad esperada por el tamaño de la exposición del segmento— y los coeficientes β se interpretan como efectos sobre la tasa por unidad de exposición.

4.4 Diagnóstico exploratorio

Antes de ajustar el modelo bayesiano, es indispensable realizar un análisis exploratorio sistemático de los datos preparados. Este diagnóstico permite verificar la coherencia interna de los insumos, identificar observaciones atípicas, evaluar la capacidad predictiva de las covariables y detectar posibles violaciones de los supuestos del modelo.

4.4.1 Distribución de conteos

El análisis de la distribución de los conteos observados Y_i permite caracterizar la variabilidad entre segmentos y evaluar la adecuación de las familias distribucionales consideradas para el modelamiento.

Los estadísticos descriptivos básicos —media, mediana, desviación estándar, coeficientes de asimetría y curtosis— proveen una caracterización inicial de la distribución. La comparación entre la media y la varianza muestral:

$$\bar{Y} = \frac{1}{I} \sum_{i=1}^I Y_i, \quad S_Y^2 = \frac{1}{I-1} \sum_{i=1}^I (Y_i - \bar{Y})^2$$

ofrece un diagnóstico informal de sobredispersión: si $S_Y^2 \gg \bar{Y}$, la distribución de Poisson puede ser insuficiente y el modelo binomial negativo resulta más apropiado. El índice de dispersión $D = S_Y^2 / \bar{Y}$ cuantifica el grado de sobredispersión; valores superiores a 1.5 o 2 suelen justificar el uso de modelos más flexibles.

```
resumen_conteos <- data.frame(
  n_segmentos = length(Y),
  media       = mean(Y),
```

```

    mediana      = median(Y),
    desv_est     = sd(Y),
    asimetria    = moments::skewness(Y),
    curtosis     = moments::kurtosis(Y),
    indice_disp  = var(Y) / mean(Y)
  )

  hist(log(Y + 1),
        breaks = 40,
        main   = "Distribución de log(Y + 1) por segmento",
        xlab   = "log(conteo + 1)",
        col    = "#CBD5E1",
        border = "white")

```

La visualización de la distribución debe realizarse tanto en escala original como en escala logarítmica. En la escala original, la distribución suele ser fuertemente asimétrica con cola derecha pesada; en la escala logarítmica, la distribución es más simétrica y permite evaluar si la especificación log-lineal es adecuada.

La proporción de ceros en los conteos es otro indicador relevante. Un exceso de ceros respecto a lo esperado bajo el modelo de Poisson puede indicar la presencia de segmentos genuinamente deshabitados, problemas de cobertura en áreas con baja densidad, o la necesidad de incorporar un componente de inflación de ceros en el modelo.

4.4.2 Outliers

La identificación de observaciones atípicas en los conteos y en las covariables auxiliares es fundamental para evitar que estas observaciones dominen la estimación de los parámetros del modelo. En el contexto de datos de conteo, los outliers pueden manifestarse como valores excepcionalmente altos o bajos en relación con la tendencia general de los datos, o como combinaciones inusuales de conteo y covariables.

Detección basada en residuos del modelo nulo. Un modelo de regresión de Poisson sin covariables permite obtener residuos de Pearson para cada segmento:

$$r_i^P = \frac{Y_i - \hat{\lambda}_i}{\sqrt{\hat{\lambda}_i}}$$

donde $\hat{\lambda}_i = \exp(\hat{\alpha})$ con $\hat{\alpha} = \log(\bar{Y})$. Segmentos con $|r_i^P| > 3$ son candidatos a revisión como observaciones atípicas.

Detección basada en la distancia de Cook. En el modelo log-lineal con covariables, la distancia de Cook D_i cuantifica la influencia del segmento i sobre el vector de coeficientes estimados. Valores elevados de D_i indican que la exclusión del segmento i modificaría sustancialmente los coeficientes del modelo.

Detección multivariada. Las observaciones atípicas en el espacio de covariables pueden identificarse mediante la distancia de Mahalanobis:

$$d_i^2 = (\mathbf{x}_i - \bar{\mathbf{x}})^\top \hat{\Sigma}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}})$$

donde $\bar{\mathbf{x}}$ es el vector de medias y $\hat{\Sigma}$ es la matriz de covarianza muestral de las covariables. Bajo normalidad multivariada, $d_i^2 \sim \chi_p^2$, y valores superiores al percentil 97.5 de esta distribución son indicativos de observaciones atípicas en el espacio de covariables.

```
lambda_nulo      <- mean(Y)
residuos_p       <- (Y - lambda_nulo) / sqrt(lambda_nulo)
segmentos_outlier <- which(abs(residuos_p) > 3)

X_mat  <- as.matrix(covariables_std)
d2_mah <- mahalanobis(X_mat, colMeans(X_mat), cov(X_mat))
p_valor <- pchisq(d2_mah, df = ncol(X_mat), lower.tail = FALSE)
outliers_multivariados <- which(p_valor < 0.025)
```

Una vez identificadas, las observaciones atípicas deben revisarse para determinar si corresponden a errores de procesamiento, a características genuinas del territorio o a problemas de cobertura del operativo. La decisión sobre su tratamiento —corrección, exclusión o inclusión con peso reducido— debe documentarse explícitamente.

4.4.3 Relación entre variables

El análisis de la relación entre la variable dependiente y las covariables auxiliares permite evaluar la pertinencia predictiva de cada fuente de información y orientar las decisiones de especificación del modelo.

Correlación con los conteos. La correlación de Pearson entre $\log(Y_i + 1)$ y cada covariable estandarizada $\tilde{x}_{i,k}$ proporciona una medida lineal de la asociación bivariada. Covariables con correlación superior a 0.5 en valor absoluto suelen tener valor predictivo relevante; covariables con correlación inferior a 0.1 pueden ser candidatas a exclusión del modelo.

Diagramas de dispersión. La representación gráfica de $\log(Y_i + 1)$ contra cada covariable permite detectar relaciones no lineales, patrones de heteroscedasticidad y grupos de segmentos con comportamiento diferenciado. La adición de una curva de suavizado no paramétrico (LOESS) facilita la identificación de estructuras no lineales que podrían requerir transformaciones adicionales de las covariables.

Correlación entre covariables. La matriz de correlación entre las covariables auxiliares permite identificar pares con alta colinealidad. Correlaciones superiores a 0.85 en valor absoluto indican que dos covariables aportan información casi redundante. Los factores de inflación de varianza (VIF) son una herramienta complementaria para el diagnóstico de multicolinealidad:

$$\text{VIF}_k = \frac{1}{1 - R_k^2}$$

donde R_k^2 es el coeficiente de determinación obtenido al regresar la covariable k sobre el resto de covariables. Valores de $\text{VIF}_k > 10$ son indicativos de multicolinealidad problemática.

```
library(corrplot)
cor_mat <- cor(cbind(log_Y = log(Y + 1), covariables_std),
               method = "pearson")
```

```
corrplot(cor_mat,  
         method      = "color",  
         type        = "upper",  
         addCoef.col  = "black",  
         number.cex   = 0.7,  
         tl.cex       = 0.8)  
  
modelo_ols <- lm(log(Y + 1) ~ ., data = as.data.frame(covariables_std))  
car::vif(modelo_ols)
```

Análisis por estrato territorial. La relación entre la variable dependiente y las covariables puede variar entre distintos estratos territoriales —urbano/rural, región geográfica, nivel de cobertura—. La exploración estratificada permite detectar interacciones relevantes que podrían justificar la inclusión de términos de interacción o la estimación diferenciada de coeficientes por grupo.

La documentación sistemática de los resultados del diagnóstico exploratorio es un insumo esencial para la especificación del modelo. Las decisiones sobre transformaciones, exclusión de covariables, tratamiento de outliers y estratificación del análisis deben fundamentarse en este diagnóstico y quedar registradas para garantizar la reproducibilidad y auditabilidad de las estimaciones finales.